

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- Aide et FAQ Médiascope / INA*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).
- AKATA (Zeynep), BALLIET (Dan), DE RIJKE (Maarten), DIGNUM (Frank), DIGNUM (Virginia), EIBEN (Guszt), FOKKENS (Antske), GROSSI (Davide), HINDRIKS (Koen), HOOS (Holger), *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53-8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587.
- Amalia.Js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).
- Analyse Des Tendances Médias Par l'IA - Les Traitements Réalisés Par Les Outils d'intelligence Artificielle Utilisés Sur Data.Ina.Fr / Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- Apprentissage profond (deep learning)*, URL : <https://www.cnil.fr/fr/definition/apprentissage-profond-deep-learning> (visité le 18/07/2026).
- AQUINO (Alexandra Jonker Judith), *Pourquoi la qualité des données est essentielle au succès de l'IA / IBM*, janv. 2026, URL : <https://www.ibm.com/fr-fr/think/topics/ai-data-quality> (visité le 14/08/2026).
- ARNAB (Anurag), DEHGhani (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).
- *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BARREAUX (Sabine), DAILLE (Béatrice) et JACQUEY (Évelyne), « Indexation automatique en SHS : bilan d’une expérimentation », *I2D - Information, données & documents*, 54–1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.
- BASSAÏSTEGUY (Sidonie), *Le Médium, c’est La Mémoire : Archivages Du Document à l’Institut National de l’audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).
- BENJAMIN (Walter), *L’oeuvre d’art à l’époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu’est-ce qu’un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l’IA 2025 », dans *Conférence Nationale Sur Les Applications de l’Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC ’19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-

- 142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CHAMBONNET (Sébastien), « Définir une architecture de l'information pour la sauvegarde du patrimoine scientifique et technique contemporain (Patstec), à l'heure du web de données » (, 2015).
- COCO Detection Dataset*, nov. 2023, URL : <https://docs.ultralytics.com/datasets/detect/coco> (visité le 26/07/2026).
- COLAVIZZA (Giovanni), BLANKE (Tobias), JEURGENS (Charles) et NOORDEGRAAF (Julia), « Archives and AI : An Overview of Current Debates and Future Perspectives », *J. Comput. Cult. Herit.* 15-1 (déc. 2021), 4 :1-4 :15, DOI : 10.1145/3479010.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

- DEVELOPMENT (S. O.), *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).
- DIALOGUE (IFLA Working Group on FRBR/CRM), « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).
- Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- DU (Lin), LE (Brandon) et HONIG (Edouardo), « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.
- Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA *Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- FICK (Hanna), FREDRIKSSON (Anneli), LINDBLOM (Helena), FREDRIKSSON (Anneli) et LINDBLOM (Helena), « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.
- France 2030 : un plan d'investissement pour la France* / economie.gouv.fr, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GILL (Sandrine), « Les archives audiovisuelles au tamis des archivistes », dans *Les nouveaux paradigmes de l'archive*, dir. Claire Scopsi, Clothilde Roullier, Martine Sin Blima-Barru et Édouard Vasseur, Pierrefitte-sur-Seine, 2024 (Actes), DOI : 10.4000/books.pan.7249.
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar>.

- org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2 (visité le 08/07/2026).
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HERVÉ (Nicolas), LETESSIER (Pierre), Derval (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- Home - PySceneDetect, URL : <https://www.scsenetect.com/> (visité le 25/07/2026).
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- IFLASTANDARDS.INFO, *Frbrro*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- *Frbrro*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- ISAAC (Antoine), BACHIMONT (Bruno) et LAUBLET (Philippe), « Indexation de documents AV : ontologies, patrons de conception et d'utilisation » (, 2005).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

- L'intelligence artificielle au service de la création de métadonnées*, URL : <https://www.archimag.com/demat-cloud/2022/04/15/intelligence-artificielle-creation-metadonnees> (visité le 03/08/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et*, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables* / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).
- LALANDE (Steffen), BELOUED (Abdelkrim) et FARGE (Odile), « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.
- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), DERVAL (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.
- LIU (Haotian), LI (Chunyuan), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text*,

- Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).
- MeMAD-project/Mmca : *MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- MeMAD-project/Mmca : *MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- Modèles FRBR, FRAD et FR SAD, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- Module 6 - Section 7 : *Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- MORSE (Christopher), « Les musées et l'expérience utilisateur (UX) », *La Lettre de l'OCIM. Musées, Patrimoine et Culture scientifiques et techniques*—200 (2022/mars/01), p. 38-43, DOI : 10.4000/ocim.4777.
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL,

- 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).
- Outils d'aide à l'analyse des médias audiovisuels / INA*, URL : <https://inatheque.ina.fr/outils-d-aide-a-l-analyse-des-medias-audiovisuels> (visité le 03/08/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).
- PAILLARD (Isabelle), « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Prelinger Archive – Internet Archive Help Center*, URL : <https://help.archive.org/help/prelinger-archive/> (visité le 14/08/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Projet Dataset / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).

- Projet Snoop* / INA, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).
- Projet Snoop* / INA, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 05/08/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ?* / IBM, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- Qu'est-ce que la modélisation de données ?* / IBM, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- Qu'est-ce que la qualité des données ?* / IBM, sept. 2022, URL : <https://www.ibm.com/fr-fr/think/topics/data-quality> (visité le 14/08/2026).
- Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SCHIAPPA (Madeline C.), RAWAT (Yogesh S.) et SHAH (Mubarak), « Self-Supervised Learning for Videos : A Survey », *ACM Computing Surveys*, 55-13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].
- SIGNOLES (Aurélien Bergonnier), « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().

- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605. *Systèmes et données*, URL : <https://www.transition-bibliographique.fr/systemes-et-donnees/> (visité le 08/07/2026).
- TALBI (Ilyes), *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).
- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLET, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsol/frbreng.pdf>.
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).

- Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).
- UNIVERSALIS (Encyclopædia), *Rushes : définition et synonymes*, URL : <https://www.universalis.fr/dictionnaire/rushes/> (visité le 22/08/2026).
- Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters*, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).
- VANG-Z, *Annotating a YOLOv8 Dataset Using Label Studio*, sept. 2023, URL : <https://richelf.tech/en/posts/2023-09/0f87cd80-8c23-c2dd-40f3-e1d2df83c2f7.html> (visité le 29/08/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*-hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].
- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Chang-jin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wen-guan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

”Les archives audiovisuelles doivent satisfaire à des normes sévères en ce qui concerne la documentation de leurs acquisitions, des communications et d’autres transactions afin de démontrer le sérieux de leur gestion. Du fait de la complexité de leurs fonds, la précision de l’information est ici essentielle.”¹

Dans la Philosophie de l’archivistique audiovisuelle publiée par l’UNESCO, Edmonson Ray pose les fondements de la complexité de la gestion et de l’indexation des documents audiovisuels en raison de la nature de leur support, une indexation qui doit alors être soumise à une structure définie et claire pour en instaurer la compréhension. L’auteur définit les documents audiovisuels comme suit :

”Constituent des documents audiovisuels les œuvres comprenant des images et / ou des sons reproductibles réunis sur un support matériel dont : l’enregistrement, la transmission, la perception et la compréhension exigent le recours à un dispositif technique ; le contenu visuel présente une durée linéaire”²

Ainsi, contrairement aux documents imprimés dont la forme rend accessible le contenu, les supports audiovisuels (films, bandes audio, fichiers vidéo) se caractérisent par une opacité qui nous amène à les qualifier de « boîtes noires »³. Le support physique ne révèle que peu ou pas d’informations sur le contenu du document, qui n’est accessible qu’à sa lecture à l’aide d’un appareil de lecture adéquat, et cela, même une fois le document numérisé. Les institutions patrimoniales préservatrices de fonds audiovisuels sont, d’une part, spécifiquement confrontées à la complexité de ce type de contenu dont l’archiviste doit en analyser les images, le son, le montage, la linéarité, etc, et d’autre part, au volume de ces collections,

¹Une Philosophie de l’archivistique Audiovisuelle - UNESCO Bibliothèque Numérique, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).

²*Ibid.*

³Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

que le support ne permet pas d'en décrire le contenu de manière efficace. La description du contenu audiovisuel demande un temps de travail considérable, et repose inévitablement sur un matériel de lecture adéquat. L'outil utilisé afin de gérer les collections peut aider à structurer la description d'un contenu complexe. (deuxième problème : volume : solution = automatisation) En effet, au sein des institutions patrimoniales, la gestion des collections est le plus souvent permise par un outil de gestion des collections, défini comme suit par le ministère de la culture :

Progiciel spécialisé permettant de gérer des informations structurées et des multimédias sur les objets conservés au sein d'un musée, que ces derniers lui soient affectés ou déposés. C'est un système d'information partagé dont les fonctionnalités correspondent au cycle de vie de l'objet⁴.

Ainsi défini, un outil de gestion des collections permet la réalisation des diverses actions liées au cycle de vie de l'ensemble des objets de collection préservés au sein d'une institution. La réalisation de ces actions repose nécessairement sur la production "d'informations structurées" exploitables au sein du système. Cette structuration est permise par l'indexation, « l'opération qui consiste à décrire et à caractériser un document à l'aide de représentations des concepts évoqués dans ce document ».⁵ L'indexation permet précisément d'intelligibiliser un objet au sein d'un système de gestion des collections et de le rendre repérable et interrogeable auprès de l'utilisateur. Dans le cas des collections audiovisuelles, la description d'un objet existe à plusieurs niveaux : contenu intellectuel de l'oeuvre, versions de l'oeuvre, publications de l'oeuvre, localisation et état matériel de ses exemplaires... Une indexation simple ne permet pas la hiérarchisation de ces différents niveaux de description, or, ils facilitent la gestion de l'objet. La mise en place d'une modélisation des données d'indexation permet notamment de les structurer et de les hiérarchiser, afin de mieux appréhender la complexité de la description de tels contenus. Un outil de gestion des collections peut ainsi s'appuyer sur un modèle de données, tel que le FRBR (*Functional Requirements for Bibliographic Records*), modèle que nous analyserons au cours de cette étude. Issu du milieu des bibliothèques, il est également largement utilisé pour la gestion de collections audiovisuelles dont la nature se prête particulièrement à une indexation à différents niveaux. En effet, un document audiovisuel, reproductible par nature, se caractérise par son contenu intellectuel et ses multiples versions et publications, ainsi que ses exemplaires physiques. Ce modèle, implanté au sein

⁴ *Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).

⁵ *Module 6 - Section 7 : Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).

d'un outil de gestion des collections, permet alors de dissocier le contenu intellectuel d'un objet de son support matériel. Le FRBR est toutefois variable selon la collection audiovisuelle, dont la nature conditionne les niveaux d'indexation nécessaires. Une collection expérimentale non diffusée ne nécessite pas les mêmes niveaux d'indexation qu'une collection destinée au grand public. Ainsi, la structure de l'indexation des collections au sein d'un outil de gestion peut être adapté en fonction de la nature de la collection gérée au sein de chaque institution.

Par ailleurs, si la modélisation des données d'indexation permet d'adapter l'outil de gestion des collections à la complexité descriptive des collections audiovisuelles, le volume de ces collections ne permet pas à une institution de rendre compte de la globalité de ses objets au sein d'un tel outil. C'est pourquoi face à l'augmentation croissante des productions de documents et des acquisitions patrimoniales, la mise en place de solutions automatiques au sein d'outils de gestion permettrait d'accélérer la structuration de l'information afin de pouvoir y donner largement accès.⁶ Les tâches d'indexation permises par un outil de gestion des collections restent en effet répétitives et chronophage, et font désormais l'objet de tentatives d'automatisation à l'aide de l'intelligence artificielle. Dans le cas de documents textuels ou iconographiques, l'émergence des modèles fondés sur l'intelligence artificielle, offre des possibilités d'extraction automatique de métadonnées efficaces sur des documents numérisés. Toutefois, les collections audiovisuelles, résistent à la mise en place d'une extraction automatique de leur contenu, en raison de leur format "boîte noire"⁷. Ainsi, d'une part, l'indexation automatique de ces fonds supposerait que les modèles d'intelligence artificielle soient capables de lire et de comprendre le langage cinématographique, caractérisé par la mise en mouvement d'images fixes, le son, et le montage. Or, la compréhension automatique de ce langage reste inégale, en particulier lorsqu'elle est confrontée à des fonds d'archives audiovisuels patrimoniaux, anciens ou dégradés, dont la qualité sonore et visuelle est compromise. A priori, l'étude d'un tel type de documents nécessiterait des algorithmes d'intelligence artificielle lourds et coûteux, incompatibles avec les logiques institutionnelles patrimoniales. Le rôle de recherche et de proposition d'une indexation automatique pour les collections audiovisuelles reviendrait à l'éditeur de l'outil de gestion des collections, dont la logique produit encourage l'innovation constante. Toutefois cette innovation se heurte à une double difficulté que nous avons posée : la complexité pour les modèles automatiques de lire et de comprendre un contenu visuel, sonore et temporel, ainsi que l'inscription de fonctionnalités automatiques au sein d'un modèle de données (FRBR) variable, hautement dépendant du contexte institutionnel. C'est précisément cette double difficulté qui anime l'étude de ce mémoire de recherche, réalisé dans

⁶Sabine Barreaux, Béatrice Daille et Évelyne Jacquey, « Indexation automatique en SHS : bilan d'une expérimentation », *I2D - Information, données & documents*, 54-1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.

⁷B. Bachimont, *Indexation et archivage de contenus multimédias...*

le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, éditrice de solutions logicielles de gestion des collections. Effectué au sein de l'équipe métier, forte de propositions de fonctionnalités innovantes adaptées aux besoins des clients institutionnels, ce stage se porte spécifiquement sur l'amélioration de l'espace de travail dédié aux archives audiovisuelles (S-movies), fondé sur le FRBR, à travers le projet d'automatiser certains pans de l'indexation à l'aide de l'intelligence artificielle. Les réflexions et observations d'un point de vue métier qui ont traversé ce stage constituent le point de départ de ce mémoire, dont l'étude examine les conditions de faisabilité et les modalités d'intégration d'une indexation automatique appliquée à l'audiovisuel au sein d'un système de gestion de collections fondé sur une modélisation adaptative du FRBR.

Intégrer un état de l'art : sur l'automatisation de l'indexation des archives audiovisuelles : combinaison de plusieurs algorithmes, pas d'outils concret qui feraient l'ensemble du processus d'indexation. Ce mémoire tente d'articuler un pipeline d'indexation automatique avec un modèle FRBR adaptatif

Dans quelle mesure la variabilité du modèle de données FRBR adapté aux archives audiovisuelles conditionne-t-elle la mise en place d'une indexation automatique pour ce type d'archives ? Quels types d'algorithmes fondés sur l'intelligence artificielle peuvent être proposés au sein d'un outil de gestion des collections adaptatif à la nature des collections audiovisuelles ? Dans une première partie, nous analyserons les fondements du modèle FRBR et les modalités de son adaptation aux archives audiovisuelles, afin d'examiner les questions documentaires posées par le projet de la mise en place d'une indexation automatique de tels documents. Dans une seconde partie nous étudierons la possibilité d'une implémentation concrète d'outils d'indexation automatique au sein d'une modélisation FRBR d'un outil de gestion des collections. Nous y analyserons la faisabilité technique d'une mise en place de l'indexation à partir d'un séquençage automatique de fichiers numériques audiovisuels et d'une extraction automatique de mots-clés, pour en analyser le reversement au sein des différents niveaux de description modélisés par le FRBR. Enfin, nous évaluerons dans une troisième partie les limites, biais et enjeux éthiques liés à l'inadaptation des données d'entraînement d'IA aux fonds d'archives. Nous montrerons alors que les limites du « tout-automatique » invitent à réorienter la conception des logiciels métier vers un paradigme d'indexation augmentée et d'intelligence hybride**, plaçant l'interaction homme-machine au cœur de la gouvernance de la qualité documentaire.

Première partie

Indexer les archives audiovisuelles

Deuxième partie

Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR

1. Traitement audiovisuel

Les tâches d'analyse automatique pouvant être appliquées aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent davantage vers le media vidéo, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance⁸. Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. Si la détection automatique des plans dans un flux vidéo est maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image, la détection sémantique de séquences reste inexploitée. Comme le souligne Bhargav dans quel article ? et ses coauteurs, "pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques. [Traduction personnelle]"⁹.

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle et d'indexation automatisée. Au courant de notre proposition, la segmentation est moins considérée comme un prérequis technique que comme une fonctionnalité documentaire à part entière, directement articulée à l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

a. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont globalement désignées sous le terme de Audiovisual Processing (AVP)¹⁰.

Appliquées à un grand nombre de données, ces technologies permettent de passer du

⁸Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁹"reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material" Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240

¹⁰Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

"close" au "distant viewing", c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble.¹¹ Les tâches de traitement automatique permettraient en effet de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données afin d'en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

De nombreux projets sont dédiés à l'analyse automatique de corpus audiovisuels, toutefois, aucun projet n'est concrètement dédié à la segmentation temporelle en différentes séquences afin d'en indexer le contenu. L'Institut National Audiovisuel (Institut National de l'Audiovisuel (INA)), est notamment pionnier dans la proposition de projets d'analyse automatique appliquée à l'audiovisuel. L'INA a par exemple mis en place un outil de segmentation, InaSpeechSegmenter, toutefois dédié à la segmentation du discours entre hommes et femmes, dans une optique statistique¹². Cet algorithme de segmentation, appliqué au son, ne peut être pris comme exemple d'application pour notre étude, centrée sur l'analyse du sens de l'image en mouvement.

Par ailleurs, le projet MeMad, réunit un ensemble d'outils dédiés à l'analyse automatique de l'audiovisuel développés par l'Université d'Aalto, EURECOM, l'INA et l'Université d'Helsinki¹³. Parmi les outils développés, nous pouvons citer par exemple un outil de traduction du discours (Speech translation), l'outil inaFaceGender, un outil de reconnaissance faciale (Face recognition), un outil permettant d'identifier la langue parlée (Spoken language identification)¹⁴. Ces projets restent centrés sur l'analyse du son et du texte inclut dans l'image et ne peuvent donc pas être pris en compte dans notre analyse. Au sein de cette sous section, nous tenterons ainsi d'évaluer les outils et méthodes disponibles et dédiés au traitement audiovisuels, afin de proposer un processus adéquat.

L'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de *computer vision*, ou de vision par ordinateur. Le terme définit un sous-domaine d'application de l'intelligence artificielle qui permet d'entraîner un système d'intelligence artificielle à l'analyse des images fixes ou en mouvement¹⁵. La vision par ordinateur s'appuie largement sur des modèles de *machine learning*, ou apprentissage machine, qui désigne une branche de l'intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique

¹¹ *Ibid.*

¹² *Analyse Des Tendances Médias Par l'IA - Les Traitements Réalisés Par Les Outils d'intelligence Artificielle Utilisés Sur Data.Ina.Fr / Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).

¹³ *MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).

¹⁴ *Ibid.*

¹⁵ Rina Diane Caballar Stryker Cole, *Qu'est-ce que la vision par ordinateur ? / IBM*, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

plus intelligent.¹⁶ L'apprentissage machine permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données.¹⁷ La vision par ordinateur classique s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques¹⁸. Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d'apprentissage machine¹⁹. De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut être mis en place sur l'ensemble des données, seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds²⁰. Ces modèles relèvent également de la vision par ordinateur, mais fondée sur l'apprentissage profond, permettant notamment de gérer l'analyse de flux vidéo. La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l'apprentissage machine. L'apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'exécuter des tâches automatisées, réduisant le besoin d'intervention humaine, et améliorant ainsi le rapport cout-efficacité²¹. Il suffirait de fournir

¹⁶Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹⁷*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹⁸Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹⁹*Ibid.*

²⁰Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

²¹N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données²². Par rapport aux techniques traditionnelles de vision par ordinateur, l'apprentissage profond permet d'obtenir une plus grande précision dans les tâches d'analyse audiovisuelle telles que la classification d'images, la segmentation, la détection d'objets²³.

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la vision par ordinateur pour la classification d'images et la reconnaissance d'objets, est celui des réseaux de neurones convolutifs (CNN). Appliqués à des corpus d'images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d'en extraire les couleurs et les contours.²⁴ Les tâches que permettent les CNN sont plutôt bien adaptées à l'image fixe, puisqu'ils extraient des éléments fixes de l'image.

Néanmoins, d'autres modèles issus de l'apprentissage profond tels que les transformers s'avèrent davantage efficace sur des tâches dédiées à l'image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent grâce à un mécanisme d'auto-attention qui leur permet de détecter les relations et dépendances entre les données²⁵. Tandis que les CNN analysent les données de manière locale dans l'image, sans prendre en compte les interdépendances qui les régissent temporellement, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d'entre elles²⁶. Les CNN ne permettent pas, par exemple, de discerner les "dépendances à longue portée" telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins²⁷. Ainsi, ils seraient davantage adaptés à l'analyse d'images en mouvement puisqu'ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d'une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l'intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d'interpréter les analyses qui sont produites²⁸. En effet, une fois entraînés, il est difficile d'en modifier les paramètres puisqu'ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi

²² *Ibid.*

²³ *Ibid.*

²⁴ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

²⁵ Cole Stryker Bergmann Dave, *Qu'est-ce qu'un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

²⁶ *Ibid.*

²⁷ *Ibid.*

²⁸ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

difficile à comprendre et à exposer²⁹. Deuxièmement, les algorithmes de type transformers sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe³⁰. Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d'un large jeu de données d'entraînement afin d'éviter un surapprentissage impliquant des biais multiples³¹. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu'il s'agirait de réadapter à un contexte patrimonial³². Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l'analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d'analyse automatique d'un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 1 ci-dessous permet de comparer les compétences des types de modèles cités pour l'analyse d'un flux vidéo.

²⁹N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

³⁰Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

³¹Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

³²*Ibid.*

Type d'approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan - Calcul d'histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d'objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d'images fixes extraites du flux vidéo - Détection d'objets ou caractéristiques dans l'image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 1 : Comparatif des approches de traitement audiovisuel automatique

Comme l'illustre le Tableau 1, si les architectures fondées sur les transformers offrent des compétences puissantes, notamment pour l'automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d'entraînement conséquents. À l'inverse, la vision par ordinateur classique offre une stabilité d'analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d'en extraire le sens. Ce constat justifie l'orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

b. Outils et modèles disponibles

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués de documents audiovisuels, leur architecture nous donne des pistes d'expérimentations afin de pouvoir implémenter un tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéos

en différentes séquences. L’optique de cette étude est de fournir une proposition d’implémentation de fonctionnalités automatiques au sein d’un outil de gestion des collections d’un point de vue métier, au regard des besoins utilisateurs. Par conséquent, notre étude analysera l’architecture des algorithmes sélectionnés sans en détailler les mécanismes techniques.

Tout d’abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des transformers notamment, une des solutions envisagée consisterait à transformer un flux d’images en mouvement en la série d’images fixes qui le composent. Ce processus écarterait notamment le besoin d’analyser les relations entre les images par un mécanisme d’auto-attention prévu par les transformers. En effet, le médium cinématographique se caractérise par l’enchaînement d’une succession d’images fixes produisant ainsi l’illusion du mouvement. La transformation de ce flux à l’état d’images fixes par un outil technique permettrait de pouvoir gérer l’analyse sémantique de ces images par des processus légers prévus par la vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d’analyse que ceux prévus pour l’image fixe, fondés sur la vision par ordinateur classique.

Cette segmentation d’un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d’une analyse sémantique, regroupant ces plans fixes en des séquences sémantiques. Dans un article sur la mise en place d’un processus de segmentation temporelle, Xin prône notamment le découpage syntaxique tel que nous l’avons défini comme étape préliminaire à l’analyse sémantique des images par des modèles d’intelligence artificielle³³. La segmentation syntaxique d’un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

Ainsi, la segmentation automatique d’un document audiovisuel en séquences serait fondée sur l’analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes³⁴. Ces plans sont en réalité retenus par l’algorithme comme des images-clés contenues au sein de chaque séquences, calculées comme l’image la plus représentative de la présence des éléments dans un flux donné³⁵. Ce principe, qualifié de sélection de données, permet d’alléger nettement la puissance de calcul et la structure des algorithmes³⁶. Ces images-clés seraient ensuite analysées par un algorithme fondé sur des CNN, afin d’y ajouter une analyse sémantique et de les regrouper

³³Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

³⁴*Ibid.*

³⁵*Ibid.*

³⁶*Ibid.*

en séquences.

Ce processus est notamment appliqué par la bibliothèque python Pyscenedetect qui permet la segmentation d'un flux vidéo à l'aide de différents paramètres définis en amont³⁷. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l'analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquences audiovisuelle, Pyscenedetect permet d'en extraire les image clés, c'est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de vision par ordinateur classique, qui concrétise la mise en oeuvre de la comparaison syntaxique d'images fixes. L'outil s'appuie sur des détecteurs mathématiques afin d'analyser les différences structurelles entre les images-clés tirées d'une vidéo³⁸. Il s'agit ainsi d'un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d'entraînement particulier, comme c'est le cas des outils de vision par ordinateur fondés sur l'apprentissage profond. Pyscenedetect permet d'isoler des images-clés de l'image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l'outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l'image, une détection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d'un plan avec les plans adjacents (méthode *detect-adaptive*)³⁹. En théorie, Pyscenedetect isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d'images, et non des séquences, unités de sens narratives. Néanmoins, Pyscenedetect permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l'élévation de la valeur du seuil de détection ou la fixation d'une durée minimale de séquences (*min-scene-len*), l'outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu'en cas de détection de changements visuels majeurs tels que l'éclairage, le décor, la composition, etc⁴⁰. Par ce biais, la segmentation syntaxique proposée par Pyscenedetect pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l'outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquences retenue. Le diagramme de flux 1 ci-dessous illustre la manière dont l'outil pourrait être paramétré afin de segmenter le flux vidéo en séquences.

Pour chaque changement détecté, une nouvelle séquence est ainsi créée et une images-clés est automatiquement enregistrée, associée au fichier vidéo d'origine. Nous proposerons

³⁷ *Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³⁸ *Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

³⁹ *Ibid.*

⁴⁰ *Ibid.*




FIG. 1 : Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect

la réutilisation de cette images-clés au sein du processus suivant, dédié à l'analyse sémantique des séquences préalablement détectées, afin de ne pas surcharger les algorithmes. Ce système images-clés permettrait ainsi d'alléger le processus d'analyse sémantique, puisque les algorithmes reçoivent des images fixes au lieu de fichiers vidéos plus ou moins lourds. Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Samarth Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus⁴¹. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même après numérisation ou restauration⁴². En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus⁴³. De plus, Samarth Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé⁴⁴. Toutefois, un des avantages majeurs de l'outil Pyscenedetect est sa disponibilité et la possibilité de le mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

⁴¹S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

⁴²*Ibid.*

⁴³J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴⁴S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

c. Mise en application

Au sein du chapitre suivant, nous mettrons à l'épreuve l'adaptabilité de l'outil que nous avons décrit pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, construit par des plans fixes, en noir et blanc et muets. Nous tenterons d'appliquer le processus de segmentation proposé par Pyscenedetect sur un tel corpus, afin d'en comprendre les données qui pourraient être générées. Le corpus, utilisé ici comme cas d'étude, se caractérise notamment par son ancienneté, et donc par la dégradation de la pellicule sur laquelle l'image s'inscrit. L'outil pourrait ainsi rencontrer des difficultés lors de l'identification des coupures et des changements de plans, brouillés par la dégradation de l'image. Toutefois, la structure du contenu de ces archives facilite la tâche de l'outil, composé d'une succession de plans fixes, dont les coupures sont suffisamment marquées, en fait un corpus relativement bien adapté à ce type de tâche automatique, qui pourrait identifier les coupes plus facilement.

Par ailleurs, Pyscenedetect, nous l'avons vu, est un outil dédié à la détection de coupures et à la segmentation d'un flux vidéo en différents plans. Or, dans cette étude, nous cherchons à montrer comment segmenter un flux audiovisuel en différentes séquences, unités sémantiques autonomes. Dès lors, comment paramétrer un tel outil pour la détection d'éléments sémantiques plus larges tels que les séquences ?

Une solution envisagée serait d'augmenter la valeur du seuil de coupures (treshold), pour que l'outil ne détecte plus les micro-coupures entre les images mais des coupes plus larges, à l'échelle de séquences⁴⁵. L'outil enregistrerait alors un changement de séquence seulement lors d'une rupture significative de l'espace-temps à l'image. Ce paramétrage reste toutefois limité puisque plusieurs plans adjacents peuvent être radicalement différents d'un point de vue syntaxiques, tout en appartenant bien à la même séquence. Par exemple, une même séquence peut contenir un gros plan et un plan d'ensemble, dont la composition visuelle est bien différente. Dans le cas du corpus d'archives audiovisuelles décrit, les plans restent larges et fixes, montrant l'ensemble du décor dans lequel ils s'inscrivent. Ainsi, le paramétrage du seuil pourrait être adéquatement réglé pour la détection de changements de décor, sur ce corpus donné, afin de segmenter le flux vidéo en différentes séquences.

Par ailleurs, il est possible de régler l'outil sur une durée minimale de détection de coupures à l'aide du paramètre "min-scene-len", pour que le processus n'effectue de coupures qu'après un laps de temps défini⁴⁶. La définition de ce paramètre nécessite une analyse statistique du corpus segmenté afin d'en définir la durée moyenne d'une séquence. Au sein du

⁴⁵ *Command-Line - PySceneDetect...*

⁴⁶ *Ibid.*

logiciel de gestion des collections prévu par Skinsoft, l’institution qui gère ce corpus d’archives documente déjà les séquences contenues par les différentes œuvres au sein des notices de films physiques, sous la forme de repères temporels. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de time codes afin de déterminer la durée moyenne d’une séquence au sein du corpus. D’après nos observations, les séquences extraites sont généralement d’une durée de 60 secondes. Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d’images plus importante, permettant à l’outil de comparer le contenu visuel d’un plan par rapport à une grande variété de plans qui l’entourent⁴⁷. Ce paramètre permettrait encore de régler l’outil sur la détection de changements majeurs dans l’image, dans l’optique d’en extraire uniquement les séquences.

Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données en sortie. D’une part, un fichier JSON ou CSV contenant les time codes de début et de fin correspondant aux séquences identifiées au sein de chaque fichier vidéo ingéré. Chaque séquence est alors associée à un identifiant unique et à des times codes de début et de fin. D’autre part, l’outil permet également d’extraire pour chaque séquence un fichier image, qui correspond à l’image fixe médiane, censée être la plus représentative de la séquence, désignée par le terme d’image clé⁴⁸.

Toutefois, si ce paramétrage permettrait une plus grande flexibilité pour la segmentation d’un flux vidéo en séquences, l’outil reste limité dans l’automatisation de cette tâche. D’une part l’outil est prévu pour la détection automatique de changement de plan, et d’autre part, une séquence ne se définit pas seulement comme une caractéristique syntaxique du langage cinématographique, comme c’est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence concrétise un choix narratif, matérialisé généralement par un changement d’espace-temps. C’est pourquoi, un outil dont l’automatisation est fondée sur des seuils mathématiques reste limité pour une telle tâche. Nous proposons alors de réaliser une analyse sémantique des séquences détectées, afin de ré associer leur sens à ces coupures détectées automatiquement, tout en réutilisant les données produites : les times codes et l’image clé associés à chaque séquence.

La segmentation syntaxique effectuée par Pyscenedetect constitue un “filtre”, c’est-à-dire un premier niveau dans notre chaîne d’indexation automatique des archives audiovisuelles⁴⁹. Les données issues de ce premier niveau permettent d’amoindrir le volume de données, caractéristique des fichiers vidéo, transmis aux algorithmes d’indexation automatique. Dès lors, les images-clés produites par glspyscene peuvent être soumises à un modèle neuronal de détection d’objets tel que YOLO (You only look once), afin d’extraire le sens

⁴⁷ *Ibid.*

⁴⁸ *Ibid.*

⁴⁹ Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*




FIG. 2 : Mise en application de Pyscenedetect

de ces segments et leur rendre leur valeur sémantique. La sous-section suivante détaille la manière dont ce modèle, appliqué aux glsimgcle des séquences, permet d'en extraire les caractéristiques sémantiques à des fins d'indexation.

????

Il est courant d'utiliser des modèles préentraînés sur un grand jeu de données et de le réajuster ensuite au jeu de données en question, au sein d'un contexte précis.⁵⁰ Ce modèle peut justement servir de modèle de caractéristiques à analyser sur les vidéos, un second entraînement, dans le contexte peut aider à l'affiner et à l'adapter au corpus spécifique. Le rendre d'abord familier au langage audiovisuel.

Malgré de grandes avancées dans le processing audiovisuel, avec des outils comme la computer vision appliquée à la vidéo, et la reconnaissance de discours automatique (ASR), ces outils restent largement inaccessibles et hors de portée pour les institutions patrimoniales.⁵¹ Ils sont utilisés par des entreprises commerciales pour du montage vidéo par exemple. Le manque d'utilisation de ces outils dans le domaine des sciences humaines expliquent l'inexistence de données d'entraînement adaptées au secteur.⁵² L'analyse vidéo par un processus humain prend un temps considérable, puisqu'il faut lire le fichier audiovisuel et en analyser les composants, le langage. Ainsi, l'indexation des archives audiovisuelles se cantonne souvent aux métadonnées, sans en exposer les données, le contenu.

Et donc en pratique, comment appliquer le traitement audiovisuel à des corpus d'archives audiovisuelles patrimoniales ?

transition : nécessité d'un mapping vers le FRBR : faire correspondre la sortie de ces pipelines avec un modèle de données.

2. Description et indexation automatique

Quoi décrire ?

à rajouter pour faire la transition :

La description automatique d'images peut être centrée sur de nombreux éléments au sein d'une séquences de film : dialogues, ambiance sonore, visages, objets, spatialité des éléments, actions, émotions... Toutefois, la définition d'un processus au sein d'un logiciel de gestion des collections impose un cadrage défini des fonctionnalités. Le corpus patrimonial retenu pour notre étude, constitué de rush muets des premiers temps, exclue d'emblée l'analyse

⁵⁰J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁵¹N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁵²*Ibid.*

automatique de caractéristiques sonores. L’analyse automatique se concentre donc exclusivement sur les caractéristiques visuelles de l’image. Deux approches coexistent alors, celle de l’identification des éléments dans l’image de manière précise, ou celle d’éventuellement générer des résumés automatiques sur ces séquences, à une échelle plus globale. Or, la seconde approche, fondée sur des grands modèles de langage, implique des architectures génératives coûteuses et lourdes. Nous choisissons ainsi d’adopter la première, afin de garantir une indexation fiable et stable, plus légère, à travers la détection et l’identification d’objets sur les images-cléspréalablement extraites. Cette tâche peut être réalisée par des architectures de réseaux de neurones relativement légers, pouvant extraire des concepts directement indexables au sein du logiciel.

a. Outils utilisés

Si pour la tâche de segmentation automatique, nous avons écarté les architectures de modèles fondés sur des réseaux de neurones, la reconnaissance d’objets dans l’image suppose une prédiction fondée sur un apprentissage machine profond des réseaux de neurones. En effet, la plupart des outils de reconnaissance d’objets dans l’image sont fondés sur des modèles de réseaux de neurones convolutifs (CNN) dont nous avons exposé le fonctionnement dans la section précédente. Dans le domaine du patrimoine, dont le logiciel de Skinsoft gère les données des institutions, se pose la question d’une infrastructure adaptée qui permet d’assurer la sécurité des données produites. Les solutions commerciales d’analyse automatique sont pour la plupart fondées sur un Cloud externe qui implique le déplacement des données. Ces solutions sont inadaptées au contexte d’analyse de données patrimoniales en raison de propriété intellectuelle et de sécurité. Ainsi, le principe retenu afin de guider notre choix d’outil est celui d’”amener l’algorithme aux données”, via un développement local interne des modèles d’analyse⁵³. Afin de répondre à cette contrainte, notre choix s’est tourné vers des modèles en libre accès. Nous détaillerons dans cette section l’utilisation de l’architecture YOLO, une série d’algorithmes dédiés à la détection d’objets visuels dans les images et les flux vidéo, et fondé sur les réseaux neuronaux convolutifs, développé par Joseph Redmond en 2015, puis repris par Ultralytics en 2020⁵⁴. C’est l’un des outils de détection d’objets les plus documentés, y compris dans le domaine des sciences humaines et du patrimoine. Fondé sur la vision par ordinateur et entraîné grâce à des méthodes d’apprentissage profond, YOLO est en accès libre, et permet notamment la détection d’objets et la classification d’images, permettant ainsi de poser les bases d’une indexation⁵⁵. Le modèle extrait dans un premier

⁵³ *Ibid.*

⁵⁴ Ilyes Talbi, *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).

⁵⁵ Glenn Jocher, *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.

temps les caractéristiques visuelles de l'image qui lui est donnée, les agrège, afin de finalement proposer une détection d'objets⁵⁶. Les versions récentes du modèle telles que YoLo12 ne sont désormais plus seulement basées sur des CNN mais sur des mécanismes d'auto-attention, similaires à ceux des transformers dont nous avons évoqué l'architecture⁵⁷. Toutefois, comme nous l'avons évoqué, cette architecture demande une consommation de mémoire élevée et une puissance de calcul lourde⁵⁸. Ultralytics, créateur du modèle, recommande des versions moins avancées pour une mise en application rapide, telles que la version YOLOv8, uniquement fondée sur un réseau de neurones convolutif⁵⁹. YOLOv8 propose une version optimisée de cette architecture en trois temps : extraction, aggrégation, et détection⁶⁰. Le modèle se caractérise par sa capacité à analyser l'image en une seule fois, contrairement à d'autres modèles dont les résultats impliquent plusieurs analyses de certaines parties de l'image⁶¹. Si la détection d'objets prévue par YOLO peut être appliquée à des flux vidéo, nous souhaitons l'intégrer comme composant complémentaire au processus de segmentation précédemment décrit. De fait, il est pertinent de réutiliser l'image clé fixe, produite et sauvegardée par l'outil pyscenedetect, associée à chaque séquence, afin de la faire analyser par le modèle. Ceci permettrait de réduire le temps de calcul du processus et d'améliorer l'efficacité des prédictions, puisque le modèle reçoit un minimum d'informations. Ainsi, l'application du modèle YOLO s'impose comme la suite logique du pipeline de segmentation détaillé précédemment, afin d'indexer les segments produits, via l'utilisation des images-clés. Si le premier processus de segmentation produit des données temporelles associées à chaque séquence sous la forme de time codes, YOLO produit des données sémantiques sur ces mêmes séquences. À l'issue de l'analyse d'une image-clé, le modèle YOLO est capable de produire trois types de données : des étiquettes sur les objets identifiés, un score de confiance qui indique l'indice de certitude concernant la prédiction, des coordonnées spatiales de localisation de l'objet détecté dans l'image⁶². Les étiquettes produites sur les objets identifiés, permettant de décrire les caractéristiques de l'image, pourront être indexées comme des mots-clés au sein du logiciel de gestion des collections. Ces mots-clés seront associés aux time-codes de chaque séquence détectée. Ainsi, chaque séquence contiendrait les données suivantes : des time codes qui l'identifient comme

⁵⁶J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁵⁷YOLO12 : Détection d'objets centrée sur l'attention, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).

⁵⁸*Ibid.*

⁵⁹Explorer Ultralytics YOLOv8, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).

⁶⁰Muhammad Yaseen, *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].

⁶¹Joseph Redmon, Santosh Divvala, Ross Girshick et Ali Farhadi, *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

⁶²*Ibid.*

extrait, des étiquettes/mots-clés sur les objets qu'elle contient, et des données qui permettraient aux utilisateurs de vérifier la prédiction et de la valider. Le score de confiance produit par le modèle, permet en effet d'indiquer à l'utilisateur la certitude de l'étiquette associée à tel objet détecté. De même, les coordonnées spatiales de l'étiquette produite permettent à l'utilisateur de vérifier dans l'image si l'étiquette produite est associée au bon objet.

b. Entraînement

L'analyse automatique du contenu des images repose donc sur les architectures des CNN, fondées sur des méthodes d'apprentissage profond, dont YOLO est un exemple concret. Toutefois, les algorithmes fondés sur l'apprentissage profond subissent généralement un entraînement supplémentaire afin d'analyser adéquatement le contenu des images en fonction d'un contexte donné. Deux approches méthodologiques d'entraînement peuvent être appliquées, l'apprentissage supervisé et l'apprentissage non supervisé. L'apprentissage supervisé est fondé sur l'utilisation de données annotées pour l'amélioration des prédictions du modèle d'analyse d'image, tandis que l'apprentissage non supervisé exécute des tâches d'analyse et de classification à partir de données brutes, non annotées⁶³. Toutefois, l'apprentissage non supervisé ne permet pas d'adapter suffisamment le modèle de détection d'objets au corpus d'images spécifique étudié. En effet, si Yolov8 a toutefois fait l'objet d'un pré-entraînement en amont de sa mise à disposition, sur le jeu de données COCO, ce dernier, composé de 200 000 images annotées, reste généraliste et adapté à la détection d'objets communs et contemporain⁶⁴. Or, l'efficacité des modèles basés sur l'apprentissage profond sur un corpus spécifique dépend fondamentalement de nature et de la qualité de leur données d'entraînement. Au sein des sous sections suivantes, nous prendrons comme exemple d'application le projet des archives britanniques en ligne, qui propose une chaîne de traitement pour la détection d'objet basée sur l'apprentissage profond et la supervision humaine⁶⁵. Le projet, à travers la mise en place d'une supervision au sein du processus d'analyse par le modèle, propose de mettre en application le concept de Human-in-the-Loop⁶⁶. Le corpus étudié, caractérisé par l'ancienneté de ses images en fait un corpus d'images spécifique sur lequel l'algorithme doit subir un en-

⁶³Julianna Delua, *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

⁶⁴YOLO Algorithm for Object Detection Explained [+Examples], janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

⁶⁵Surya Kasturi, Alex Shenfield, Chris Roast, Danny Le Page et Alice Broome, « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

⁶⁶*Ibid.*

entraînement supplémentaire, supervisé. Afin d’adapter le modèle à notre corpus et ainsi d’en améliorer l’efficacité, une phase de pré traitement est nécessaire sur les données du corpus, au cours de laquelle des images sont sélectionnées afin d’être annotées pour être pré-testées par le modèle⁶⁷. La supervision humaine est déterminante dans ce processus, particulièrement dans le cas d’analyse de corpus inédits sur lesquels l’algorithme reste à entraîner⁶⁸. Les british online archives implémentent l’adaptation du modèle par la pré sélection d’un nombre d’images définis, annotées manuellement à l’aide de la plateforme Label Studio⁶⁹. Label Studio est une plateforme open source déployable localement, qui permet ainsi de respecter la protection des données analysées⁷⁰. Afin d’éviter l’annotation manuelle de l’ensemble des images-clés issues du processus de segmentation, il peut être envisagé d’exécuter au préalable YOLO depuis Label Studio sur l’ensemble des images-clés du corpus afin de générer une base de prédictions⁷¹. Les détections brutes générées peuvent ensuite être importées au sein de la plateforme comme une couche d’annotation préalable à partir de laquelle affiner le modèle. Au sein de Label Studio, les prédictions s’affichent sous la forme de *bounding boxes*, c’est-à-dire de boîtes englobantes autour des objets détectés dans l’image, avec le score de confiance qui y est associé⁷². Le paramètre [choices] permet au modèle de proposer une classification sur les objets détectés, c’est-à-dire un mot clé⁷³. Afin de focaliser la supervision du modèle sur les éléments les plus pertinents, il peut être décidé de ré annoter les images dont la détection est jugée incertaine par le modèle via un score de confiance en dessous du seuil minimal attendu⁷⁴. Les archives britanniques préconisent également la suppression des boîtes englobantes redondantes afin de sélectionner celles qui sont les plus pertinentes pour la supervision⁷⁵. Dans Label Studio, les utilisateurs (une équipe technique dans le cas de Skinsoft) examinent les prédictions ainsi générées sur les images, rectifient si besoin la définition des ”boîtes” et la classification associée⁷⁶. Les données ainsi corrigées sont exportées au format YOLO depuis Label Studio, puis réinjectées dans la chaîne de réentraînement du modèle afin d’améliorer

⁶⁷ *Ibid.*

⁶⁸ *Ibid.*

⁶⁹ *Ibid.*

⁷⁰ *Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).

⁷¹ S. O. Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).

⁷² S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁷³ *Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).

⁷⁴ S. O. Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline...*

⁷⁵ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁷⁶ *Ibid.*

les performances en accord avec le corpus⁷⁷. Cette méthode s'appuie sur le transfert d'apprentissage (transfert learning), qui consiste à *fine tuner* un modèle existant, c'est-à-dire de l'affiner, afin de l'adapter au corpus analysé⁷⁸. À défaut de réentraîner le modèle dans sa globalité, les prédictions réalisées à partir du jeu de données d'entraînement COCO sont conservées puis spécialisées sur un corpus donné⁷⁹. L'affinage du modèle via la rectification et l'annotation des données, constitue une étape de prétraitement, en amont de l'analyse des données, afin d'améliorer l'efficacité de la détection d'objets⁸⁰. Cette étape de pré-traitement, avant le processus d'analyse, implique la définition des types de mots clés souhaités, pour l'indexation des séquences. En effet, les étiquettes associées aux objets au sein des images correspondent aux mots-clés qui seront prédits par le modèle lors de l'analyse. Dans le cadre du corpus étudié, il est pertinent d'extraire les mots-clés déjà indexés sur les séquences au sein du logiciel. Ces mots-clés varient selon le contenu de l'image et peuvent, par exemple, être les suivants : affiche, foule, policier, gendarme, drapeau, etc. Ces mots-clés, tout comme le jeu de données COCO, sont assez génériques. De fait, le pré traitement est avant tout utile pour l'entraînement du modèle à pouvoir détecter des objets au sein d'images dont la qualité est compromise.

c. Processus de validation technique

Poursuite de l'application du concept HIL

Afin de gérer les essais-erreurs de l'affinage du modèle sur les données spécifiques du corpus, il est pertinent de mettre en place un processus de validation technique du traitement. Ce processus permettrait d'une part de valider les résultats du modèle, et d'autre part, d'assurer la concordance entre les données produites par le modèle avec les données déjà existantes au sein du logiciel.

La validation des prédictions du modèle peut être effectuée au sein de la plateforme Label Studio. Les archives britanniques proposent que le jeu de données test utilisé précédemment afin de corriger les prédictions, soit distinct d'un second jeu de données test, dédié à l'évaluation des performances du modèle, à différents niveaux de supervision humaine⁸¹. Sur ce second jeu de données, sont notamment intégrées des métadonnées de supervision humaine. En effet, Kasturi explique l'introduction des notations "HIL-10 %, HIL-15 % et HIL-20 %, qui signifient respectivement que les utilisateurs ont corrigé 10 %, 15 % et 20 %

⁷⁷ *Ibid.*

⁷⁸ S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

⁷⁹ *Ibid.*

⁸⁰ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁸¹ *Ibid.*

des boîtes englobantes prédites peu performantes dans l’ensemble de données de test.”⁸². (traduction de : HIL-10%, HIL-15%, and HIL-20%, which signify that users have corrected 10%, 15%, and 20% of poorly performing predicted bounding boxes in the test dataset, respectively). Les données corrigées manuellement remplacent ensuite certaines images au hasard dans le premier jeu de données d’apprentissage, constituant un nouveau jeu de données d’entraînement sur lequel le modèle s’affine⁸³. Le modèle ainsi affiné est finalement exécuté sur le second jeu de données, corrigé selon différents niveaux d’intervention humaine⁸⁴. Pour chaque niveau de supervision, sont analysés les ”scores moyens d’Intersection over Union (mIOU) et de précision moyenne (mAP), ainsi que de la précision et du rappel”⁸⁵. Les résultats obtenus montrent que les performances du modèle s’améliorent considérablement à mesure que le pourcentage d’images corrigées manuellement augmente⁸⁶. En effet, l’enrichissement du jeu de données permet au modèle d’appréhender l’analyse des images de manière plus précise. L’auteur note toutefois la nécessité de poursuivre l’évaluation du modèle sur d’autres données afin de vérifier son adaptabilité et ses performances pour la détection d’autres types d’objets⁸⁷. En effet, le modèle devrait être ré entraîné constamment, à mesure qu’il soit exécuté sur de nouvelles données. (Active learning)

De plus, le processus de validation technique implique également la validation de l’indexation des données produites au sein du logiciel, en adéquation avec les règles métier en place. Au sein de l’espace de travail S-Movies dédié au corpus étudié, l’indexation des mots-clés est contrôlée par le thésaurus ”keyword”. Or, le modèle YOLO est nativement pré entraîné sur un jeu de données généraliste dont les étiquettes produites ne correspondront pas directement aux autorités indexées dans la base de données. Deux cas peuvent être gérés par l’utilisateur côté technique. D’une part, les mots-clés produits par le modèle peuvent déjà être indexés sous une forme contrôlée au sein du logiciel. Dans ce cas, il revient à l’utilisateur de vérifier que les mots-clés générés par le modèle concordent avec la forme indexée contrôlée au sein du logiciel. À terme, cette tâche de validation pourra être gérée par un LLM, un grand modèle de langage, déjà employé par Skinsoft pour un outil de recherche en langage naturel par exemple. Ce grand modèle de langage pourra être capable, à partir du thésaurus indexé dans le logiciel, de valider les formes contrôlées des mots-clés générés par YOLO. Pour cela, un mapping (tableau de correspondance) pourra être fourni au LLM entre les mots-clés que le modèle peut potentiellement générer, et leur forme contrôlée dans le thésaurus. Nous avons effectivement déjà élaboré un tel tableau au cours de notre stage dans le cadre de la

⁸² *Ibid.*

⁸³ *Ibid.*

⁸⁴ *Ibid.*

⁸⁵ *Ibid.*

⁸⁶ *Ibid.*

⁸⁷ *Ibid.*

mise en place de l'intelligence artificielle pour d'autres tâches, notamment la mise en place d'une recherche en langage naturel. Pour cette tâche tout à fait différente que celle que nous décrivons dans ce mémoire, nous avons effectué une table de correspondance entre les champs contrôlés pouvant être requêtés dans le logiciel et leur définition en langage naturel, préparant ainsi la gestion de synonymes et de termes employés par l'utilisateur potentiellement pour requêter ces champs. Sur le même principe, nous pourrions mettre en place une table de correspondance afin d'assurer la validation des données produites et d'assurer *in fine* leur indexation au sein de l'application. Un calcul de similarité aide le LLM à repérer les termes similaires et les rapprocher de leur forme contrôlée. D'autre part, si les mots clés n'existent pas sous une forme contrôlée au sein du thésaurus et qu'aucune correspondance n'est détectée, un nouveau terme de thésaurus pourra être créé au sein du logiciel, avec l'accord de l'utilisateur.

La segmentation temporelle ne se suffit pas à elle-même, mais nécessite une description du contenu des segments, afin d'en rétablir la qualité de séquences, unité audiovisuelle à la fois syntaxique et sémiotique. L'approche retenue afin de décrire automatiquement le contenu de ces segments est celle de l'implémentation du modèle YOLOv8, dont le temps de calcul et de prédiction est réduit par son application aux images-clés produites par la segmentation. L'efficacité du processus repose sur la supervision et la validation humaine, côté technique, des prédictions produites par le modèle, en accord avec les règles métier du logiciel. Toutefois, l'indexation définitive au sein du logiciel doit être validée par l'utilisateur métier via une interface dédiée, et au sein du modèle de données FRBR.

3. Comment indexer les données automatiquement produites ? : interface d'indexation

- Processus côté interface

L'objet de notre étude est le reversement des données produites par l'indexation automatique au sein du modèle FRBR, adapté aux archives audiovisuelles. Si les outils d'extraction automatique tels que YOLOv8, nécessitent un réentraînement spécifique au corpus étudié, une seconde difficulté s'impose, celle de l'alignement de ces données avec un modèle de données personnalisé. Le modèle de données FRBR est, en effet, configuré selon les besoins métier de chaque institution et conditionne l'organisation des données pour l'utilisateur au sein de l'interface. Dès lors, comment reverser des données produites automatiquement, au sein d'un modèle de données configurable ? Ce reversement concrétise en effet l'indexation automatique, puisque les données deviennent visibles et requêtables par les utilisateurs, au sein de l'interface du logiciel.

a. Reversement des données au sein du FRBR

FRBRisation des données générées par IA

Une fois les deux processus de segmentation et de détection d'objets finalisés, deux types de données sont produits : les time codes, chiffrés, et les mots-clés, textuels et sémantiques. L'enjeu est de structurer ces données au sein du modèle FRBR existant.

Création d'une nouvelle entité : Les outils automatiques utilisés lors du processus ont extrait des données depuis un média, associé au niveau de l'item numérique au sein du modèle de données préexistant. Or, le niveau item contient des éléments de description matérielle techniques, alors que les mots-clés et repères temporels relèvent d'une description intellectuelle et syntaxique. Dès lors, la création d'une entité intellectuelle dédiée à la séquence s'impose. Afin d'illustrer l'intégration d'une entité de description intermédiaire, entre l'oeuvre et l'item numérique, prenons l'exemple de la plateforme Okapi (Open and Knowledge-based Annotation and Publishing Interface), développée par le département Recherche et Innovation de l'INA⁸⁸. Afin de favoriser la description collaborative de contenus multimédias, la plateforme offre la possibilité aux utilisateurs de concevoir des modèles de description personnalisés⁸⁹. La plateforme permet notamment de séparer l'extrait audiovisuel du média, dont il constitue un niveau descriptif propre. Une strate supplémentaire de description est ainsi dédiée à la description intellectuelle du média. Le modèle FRBR tel que nous l'avons décrit ne propose, a priori, pas d'entité descriptive dédiée à la séquence. L'entité "d'agrégats", proposée par le manuel de la FIAF pourrait y correspondre. Toutefois, ceux-ci "sont conçus et créés dès le début pour rassembler plusieurs composantes individuelles formant un tout."⁹⁰. Or, au sein du corpus étudié, les rushes ne font pas partie d'un montage. Toute segmentation est une interprétation a posteriori de la construction de l'archive, et donc un remontage. L'entité de "fragment d'expression" proposé par l'IFLA au sein du modèle FRBR bibliographique semble plus adéquate⁹¹. L'International Federation of Library Associations and Institutions (IFLA) définit le fragment comme "des parties d'expressions qui ne constituent pas elles-mêmes des expressions autonomes.[...] Un « Fragment d'expression » n'est identifié qu'en fonction de son occurrence au sein d'un tout connu ou supposé."⁹². Cette entité semble correspondre à la notion de séquences telle que nous l'avons décrite. Elle serait rattachée

⁸⁸Steffen Lalande, Abdelkrim Beloued et Odile Farge, « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco-MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.

⁸⁹*Ibid.*

⁹⁰FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

⁹¹[iflstandards.info](https://www.iflstandards.info), *Frbrroo*, mars 2026, URL : <https://www.iflstandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).

⁹²*Ibid.*

à l’Oeuvre, conformément à l’adaptation du FRBR par les recommandations de la FIAF, et permettrait le reversement spécifique des times-codes et mots-clés. La figure 3 ci-dessous illustre l’intégration de l’entité du fragment d’oeuvre au modèle de données existant.




FIG. 3 : Intégration du Fragment au modèle de données

Au sein de la plateforme Okapi, la création d’une entité intermédiaire de description, permet aux données descriptives produites à partir du média, d’être reversées au sein d’un niveau parent essentiellement descriptif, celui de l’extrait. Au sein du modèle de données existant, adapté au corpus étudié, les time codes et les mots-clés sont déjà indexés manuellement en tant que données au sein de l’application. En effet, les times codes sont renseignés au niveau de l’item numérique, dans un champ notes, et l’item comporte le champ type renseigné par la valeur “fichier time codé”, afin de signifier sa qualité d’extrait. De plus, les mots-clés sont renseignés au niveau de l’indexation de l’oeuvre, donc du rush original. La modélisation de la segmentation au sein du modèle actuel implique un nombre conséquent de relations entre les éléments, complexifiant ainsi la navigation de l’utilisateur. En effet, une notice d’item physique renseigne tous les extraits numériques (items numériques) qui lui sont liés. L’item numérique (segment) renseigne le film physique duquel il est extrait, tandis que le niveau oeuvre renseigne uniquement les extraits numériques qui lui sont associés. La création d’une nouvelle entité simplifierait la navigation au sein de l’interface et permettrait de séparer la description en différents niveaux, intellectuel et technique, conformément aux principes du FRBR. La nouvelle entité de fragments permettrait éventuellement de préciser un contexte de segmentation et des champs dédiés aux mots clés et aux time codes. Le tableau 2 ci-dessous illustre la répartition de la description entre le fragment d’Oeuvre et l’item

numérique. Pour des raisons de clarté, d'autres données descriptives ont été intégrées afin d'illustrer la répartition entre la description intellectuelle et matérielle.

Entité FRBR	Champ / Attribut	Exemples de valeurs
Fragment d'Oeuvre <i>(Description intellectuelle)</i>	Contexte	Segmentation automatique de tel item physique
	Description générale	Description du contenu sémantique de la séquence
	Processus de segmentation	Automatique (Outil utilisé et paramètres appliqués)
	Time codes	Time codes de début et de fin de la séquence
	Mots-clés	Mots-clés extraits par YOLO
	Image-clé associée	Lien direct vers le fichier de l'image-clé
	Oeuvre parente	Identifiant de l'oeuvre associée, lien direct vers la notice
	Item physique associé	Identifiant de l'item physique associé dont est tirée la séquence, lien direct vers la notice
	Item numérique associé	Identifiant de l'item numérique associé, lien direct vers la notice
Item Numérique <i>(Description technique et matérielle)</i>	Fragment associé	Identifiant du fragment associé, lien direct vers la notice
	Données techniques	Résolution de l'image, taille, format
	Données de conservation	Emplacement, contenant
	Média associé	fichier média de la séquence

TAB. 2 : Attributs et exemples de valeurs associées aux entités Fragment d'Expression et Item Numérique.

Les métadonnées automatiquement produites seraient intégrées au niveau du fragment, tandis que l'item numérique contiendrait le média et les données techniques. Une difficulté subsiste toutefois. En effet, les processus s'exécutent au niveau du fichier numérique et de son média, tandis que les métadonnées produites doivent pouvoir enrichir un niveau descriptif supérieur, celui du fragment. Deux configurations peuvent être envisagées afin d'opérer ce reversement automatiquement. D'une part, l'application gère actuellement l'héritage des données d'un niveau supérieur à un niveau inférieur via la configuration de méta-masques, qui ciblent les niveaux inférieurs au sein desquels reverser les données. Néanmoins, le processus automatisé décrit impliquerait la configuration de masques ascendants, permettant de reverser des métadonnées générées au niveau de l'item, vers l'entité de fragment. Cette configuration

complexifie toutefois la compréhension du modèle de données. D'autre part, pourrait être envisagé la mise en place d'un tableau de correspondance ou d'un script permettant d'associer les sorties de données du processus aux entités dans lesquelles elles doivent être injectées.

b. Interface de validation pour l'utilisateur

Deux axes : visualisation et validation (intégrer à ces deux axes la transparence sur le processus : données de gestion)

Processus d'interface avec ce nouveau schéma de données

(Proposer un diagramme de décision pour exposer le processus interface utilisateur)

Le changement au niveau du modèle FRBR s'effectue en backend de l'application, par les équipes techniques et les équipes métiers afin de préparer l'application à l'implémentation de processus automatiques. Toutefois, comment le processus automatique de segmentation puis d'indexation est-il représenté au sein de l'interface, pour l'utilisateur ?

D'abord théorie, puis mise en application dans l'exemple de l'application. D'abord lire ce que j'ai écrit en citations.

Nous pouvons imaginer le processus suivant en frontend, dans l'interface visible de l'application pour l'utilisateur. L'utilisateur procède à l'ingest d'un fichier numérisé d'une œuvre/rushe dans sa globalité. L'ingest d'un fichier numérique vidéo devrait pouvoir déclencher la proposition suivante pour l'utilisateur : Souhaitez-vous segmenter automatiquement ce fichier ? Une infobulle devrait indiquer à l'utilisateur ce qu'implique cette segmentation automatique, le processus expliqué en quelques phrases. En effet, au début de l'implémentation du processus et pour tout nouvel utilisateur confronté à cette nouvelle fonctionnalités automatiques, il est recommandé d'être "familiarisé" au "fonctionnement et limites" de ces outils, comme par exemple "la manière dont sont produites les sorties, les éventuels transferts de données, ainsi que les usages autorisés et les usages interdits."⁹³ Ces informations pourront notamment aider l'utilisateur à pouvoir valider, par la suite, les données produites par les pipelines automatisés. Skinsoft prévoit par exemple déjà des modes d'emploi à l'attention des utilisateurs lors de la livraison de nouvelles fonctionnalités. Toutefois, les informations relatives au processus devront être intégrées à l'interface et au processus, pour des soucis de transparence et de création conforme des données. Ainsi, "l'intégration de briques d'IA générative dans un système d'information (SI) devrait être pensée avec des éléments de design informant clairement les utilisateurs de l'origine de la proposition, leur rappelant qu'il leur revient de ne pas prendre « telle quelle » la proposition. Par exemple, le système peut

⁹³ *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).

proposer pour chaque question au moins deux réponses, ce qui permet à l'opérateur humain de sélectionner les éléments pertinents de chaque réponse pour consolider la sienne.”⁹⁴ Au lieu de proposer deux réponses, ce qui surchargerait l'interface, et de plus, ce n'est pas adapté ici puisque le processus de segmentation n'utilise pas d'intelligence artificielle capable de raisonner. Nous pourrions proposer, si l'utilisateur ne valide pas les données produites, la possibilité de "permettre CROCHETS un point de contact pour remonter des problèmes ou des difficultés d'ordre éthique”⁹⁵. L'interface devra ainsi prévoir un formulaire décrivant la raison du refus des données, envoyé à l'équipe technique afin que le processus puisse être amélioré au niveau de ses paramètres. Ainsi, dans les premiers mois de sa mise en place, l'implémentation pourra faire l'objet d'essais erreurs auprès des utilisateurs afin de pouvoir être perfectionné. Selon les recommandations du livre blanc : "lors des premiers mois et années de l'utilisation des IA, il est recommandé de recueillir régulièrement l'avis des utilisateurs finaux sur l'utilité et les limites du système”⁹⁶

En effet, il faudra également lui indiquer les actions qu'il va devoir effectuer au cours du processus. En effet, il devra être demandé à l'utilisateur de valider ou non, les données produites.

La validation est utile à la responsabilisation des utilisateurs pour l'usage des outils d'automatisation en les "incitant à vérifier les données fournies en entrée et la qualité des sorties ”⁹⁷ Les outils d'automatisation doivent être des facilitateurs sans rendre l'indexation trop automatique et facile. L'interface doit prévoir ces étapes de validation de manière simple pour l'utilisateur.⁹⁸

Les données de gestion sur la production de ces données doivent être automatiquement enregistrées par l'application : quel est l'outil utilisé, le processus effectué, qui a validé, quand... L'application prévoit déjà un enregistrement des données de gestion et de l'historique des modifications automatique sur les notices via un menu spécifique. Un nouveau menu pourrait être créé pour les données de gestion automatiques des notices.

Une fois que le fichier numérique a été segmenté, l'interface doit pouvoir présenter à l'utilisateur les times codes choisis avec l'image clé associée pour que l'utilisateur puisse visualiser les coupures qui ont été sélectionnées en accord avec les différences entre les images. Si l'utilisateur valide la segmentation, l'interface indexe les time codes sur le fichier numérique associé automatiquement dans le champ dédié, propose la génération de mots clés sur les segments générés : l'utilisateur pourra alors choisir s'il veut appliquer la génération de mots

⁹⁴ *Ibid.*

⁹⁵ *Ibid.*

⁹⁶ *Ibid.*

⁹⁷ *Ibid.*

⁹⁸ **zotero-item-632.**

clés sur tous les segments ou seulement des segments spécifiques sous la forme d’une sélection. Une fois le processus de génération de mots clés terminé, l’interface propose à l’utilisateur de valider les mots clés en accord avec les images clés analysées.

Si l’utilisateur ne valide pas les segments, ou n’en valide qu’une partie : il sera important d’intégrer à l’interface un formulaire d’erreurs qui explique les raisons du refus, afin de perfectionner l’algorithme de détection de segmentations. Même chose pour les mots clés. Pour les mots clés, l’interface peut proposer à l’utilisateur de modifier manuellement les mots clés pour les indexer mais aussi m-pour les renvoyer au modèle et alimenter le jeu de données sur lequel il s’entraîne.

À l’INA, les chercheurs ont développé Amalia.Js, un lecteur HTML5 extensible qui synchronise des métadonnées avec la lecture de flux vidéo ou audio, au départ conçu pour visualiser les résultats d’algorithmes d’analyse audiovisuelle. Le besoin à l’origine d’Amalia.js est donc de permettre de visualiser les résultats de pipelines d’automatisation, avec leur lot de métadonnées produites⁹⁹ Ce besoin s’explique la production de résultats et de données de différentes natures qui nécessitent d’être présentés à l’utilisateur.¹⁰⁰ L’indexation automatique regroupe tout un tas de métadonnées issues d’algorithmes et d’outils différents qu’il faut réunir dans une interface de présentation. Ainsi, à l’inverse de la visualisation des résultats que nous avons proposée en deux étapes, conformément aux deux processus différents, Amalia.js propose une visionneuse multimédia qui présente l’ensemble des résultats. Cette interface permettrait également de vérifier la conformité des données produites aux standards métiers en vigueur au sein du logiciel : « Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »¹⁰¹. Par la même occasion, l’interface permet également d’annoter la vidéo et de corriger manuellement les données produites directement sur le fichier vidéo. Le logiciel permet à l’utilisateur d’annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »¹⁰². La correction humaine permet d’avoir des métadonnées plus justes, mais permet aussi d’avoir des données d’entraînement pour améliorer les algorithmes d’indexation automatique. (aussi vu chez Vanderbilt). Utilisateur comme rôle de correction et d’enrichissement sur une base générée automatiquement.

⁹⁹Nicolas Hervé, Pierre Letessier, Mathieu Derval et Hakim Nabi, « Amalia.Js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

¹⁰⁰*Ibid.*

¹⁰¹*Ibid.*

¹⁰²*Ibid.*

Le plugin timeline proposé par Amalia.js est particulièrement intéressant pour notre étude puisqu'il permet d'afficher les métadonnées horodatées sur l'image.¹⁰³ (cf capture d'écran word) Le plugin permet de visualiser les segments temporels et les images clés en lien avec ces segments.

Par ailleurs, le plugin de superposition permet d'encadrer les objets détectés dans l'image par les algorithmes. Nous pouvons imaginer, au lieu de développer deux plugins différents, de développer le premier plugin temporel, afin d'afficher les objets détectés par yolo sur les images clés, et d'ouvrir une fenêtre latérale avec les mots clés proposés. Un mode d'édition pourrait permettre alors à l'utilisateur de modifier les mots clés si les résultats ne sont pas satisfaisants. À la modification de l'utilisateur, l'application détecte la modification et la renvoie à l'équipe technique pour réentraîner le modèle sur les données corrigées.

Exemple d'écran scindé pour le plugin d'édition, qui serait dans le cas de notre étude, intégré au plugin temporel pour accepter la proposition de mots clés : (cf capture)

Exemple de la plateforme okapi :

“Okapi fournit un ensemble d'outils destiné à l'analyse sémantique et sémiotique de contenus multimédia (vidéo, image, son) et à la gestion de corpus de vidéos, d'extraits sonores et de parties d'images. Les outils d'analyse permettent l'indexation et la description sémantique de contenu sur la base d'ontologies qui décrivent les objets et classes des domaines étudiés. Les outils de gestion de corpus fournissent des services pour la constitution, la visualisation, l'enrichissement et la valorisation de corpus thématiques.”¹⁰⁴ (cf capture d'écran)

Prévoir une file d'attente et une barre de chargement de traitement : tableau de bord skinsoft

c. Rendre les données recherchables et découvrables

Une fois les données validées et indexées au sein du modèle de données, elles peuvent être exploitées au sein du logiciel comme n'importe quelle autre donnée documentaire, et peuvent notamment être requêtables. La création d'une potentielle nouvelle entité, la séquence, modifie le rapport de l'utilisateur aux objets documentés au sein du logiciel. L'utilisateur peut désormais accéder non plus seulement aux archives audiovisuelles dans leur entièreté mais à leurs segments. L'indexation de segments d'archives audiovisuelles ne produirait ainsi non plus seulement une simple indexation mais une “indexation fine” du contenu, selon Bachimont

¹⁰³Amalia.js - Metadata Enriched HTML5 Video Player, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).

¹⁰⁴S. Lalande, A. Beloued et O. Farge, « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles... ».

(2007).¹⁰⁵

Ainsi, une recherche par mots-clés dans notre cas permet à l'utilisateur d'accéder directement aux segments d'archives concernés par ce mot-clé. Cela permet notamment à l'utilisateur d'accéder à des éléments plus précis en accord avec la requête effectuée au lieu d'accéder à des archives audiovisuelles entières qu'il faudrait visionner. Mais encore faut-il que les segments sélectionnés soient compatibles avec Ainsi, une recherche par mots-clés dans notre cas permet à l'utilisateur d'accéder directement aux segments d'archives concernés par ce mot-clé. Cela permet notamment à l'utilisateur d'accéder à des éléments plus précis en accord avec la requête effectuée au lieu d'accéder à des archives audiovisuelles entières qu'il faudrait visionner. Mais encore faut-il que les segments sélectionnés soient compatibles avec les besoins utilisateurs. Les nouveaux segments créés pourront ainsi être intégrés aux différents modes de recherche et de filtrage proposés par le logiciel de gestion des collections. Par exemple, l'application de skinsoft propose une recherche simple, une recherche avancée, une recherche plein texte ciblée, une recherche par image. Une recherche en langage naturel, s'appuyant sur la technologie du NLP est également en cours de développement, dans laquelle la recherche des segments pourra s'intégrer. L'utilisateur pourrait ainsi formuler une description de ce qu'il recherche, en langage naturel, et obtenir des résultats visuels pertinents. La recherche par image pourra également être davantage employée dans le cadre de la description des segments. Les résultats de recherche pourront présenter en vignette, l'image clé associée au segment décrit, sur laquelle l'utilisateur peut cliquer. Il accède à la fiche de description intellectuelle de la séquence comprenant les mots clés et les time codes correspondants. Le fichier numérique correspondant à la séquence est associé sous la forme d'item lié dans une grille de recherche. Le risque, énoncé par Bachimont, est le suivant : "les segments peuvent se désolidariser du contenu dont ils sont issus, perdant ainsi leur origine et nature documentaires."¹⁰⁶. Toutefois, le modèle de données FRBR limite ce risque, dans la mesure où il contraint les liens entre les entités. Les séquences en tant que fichiers numériques, seront ainsi toujours reliées à une notice de séquence descriptive intellectuelle, elle-même rattachée au niveau le plus haut, l'œuvre. L'un des besoins utilisateur fondateur du modèle de données FRBR est précisément celui de la recherche, de pouvoir identifier des ressources précises. (Retrouver le besoin utilisateur) La création d'une nouvelle entité au sein du modèle de données permettrait d'éviter ce risque d'isolement de segments de son oeuvre originale. Les données produites automatiquement peuvent alimenter d'autres modes de recherche innovants telle que la recherche visuelle par l'exemple et l'apprentissage interactif (cf Snoop). Ces nouveaux modes de recherche permettent également aux systèmes d'IA d'apprendre grâce aux retours

¹⁰⁵B. Bachimont, *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).

¹⁰⁶*Ibid.*

utilisateurs : faire le lien avec ce qui est développé par skinsoft : RAG, LLM, NLP...

Snoop v6 : moteur visuel de recherche, d'apprentissage et de prédiction à très large échelle. Cette technologie permet à un utilisateur de formuler une requête par l'exemple (un morceau d'image représentant un logo, tableau, monument, ...) à retrouver dans des fonds d'images et de vidéos de grande taille. De plus, à partir d'une base connaissances (ensemble de classes, comme dans le cas de Pl@ntNet). Snoop a aussi des fonctionnalités d'apprentissage de réseaux profonds et de prédiction. Nos forces :

Images et vidéos : Snoop peut gérer un corpus comportant à la fois des images et des vidéos ce qui permet de construire des liens visuels entre ces 2 types de contenus.

L'interactivité à très large échelle, peu coûteuse en CPU et mémoire.

Prédiction à large échelle avec des centaines de milliers d'utilisateurs par jour sur un seul serveur¹⁰⁷

L'un des composants technologiques de Snoop est le bouclage de pertinence, permettant de créer des modèles d'entités visuelles personnalisés. Le schéma ci-dessous résume ce processus dans lequel Snoop est sollicité par une première recherche avec quelques images choisies par l'utilisateur et représentant sa requête. Quelques contenus visuels similaires retrouvés par Snoop sont ensuite marqués par l'utilisateur, soit positivement (ceux qui correspondent à sa recherche), soit négativement (des contre-exemples). Puis Snoop utilise ces informations pour créer un modèle des connaissances transmises par l'utilisateur. Tant que ce dernier n'est pas satisfait, l'IA propose à nouveau des résultats pouvant être annotés. (source : Snoop, un moteur de recherche visuelle interactif A. Joly, J-C. Lombardo, J-P. Moreux, Q. Leroy et O. Buisson Culture et Recherche (141), 2020 (lien)

Ce que produit l'indexation des segments : “Alors que selon l'indexation traditionnelle, l'enjeu est de retrouver le ou les documents contenant l'information recherchée, l'indexation fine du contenu permet de ne retrouver que les segments concernés par la recherche d'information et de paramétrer l'usage de ces segments. Si le document demeure présent dans les résultats de la recherche dans une indexation et recherche traditionnelles, il n'en est pas de même dans une recherche profitant de l'indexation fine du contenu, dans la mesure où les segments peuvent se désolidariser du contenu dont ils sont issus, perdant ainsi leur origine et nature documentaires. Devenant des ressources, ces segments sont remobilisés pour la production d'autres contenus dont ils constituent les composants” B. Bachimont, 2007¹⁰⁸

Une fois produites, les données doivent être indexées afin d'être requêtables au sein de l'application. : juste sous sous partie indexation des données d'un pdv technique pour qu'elles soient requêtables comme d'autres données.

¹⁰⁷ *Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).

¹⁰⁸ Id., *Ingénierie des connaissances et des contenus...*

”Si l’utilisation envisagée consiste à fournir des données personnelles (données des clients ou des collaborateurs) ou de la documentation sensible ou stratégique (par exemple pour le RAG), il semble généralement plus opportun et plus sécurisé de privilégier le déploiement de solutions « sur site » (on premise) qui présentent l’avantage de limiter les risques d’extraction de données auprès d’un tiers”¹⁰⁹ ”s’il est envisagé d’utiliser un système sous forme d’API, il faut souligner que la maîtrise du système est alors quasi exclusivement dans les mains du fournisseur. Il convient donc d’être particulièrement vigilant sur les données soumises au système d’IA”¹¹⁰

Le besoin à l’origine d’Amalia.js est de permettre de visualiser les résultats de pipelines d’automatisation, avec leur lot de métadonnées produites : « Whatever the field of analysis, we always need to be able to quickly and easily view the results of the methods we are developing. This problem is particularly true as we often manipulate large amount of videos. Developing visualization and annotation tools is often a tedious task that deserves to be pooled. »¹¹¹ « The analysis being at different levels (keyframes, video segments, audio channels, associated synopses, one video alone or relative to a corpus...) results are obtained in very different natures, often needing quite specific approaches to be presented to the end user. »¹¹² L’indexation automatique regroupe tout un tas de métadonnées issues d’algorithmes et d’outils différents qu’il faut réunir dans une interface de présentation.

C’est une interface pour visualiser et pour corriger.

Comment regrouper dans la même interface des métadonnées de nature très différentes attachées à la même vidéo ?

Les métadonnées horodatées : issues de la segmentation vidéo.

« The main principle of amalia.js is to have a unified metadata model. Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »¹¹³. Importance d’avoir une interface de standardisation des métadonnées : important pour skinsoft qui doit s’adapter aux normes employées par les clients.

Le logiciel permet à l’utilisateur d’annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »¹¹⁴. La correction humaine permet d’avoir des métadonnées plus

¹⁰⁹ *Les questions-réponses de la CNIL sur l’utilisation d’un système d’IA générative...*

¹¹⁰ *Ibid.*

¹¹¹ N. Hervé, P. Letessier, M. Derval, *et al.*, « Amalia.Js... ».

¹¹² *Ibid.*

¹¹³ *Ibid.*

¹¹⁴ *Ibid.*

justes, mais permet aussi d'avoir des données d'entraînement pour améliorer les algorithmes d'indexation automatique. (aussi vu chez Vanderbilt). Utilistauer comme rôle de correction et d'enrichissement sur une base générée automatiquement.

SOUS PARTIE 3 :

"A major challenge for making AVP tools available is that the underlying algorithms need direct access to the data, yet due to strict IPR regulation this data often cannot leave the archives' digital environment. A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms."¹¹⁵. Solution : projet CLARIAH

"Moreover, DANE is designed to be able to function in environments where there are fewer compute resources, or environments where access to the data is rate limited, as is typical for AV archives. To make this possible, the DANE architecture (as shown in Figure 2) divides the tasks to be performed over different workers that perform one specific type of analysis, where the work is assigned to a worker by means of message broker queuing system. The results of the analyses are communicated back to the server by the workers, and made available via an API to clients (e.g., other services or individual users)."¹¹⁶ (+ schéma qui montre l'architecture)

"To enrich the AV collections in the Media Suite with automatically generated (and time-coded) metadata an assortment of AVP tools had been added to DANE, ranging from Semantic Object Detection, to colour analysis, to Automatic Speech Recognition."¹¹⁷

"These tools generate two types of metadata : (i) structured data which can be integrated into the existing metadata systems, and (ii) feature vectors which describe the data on a more abstract level, but which can be integrated in new types of interfaces and search systems. For instance, with an Object Recognition model it is possible to recognise which objects are present in an image, but the output of such a model can also be used to perform more abstract visual similarity queries"¹¹⁸

exemple d'indexation automatique à la bibliothèque nationale de finlande "L'API « suggest » est au cœur de ce web service : en fournissant un document textuel en entrée, on obtient en sortie une liste (au format JSON) de suggestions de concepts pour l'indexer ainsi que l'appréciation quantifiée de leur niveau de pertinence. Autre fonctionnalité importante, « learn »

¹¹⁵N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

¹¹⁶*Ibid.*

¹¹⁷*Ibid.*

¹¹⁸*Ibid.*

est capable de mettre à jour les programmes en exploitant des correspondances vérifiées entre des documents décrits et les mots sujets choisis.”¹¹⁹ss

¹¹⁹Osma Suominen, « Annif, l’indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.

Troisième partie

partie 3

Conclusion

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

Annexe A

Le titre très long de la première
annexe

Glossaire

apprentissage machine . 36, 37, 55

apprentissage profond . 37, 55

Archives audiovisuelles . 7, 55

Audiovisual Processing . 35, 55

CNN Architecture de réseau de neurones artificiels spécialement adaptée au traitement et à l'analyse d'images numériques.. 37, 38, 55

Expression . 55

FIAF Fédération Internationale des archives du film. Organisation regroupant les cinémathèques et édité le manuel de catalogage audiovisuel fondé sur le modèle FRBR.. 55

FRBR Functional Requirements for Bibliographic Records. Modèle conceptuel entité-association développé par l'IFLA.. 3–7, 55, 61

Item . 55

Manifestation . 55

Oeuvre . 55

rush Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant le matériau source d'un film.. 55

réseaux de neurones profonds . 37, 55

transformers . 37, 38, 55

vision par ordinateur . 36, 37, 55

Liste des abréviations

CIDOC-CRM object-oriented Conceptual Reference Model. 6, 55

FRAD Fonctionnalités requises des données d'autorité. 6, 55

FRBRoo long. 6, 7, 55

FRSAD Fonctionnalités requises des données d'autorité matière. 55

IFLA International Federation of Library Associations and Institutions. 3, 55

IFLA-LRM long. 6, 55

WVMI Work, Variant, Manifestation, Item.. 55

Liste des tableaux

1	Comparatif des approches de traitement audiovisuel automatique	10
2	Attributs et exemples de valeurs associées aux entités Fragment d'Expression et Item Numérique.	27

Table des figures

1	Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect	13
2	Mise en application de Pyscenedetect	16
3	Intégration du Fragment au modèle de données	26

Table des matières

Résumé	i
Remerciements	iii
Introduction	xix
I Indexer les archives audiovisuelles	1
II Implémenter l’indexation automatique des archives audiovisuelles au sein d’une remodelisation du FRBR	3
1. Traitement audiovisuel	5
a. Machine learning et deep learning	5
b. Outils et modèles disponibles	10
c. Mise en application	14
2. Description et indexation automatique	17
a. Outils utilisés	18
b. Entraînement	20
c. Processus de validation technique	22
3. Comment indexer les données automatiquement produites ? : interface d’indexation	24
a. Reversement des données au sein du FRBR	25
b. Interface de validation pour l’utilisateur	28
c. Rendre les données recherchables et découvrables	31
III partie 3	37
Conclusion	39

A Titre court	43
Glossaire	47
Liste des abréviations	49