

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès cinéma

diplômé.e de master

Segmentation et indexation automatiques des archives audiovisuelles

**L'enjeu du modèle de données au sein d'un
logiciel de gestion des collections - le cas
S-Movies chez Skinsoft**

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Ce mémoire a été réalisé dans le cadre du Master Technologies numériques appliquées à l'histoire de l'École nationale des chartes. Il est rédigé dans le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, editrice de solutions logicielles pour la gestion des collections et il est dédié au projet d'implémentation de l'intelligence artificielle, spécifiquement pour l'indexation des archives audiovisuelles. Ce mémoire expose la proposition d'un processus de segmentation et d'indexation des archives audiovisuelles en lien avec le modèle de données qui structure l'interface d'un logiciel de gestion des collections.

Mots-clés : Archives audiovisuelles ; gestion des collections ; modélisation de données ; intelligence artificielle ; segmentation temporelle ; indexation automatique ; interface ; vision par ordinateur ; *YOLO* ; *Pyscenedetect* ; FRBR.

Informations bibliographiques : Clotilde Long, *Segmentation et indexation automatiques des archives audiovisuelles. L'enjeu du modèle de données au sein d'un logiciel de gestion des collections*, mémoire de master « Technologies numériques appliquées à l'histoire », dir. Maxime Challon, École nationale des chartes, 2026.

Remerciements

MES remerciements vont tout d’abord à mon directeur de recherche, Maxime Challon, pour ses précieux conseils tout au long de l’écriture du mémoire.

Je tiens également à remercier l’ensemble de l’équipe métier chez Skinsoft pour sa bienveillance, qui a permis à mon stage d’être riche d’apprentissages.

Je remercie également ma famille et mes amies, Anouck, Zoé et Ambre pour leur soutien lors de la rédaction, et tout particulièrement Florence et Xavier pour leurs relectures.

Bibliographie

- AKATA (Zeynep), BALLIET (Dan), DE RIJKE (Maarten), DIGNUM (Frank), DIGNUM (Virginia), EIBEN (Guszt), FOKKENS (Antske), GROSSI (Davide), HINDRIKS (Koen), HOOS (Holger), *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53–8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587.
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), « Bibliothèques Numériques Audiovisuelles : Des Enjeux Scientifiques et Techniques », *Document Numérique*, 2 (1998), p. 219-242.
- *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).
- *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BENJAMIN (Walter), *L'oeuvre d'art à l'époque de sa reproductibilité technique*, 1935.
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BIBLIOTHÈQUE KANDINSKY, *Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).

- BNF, *Modèles FRBR, FRAD et FRSAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/authorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters, Video-Based Object and Event Analysis 30-2* (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARRIVE (Jean), « Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », dans *Big data : Information et stratégie*, 2014, p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CIDOC CRM, *LRMoo Home / CIDOC CRM*, URL : <https://cidoc-crm.org/lrmoo> (visité le 04/09/2026).
- CNIL, *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).
- COLAVIZZA (Giovanni) et JAILLANT (Lise), « AI Ready : How to Prepare Archives for Artificial Intelligence, Improve Discoverability, and Enhance Access », *Archives and Records*, 0-0 (juin 2026), p. 1-22, DOI : 10.1080/23257962.2026.2675937.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).
- DEVELOPMENT (SO), *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).

- EDMONSON, RAY, *Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).
- FIAF, *Le manuel de catalogage des images animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FRANCEARCHIVES, *Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://api.semanticscholar.org/CorpusID:58358915> (visité le 08/07/2026).
- HERVÉ (Nicolas), LETESSIER (Pierre), DERVAL (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- IBM, *Qu'est-ce que la modélisation de données ?*, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- *Qu'est-Ce Qu'Elasticsearch ?*, URL : <https://www.ibm.com/fr-fr/think/topics/elasticsearch> (visité le 05/09/2026).
- *Qu'est-Ce Que Le Machine Learning (ML) ?*, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- *Statement on FRBRoo / CIDOC CRM*, URL : <https://cidoc-crm.org/Resources/statement-on-frbroo> (visité le 04/09/2026).
- IFLA, *FRBRoo as IFLA Standard*, URL : <https://www.ifla.org/news/frbroo-as-ifla-standard/> (visité le 04/09/2026).
- *Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters*, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- IFLA WORKING GROUP ON FRBR/CRM, « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).

- IFLASTANDARDS.INFO, *Frbrroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbrroo.html> (visité le 03/08/2026).
- INA, *Aide et FAQ Médiascope*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).
- *Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).
- *Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-editor-options.html> (visité le 30/08/2026).
- *Analyse des tendances médias par l'IA - Les traitements téalisés par les outils d'intelligence artificielle utilisés sur Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).
- *Projet Dataset*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).
- *Projet Snoop*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).
- INSTITUT AUDIOVISUEL DE MONACO, *L'Aigle à deux têtes*, URL : <https://institut-audiovisuel.mc/evenement/laigle-deux-tete/> (visité le 04/09/2026).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOLY (A.), LOMBARDO (J-C), MOREUX (J-P), LEROY (Q) et BUISSON (O), « Snoop, Un Moteur de Recherche Visuelle Interactif », *Culture et Recherche (141)*–141 (2020), p. 14-15.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- KASSEL (Raphael), *L'apprentissage auto-supervisé : Qu'est-ce que c'est ? Comment ça marche ?*, janv. 2026, URL : <https://liora.io/apprentissage-auto-supervise-tout-savoir> (visité le 02/09/2026).
- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.
- LABEL STUDIO, *Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).
- *Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).

- LALANDE (Steffen), BELOUED (Abdelkrim) et FARGE (Odile), « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).
- MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- MINISTÈRE DE L'ÉCONOMIE, *France 2030 : un plan d'investissement pour la France*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- MINISTÈRE DE LA CULTURE, *La stratégie du ministère pour des intelligences artificielles culturelles et responsables*, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- *Dico des musées*, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PYSCENEDETECT, *Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).
- Qu'est-ce qu'une base de données NoSQL ?* / IBM, janv. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/nosql-databases> (visité le 05/09/2026).
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

- RONFARD, RÉMI, *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. 2009, URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SOUND & VISION, *AI in Audiovisual Archives*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Cole), *Qu'est-ce qu'un LLM (Large Language Models) ?* / IBM, févr. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/large-language-models> (visité le 06/09/2026).
- STRYKER (Cole) et BERGMANN (Dave), *Qu'est-ce qu'un modèle transformer ?*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- STRYKER (Cole) et CABALLAR (Rina Diane), *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- TALBI (Ilyes), *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).
- TILLETT, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpso/frbreng.pdf>.
- ULTRALYTICS, *Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- *YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- V7 DARWIN, *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- WISE (Nikki), FENLON (Katrina), MARSH (Diana), SORENSSEN (Amanda), SMOKE (Ugoma), NAVARETTE (Candy) et HAVENS (Lucy), « 'Appears to Be about' : An Evaluation of AI-generated Metadata Quality for Community Archives », *Information Research an international electronic journal*, 31-iConf (mars 2026), p. 417-437, DOI : 10.47989/ir31iConf64144.
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wen-guan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Introduction

La nature audiovisuelle des documents [...] leur confère le statut d'objets temporels. Il se pose alors le problème spécifique à l'audiovisuel de parcours et de navigation dans un objet temporel [...] pour le rendre manipulable dans le cadre d'une exploitation donnée¹.

Dès 1998, le chercheur Bruno Bachimont exprime la manière dont la manipulation des contenus audiovisuels, au sein des pratiques documentaires, est contrainte par leur nature temporelle, fixée sur un support. En effet, les documents audiovisuels comprennent "des images et / ou des sons reproductibles réunis sur un support matériel dont : l'enregistrement, la transmission, la perception et la compréhension exigent le recours à un dispositif technique"². Le support, numérique ou analogique, contraint la consultation du contenu, poussant les institutions patrimoniales à privilégier une "consultation indirecte" via sa description³. De fait, l'appui sur un logiciel de gestion des collections joue un rôle déterminant dans la mise en valeur et l'organisation de la description des fonds audiovisuels, qui, dans un contexte de préservation patrimoniale, sont désignés par le terme d'archives audiovisuelles. Dispositif avant tout technique, un logiciel de gestion des collections permet de gérer les "informations structurées" produites par les tâches d'indexation, conformément à des règles métiers, en fournissant notamment un modèle de données, afin d'organiser la description en couches intelligibles et interreliées⁴.

Or, la structuration de la description au sein d'un tel outil (l'indexation) présuppose justement l'analyse approfondie du contenu audiovisuel comme "objet temporel", via l'étude de sa syntaxe en différents plans et séquences, permettant de concrétiser une "navigation" précise⁵. Cette analyse précise dont les archives audiovisuelles devraient être l'objet, est tou-

¹Bruno Bachimont, « Bibliothèques Numériques Audiovisuelles : Des Enjeux Scientifiques et Techniques », *Document Numérique*, 2 (1998), p. 219-242.

²Edmonson, Ray, *Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).

³B. Bachimont, « Bibliothèques Numériques Audiovisuelles... ».

⁴Ministère de la Culture, *Dico des musées*, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).

⁵B. Bachimont, « Bibliothèques Numériques Audiovisuelles... ».

tefois contrainte par la densification des collections patrimoniales ⁶. Il devient ainsi difficile de traiter l'ensemble des fonds audiovisuels, via leur lecture sur un support, leur analyse fine et la structuration de leur description. Si l'interface logicielle permet de structurer la description produite, il ne permet toutefois pas encore de palier à ces contraintes de temps et de moyens.

Or justement, le développement croissant de l'intelligence artificielle offre des fonctionnalités innovantes afin d'automatiser certaines pratiques documentaires, dont l'indexation. L'automatisation de l'indexation appliquée aux collections audiovisuelles permettrait l'analyse et la description du flux audiovisuel de manière efficace, afin d'y donner largement accès. L'éditeur de gestion des collections, dont la logique commerciale encourage l'innovation, possèderait alors un rôle pivot dans la proposition de fonctionnalités automatiques aux institutions, permettant ainsi d'accélérer et d'améliorer la découvrabilité de collections complexes.

Néanmoins, si certaines tâches classiques d'analyse du contenu de l'image sont démocratisées, y compris en milieu patrimonial, la compréhension fine de la syntaxe audiovisuelle reste encore sous développée, puisqu'elle nécessite a priori des algorithmes lourds et coûteux. C'est notamment le cas de la segmentation du flux audiovisuel en les différentes séquences qui le composent, qui permettrait pourtant une description fine du contenu afin d'établir une "navigation" au sein du document⁷.

Une double complexité se pose ainsi. D'une part, la nécessité de développer une automatisation de l'indexation des documents audiovisuels est contrainte par l'inexploitation d'une compréhension fine de leur syntaxe en différentes séquences, par les algorithmes d'intelligence artificielle existants. D'autre part, l'implémentation de processus automatisés au sein d'un outil de gestion densifie la production de l'information, complexifiant de fait la structuration du modèle de données existant, propre à des normes et règles métier contextuelles.

C'est précisément cette double difficulté qui anime l'étude de ce mémoire de recherche, réalisé dans le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, éditrice de solutions logicielles pour la gestion des collections. Effectué au sein de l'équipe métier, initiatrice de fonctionnalités innovantes adaptées aux besoins du patrimoine, ce stage se porte spécifiquement sur l'amélioration générale d'un espace de travail dédié à la gestion des archives audiovisuelles (S-movies), fondé sur le *Functional Requirements for Bibliographic Records* (FRBR) (*Functionnal requirements for bibliographic records*). L'amélioration de cette interface est motivée par le projet d'automatiser certaines tâches d'indexation à l'aide de l'intelligence artificielle. Ces tâches, issues d'une demande client spécifique, comprennent la segmentation automatique de contenus audiovisuels en séquences, puis leur indexation. Les réflexions et ob-

⁶Cette densification est produite par la nature même du document audiovisuel, dont la reproductibilité technique permet la copie multiple à l'identique des exemplaires.

⁷*Ibid.*

servations, à la fois techniques et métier, qui ont traversé notre stage, constituent le point de départ de ce mémoire, qui examine les conditions de faisabilité et les modalités d'intégration d'une indexation automatique appliquée à l'audiovisuel au sein d'une modélisation adaptative du FRBR. Si le projet n'a pas été développé en cours de stage, notre étude examine toutefois les implications et les enjeux soulevés par la mise en place d'une automatisation de l'indexation des collections audiovisuelles, en accord avec les besoins métier existants.

Dès lors, dans quelle mesure la variabilité du modèle de données FRBR, adapté aux spécificités des archives audiovisuelles, conditionne-t-elle la mise en place d'une segmentation et d'une indexation automatiques pour ce type d'archives ? Les outils existants permettent-ils l'automatisation de tâches documentaires dédiées à de telles collections ? Quelle est la direction adoptée par un éditeur de gestion des collections afin de concilier pratiques documentaires appliquées à des corpus spécifiques, et une éthique d'usage au sein d'un même processus ?

Dans une première partie, nous analyserons les fondements du modèle de données FRBR tel qu'il a été pensé pour le milieu des bibliothèques, avant de nous pencher sur les modalités de son adaptation aux archives audiovisuelles. Nous prendrons pour exemple l'espace de travail S-Movies, développé par Skinsoft, à travers l'étude d'un corpus audiovisuel spécifique. La présentation contextuelle du modèle de données nous amènera à examiner les complexités documentaires posées par le projet de la mise en place d'une segmentation et d'une indexation automatiques des documents audiovisuels.

Dans une seconde partie nous nous focaliserons d'une part sur les technologies existantes pour l'automatisation du traitement audiovisuel, avant de nous pencher sur les outils disponibles pour la segmentation automatique du flux audiovisuel en séquences. Nous proposerons une mise en application de la segmentation à travers l'outil *Pyscenedetect*, en mettant à l'épreuve le corpus audiovisuel présenté en première partie. D'autre part, à partir du même corpus, nous proposerons la description des segments produits par mots-clés, à l'aide du modèle *You only look once* (*YOLO*), dont nous examinerons les modalités d'entraînement et de validation. Nous nous pencherons finalement sur l'indexation des données produites automatiquement au sein du modèle de données FRBR, à travers une validation utilisateur, afin d'améliorer la découvrabilité des documents.

Dans une troisième partie, nous examinerons la manière dont le concept d'Intelligence hybride offre des perspectives pour la mise en place d'un processus éthique et généralisable. Nous verrons que l'intégration de l'utilisateur à chaque étape du processus permet d'assurer le contrôle de la qualité et de la structure des données produites, à condition que l'interface actuelle subisse des évolutions. Enfin, nous évaluerons la mesure dans laquelle un tel processus pourra être généralisé à d'autres institutions, grâce au concept d'Intelligence hybride, au

regard des besoins existants concernant l'indexation et la segmentation.

Première partie

Modéliser les données audiovisuelles

La modélisation des données constitue le fondement d’une gestion structurée de fonds patrimoniaux. Appliquée aux archives audiovisuelles, la modélisation se heurte toutefois à la nature temporelle de tels objets. Cette partie explore la modélisation théorique des données documentaires, puis son application aux archives audiovisuelles, qui constitue le contexte de toute implémentation de fonctionnalité automatique.

Le premier chapitre examine les fondements théoriques de la modélisation en s’appuyant sur le modèle FRBR. Fondé sur les besoins d’accès des utilisateurs, il offre une structure verticale de nature entité-relation pour les systèmes documentaires bibliographiques, que la Fédération Internationale des archives du film. (FIAF) (Fédération internationale des archives audiovisuelles) adapte aux archives audiovisuelles.

Le second chapitre étudie la mise en œuvre de l’adaptation du FRBR aux archives audiovisuelles au sein de l’architecture logicielle développée par l’éditeur Skinsoft, à travers l’analyse de l’espace de travail S-Movies. Nous évaluerons l’adaptation du modèle aux normes métier documentaires via l’analyse d’un corpus audiovisuel spécifique.

Enfin, le troisième chapitre évoque le projet d’automatisation de l’indexation pensé par Skinsoft. Nous y analyserons la nécessité documentaire de la tâche de segmentation, préalable à l’indexation afin de prévoir l’inscription d’un processus adapté aux besoins.

Chapitre 1

Le FRBR, un modèle de données bibliographiques

Cette partie s’attache à définir en premier lieu le FRBR comme modèle de données conçu pour le milieu des bibliothèques, fondé sur les besoins utilisateurs. Nous examinerons ensuite dans quelle mesure il peut être adapté à d’autres objets de collection au statut composite, et spécifiquement aux archives audiovisuelles, notre objet d’étude. Cette partie contextualise ainsi la modélisation de données propre à la gestion des archives audiovisuelles, afin de préparer son analyse au sein d’un système de gestion des collections.

I. Un modèle conceptuel fondé sur les besoins utilisateurs

1. Une structure entité-relation

La modélisation de données désigne le “processus de création d’une représentation visuelle de l’ensemble d’un système d’information ou de parties de celui-ci pour communiquer les connexions entre les points de données et les structures.”¹. Le modèle de données conditionne ainsi la structure de l’information au sein d’un système de gestion, et permet de modéliser les liens entre les différentes données rattachées à un même document. Le FRBR est un exemple de modèle de données, dont l’objectif principal est de faciliter l’identification des données pour l’utilisateur.

Le FRBR, est un modèle conceptuel de données bibliographiques élaboré par l’*International*

¹IBM, *Qu’est-ce que la modélisation de données ?*, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).

Federation of Library Associations and Institutions (IFLA) de 1992 à 1996². Ce modèle établit la mise en place de quatre niveaux hiérarchiques principaux pour le catalogage d'un document (fig. 1.1) : le niveau Œuvre, en haut de la hiérarchie, décrit les caractéristiques abstraites de la création de l'œuvre ; le niveau Expression englobe les caractéristiques de son contenu intellectuel ; le niveau Manifestation décrit les modalités de sa publication ; et le niveau Item décrit les caractéristiques individuelles du document en tant qu'exemplaire^{3 4}.




Figure 1.1 - Entités principales du modèle FRBR

Le FRBR est qualifié de modèle entité-relation, puisqu'il modélise précisément les relations qui peuvent exister entre les différents niveaux de description, comme le montre la figure 1.1 ci-dessus. Ainsi, une Œuvre peut avoir plusieurs Expressions différentes, qui chacune peuvent être incarnées dans plusieurs Manifestations différentes, qui chacune peuvent être exemplifiées par plusieurs Items. Le FRBR permet justement d'organiser la complexité de ces relations afin de permettre à l'utilisateur d'un système d'information de trouver la donnée qu'il cherche de manière précise et efficace. Afin d'illustrer la manière dont s'articule la description d'un ouvrage bibliographique selon la modélisation proposée par le FRBR, prenons l'exemple de l'ouvrage *Qu'est-ce que le cinéma* d'André Bazin. Au niveau Œuvre, est décrite l'idée intellectuelle de l'ouvrage, essentiellement matérialisée par son contexte de création. Cet ouvrage, est notamment exprimé et matérialisé au sein d'un texte intégral en quatre volumes écrit entre 1958 et 1962, dont les modalités sont décrites au niveau Expression. Cette Expression de l'ouvrage est notamment publiée comme édition originale aux Editions du Cerf, dont les modalités sont décrites au niveau Manifestation. Enfin, l'exemplaire individuel de cette Manifestation est potentiellement conservé dans une bibliothèque avec une côte unique, dont les caractéristiques physiques sont décrites au niveau Item. Le foisonnement d'éléments liés à une même œuvre peut rapidement rendre complexe la navi-

²BnF, *Modèles FRBR, FRAD et FRSAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).

³*Ibid.*

⁴Nous donnerons des majuscules aux entités du FRBR au sein de ce mémoire, afin de les distinguer en tant qu'entités de leurs autres significations, telles qu'une oeuvre cinématographique par exemple

gation de l'utilisateur au sein d'un outil de gestion des collections. La description proposée par le modèle FRBR permet de distinguer les différentes étapes du cycle de vie d'une œuvre avec d'un côté sa conception intellectuelle, et de l'autre, ses différentes matérialisations. La modélisation de cette distinction permet une navigation plus fluide entre les éléments liés au sein d'un catalogue.

2. Entités de second et troisième groupes

Notons qu'à ces quatre entités de premier groupe : Œuvre, Expression, Manifestation, Item, s'ajoutent deux entités de second groupe : les Personnes et Collectivités. Elles expriment le rôle joué sur la production ou le contenu d'une ou plusieurs entités du premier groupe⁵. Par exemple, l'auteur est relié aux niveaux Œuvre et Expression, l'éditeur au niveau Manifestation, le catalogueur au niveau Item. Enfin, il existe des entités de sujet, formant un troisième groupe intégré au modèle, qui correspondent à des Concepts, Objets, Évènements ou Lieux liés aux entités de premier et de second groupe⁶. Ainsi, une Œuvre peut avoir pour sujet un Lieu, mais elle peut être elle-même le sujet d'une autre Œuvre. De même, les entités responsables de second groupe peuvent également être sujets d'une Œuvre. Réunies, les entités des trois groupes confondus modélisent une structure complexe caractérisée par les liens entre éléments, comme le montre la figure 1.2.

⁵IFLA Study Group on the Functional Requirements for Bibliographic Records, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).

⁶*Ibid.*




Figure 1.2 - Entités de second et troisième groupes du modèle FRBR

Toutefois, dans le cadre de ce mémoire, nous nous concentrerons sur les entités de premier groupe, qui constituent les entités centrales de description d'un modèle de données, qui conditionnent la structure d'un système de gestion des collections. Tel que nous le verrons à travers l'exemple du logiciel développé par Skinsoft, les entités de second et troisième groupe constituent moins des entités à part entière que des éléments de description annexes dont la forme est contrôlée.

3. Localiser, identifier, sélectionner, accéder

Le modèle FRBR, fondé sur les relations entre entités, est avant tout conçu dans l'optique de faciliter la navigation de l'utilisateur au sein d'un catalogue, entre les liens qui régissent les différents éléments d'une collection. Le FRBR prétend en effet répondre à quatre besoins utilisateur principaux : trouver, identifier, sélectionner, obtenir⁷. Il permet à l'utilisateur de localiser la ressource, d'identifier si elle correspond bien à ce qu'il cherche, de la sélectionner selon ses besoins, avant d'accéder finalement à son contenu. Nous ajouterons que le besoin fondateur de la création d'un tel modèle est également celui de pouvoir visualiser et explorer les liens de la ressource identifiée avec d'autres ressources pertinentes qui y sont directement associées⁸. Ce modèle de données se situerait donc à l'intersection de deux besoins principaux : celui d'améliorer la connaissance sur une ressource donnée en visibilisant ses

⁷Tillett, Barbara B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

⁸*Ibid.*

relations, et celui d'améliorer l'expérience utilisateur en proposant une interface navigable et intuitive.

Notons que ces besoins s'appliquent non seulement à l'utilisateur faisant partie d'un public, au sein d'un catalogue ou d'une base de données en ligne, mais également à un utilisateur métier, interne à l'institution et gestionnaire des collections. C'est précisément sur les besoins métier de ce dernier que se concentre l'analyse de ce mémoire de recherche. De fait, les enjeux de l'implémentation et de l'adaptation du modèle FRBR se situent au cœur des ambitions d'un logiciel de gestion des collections, dont l'objectif est d'améliorer l'interface afin d'assurer l'efficacité des tâches de l'utilisateur métier.

II. Extension et adaptation du FRBR

1. Le FRBR pour la gestion de collections

Le modèle FRBR est ainsi un modèle conçu par et pour les bibliothèques. À ce jour, les bibliothèques n'utilisent plus seulement le modèle FRBR mais également la somme de ses modèles étendus : le Fonctionnalités requises des données d'autorité (FRAD) pour la description des autorités, et le Fonctionnalités requises des données d'autorité matière (FRSAD) pour la description des sujets⁹. La somme de ces modèles constitue le modèle *Library reference model* (IFLA-LRM), successeur du FRBR. Le modèle FRBR est toutefois largement utilisé dans le domaine de la gestion des collections muséales. Or, sa qualité de modèle ne prétend pas normaliser la description des données, seulement d'en cadrer l'affichage. De fait, les entités proposées par le modèle FRBR peuvent paraître génériques, et doivent être soumises à une redéfinition à chaque implémentation selon le contexte donné¹⁰. Cette flexibilité ne doit néanmoins pas nuire à l'objectif principal, celui de faciliter la navigation de l'utilisateur, en explicitant les "interrelations" entre les notices et les données produites¹¹. Nous étudierons au sein des chapitres suivants d'une part, son adaptation normée à d'autres types de documents, et d'autre part, l'adaptation de sa modélisation à différents contextes institutionnels.

Le modèle de données FRBR est adapté au milieu muséal en 2015 à travers une version

⁹BnF, *Modèles FRBR, FRAD et FRSAD...*

¹⁰Patrick Boeuf, « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).

¹¹*Ibid.*

orientée objet, le FRBR orienté objet (FRBRoo), extension du object-oriented Conceptual Reference Model (CIDOC-CRM), l'ontologie de référence dédiée au patrimoine culturel et muséal¹² ¹³. Il s'agit d'un modèle conceptuel général visant l'interopérabilité entre les données provenant d'institutions diverses dont les musées, les centres d'archives et les bibliothèques¹⁴.

Ce dernier modélise une approche descriptive centrée sur les événements entourant l'objet décrit. Ainsi, les entités bibliographiques ne sont plus seulement décrites par des attributs, mais par des événements spatio-temporels qui les créent et les font évoluer selon différents contextes¹⁵. Cette adaptation du FRBR est particulièrement pertinente pour la description de collections de musées composites et de différentes natures, pouvant englober à la fois la description de tableaux, sculptures, ouvrages, specimens, films, etc. Tandis que le FRBR est modélisé à partir de la nature d'un document bibliographique, le FRBRoo remplace la description dans un contexte plus large, celui d'événements situés dans l'espace et dans le temps, et qui peuvent agir sur n'importe quel type d'objet.

2. Le cas des archives audiovisuelles

Cette approche par événements, plutôt centrée sur la nature de l'objet, paraît intéressante pour la gestion des archives audiovisuelles, objet de notre étude. En effet, les archives audiovisuelles possèdent un statut hybride au sein d'institutions patrimoniales, relevant à la fois de la création artistique, de l'œuvre et d'un archivage du réel, et d'un témoignage¹⁶. Le FRBRoo propose des subdivisions de l'entité Œuvre, plus précises, dont la Captation (*Recording work*), faisant référence à l'action de "saisir certains aspects des événements en les enregistrant [Traduction personnelle]" ¹⁷. L'entité de Captation semble illustrer le caractère large et à la fois plus spécifique englobé par les archives audiovisuelles, faisant directement référence à l'enregistrement du réel sur un dispositif technique. Le FRBRoo conserve ensuite les entités prévues par le FRBR : l'Expression, la Manifestation, l'Item, en les détaillant

¹²Sarah L. Gillis, « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://api.semanticscholar.org/CorpusID:58358915> (visité le 08/07/2026).

¹³Le FRBRoo a désormais été révisé sous la forme du modèle LRMoo dont la sortie officielle a été réalisée en 2024. Nous conservons ici l'exemple du FRBRoo, davantage parlant pour notre étude sur la modélisation des données audiovisuelles CIDOC CRM, *LRMoo Home / CIDOC CRM*, URL : <https://cidoc-crm.org/lrmoo> (visité le 04/09/2026)

¹⁴IFLA, *FRBRoo as IFLA Standard*, URL : <https://www.ifla.org/news/frbroo-as-ifla-standard/> (visité le 04/09/2026).

¹⁵IFLA Working Group on FRBR/CRM, « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).

¹⁶Walter Benjamin, *L'œuvre d'art à l'époque de sa reproductibilité technique*, 1935.

¹⁷"the concept of capturing aspects of events by recording them" IBM, *Statement on FRBRoo / CIDOC CRM*, URL : <https://cidoc-crm.org/Resources/statement-on-frbroo> (visité le 04/09/2026)

toutefois davantage¹⁸.

Néanmoins, si le FRBRoo constitue une adaptation pertinente du FRBR pour le milieu muséal, sa structure trop étendue ne permet pas de rendre compte spécifiquement la nature propre du médium cinématographique, qui fonde la gestion des collections audiovisuelles. Ainsi, les institutions préservatrices de collections audiovisuelles se tournent davantage vers des adaptations métier spécifiques, comme celle élaborée par la Fédération des archives du film (FIAF). La FIAF propose en effet une application du FRBR spécifique aux usages métier de description des archives audiovisuelles, au sein d'un manuel de catalogage des images animées.

III. Une adaptation spécifique aux archives audiovisuelles

L'adaptation du modèle FRBR aux archives audiovisuelles implique un double paramètre : la prise en compte d'une part, de la nature propre du langage cinématographique, et d'autre part, des spécificités des corpus audiovisuels conservés. La modélisation en différentes couches de description prévue par le FRBR est pertinente pour le cinéma, qui partage avec le milieu bibliographique un mode de production industriel, permettant ainsi de distinguer la création intellectuelle de ses copies et diffusions multiples. Toutefois, les niveaux bibliographiques classiques dits *Work*, *Expression*, *Manifestation*, *Item*. (WEMI) restent limités pour la description métier des spécificités des archives audiovisuelles.

1. Du WEMI au *Work*, *Variant*, *Manifestation*, *Item*. (WVMI)

Premièrement, alors que les bibliothèques conservent principalement des copies identiques d'une même publication, les archives audiovisuelles sont fréquemment amenées à gérer des objets uniques et rares caractéristiques des archives, tels que des *rushes*, des films amateurs, des montages inachevés, des copies annotées, etc.¹⁹. Pour ce type de collections, le niveau *Manifestation* devient obsolète, en raison du caractère inédit de leur création. Deuxièmement, la distinction du FRBR bibliographique entre l'Œuvre (l'idée de création), et l'Expression (sa réalisation) s'adapte mal au contexte cinématographique. En effet, un film ne prend véritablement forme qu'au moment du tournage puis du montage, ce qui rend ainsi l'idée d'une existence abstraite de création en amont, caduque. Il paraît alors pertinent

¹⁸ *Ibid.*

¹⁹ FIAF, *Le manuel de catalogage des images animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

d’appréhender l’œuvre cinématographique moins comme une entité abstraite en amont de sa réalisation, que comme une entité concrète ancrée dans un processus matériel sur un support technique.

Afin de répondre à ces contraintes imposées par le processus de création cinématographique, la FIAF élabore en 2016 un *Manuel de catalogage des images animées*²⁰. Le manuel adapte le modèle FRBR en le combinant aux règles descriptives Règles de description des archives (RDA) dédiées aux archives, et aux normes de description des œuvres cinématographiques (EN 15744 / EN 15907)²¹. Le manuel se focalise sur les entités de premier groupe afin d’en repenser l’articulation et de proposer de remplacer le schéma WEMI par le schéma WVMI (*Work, Variant, Manifestation, Item*).

2. Exemple de modélisation descriptive

En effet la FIAF propose de fusionner le niveau Expression dans celui de l’Œuvre, permettant alors à l’Œuvre de regrouper à la fois la description intellectuelle et le processus de création de l’archive cinématographique. Afin d’illustrer cette adaptation, prenons par exemple le film *L’Aigle à deux têtes*, réalisé en 1948 par Jean Cocteau. Le niveau Œuvre permettrait d’y décrire le contexte de création ainsi que le contenu. De plus, la FIAF propose une nouvelle entité, celle de Variante, optionnelle, qui se substitue à celle d’Expression. Elle permet de décrire toute version différente d’une œuvre originale dans la mesure où son sens principal n’est pas altéré²². Par exemple, une version d’un film qui serait colorisée, censurée, doublée, remontée, etc. Si nous reprenons *L’Aigle à deux têtes*, une Variante possible est celle de la restauration du film en 4K en 2023, dont le niveau Variante permettrait de décrire les variations portées sur le contenu ou la forme de l’œuvre²³. La FIAF conserve par ailleurs le niveau de Manifestation, toutefois redéfini afin de pouvoir décrire la matérialisation physique ou numérique d’une Œuvre ou de sa Variante sur un support, ainsi que son contexte de diffusion²⁴. Par exemple, la manifestation de la version restaurée de *L’Aigle à deux têtes* décrirait la sortie de cette version en *Blu-Ray* ou *DVD*. Enfin, le niveau Item est également conservé afin de décrire l’exemplaire physique ou le fichier numérique unique issu de la Manifestation d’une Œuvre ou de sa Variante²⁵. Cet exemplaire est concrètement préservé et géré par l’institution et décrit par des métadonnées de conservation.

²⁰ *Ibid.*

²¹ *Ibid.*

²² *Ibid.*

²³ Institut audiovisuel de Monaco, *L’Aigle à deux têtes*, URL : <https://institut-audiovisuel.mc/evenement/laigle-deux-tete/> (visité le 04/09/2026).

²⁴ FIAF, *Le manuel de catalogage des images animées de La FIAF...*

²⁵ *Ibid.*

Cette restructuration du FRBR permet ainsi de répondre aux besoins métiers spécifiques de gestion de collections archives audiovisuelles au sens large. Selon la FIAF, la modélisation de cette réadaptation du FRBR au sein d'un outil de gestion des collections devrait permettre aux utilisateurs métier "d'identifier, sélectionner et acquérir" efficacement toutes les variantes d'une œuvre, l'ensemble des manifestations d'une version d'une œuvre, les exemplaires physiques disponibles d'une manifestation d'une œuvre²⁶. La FIAF reprend ainsi les besoins utilisateurs fondateurs de la structuration du FRBR bibliographique en les adaptant à la nécessité de pouvoir circuler entre les différentes versions d'une œuvre, à différents stades du processus de l'industrie cinématographique.

Toutefois, l'implémentation d'un tel modèle au sein d'un outil de gestion des collections se heurte aux spécificités des différents types de corpus audiovisuels, dont certaines œuvres, par exemple, n'ont pas été diffusées et ne sont ainsi pas incarnées par une manifestation concrète. En effet, le modèle s'applique adéquatement aux corpus de cinéma dits "classiques" dont la chaîne de production industrielle est respectée : un film est réalisé à l'issue d'un tournage et d'un montage (Œuvre), puis distribué (Manifestation), et copié en multiples exemplaires (Item). Or, dans le cas de corpus spécifiques, expérimentaux, personnels, ou amateurs, qui font l'objet de descriptions complexes, la modélisation FRBR classique s'avère limitée. Ce type de corpus est notamment peu distribué ou diffusé, rendant le niveau de Manifestation obsolète.

Si le modèle FRBR original, puis son extension à travers le modèle FRBRoo sont pertinents afin de structurer la description des archives audiovisuelles, c'est véritablement la FIAF qui en produit une adaptation spécifique. Toutefois, le FRBR reste un modèle qui doit faire l'objet d'une réadaptation à chaque contexte institutionnel, lors de son implémentation au sein d'un système de gestion des collections²⁷. Le manuel de la FIAF agit ainsi comme un cadre théorique de structuration de l'information pour archives audiovisuelles au sens large. La gestion de types de corpus audiovisuels spécifiques supposerait une redéfinition des recommandations de la FIAF, adapté au contexte de gestion.

²⁶ *Ibid.*

²⁷ P. Boeuf, « Brave New FRBR World »...

Chapitre 2

Modéliser un logiciel pour la gestion des collections audiovisuelles

Comme défini en introduction, un logiciel de gestion des collections est un outil “spécialisé permettant de gérer des informations structurées”¹. De fait, il structure le système d’information qui permet à une institution d’orchestrer le cycle de vie de sa collection. Cette structuration des données doit être modélisée selon les spécificités propres au type de collection d’une institution cliente, à partir de normes descriptives définies pour l’indexation des collections. Dans le cas des archives audiovisuelles, le logiciel de gestion des collections devrait ainsi permettre une structuration de l’information adaptée au type de corpus conservé, tout en respectant le cadre de référence de modélisation des données, le FRBR. La restructuration du modèle de données permet de construire pour l’utilisateur, un système de gestion navigable conforme aux besoins utilisateurs fondateurs du FRBR. Nous nous attacherons dans cette partie à présenter comment le FRBR s’inscrit dans un logiciel de gestion des collections dédié aux archives audiovisuelles, à travers l’espace de travail S-movies développé par Skinsoft.

I. Configuration du FRBR au sein d’une interface logicielle

1. Architecture du logiciel développé par Skinsoft


Si le manuel de la FIAF pose le cadre d’une adaptation du modèle FRBR pour la gestion des archives audiovisuelles, il s’agit désormais de confronter ce cadre à une implémentation concrète. Pour cela, nous analyserons au cours de ce chapitre l’implémentation d’une telle

¹Ministère de la Culture, *Dico des musées...*

modélisation au sein d'un outil de gestion des collections, celui développé par Skinsoft. Nous y analyserons spécifiquement l'espace de travail développé pour la gestion des archives audiovisuelles : S-Movies. En effet, le contexte de notre étude se situe principalement dans le cadre de l'analyse de cet espace de travail, effectuée au cours de notre stage. L'analyse de la modélisation de l'espace de travail a eu pour objectif d'en proposer des améliorations afin de concrétiser le projet d'implémentation de fonctionnalités automatiques, fondées sur l'intelligence artificielle.

Présentons d'abord le fonctionnement général de l'outil de gestion des collections développé par Skinsoft. D'un point de vue technique, le système repose sur une base de données *NoSQL* orientée documents, s'appuyant sur le moteur de recherche et d'analyse *Elasticsearch*². Contrairement aux bases de données relationnelles traditionnelles basée sur le langage *SQL*, *Elasticsearch* ne s'appuie pas sur un schéma de tables reliées les unes aux autres, mais consigne l'information sous la forme de documents *JSON* au sein d'index³. Ce type d'architecture permet de gérer un grand nombre de données et de gérer l'évolutivité de leur paramétrage⁴. D'un point de vue métier, le paramétrage de l'interface permet de recréer la modélisation relationnelle préconisée par la FIAF.

Concrètement, au niveau de la présentation de l'interface, le logiciel est divisé en espaces de travail, disponibles sous la formes d'onglets en haut de l'interface (fig. 2.1). Chacun de ces espaces de travail est dédié à un type de collection⁵.



Média	Identifiant(s)	Titre	Création / Conception / Réalisation	Description(s)	Genres
	...	Les parapluies de Cherbourg	1957 Cherbourg Demy, Jacques	Madame Emery et sa fille Geneviève tiennent une boutique de parapluies. La jeune femme est amoureuse de Guy, un garagiste. Mais celui-ci part pour la guerre d'Algérie. Excitée et poussée par sa mère, Geneviève épouse Roland, un riche bijoutier.	Comédie musicale Drame romantique
	...	Les Dames de Rochefort	1967 Rochefort Démv. Jacques	Delphine et Solange sont deux jumelles de 25 ans, ravissantes et spirituelles. Delphine, la blonde, donne des leçons de danse et	Comédie musicale

Figure 2.1 - Espaces de travail

Une institution cliente de l'outil peut combiner un ou plusieurs espaces de travail, selon

²*Elasticsearch* est un moteur de recherche qui stocke des données non structurées ou semi-structurées sous forme de documents au format JSON (*JavaScript Object Notation*) IBM, *Qu'est-Ce Qu'Elasticsearch ?*, URL : <https://www.ibm.com/fr-fr/think/topics/elasticsearch> (visité le 05/09/2026)

³*Qu'est-ce qu'une base de données NoSQL ?* | IBM, janv. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/nosql-databases> (visité le 05/09/2026).

⁴*Ibid.*

⁵Les captures d'écran intégrées à notre mémoire sont issues d'une plateforme de test configurée par nos soins au cours du stage. Les collections qui y sont intégrées et visibles sont des collections fictives.

les types de collections à gérer. Cette structure permet justement d'adapter l'interface et de la modéliser par espaces de travail, pour divers objets de collection : collections muséales, collections archéologiques, collections de films, collections bibliographiques, fonds d'archives, etc. Chaque espace de travail permet notamment la gestion des acquisitions, des collections, de leurs mouvements, de projets, d'expositions, des médias, etc. Chaque espace est structuré et modélisé selon les normes en vigueur pour le type de collection géré.

2. L'espace de travail S-Movies

a. Structure fonctionnelle

L'espace de travail S-Movies, propre à la gestion des collections audiovisuelles, est modélisé selon les préconisations de la FIAF, et structuré selon les normes de descriptions RDA. Ainsi, les collections sont organisées en trois entités distinctes, conformément aux adaptations du FRBR par la FIAF : Films (Qui fait en réalité référence au niveau Item), Manifestation, Œuvre cinématographiques. Ces entités sont concrétisées sous la forme de trois tables de données principales, au sein du menu de l'interface (fig. 2.2).

Référentiels & Bases annexes	Conservation	Collections	Production culturelle & Régie
- Autorités - Carnet d'adresses - - Bibliographie - Collections / thématiques - Événements - Fonds - Marques/Signatures - - Localisations - Thésaurus	- Assurances / Estimations - Contrats de droits - - Constats d'état - Interventions - Restaurations - - Commandes/Abonnements - Acquisitions / Dépôts entrants - Pré-entrées / Commissions - Entrées - Dépôts sortants - Sorties	- Films - Manifestations - Oeuvres cinématographiques - - Médias - - Registres d'inventaire/des dépôts - Récolement/Pointage - Fiches de récolement	- Accessoires / Modèles d'accessoires - Contenants / Modèles de contenants - - Expositions / Dispositifs de médiation - Emprunts / Prêts - Programmations / Diffusions - Projets - - Financements - Mouvements - Procédures - Prêts/Consultations
Organisation du travail	Outils	Administration des accès	Configurations & Paramétrages
- Postes budgétaires - - Modèles de mission - Modèles de tâches - - Missions - Tâches - - Alertes - Statistiques	- Recherche fédérée - - Importer des données - Interroger des référentiels externes - États imprimables - Éditeur de rapports - - Mes modèles de notice - Mes grilles de recherche	- Gérer les utilisateurs - Gérer les groupes d'utilisateurs - Gérer les profils d'accès	- Gérer les établissements - Gérer les menus - Gérer les masques - Gérer les meta masques - Gérer les grilles de recherche - Paramétrer les identifiants des notices - Associer les catégories de média - Administrer les domaines de recherche - Documenter la charte de saisie - Éditeur de champs - Éditeur de requêtes - Gérer les plans

Figure 2.2 - Menu de l'espace de travail S-Movies

Dans chacune de ces tables, l'utilisateur peut créer de nouvelles notices, et y associer des notices des autres tables. Par exemple, depuis la table Œuvres cinématographiques, l'utilisateur peut créer une notice d'Œuvre et y associer des notices de Manifestations et d'Items qui y sont directement liées, via un bouton d'action (fig. 2.3).




Figure 2.3 - Lien vers des notices de Manifestation depuis une notice Œuvre

La Variante telle que définie dans le manuel de la FIAF, n'est pas représentée comme une entité en tant que telle sous la forme d'une table. Elle est intégrée à la table des Œuvres, au sein de laquelle il est possible de créer une notice d'Œuvre de type Variante.

b. Configurations spécifiques

De plus, en fonction de la nature du corpus géré, un paramétrage adaptatif est prévu afin d'ajuster l'interface aux pratiques métier de chaque institution. En effet, une adaptation supplémentaire à la modélisation de données est prévue via une configuration flexible de chacun des espaces de travail. Cette configuration s'effectue à trois niveaux : le paramétrage de champs de saisie pour chaque type de notice, l'organisation de ces champs dans des grilles de résultats de recherche, et l'assemblage des champs et des grilles de recherche dans des menus navigables pour chaque type de notice. Ce paramétrage permet de concrétier la modélisation de données prévue selon le cadre de référence utilisé.

Ainsi, une double adaptabilité est proposée. D'une part, la modélisation et la structuration de base d'un espace de travail dédié à un type de collection spécifique selon les normes recommandées, et d'autre part, un paramétrage précis de cet espace de travail, propre à la nature du corpus géré par l'institution cliente, qui conditionne les pratiques métier. Ce second niveau permet de concrétiser en un parcours métier, la modélisation fonctionnelle de l'espace de travail.

Par exemple, l'espace de travail S-Movies est pré-structuré suivant la modélisation FR-BR préconisée par la FIAF. Cette structure stable, permet à Skinsoft de proposer un espace

de travail pré défini pour chaque institution préservatrice de collections audiovisuelles. En revanche, les corpus audiovisuels peuvent être de toutes sortes et varier d'une institution à l'autre. Cette hétérogénéité suppose des règles métiers spécifiques, issues des besoins de gestion de la collection préservée. Ainsi, par exemple, une collection audiovisuelle expérimentale ou amateur ne nécessitera pas les mêmes champs de saisie, les mêmes thésaurus, ou la même disposition des résultats de recherche, qu'une collection audiovisuelle grand public.

Concrètement, au sein de l'espace de travail, la description d'un élément s'effectue au sein de champs de saisie, sélectionnés de manière adaptée aux besoins de description de l'institution donnée. Ces champs, s'ils sont paramétrables individuellement, font en réalité partie d'une structure plus large, à l'échelle de l'espace de travail dans lequel ils se situent. En effet, ces champs sont regroupés dans des masques, qui correspondent à des formulaires de saisie spécifiques au type de notice concerné. Par exemple, une notice de film physique, au niveau Item, pourra contenir un masque configuré avec les champs de saisie suivants : identifiants, format de l'item, support de l'item, etc. (fig. 2.4)

Figure 2.4 - Configuration de masques de saisie pour une notice de film physique

Ce masque peut ensuite être assemblé en tant qu'onglet au sein d'un menu d'une notice de film physique, permettant à l'utilisateur d'y remplir les champs que nous avons mentionnés (fig. 2.5 et 2.6).




Figure 2.5 - Configuration du menu d'une notice de film physique




Figure 2.6 - Affichage du menu d'une notice de film physique à la saisie

Ce système d'organisation des masques de saisie au sein de menus permet également d'effectuer des liens avec d'autres types de notices et donc d'autres entités du FRBR. Par exemple, dans le menu d'une notice de film physique, les onglets Œuvre liée et Manifestations liées permettent d'obtenir une grille de recherche qui affiche l'Œuvre liée au film et les Manifestation dont il découle (fig. 2.7).




Figure 2.7 - Configuration de grilles de recherche pour l’affichage des éléments liés

Depuis l’interface utilisateur, le menu affiche les éléments liés au sein d’une grille de résultats de recherche (fig. 2.3).

Ces configurations permettent ainsi de concrétiser la modélisation prévue par le modèle FRBR, en prévoyant une navigation des liens entre les notices via la configuration de menus et de grilles de recherche.

c. Méta-masques de saisie

Toutefois, les espaces de travail structurés par le modèle FRBR, comme c’est le cas de S-Movies, requièrent un niveau de configuration supplémentaire, afin de concrétiser le découpage de la description en niveaux hiérarchiques. Par conséquent, le logiciel développé par Skinsoft prévoit la configuration de méta-masques, des formulaires de masques de saisie pouvant cibler les champs de plusieurs types de notices –et donc plusieurs niveaux du FRBR à la fois, afin d’imbriquer ces niveaux de description au sein d’une même notice. Ce système permet à l’utilisateur de saisir implicitement des éléments de description dépendants de plusieurs niveaux du FRBR en une seule notice, permettant de surcroît au système de produire un héritage des champs d’un niveau à l’autre.

Concrètement, dans S-Movies, la notice d’Œuvre/Expression pointe sur les champs de l’Œuvre et de l’Expression, la notice de Manifestation pointe sur les champs de l’Œuvre, l’Expression et la Manifestation, la notice de l’Item pointe sur l’Œuvre, l’Expression, la Manifestation et l’Item (fig. 2.8). Ce mode de paramétrage de la description permet d’intégrer

aux niveaux du FRBR inférieurs des champs hérités des niveaux supérieurs ⁶. Le réservoir de champs à droite signale à quel niveau de description les champs appartiennent, tandis que les cibles du méta-masques apparaissent à gauche de l'interface (fig. 2.8).




Figure 2.8 - Configuration d'un méta-masque au niveau Item

Ces masques et méta masques créent ainsi une structure pérenne qui fait l'objet d'un paramétrage individuel, permettant d'ajuster la structure en fonction du type de collection et des usages métiers du client concerné. Ce paramétrage est défini au cours d'un travail de *mapping*, c'est-à-dire d'un travail de correspondance entre les données client et la structure proposée par Skinsoft, afin de trouver un accord sur les champs qui seront utilisés pour la description des collections. L'équipe de Skinsoft organise ensuite ces champs dans des formulaires de saisie (masques et méta masques), eux-mêmes organisés pour constituer des menus de notice et des grilles de résultats de recherche. L'équipe produit également des imports de thésaurus, c'est-à-dire des listes de termes normalisés, propres aux usages de l'institution concernée afin d'assurer l'interopérabilité des données saisies.

Les fondements de l'architecture de S-Movies, doublement adaptée d'une part aux collections cinématographiques, et d'autre part à des pratiques métiers spécifiques, constituent la condition de la qualité des données et de l'expérience utilisateur. L'enjeu de l'espace de travail est d'offrir une interface qui permette à l'utilisateur de décrire les collections en plusieurs niveaux sans difficulté et de pouvoir circuler entre ces niveaux et les liens qu'ils entretiennent.

⁶Notons que la présence du niveau Expression contredit le modèle FRBR préconisé par la FIAF, qui fusionne le niveau Expression dans celui d'Œuvre. Etant donné que Skinsoft possède d'autres espaces de travail modélisés sur le FRBR, comme c'est le cas de l'espace dédié à la gestion des collections bibliographiques, le niveau Expression existe seulement en théorie, mais il est inutilisé en pratique au sein de S-Movies.

Cette circulation est notamment permise par les grilles de recherche que nous avons évoquées dont le paramétrage permet d'afficher les entités liées pour chaque notice. De plus, les différents outils de recherche proposés par le logiciel, dont la recherche avancée, la recherche plein texte ciblée, ou la recherche par facettes, permettent de circuler au sein des éléments de description indexés.

Toutefois, malgré la haute configurabilité de l'interface, l'hétérogénéité des corpus audiovisuels gérés d'une institution à l'autre complexifie l'adaptation à effectuer. En effet, la modélisation FRBR préconisée par la FIAF est un cadre qu'il s'agit d'ajuster aux pratiques spécifiques de gestion des collections, elles-mêmes adaptées au type de corpus géré. L'ajustement à des corpus audiovisuels spécifiques complexifie potentiellement la fluidité de la navigation entre les liens des différentes entités du FRBR au sein de l'interface.

II. L'inscription de corpus de données audiovisuelles au sein de S-Movies

La nature du corpus audiovisuel complexifie le paramétrage de l'interface, puisqu'elle conditionne la capacité des données à s'adapter et à s'intégrer au sein du modèle FRBR. Le modèle FRBR pose une architecture fixe de l'espace de travail, via une description distincte en trois tables de saisie (Œuvres, Manifestations, Films) (fig. 2.2), ensuite configurable spécifiquement afin de définir les attributs (fig. 2.4), les liens entre les niveaux, l'affichage des menus (fig. 2.6) et des grilles de recherche. Afin d'analyser la mesure dans laquelle différents corpus audiovisuels s'intègrent au sein du modèle FRBR, nous analyserons dans cette section deux corpus de données différents, gérés par l'application développée par Skinsoft ⁷.

1. Implémentation d'un corpus audiovisuel classique

Premièrement, analysons l'intégration d'un corpus de cinéma dit "classique", au sein de l'espace de travail S-Movies. Cette collection est gérée par une institution qui préserve essentiellement des films de fiction issus d'une production commerciale "grand public" depuis les débuts du cinéma jusqu'à nos jours. Cette collection est composée d'œuvres cinématographiques, dont la modélisation prévue par le FRBR permet de restituer adéquatement la description. La production cinématographique étant une production industrielle, les films qui en sont issus s'adaptent particulièrement bien à un modèle de données par niveaux, ces différents niveaux correspondant aux étapes de production. Ces films, après leur création, ont

⁷Notons que pour des raisons de confidentialité, nous décrivons les corpus de ces institutions sans dévoiler de données précises et sans nommer les institutions de manière explicite.

donc été produits, distribués puis diffusés à une échelle plus ou moins large. Ainsi, dans ce cas précis, le FRBR est plutôt bien adapté pour modéliser le contenu des données. La réalisation du film par le montage et le tournage est décrite au niveau Œuvre, ses versions sont décrites au niveau Variante, son édition et sa diffusion sont décrites au niveau Manifestation, et l'exemplaire individuel du film, conservé par l'institution est décrit au niveau Item. De fait, le paramétrage décrit dans le chapitre précédent peut être réalisé sans trop de complexité au sein du cadre modélisé par le FRBR de la FIAF.

2. Implémentation d'un corpus audiovisuel spécifique

a. Une modélisation descriptive à deux niveaux ?

Toutefois, l'implémentation de corpus plus spécifiques compromet la configuration d'une interface structurée selon le modèle FRBR. En effet, le logiciel permet de gérer un second type de collection, composée de *rushes* documentaires muets, c'est-à-dire des séquences animées non montées, tournées des années 1910 à 1920. Ces *rushes* bruts, ont été tournés dans une optique de documentation sur différents sujets, et ne sont pas destinés à une diffusion auprès d'un public large.

Dans ce cas, l'absence de montage et de distribution commerciale rend difficile l'adaptation du corpus à la modélisation prévue par la FIAF, qui structure S-Movies. Si le contexte de création du tournage peut être décrit au niveau Œuvre, les niveaux de description inférieurs sont inadaptés. En effet, en l'absence de montage, la Variante n'existe pas puisque chaque *rushes* correspond à une matière brute, unique. Ainsi, l'absence de différentes versions d'une même œuvre invalide l'entité de Variante.

De la même façon, le niveau Manifestation perd en pertinence descriptive puisque ces *rushes* ne sont ni produits ni diffusés officiellement auprès d'un public. L'inscription de l'œuvre sur un support s'effectue ici de manière unique, et en un seul et même exemplaire. Les caractéristiques matérielles pourraient donc être décrites directement au niveau de l'Item. Ainsi, d'un modèle à quatre niveaux, il ne reste, dans ce cas précis, plus que deux niveaux de descriptions exploitables : l'Œuvre et l'Item.

Toutefois, notamment pour des raisons de conservation, une œuvre peut être copiée sur différents supports, physiques ou numériques. En effet, l'institution peut être amenée à produire des copies d'une œuvre sur des supports plus stables à des fins de préservation ou de diffusion en ligne, par exemple. Ces différentes matérialisations, bien qu'elles ne soient pas issues d'un processus commercial de diffusion, peuvent être décrites comme des Manifestations. Telle que définie par le manuel de la FIAF, une manifestation induit en effet, "tous les médias analogiques, numériques et en ligne associés à une matérialisation particulière d'une

Œuvre/Variante”⁸. Sa description peut alors être justifiée par des objectifs de conservation : copie, numérisation, restauration. Selon la FIAF, la description d’une Manifestation inclut les attributs suivants, -ici sélectionnés selon leur niveau de pertinence pour un tel corpus : type de manifestation, format (incluant les champs suivants : type de support, caractéristiques sonores, caractéristiques de couleur), notes⁹.

Ainsi, la modélisation de données observée pour la gestion de ce audiovisuel précis s’apparente à un modèle hiérarchique à deux niveaux, celui d’une Œuvre matérialisée dans une Manifestation/Item, fusionnés en une seule entité. Cette hiérarchie à deux niveaux est schématisée dans le catalogue de la FIAF en page 11, comme exemple d’application potentiel, sans que ses modalités ne soient détaillées¹⁰.

b. Analyse des pratiques métiers

Une structure *a priori* simplifiée à deux niveaux, est toutefois remise en question par l’observation des pratiques métier de saisie de la description au sein du logiciel. En effet, si théoriquement le niveau Manifestation peut être décrit, en pratique, dans le cas de la description de ce corpus produite par l’institution, il ne l’est pas. En effet, si au sein d’une notice Œuvre, les champs suivants sont décrits : identification, titre, créateur, description (sujet de la prise de vue), mots clés, films associés, manifestations associées, matériel non-film associé, archives associées, bibliographie, médias, données de gestion ; la table Manifestation, en revanche, contient un nombre conséquent de notices vides. L’application Skinsoft crée en effet automatiquement une notice de Manifestation liée lorsque l’utilisateur crée une notice d’Item. Dans ce cas, l’entité Manifestation devient une condition structurelle afin de maintenir la cohérence du modèle, mais perd son sens au sein d’un contexte d’indexation concret.

La table des items, quant à elle, est répartie en trois catégories d’objets : bobines, cassettes —qui constituent les films physiques— et films numériques. Lorsqu’un même film physique est présent en plusieurs exemplaires dans la collection, les notices sont distinguées par la mention ”bobine originale” et ”reproduction”. Les notices de films physiques contiennent une description matérielle sur le support et la condition de ce support. Elles mentionnent également les collections liées vers d’autres Item et Œuvres, vers des médias et des documents. La manifestation référente est tout de même mentionnée mais il s’agit, nous l’avons évoqué, d’une notice factice.

Enfin, les films numériques décrivent le support original depuis lequel la numérisation a été effectuée, les raisons de la numérisation —par exemple, copie de sauvegarde—, et

⁸FIAF, *Le manuel de catalogage des images animées de La FIAF...*

⁹*Ibid.*

¹⁰*Ibid.*

l’item physique qui a fait l’objet de cette numérisation. Par ailleurs, un élément précis de description a retenu notre attention dans le cadre de notre étude. En effet, la présence de marqueurs temporels au sein des notices de films numériques, traduisant l’inscription de la copie numérisée dans une œuvre plus large. En effet, certaines Œuvres (*rushes*), dont les modalités matérielles sont décrites dans une notice de film physique, ont été séquencées en extraits puis numérisées. Étant donné que les Œuvres conservées sont des *rushes* non montés, cette division en extraits a pour but de réaliser une forme de montage a posteriori, afin de rendre le contenu de ces films intelligibles via une diffusion en ligne. Ainsi, la plupart des films numériques gérés au sein de S-Movies sont issus de ce découpage depuis les *rushes* originaux. Les repères temporels expriment le rattachement précis de l’item numérique au sein d’un item physique.

Ce séquençage complexifie les liens entre les entités et modélise plutôt la structure suivante :

schéma à placer

Par exemple : Une notice Œuvre est liée à un item numérique, lui-même lié à un ou plusieurs films physiques : cassette, bobine, avec le time code mentionné pour traduire la place de l’extrait/film numérique au sein de ces supports physiques.

Les films physiques : contiennent la liste des films numériques qu’ils ont pour extrait + les différentes reproductions du film physique sur d’autres supports physiques : plusieurs bobines, plusieurs cassettes (à des fins de conservation)

Si l’espace de travail S-Movies parvient à maintenir le modèle FRBR à travers trois tables de données principales pour les corpus audiovisuels classique, la description d’un corpus plus spécifique éclipse notamment le niveau Manifestation pour ne conserver qu’une hiérarchie à deux niveaux. De plus, l’analyse de pratiques de saisie complexes au sein de l’interface soulève des enjeux de fluidité de navigation et de compréhension pour l’utilisateur. En effet, le caractère documentaire et brut du corpus observé nécessite une description fine de son contenu afin d’en restituer l’intelligibilité. Afin d’adapter l’espace de travail à des corpus spécifiques, Skinsoft engage notamment une démarche de refonte et d’améliorations, dont l’objectif est de repenser d’une part l’interface complexe fondée sur le FRBR, et d’autre part d’intégrer des fonctionnalités innovantes d’indexation automatique afin de faciliter les pratiques métier.

III. Les complexités d'interface soulevées par la modélisation FRBR

La complexité d'adapter le cadre de modélisation préconisé par la FIAF souligne des difficultés globales au niveau de l'interface et de la navigation pour l'utilisateur. Le FRBR, est pourtant fondé sur la nécessité d'une navigation explicite, à travers les besoins "d'identifier, sélectionner et acquérir" efficacement l'ensemble des éléments décrits et répartis entre les différents niveaux hiérarchiques¹¹. Si le socle architectural préconisé par la FIAF permet une navigation à plusieurs niveaux, une double complexité subsiste toutefois. D'une part, il reste complexe de mettre en place une interface intuitive qui permet à l'utilisateur d'identifier immédiatement le rôle descriptif de telle entité du FRBR ainsi que la place qu'elle occupe au sein de la hiérarchie. D'autre part, la visualisation globale des liens entre les entités n'est pas encore possible, puisqu'elle se limite au niveau de la table ou de la notice.

1. Affichage hiérarchique et terminologie

Parmi les complexités d'interface révélées par l'expérience utilisateur, certains éléments peuvent sembler anodins, mais ils limitent néanmoins la fluidité et la compréhension de la structure des données. Par exemple, l'affichage d'une hiérarchie inversée du FRBR dans le menu de l'application, peut nuire à l'intuitivité du rôle de chaque entité pour la description des collections. En effet, au sein du menu de l'interface, les tables sont présentées de telle manière à ce que le plus bas niveau du FRBR (l'Item) apparaisse en haut, suivi de la Manifestation et du plus haut niveau (l'Œuvre) (fig. 2.2). Cet affichage descendant peut nuire à la compréhension immédiate de la situation des entités au sein de la hiérarchie. De plus, au sein de S-Movies le plus bas niveau de la hiérarchie (l'Item) est désigné par la notion de "Film". Or, dans un contexte cinématographique, le film peut communément désigner à la fois une œuvre et un item individuel. La notion de film n'évoque pas le caractère unique et individuel de l'exemplaire tel qu'il est défini par le manuel de la FIAF. Une autre confusion terminologique peut être créée par la présence subsidiaire de la notion d'Expression, alors même qu'elle est destinée à la gestion de collections bibliographiques. Le détail de ces observations terminologiques est développé en annexe A (2.).

2. Configuration et visualisation des liens

La visualisation des liens entre les entités descriptives au sein de l'interface est également motrice d'améliorations de l'espace de travail. L'interface actuelle permet, après configura-

¹¹ *Ibid.*

tion, de visualiser les liens d’une notice avec d’autres notices issues de niveaux différents du FRBR. Or, il serait pertinent pour l’utilisateur d’avoir la possibilité de visualiser les liens entre entités à un niveau plus large, et de manière graphique. Par exemple, il serait pertinent de pouvoir visualiser, au niveau d’une notice Œuvre, l’ensemble des manifestations dans lesquelles elle est matérialisée, ainsi que tous les exemplaires issus de ses manifestations respectives et conservés par l’institution. Cette visualisation des liens pourrait être étendue de manière plus large au niveau de la table d’une entité, ou de celui de la collection de l’institution.

Par ailleurs, la mise en place de liens indissociables entre entités prévus par le modèle FRBR nécessitent, au sein de l’interface, des configurations spécifiques complexes. En effet, l’indissociabilité des liens entre les entités suppose que l’interface rende obligatoire pour l’utilisateur l’association de certaines notices entre elles. Par exemple, un Item doit obligatoirement être lié à une Manifestation et/ou à une Œuvre. Or l’obligation de ces liens n’est pas encore prévue par l’interface, laissant ainsi la possibilité à l’utilisateur de créer un Item sans Œuvre liée, par exemple. De même, l’interface permet notamment la suppression d’une notice Œuvre et de tous ses éléments liés (notices de Manifestations et d’Items), sans avertissement préalable. Le détail des difficultés liées aux relations entre les notice est développé en Annexe A (2.).

Ces complexités d’interface sont en réalité issues de la complexité de traduire un cadre de modélisation défini, en termes d’expérience utilisateur. Cette traduction est cruciale afin d’assurer la qualité des données indexées au sein de l’interface. En effet, l’intuitivité de l’interface permet à l’utilisateur de diviser la description d’un objet entre les différents niveaux prévus par l’application, et d’associer ces niveaux entre eux afin qu’ils soient requêttables au sein de l’interface. L’absence d’intuitivité peut notamment empêcher l’héritage des données entre les différents niveaux, dans le cas d’une notice dépourvue de liens, par exemple. L’interface doit ainsi assurer la qualité des données en instaurant une circulation intuitive au sein du modèle FRBR.

L’analyse de l’espace de travail S-Movies nous a permis d’analyser la manière dont le modèle FRBR structure l’architecture des relations entre entités, permettant la description des collections. L’analyse de l’intégration d’un corpus audiovisuel spécifique a soulevé une complexification des liens entre les entités, qui compromet la fluidité et la navigation de l’interface. Ces enjeux d’expérience utilisateur sont en réalité le résultat d’une mise en application concrète d’un modèle de données théorique. Les enjeux de navigation au sein de l’interface logicielle, loin d’être anecdotiques, conditionnent la qualité des données saisies et leur indexation. Ainsi, les projets d’amélioration de l’interface préparent le projet d’implémentation de fonctionnalités innovantes afin d’assister l’utilisateur à l’indexation.

.

Chapitre 3

Le projet d'automatiser l'indexation des archives audiovisuelles

L'architecture modélisée par le FRBR décrite jusqu'ici conditionne la structure de la description, et de fait, de l'indexation de cette description selon des normes définies. En effet, le modèle de données permet d'organiser l'indexation en couches intelligibles, permettant à l'utilisateur de se repérer au sein d'un logiciel de gestion des collections, et de faciliter les entrées de description. Les tâches d'indexation peuvent toutefois s'avérer complexes et chronophages, spécifiquement dans le cas de corpus audiovisuels tels que celui que nous avons analysé, poussant l'éditeur à émettre le projet de développement d'outils automatisés permettant d'assister l'utilisateur.

I. Les enjeux de l'indexation audiovisuelle

1. Définition de l'indexation

L'indexation documentaire est définie de la manière suivante par le chercheur Bruno Bachimont :

L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. [...] L'indexation permet de s'orienter dans la masse des documents et d'organiser ses connaissances.¹

¹B. Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

Afin de ”fournir un point d’accès sûr et vérifié à l’information”, l’indexation implique la mise en relation des termes produits par la description avec des référentiels, des thésaurus et des listes d’autorité, afin de pouvoir les intégrer de manière structurée au modèle de données². Ainsi, par exemple, le réalisateur d’un film est indexé au niveau Œuvre, par une liste contrôlée d’autorités prévue par l’outil de gestion des collections. La normalisation des données descriptives par l’indexation permet ensuite d’améliorer leur découvrabilité au sein du modèle de données grâce à des outils de recherche et la navigation entre les différentes connaissances produites³. À terme, l’indexation permet l’interopérabilité des données entre les institutions et leur partage sur le web⁴.

2. Indexer les collections audiovisuelles

Toutefois, la nature des archives audiovisuelles complexifie les tâches d’indexation pour l’utilisateur. En effet, nous l’avons évoqué, de telles archives, caractérisées par leur nature temporelle, nécessitent un dispositif de lecture adéquat, qu’il soit numérique ou analogique, afin d’en extraire le sens et de pouvoir procéder à son indexation. Il revient à l’utilisateur métier d’identifier à partir de l’archive, des événements, des lieux, des personnes et même, dans le cas du corpus analysé, des découpages temporels et thématiques au sein du flux vidéo. Ces éléments doivent ensuite pouvoir être inclus dans une ou plusieurs entités du modèle FRBR. Face à la masse potentielle des collections, l’indexation peut ainsi s’avérer laborieuse et chronophage.

De plus, une difficulté s’ajoute dans le cas de corpus spécifiques tel que celui que nous avons décrit, composé de *rushes* documentaires. En effet, le caractère brut des archives suppose en amont la segmentation du flux vidéo en différentes unités de sens thématiques, comme le montrent nos observations de la saisie des données au sein du logiciel. La description ne peut en effet s’appliquer de manière précise dans le cas d’une archive contenant de multiples unités de sens différentes, non organisées. Dans ce contexte, la segmentation temporelle en différentes séquences constituerait alors la condition préalable à toute opération d’indexation, permettant de filtrer le travail en amont. Le visionnage, puis la segmentation, s’ajoutent comme tâches préalables à une indexation déjà chronophage, justifiant ainsi la mise en place d’une automatisation afin d’assister l’utilisateur, et accélérer l’indexation des contenus. Toutefois, avant de nous pencher sur l’étude d’une automatisation, il est pertinent de comprendre ce qu’implique le travail de segmentation d’un flux audiovisuel en séquences.

²FranceArchives, *Outils pour l’indexation des archives à l’heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).

³*Ibid.*

⁴*Ibid.*

II. La nécessité de segmenter

1. Une tâche préalable à l'indexation

Dans le cas des archives audiovisuelles, une indexation fine ne peut s'effectuer à l'échelle d'un fichier brut dans sa totalité, et en particulier lorsqu'il s'agit de *rushes* contenant une succession importante de séquences non montées. Afin de rendre le contenu de ces archives exploitable et requêtable au sein d'un modèle de données, il est indispensable d'en analyser finement l'enchaînement temporel, via une tâche préalable de segmentation. Cette opération, fondée sur la structure temporelle audiovisuelle, soulève en effet des enjeux d'intelligibilité de l'archive audiovisuelle, que Rémi Ronfard exprime à travers les questionnements suivants :

Quels sont les mécanismes qui permettent d'in-terpréter cette longue séquence d'images [...] en une séquence d'actions dramatiques, reliées entre elles par des liens de causalité, et qui nous permettent d'en comprendre le sens (l'histoire) ?⁵

Les mécanismes capables de rendre intelligible le contenu audiovisuel en passant d'une "longue séquence" à "une séquence d'actions dramatiques" seraient matérialisés par la segmentation, c'est-à-dire le découpage d'un flux visuel brut en séquences plus réduites et sémantiques. En effet, dans le cadre d'une indexation documentaire, la segmentation relève d'un découpage conceptuel permettant de préparer la description et de la faciliter, et non d'un montage technique altérant le sens de l'image animée. La segmentation s'imposerait ainsi, sur certains contenus, comme la condition d'une indexation fine, en apposant à des séquences des balises temporelles afin de rendre possible "la production de descriptions structurées"⁶. Ces balises temporelles délimitent des ensembles homogènes au sein d'une archive audiovisuelle, à la manière de chapitres dans un ouvrage textuel⁷. Si la structuration de certains types de contenus audiovisuels tels que les journaux télévisés, le sport, la publicité, sont "relativement stables et explicites de leur structure", et peuvent alors facilement être segmentés, les archives audiovisuelles regroupent des corpus divers et variés, dont la structure diverse rend complexe cette tâche⁸.

⁵Ronfard, Rémi, *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. 2009, URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

⁶Peter Stockinger, *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).

⁷*Ibid.*

⁸Jean Carrive, « Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », dans *Big data : Information et stratégie*, 2014, p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

2. Une segmentation temporelle

Le terme de segmentation peut désigner trois types de tâches différentes, appliquées à l’image. En effet, elle peut être premièrement fondée sur l’enchaînement temporel des images et/ou du son, composants essentiel des contenus audiovisuels⁹. Elle peut également être fondée sur une segmentation spatiale au sein même de l’image, impliquant l’analyse de la place des éléments dans l’image¹⁰. Enfin, la segmentation peut être qualifiée de segmentation sémantique, qui permet d’identifier uniquement les éléments sémantiques à l’intérieur d’une image, afin de les décrire via des catégories prédéfinies¹¹. Parmi ces trois types de segmentation, seule le premier type, temporel, s’avère spécifique à l’image animée, puisque les segmentations spatiales et sémantiques sont également applicables à l’image fixe. La segmentation temporelle, quant à elle, permet l’analyse des différences entre les plans et ainsi des relations qu’ils entretiennent à travers le mouvement temporel.

La segmentation temporelle est particulièrement adaptée et nécessaire au corpus de *rushes* documentaires, que nous avons décrit. En effet, au sein du logiciel prévu par Skinsoft, la segmentation est déjà pratiquée par l’institution préservant ces archives, qui associe des repères temporels à des extraits numérisés et issus de *rushes* d’une durée large. Cette pratique permet d’extraire certaines séquences jugées importantes à indexer de manière précise. Ces séquences sont ensuite intelligibilisées par l’indexation précise de leur contenu, et deviennent requêtables de manière autonome au sein du modèle de données. La segmentation répond donc à un objectif fixé par l’indexation, celui d’agir comme “un filtre de pertinence” sur les éléments à indexer¹².

Ce processus de segmentation s’inscrit de manière complexe dans la structure prévue par le modèle FRBR. Comme analysé précédemment au sein de l’application du corpus de *rushes*, les segments créés sont décrits et indexés en tant qu’objets de collection au sein de la table “films numériques”, puis rattachés à la fois à l’oeuvre originale dans la table dédiée, et à la fois au film numérique duquel ils sont extraits. Or, face à la masse d’archives et au caractère brut de ces contenus, la tâche de la segmentation s’avère nécessaire. C’est dans ce contexte qu’est envisagée la mise en place d’une segmentation automatisée permettant “d’accélérer le traitement de grands volumes vidéo tout en garantissant la cohérence du processus [Traduction personnelle]”¹³.

⁹ *Ibid.*

¹⁰ Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

¹¹ *Ibid.*

¹² P. Stockinger, *Les archives audiovisuelles...*

¹³ “automated segmentation accelerates the processing of large volumes of video content and ensures consistency and accuracy in the segmentation process.” Jonathan Attard et Dylan Seychell, *Comparative Ana-*

Toutefois, face à la complexité des relations entre les entités du FRBR créées par la segmentation temporelle, et la masse des volumes d’archives, l’implémentation de fonctionnalités automatiques ne pourra être effective qu’en respectant les règles métier en vigueur et la structure adaptative du modèle de données. Dès lors, il convient d’examiner les directions adoptées par l’éditeur Skinsoft pour le projet d’automatisation de l’indexation, afin d’analyser les fondements du processus à proposer.

III. Le projet Intelligence artificielle (IA) chez Skinsoft

1. Un projet global

La mise en place d’une indexation automatique, visant à faciliter le travail des utilisateurs métier et à le rendre efficace, s’inscrit dans un projet de mise en place de l’intelligence artificielle à une plus large échelle au sein de l’application chez Skinsoft, afin d’automatiser et de faciliter les pratiques de gestion des collections. L’intelligence artificielle (IA) peut être définie ainsi :

Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement¹⁴.

L’objectif serait alors, pour un éditeur comme Skinsoft, celui de rendre ces systèmes capables de pouvoir raisonner afin d’effectuer les mêmes actions que l’homme. Dans le cadre d’un système de gestion des collections, cela signifie que les systèmes d’intelligence artificielle devront effectuer des tâches documentaires complexes telles que nous les avons décrites. Cette implémentation doit donc s’inscrire dans cadre défini donnant la direction de développement de ces machines, adapté au contexte patrimonial.

L’implémentation de l’IA au sein de l’application n’est pas seulement issue d’une logique commerciale d’innovation, elle est centrée avant tout sur l’amélioration de l’expérience utilisateur, en vue de rendre l’indexation des collections efficace. L’une des caractéristiques majeures de l’application, nous l’avons évoqué, est sa flexibilité et son adaptabilité aux spécificités des collections et à diverses règles métier. La mise en place de l’IA permettrait de mettre cette adaptabilité en place plus efficacement et à plus large échelle. Automatiser la migration de données, le paramétrage de l’application, la navigation dans l’application permettrait à

lysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV]

¹⁴Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

l’entreprise de satisfaire ses clients plus rapidement et de gérer ainsi de multiples contrats. Cette volonté d’implémenter l’IA s’inscrit notamment dans l’appel à projets ”France 2030” qui couvre la maîtrise des technologies numériques et le ”déploiement de l’innovation”¹⁵. Ce projet finance des initiatives à l’intersection de la culture, du numérique et de l’IA.

2. Identifier le besoin pour instaurer un cadre éthique

Toutefois, la question du besoin est centrale, pour une utilisation de l’IA éthique. Comme le mentionne le Ministère de la culture : ”il ne s’agit pas d’utiliser l’IA par défaut, mais d’abord d’examiner le besoin à couvrir”¹⁶. L’objectif est double pour Skinsoft. La mise en place de l’IA dans l’application permettrait d’une part d’autonomiser les institutions sur leur usage du logiciel et d’autre part d’améliorer l’efficacité de l’indexation de leurs collections. Ainsi, les équipes Skinsoft seraient moins sollicitées pour des difficultés liées à l’usage de l’application qui pourraient être réglées par une machine intelligente. Afin de répondre à ces objectifs, Skinsoft prévoit notamment la mise en place d’une recherche en langage naturel, c’est-à-dire de permettre à l’utilisateur d’effectuer des recherches plus facilement en utilisant un langage naturel—son propre langage— plutôt qu’un langage contrôlé. Cette fonctionnalité est abordée dans la spécification fonctionnelle intégrée à l’annexe A (2.). L’objectif est ainsi de rendre l’utilisation globale de l’application plus simple, et d’améliorer l’efficacité de la gestion de collections.

Toutefois, l’implémentation de l’IA pour la création de contenus structurés soulève des enjeux éthiques dès lors que l’objectif de l’indexation est de produire des connaissances pour la transmission auprès du public. De plus, les pratiques documentaires, nous l’avons vu, sont des pratiques normalisées, structurées par un modèle de données afin d’assurer leurinteropérabilité.

Ainsi, Skinsoft porte des points d’attention au projet. Les moteurs d’intelligence artificielle implémentés devraient notamment faciliter le travail des utilisateurs et être construits comme des outils de proposition, sans réaliser entièrement eux-mêmes la production de connaissance. L’humain est ainsi toujours intégré au sein de la chaîne de travail dans la définition du projet, en étant le réel décisionnaire final de ce que produit l’IA.

¹⁵Ministère de l’Économie, *France 2030 : un plan d’investissement pour la France*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).

¹⁶Ministère de la Culture, *La stratégie du ministère pour des intelligences artificielles culturelles et responsables*, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

3. Le besoin d'une segmentation et d'une indexation automatisées

Concrètement, Skinsoft souhaite mettre en place différents moteurs d'intelligence artificielle, entraînés sur des données patrimoniales, et dédiés à l'automatisation partielle de tâches métier dans l'application. Parmi ces tâches, il est prévu l'automatisation de l'indexation au sens large au sein de l'application, et notamment appliquée aux archives audiovisuelles, dans S-Movies. Si, pour les images fixes, peut être mise en place une analyse automatique de leur contenu afin de l'indexer, l'indexation automatique des archives audiovisuelles se découpe, en théorie, en plusieurs sous-tâches, propres à la nature du médium cinématographique.

Ainsi, le moteur d'intelligence artificielle dédié à l'indexation des archives audiovisuelles au sens large, peut être divisé en plusieurs sous-moteurs, tous dédiés à l'analyse de la coordination du son avec le mouvement des images et leur contenu. Concrètement, cela peut désigner les tâches automatiques suivantes : transcription et analyse du son, reconnaissance des locuteurs, segmentation et analyse des images en mouvement, la transcription du texte présent dans l'image. Les données extraites de ces différentes tâches devront être automatiquement inscrites au sein de référentiels afin d'assurer leur interopérabilité. Par exemple, lors de la reconnaissance d'un locuteur, son nom doit pouvoir être relié à sa notice d'autorité dans l'application.

Toutefois, le projet d'automatiser l'indexation est issu d'une demande spécifique d'une institution cliente du logiciel, gestionnaire du corpus audiovisuel spécifique que nous avons décrit, constitué de *rushes*, nécessitant également un processus de segmentation. Or, la mise en place de la segmentation suppose d'en définir la granularité d'analyse au niveau de la syntaxe audiovisuelle, composée d'éléments divers : le plans, la séquence, la scène, etc.¹⁷. Dans le cadre de ce corpus, la segmentation manuelle s'effectue déjà au niveau de la séquence. Une séquence, en termes cinématographiques, peut être définie comme "une unité d'action, un fragment du film qui raconte en plusieurs plans une suite d'événements isolable dans la construction narrative."¹⁸. Dans ce contexte, la segmentation désigne donc la division d'images en mouvements en plusieurs séquences.

L'institution souhaiterait ainsi avoir à sa disposition un outil qui détecterait automatiquement les changements de séquences, pour pouvoir les décrire individuellement de manière fine, évitant ainsi une description trop globale au niveau du *rushes*. Comme nous l'avons évoqué, des marqueurs temporels sont déjà présents dans les données de l'institution, au sein des notices Oeuvres, afin de délimiter les séquences pertinentes. L'objectif est alors celui d'automatiser l'apposition de marqueurs temporels sur la vidéo en détectant les changements majeurs d'action, de lieu, d'objets ou de personnages, marquant le passage d'une séquence à

¹⁷P. Stockinger, *Les archives audiovisuelles...*

¹⁸Marie-Thérèse Journot, *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.

une autre.

À ce besoin s’ajoute celui d’indexer automatiquement les séquences identifiées par des mots-clés, afin de leur donner une valeur sémantique. En effet, les séquences, au sein de la syntaxe cinématographique, désignent une unité à la fois temporelle et sémantique, marquant un changement de forme significatif au sein du flux audiovisuel, mais également un changement de fond et de sens donné à l’image. Ainsi, la segmentation ne suffit pas à les qualifier de séquences, puisque c’est véritablement leur description qui leur redonne leur sens. Cette description doit ainsi pouvoir être automatisée par la production de mots-clés, puis indexée en lien avec les normes métier employées.

Ainsi, le besoin d’automatisation identifié se divise en deux tâches spécifiques : la segmentation du flux audiovisuel en séquences, et leur indexation par mots-clés. L’automatisation de ces tâches permettrait une accélération du traitement des fonds audiovisuels, et à terme, une mise à disposition plus large auprès d’utilisateurs. Si le projet d’automatiser ces tâches est issu d’un besoin spécifique à une institution, il pourra être généralisé à toute institution qui préserve des collections audiovisuelles.

Le traitement des collections audiovisuelles exige une articulation entre la segmentation temporelle d’une part, et l’indexation des séquences produites, d’autre part. En effet, la segmentation s’impose comme la condition préalable indispensable à une description documentaire exploitable par les utilisateurs. À travers la construction d’un cadre pour le projet d’implémentation de l’IA au sein de son logiciel, Skinsoft souhaite concevoir, à partir des besoins métier, un outil d’assistance pour le traitement massifs des fonds audiovisuels. L’identification des besoins d’une part, et du cadre théorique d’implémentation d’autre part, permet d’imaginer un processus automatique qui s’inscrit au sein de la structure documentaire du FRBR.

L'analyse du modèle FRBR a démontré la pertinence d'une approche entités-relations afin de rendre compte de la complexité des œuvres audiovisuelles. Toutefois, à travers l'analyse de S-Movies, il a été constaté que l'intégration du FRBR exige des efforts d'ergonomie afin de garantir une expérience utilisateur fluide, sans pour autant perdre l'intelligibilité du modèle.

Dans ce contexte, afin d'améliorer l'efficacité du traitement, le projet d'automatisation de l'indexation vient ajouter une difficulté à une modélisation déjà complexe. L'analyse théorique des pratiques d'indexation via la tâche de segmentation a permis d'instaurer les fondements d'un processus automatique, qui place l'utilisateur au centre.

Dès lors, nous nous pencherons sur le processus d'automatisation en lui-même, inscrit dans une modélisation de données adaptative, à travers les questionnements suivants : quels outils permettent de segmenter et d'indexer les archives audiovisuelles automatiquement ? Comment intégrer ce processus au modèle de données actuel ?

Deuxième partie

Implémenter une segmentation et une
indexation automatiques des archives
audiovisuelles

Cette seconde partie est consacrée à la mise en œuvre théorique d’une chaîne de traitement automatique pour la segmentation en séquences du flux audiovisuel, et l’indexation de ces séquences par mots-clés. L’enjeu fondamental de notre réflexion est d’adapter des outils techniques fondés sur l’intelligence artificielle, tout en prenant en compte les exigences de structure documentaire, ainsi que la complexité des archives audiovisuelles.

Le premier chapitre analyse d’abord la mise en place théorique d’une segmentation automatique à travers l’outil *Pyscenedetect*, fondé sur la vision par ordinateur. Le second chapitre analyse par ailleurs la description automatique des séquences produites via des mots-clés, à l’aide de l’outil *YOLO*. Nous évaluerons les besoins d’entraînement de ce modèle, fondé sur un réseau de neurones convolutif, ainsi que la mise en place d’un dispositif de validation technique pour les prédictions produites. Enfin, nous évaluerons les enjeux de reversement des données produites au sein du modèle de données décrit en première partie, nécessitant une supervision de l’utilisateur à chaque étape.

Chapitre 4

Application d'une segmentation temporelle automatique

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle automatisée. Notre proposition, considère moins la segmentation comme un prérequis technique que comme une tâche documentaire à part entière, directement articulée à l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

I. Traitement audiovisuel automatique

1. État des lieux

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la vision par ordinateur et la reconnaissance de discours automatique sont globalement désignées sous le terme de traitement audiovisuel¹.

Appliquées à un grand nombre de données, ces technologies permettent de passer du "*close*" au "*distant viewing*", c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble². Les tâches de traitement automatique permettraient en effet de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données

¹Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

²*Ibid.*

afin d'en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

Les tâches d'analyse automatique pouvant être appliquées aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent de plus en plus vers le contenu audiovisuel, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance³.

Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. Si la détection automatique des plans dans un flux vidéo est maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image, la détection sémantique de séquences reste inexploitée. Comme le souligne Samarth Bhargav, "pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques. [Traduction personnelle]"⁴.

En effet, de nombreux projets sont dédiés à l'analyse automatique de corpus audiovisuels, toutefois, aucun n'est concrètement dédié à la segmentation temporelle en différentes séquences afin d'en indexer le contenu. L'Institut National de l'Audiovisuel (INA), est notamment pionnier dans la proposition de projets d'analyse automatique appliquée à l'audiovisuel. L'INA a par exemple mis en place un outil de segmentation, *InaSpeechSegmenter*, toutefois dédié à la segmentation du discours entre hommes et femmes, dans une optique statistique⁵. Cet algorithme de segmentation, appliqué au son, ne peut être pris comme exemple d'application pour notre étude, centrée sur l'analyse du sens de l'image en mouvement.

Par ailleurs, le projet *MeMad*, réunit un ensemble d'outils dédiés à l'analyse automatique de l'audiovisuel développés par l'Université d'Aalto, EURECOM, l'INA et l'Université d'Helsinki⁶. Parmi les outils développés, nous pouvons citer par exemple un outil de traduction du discours (*Speech translation*), l'outil *InaFaceGender*, un outil de reconnaissance faciale (*Face recognition*), un outil permettant d'identifier la langue parlée (*Spoken language*

³Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁴"reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material" Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240

⁵INA, *Analyse des tendances médias par l'IA - Les traitements réalisés par les outils d'intelligence artificielle utilisés sur Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).

⁶*MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).

identification)⁷. Ces projets restent centrés sur l’analyse du son et du texte inclut dans l’image et ne peuvent donc pas être pris en compte dans notre analyse. Au sein de cette sous section, nous tenterons ainsi d’évaluer les outils et méthodes disponibles et dédiés au traitement audiovisuels, afin de proposer un processus adéquat.

2. La vision par ordinateur

a. La vision par ordinateur classique

L’application des technologies d’intelligence artificielle au domaine des images (images fixes ou vidéos) est désignée sous le terme de *computer vision*, vision par ordinateur en français. Le terme définit un sous-domaine d’application de l’intelligence artificielle qui permet d’entraîner un système d’IA à l’analyse des images fixes ou en mouvement⁸.

La vision par ordinateur s’appuie largement sur des modèles d’apprentissage machine (*machine learning*), qui désigne une branche de l’IA regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent⁹. L’apprentissage machine permet d’entraîner des algorithmes capables d’apprendre à partir de données d’entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données¹⁰. La vision par ordinateur classique s’appuie sur l’apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d’images fixes et d’images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d’intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques¹¹.

Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d’apprentissage machine¹². De plus, la plupart de ces corpus sont d’une taille conséquente, forçant ainsi la mise en place d’algorithmes de prédiction, puisque l’entraînement machine ne peut être mis en place sur l’ensemble des données,

⁷*Ibid.*

⁸Cole Stryker et Rina Diane Caballar, *Qu’est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

⁹J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

¹⁰IBM, *Qu’est-Ce Que Le Machine Learning (ML)?*, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹¹Niall O’ Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹²*Ibid.*

seulement sur un échantillon donné.

b. Vision par ordinateur fondée sur l'apprentissage profond

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds¹³. Ces modèles relèvent également de la vision par ordinateur, mais fondée sur l'apprentissage profond, permettant notamment de gérer l'analyse de flux vidéo. La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l'apprentissage machine. L'apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'exécuter des tâches automatisées, réduisant le besoin d'intervention humaine, et améliorant ainsi le rapport cout-efficacité¹⁴. Il suffirait de fournir au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données¹⁵. Par rapport aux techniques traditionnelles de vision par ordinateur, l'apprentissage profond permet d'obtenir une plus grande précision dans les tâches d'analyse audiovisuelle telles que la classification d'images, la segmentation, la détection d'objets¹⁶.

3. Transformers et réseaux de neurones convolutifs (CNN)

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la vision par ordinateur pour la classification d'images et la reconnaissance d'objets, est celui des réseaux de neurones convolutifs (CNN). Appliqués à des corpus d'images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d'en extraire les couleurs et les contours¹⁷. Les tâches que permettent les CNN sont plutôt bien adaptées à l'image fixe, puisqu'ils extraient des éléments fixes de l'image.

¹³Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

¹⁴N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

¹⁵*Ibid.*

¹⁶*Ibid.*

¹⁷Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

Néanmoins, d'autres modèles issus de l'apprentissage profond tels que les *transformers* s'avèrent davantage efficace sur des tâches dédiées à l'image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les *transformers* fonctionnent grâce à un mécanisme d'auto-attention qui leur permet de détecter les relations et dépendances entre les données¹⁸. Tandis que les CNN analysent les données de manière locale dans l'image, sans prendre en compte les interdépendances qui les régissent temporellement, les *transformers* examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d'entre elles¹⁹. Les CNN ne permettent pas, par exemple, de discerner les "dépendances à longue portée" telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins²⁰. Ainsi, ils seraient davantage adaptés à l'analyse d'images en mouvement puisqu'ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d'une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type *transformers*.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l'intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d'interpréter les analyses qui sont produites²¹. En effet, une fois entraînés, il est difficile d'en modifier les paramètres puisqu'ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi difficile à comprendre et à exposer²².

Deuxièmement, les algorithmes de type *transformers* sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe²³. Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d'un large jeu de données d'entraînement afin d'éviter un surapprentissage impliquant des biais multiples²⁴. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu'il s'agirait de réadapter à un contexte patrimonial²⁵.

¹⁸C. Stryker et Dave Bergmann, *Qu'est-ce qu'un modèle transformer ?*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

¹⁹*Ibid.*

²⁰*Ibid.*

²¹A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

²²N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

²³Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

²⁴Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

²⁵*Ibid.*

Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l’analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d’analyse automatique d’un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 4.1 ci-dessous permet de comparer les compétences des types de modèles cités pour l’analyse d’un flux vidéo.

Type d’approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan - Calcul d’histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d’objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d’images fixes extraites du flux vidéo - Détection d’objets ou caractéristiques dans l’image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 4.1 : Comparatif des approches de traitement audiovisuel automatique

Comme l’illustre le Tableau 4.1, si les architectures fondées sur les *transformers* offrent des compétences puissantes, notamment pour l’automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d’entraînement conséquents. À l’inverse, la vision par ordinateur classique offre une stabilité d’analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d’en extraire le sens. Ce constat justifie l’orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

II. Outils de segmentation automatique

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués d'archives audiovisuelles, leur architecture donne des pistes d'expérimentations afin de pouvoir implémenter un tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéo en différentes séquences. L'optique de cette étude est de fournir une proposition d'implémentation de fonctionnalités automatiques au sein d'un outil de gestion des collections d'un point de vue métier, en prenant en compte les besoins utilisateurs.

1. Décomposer le mouvement

Tout d'abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des *transformers*, une des solutions envisagée consisterait à transformer un flux d'images en mouvement en la série d'images fixes qui le composent. Ce processus écarterait notamment le besoin d'analyser les relations entre les images par un mécanisme d'auto-attention prévu par les *transformers*. En effet, le médium cinématographique se caractérise par l'enchaînement d'une succession d'images fixes produisant l'illusion du mouvement. La transformation de ce flux à l'état d'images fixes par un outil technique permettrait de pouvoir gérer l'analyse sémantique de ces images par des processus légers prévus par la vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d'analyse que ceux prévus pour l'image fixe, fondés sur la vision par ordinateur classique.

Cette segmentation d'un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d'une analyse sémantique, regroupant ces plans fixes en des séquence sémantiques. Dans un article sur la mise en place d'un processus de segmentation temporelle, Yuelin Xin prône notamment le découpage syntaxique tel que nous l'avons défini comme étape préliminaire à l'analyse sémantique des images par des modèles d'intelligence artificielle²⁶. La segmentation syntaxique d'un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

²⁶Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

Ainsi, la segmentation automatique d'un document audiovisuel en séquences serait fondée sur l'analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes²⁷. Ces plans sont en réalité retenus par l'algorithme comme des images-clés contenues au sein de chaque séquence, calculées comme l'image la plus représentative de la présence des éléments dans un flux donné²⁸. Ce principe, qualifié de sélection de données, permet d'alléger nettement la puissance de calcul et la structure des algorithmes²⁹. Ces images-clés seraient ensuite analysées par un algorithme fondé sur des CNN, afin d'y ajouter une analyse sémantique et de les regrouper en séquences.

2. PySceneDetect

Ce processus est notamment appliqué par la bibliothèque python *Pyscenedetect* qui permet la segmentation d'un flux vidéo à l'aide de différents paramètres définis en amont³⁰. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l'analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquence audiovisuelle, *Pyscenedetect* permet d'en extraire les images-clés, c'est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de vision par ordinateur classique (non fondé sur un algorithme d'IA), qui concrétise la mise en oeuvre de la comparaison syntaxique d'images fixes. L'outil s'appuie sur des détecteurs mathématiques afin d'analyser les différences structurelles entre les images-clés tirées d'une vidéo³¹. Il s'agit ainsi d'un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d'entraînement particulier, comme c'est le cas des outils de vision par ordinateur fondés sur l'apprentissage profond. *Pyscenedetect* permet d'isoler des images-clés de l'image animée, de les regrouper par similarité et de les dissocier selon leurs différences.

3. Fonctionnement

a. Paramétrages

Trois méthodes de détection sont proposées par l'outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l'image, une dé-

²⁷ *Ibid.*

²⁸ *Ibid.*

²⁹ *Ibid.*

³⁰ PySceneDetect, *Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³¹ *Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

tection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d'un plan avec les plans adjacents (méthode *detect-adaptive*)³². En théorie, *Pyscenedetect* isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d'images, et non des séquences, unités de sens narratives. Néanmoins, *Pyscenedetect* permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l'élévation de la valeur du seuil de détection ou la fixation d'une durée minimale de séquence (*min-scene-len*), l'outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu'en cas de détection de changements visuels majeurs tels que l'éclairage, le décor, la composition, etc³³. Par ce biais, la segmentation syntaxique proposée par *Pyscenedetect* pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l'outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquence retenue. Le diagramme de flux 4.1 ci-dessous illustre la manière dont l'outil pourrait être paramétré afin de segmenter le flux vidéo en séquences.




Figure 4.1 - Schéma du processus de détection de coupures par *Pyscenedetect*

Pour chaque changement détecté, une nouvelle séquence est ainsi créée et une images-clés est automatiquement enregistrée, associée au fichier vidéo d'origine. Nous proposerons la réutilisation de cette image au sein du processus suivant, dédié à l'analyse sémantique des séquences préalablement détectées, afin de ne pas surcharger les algorithmes. Ce système permettrait ainsi d'alléger le processus d'analyse sémantique, puisque les algorithmes reçoivent

³² *Ibid.*

³³ *Ibid.*

des images fixes au lieu de fichiers vidéos plus ou moins lourds.

b. Limites

Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Samarth Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus³⁴. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même après numérisation ou restauration³⁵. En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus³⁶. De plus, Samarth Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé³⁷. Toutefois, un des avantages majeurs de l'outil *Pyscenedetect* est sa disponibilité et la possibilité de le mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

III. Mise en application

1. Spécificités du corpus traité

Au sein du chapitre suivant, nous mettrons à l'épreuve l'adaptabilité de l'outil que nous avons décrit pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, construit par des plans fixes, en noir et blanc et muets. Nous tenterons d'appliquer le processus de segmentation proposé par *Pyscenedetect* sur un tel corpus, afin d'en comprendre les données qui pourraient être générées. Le corpus, utilisé ici comme cas d'étude, se caractérise notamment par son ancienneté, et donc par la dégradation de la pellicule sur laquelle l'image s'inscrit. L'outil pourrait ainsi rencontrer des difficultés lors de l'identification des coupures et des changements de plans, brouillés par la dégradation de l'image. Toutefois, la structure du contenu de ces archives facilite la tâche de l'outil, composé d'une succession de plans fixes, dont les coupures sont suffisamment marquées, en fait un

³⁴S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

³⁵*Ibid.*

³⁶J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

³⁷S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

corpus relativement bien adapté à ce type de tâche automatique, qui pourrait identifier les coupes plus facilement.

Par ailleurs, *Pyscenedetect*, nous l'avons vu, est un outil dédié à la détection de coupures et à la segmentation d'un flux vidéo en différents plans. Or, dans cette étude, nous cherchons à montrer comment segmenter un flux audiovisuel en différentes séquences, unités sémantiques autonomes. Dès lors, comment paramétrer un tel outil pour la détection d'éléments sémantiques plus larges tels que les séquences ?

a. Paramètres appliqués

Une solution envisagée serait d'augmenter la valeur du seuil de coupures (threshold), pour que l'outil ne détecte plus les micro-coupures entre les images mais des coupes plus larges, à l'échelle de séquences³⁸. L'outil enregistrerait alors un changement de séquence seulement lors d'une rupture significative de l'espace-temps à l'image. Ce paramétrage reste toutefois limité puisque plusieurs plans adjacents peuvent être radicalement différents d'un point de vue syntaxique, tout en appartenant bien à la même séquence. Par exemple, une même séquence peut contenir un gros plan et un plan d'ensemble, dont la composition visuelle est bien différente. Dans le cas du corpus d'archives audiovisuelles décrit, les plans restent larges et fixes, montrant l'ensemble du décor dans lequel ils s'inscrivent. Ainsi, le paramétrage du seuil pourrait être adéquatement réglé pour la détection de changements de décor, sur ce corpus donné, afin de segmenter le flux vidéo en différentes séquences.

Par ailleurs, il est possible de régler l'outil sur une durée minimale de détection de coupures à l'aide du paramètre "*min-scene-len*", pour que le processus n'effectue de coupures qu'après un laps de temps défini³⁹. La définition de ce paramètre nécessite une analyse statistique du corpus segmenté afin d'en définir la durée moyenne d'une séquence. Au sein du logiciel de gestion des collections prévu par Skinsoft, l'institution qui gère ce corpus d'archives documente déjà les séquences contenues par les différentes œuvres au sein des notices de films physiques, sous la forme de repères temporels. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de *time-codes* afin de déterminer la durée moyenne d'une séquence au sein du corpus. D'après nos observations, les séquences extraites sont généralement d'une durée de 60 secondes.

Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d'images plus importante, permettant à l'outil de comparer le contenu visuel d'un plan par rapport à une grande variété de plans qui l'entourent⁴⁰. Ce paramètre permettrait

³⁸ *Command-Line - PySceneDetect...*

³⁹ *Ibid.*

⁴⁰ *Ibid.*

encore de régler l'outil sur la détection de changements majeurs dans l'image, dans l'optique d'en extraire uniquement les séquences.

b. Données produites

Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données en sortie. D'une part, un fichier JSON ou CSV contenant les *time-codes* de début et de fin correspondant aux séquences identifiées au sein de chaque fichier vidéo ingesté. Chaque séquence est alors associée à un identifiant unique et à des *times-codes* de début et de fin. D'autre part, l'outil permet également d'extraire pour chaque séquence un fichier image, qui correspond à l'image fixe médiane, censée être la plus représentative de la séquence, désignée par le terme d'image clé⁴¹.

Ainsi, la mise en application de l'outil *Pyscenedetect*, de l'analyse des données d'origine jusqu'à la production des données de sortie, pourrait être schématisée de la manière suivante (fig. 4.2)

Toutefois, si ce paramétrage permettrait une plus grande flexibilité pour la segmentation d'un flux vidéo en séquences, l'outil reste limité dans l'automatisation de cette tâche. D'une part l'outil est prévu pour la détection automatique de changement de plan, et d'autre part, une séquence ne se définit pas seulement comme une caractéristique syntaxique du langage cinématographique, comme c'est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence concrétise un choix narratif, matérialisé généralement par un changement d'espace-temps. C'est pourquoi, un outil dont l'automatisation est fondée sur des seuils mathématiques reste limité pour une telle tâche. Nous proposons alors de réaliser une analyse sémantique des séquences détectées, afin de réassocier leur sens à ces coupures détectées automatiquement, tout en réutilisant les données produites : les *times-codes* et l'image clé associés à chaque séquence.

Ainsi, la segmentation syntaxique effectuée par *Pyscenedetect* constitue un “filtre”, c'est-à-dire un premier niveau dans notre chaîne d'indexation automatique des archives audiovisuelles⁴². Les données issues de ce premier niveau permettent d'amoindrir le volume de données, caractéristique des fichiers vidéo, transmis aux algorithmes d'indexation automatique. Dès lors, les images-clés produites par *Pyscenedetect* peuvent être soumises à un modèle neuronal de détection d'objets tel que *YOLO* (*You only look once*), afin d'extraire le sens de ces segments et leur rendre leur valeur sémantique. La sous-section suivante détaille la manière dont ce modèle, appliqué aux images-clés issues des différentes séquence, permet d'en extraire les caractéristiques sémantiques à des fins d'indexation.

⁴¹ *Ibid.*

⁴² Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*




Figure 4.2 - Mise en application de *PyScenedetect*

Chapitre 5

Décrire et indexer les séquences automatiquement

La valeur d'une séquence, au sein d'un flux audiovisuel, réside non seulement dans sa délimitation temporelle mais également sémantique. Ainsi, une description sémantique doit être articulée à la segmentation dont elles sont issues, afin de la justifier. Dans le contexte du corpus choisi, le besoin, articulé à une segmentation automatique, est celui d'une description automatisées des séquences produites par mots-clés. Ainsi, ce chapitre propose un second processus de description et d'indexation, fondé sur le modèle *YOLO*.

I. Choisir un modèle d'IA adapté

La description centrée sur la production de mots-clés peut être réalisée par la détection automatique d'objets au sein des images-clés produites, et ainsi reposer sur un processus plus léger. Cette tâche peut en effet être réalisée automatiquement par des architectures de réseaux de neurones relativement légers, pouvant extraire des concepts à partir de l'analyse de l'image, et les rendre directement indexables au sein du logiciel.

1. Appliquer les algorithmes aux données

En effet, si pour la tâche de segmentation nous avons écarté les architectures de modèles fondés sur des réseaux de neurones, la reconnaissance d'objets dans l'image suppose une prédiction par des réseaux de neurones, dont l'architecture est fondée sur l'apprentissage profond. La plupart des outils de reconnaissance d'objets dans l'image sont fondés sur des CNN dont nous avons exposé le fonctionnement. Dans le domaine patrimonial, l'infrastructure choisie doit être adaptée afin qui d'assurer la sécurité des données produites. Or les

solutions commerciales d'analyse automatique sont pour la plupart implémentées via un système infonuagique externe, qui implique le déplacement des données. Ces solutions s'avèrent donc inadaptées au contexte d'analyse de données patrimoniales pour des raisons de propriété intellectuelle et de sécurité. Ainsi, le principe retenu afin de guider notre choix d'outil est celui d'"amener l'algorithme aux données [Traduction personnelle]"¹, via un développement local interne des modèles d'analyse². Afin de répondre à cette contrainte, notre choix s'est tourné vers des modèles en libre accès. Nous détaillerons dans cette section l'utilisation de l'architecture *YOLO*, une série d'algorithmes dédiés à la détection d'objets visuels dans les images et les flux vidéo, et fondé sur les réseaux neuronaux convolutifs, développé par Joseph Redmond en 2015, puis repris par Ultralytics en 2020³.

2. *YOLO*

YOLO est l'un des outils de détection d'objets les plus documentés, y compris dans le domaine des sciences humaines et du patrimoine. Fondé sur la vision par ordinateur et entraîné grâce à des méthodes d'apprentissage profond, *YOLO* est disponible en accès libre, et permet notamment la détection d'objets et la classification d'images, permettant ainsi de poser les bases d'une indexation⁴. Le modèle extrait dans un premier temps les caractéristiques visuelles de l'image qui lui est donnée, les agrège, afin de finalement proposer une détection d'objets⁵. Les versions récentes du modèle telles que YOLOv12 ne sont désormais plus seulement basées sur des CNN mais sur des mécanismes d'auto-attention, similaires à ceux des *transformers* dont nous avons évoqué l'architecture⁶. Toutefois, comme nous l'avons évoqué, cette architecture demande une consommation de mémoire élevée et une puissance de calcul lourde⁷. Ultralytics, créateur du modèle, recommande des versions moins avancées pour une mise en application rapide, telles que la version YOLOv8, uniquement fondée sur un réseau de neurones convolutif⁸. YOLOv8 propose une version optimisée de cette architecture en trois temps : extraction, aggrégation, et détection⁹. Le modèle se caractérise par

¹ "bring algorithms to the data"

²N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

³Ilyes Talbi, *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).

⁴Glenn Jocher, *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.

⁵J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁶Ultralytics, *YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).

⁷*Ibid.*

⁸Id., *Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).

⁹Muhammad Yaseen, *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].

sa capacité à analyser l'image en une seule fois, contrairement à d'autres modèles dont les résultats impliquent plusieurs analyses de certaines parties de l'image¹⁰.

3. Intégration au processus

Si la détection d'objets prévue par *YOLO* peut être appliquée à des flux vidéo, nous souhaitons l'intégrer comme composant complémentaire au processus de segmentation précédemment décrit. De fait, il peut être pertinent de réutiliser l'image-clé fixe, produite et sauvegardée par l'outil *Pyscenedetect*, associée à chaque séquence, afin de la faire analyser par le modèle. Ceci permettrait de réduire le temps de calcul du processus et d'améliorer l'efficacité des prédictions, puisque le modèle reçoit un minimum d'informations. Ainsi, l'application du modèle *YOLO* s'impose comme la suite logique du pipeline de segmentation détaillé précédemment, afin d'indexer les segments produits, via l'utilisation des images-clés. Si le premier processus de segmentation produit des données temporelles associées à chaque séquence sous la forme de *time-codes*, *YOLO* produit des données sémantiques sur ces mêmes séquences. À l'issue de l'analyse d'une images-clés, le modèle *YOLO* est capable de produire trois types de données : des étiquettes sur les objets identifiés, un score de confiance qui indique l'indice de certitude concernant la prédiction, des coordonnées spatiales de localisation de l'objet détecté dans l'image¹¹. Les étiquettes produites sur les objets identifiés, permettant de décrire les caractéristiques de l'image, pourront être indexées comme des mots-clés au sein du logiciel de gestion des collections. Le processus de détection d'objets prévu par *YOLO* à partir d'une image-clé est schématisé par la figure 5.1.

Les mots-clés produits à partir des étiquettes sont ensuite associés aux *time-codes* de chaque séquence détectée. Ainsi, chaque séquence contiendrait les données suivantes : des repères temporels qui l'identifient comme extrait, des étiquettes/mots-clés sur les objets qu'elle contient, et des données qui permettraient aux utilisateurs de vérifier la prédiction et de la valider. Le score de confiance produit par le modèle, permet en effet d'indiquer à l'utilisateur la certitude de l'étiquette associée à tel objet détecté. De même, les coordonnées spatiales de l'étiquette produite permettent à l'utilisateur de vérifier dans l'image si l'étiquette produite est associée au bon objet.

¹⁰Joseph Redmon, Santosh Divvala, Ross Girshick et Ali Farhadi, *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

¹¹*Ibid.*




Figure 5.1 - Processus de détection d'objets de *YOLO*

II. Entraînement du modèle YOLO

1. Apprentissage supervisé et non supervisé

L'analyse automatique du contenu des images repose donc sur une architecture de type CNN, fondée sur des méthodes d'apprentissage profond, dont *YOLO* est un exemple concret. Toutefois, les algorithmes fondés sur l'apprentissage profond subissent généralement un entraînement supplémentaire afin d'analyser adéquatement le contenu des images en fonction d'un contexte donné.

Deux approches méthodologiques d'entraînement peuvent être appliquées, l'apprentissage supervisé et l'apprentissage non supervisé. L'apprentissage supervisé est fondé sur l'utilisation de données annotées pour l'amélioration des prédictions du modèle d'analyse d'image, tandis que l'apprentissage non supervisé exécute des tâches d'analyse et de classification à partir de données brutes, non annotées¹². Toutefois, l'apprentissage non supervisé ne permet

¹²Julianna Delua, *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL :

pas d'adapter suffisamment le modèle de détection d'objets au corpus d'images spécifique étudié. En effet, si Yolov8 a toutefois fait l'objet d'un pré-entraînement en amont de sa mise à disposition, sur le jeu de données COCO, ce dernier, composé de 200 000 images annotées, reste généraliste et adapté à la détection d'objets communs contemporains¹³. Or, l'efficacité des modèles basés sur l'apprentissage profond sur un corpus spécifique dépend fondamentalement de nature et de la qualité de leur données d'entraînement.

Au sein des sous-sections suivantes, nous prendrons comme exemple d'application le projet des Archives britanniques en ligne, qui proposent une chaîne de traitement pour la détection d'objet basée sur l'apprentissage profond et la supervision humaine¹⁴. Le projet, à travers la mise en place d'une supervision au sein du processus d'analyse par le modèle, propose de mettre en application le concept de "Human in the loop", c'est-à-dire de placer au cœur du processus l'intervention humaine¹⁵.

2. Annotation des données

Le corpus étudié, caractérisé par l'ancienneté de ses images en fait un corpus d'images spécifique sur lequel l'algorithme doit subir un entraînement supplémentaire, supervisé. Afin d'adapter le modèle à notre corpus et ainsi d'en améliorer l'efficacité, une phase de pré traitement est nécessaire sur les données du corpus, au cours de laquelle des images sont sélectionnées afin d'être annotées pour être pré-testées par le modèle¹⁶. La supervision humaine est déterminante dans ce processus, particulièrement dans le cas d'analyse de corpus inédits sur lesquels l'algorithme reste à entraîner¹⁷. Les archives britanniques implémentent l'adaptation du modèle par la pré sélection d'un nombre d'images défini, toutes annotées manuellement à l'aide de la plateforme *Label Studio*¹⁸. *Label Studio* est une plateforme en accès libre et déployable localement, permettant ainsi de respecter la protection des données analysées¹⁹.

<https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

¹³V7 Darwin, *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

¹⁴Surya Kasturi, Alex Shenfield, Chris Roast, Danny Le Page et Alice Broome, « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

¹⁵*Ibid.*

¹⁶*Ibid.*

¹⁷*Ibid.*

¹⁸*Ibid.*

¹⁹Label Studio, *Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).

Afin d'éviter l'annotation manuelle de l'ensemble des images-clés issues du processus de segmentation, il peut être envisagé d'exécuter au préalable *YOLO* depuis *Label Studio* sur l'ensemble des images-clés du corpus afin de générer une base de prédictions²⁰. Les détections brutes générées peuvent ensuite être importées au sein de la plateforme comme une couche d'annotation préalable à partir de laquelle affiner le modèle. Au sein de *Label Studio*, les prédictions s'affichent sous la forme de *bounding boxes*, c'est-à-dire de boîtes englobantes autour des objets détectés dans l'image, avec le score de confiance qui y est associé²¹. Le paramètre *choices* permet au modèle de proposer une classification sur les objets détectés, c'est-à-dire un mot-clé²². Afin de focaliser la supervision du modèle sur les éléments les plus pertinents, il peut être décidé de ré-annoter les images dont la détection est jugée incertaine par le modèle, via un score de confiance en dessous du seuil minimal attendu²³. Les archives britanniques préconisent également la suppression des boîtes englobantes redondantes afin de sélectionner celles qui sont les plus pertinentes pour la supervision humaine²⁴.

3. Affinage du modèle

Dans *Label Studio*, les utilisateurs (une équipe technique dans le cas de Skinsoft) examinent les prédictions ainsi générées sur les images, rectifient si besoin la définition des "boîtes" et la classification associée²⁵. Les données ainsi corrigées sont exportées au format *YOLO* depuis *Label Studio*, puis réinjectées dans la chaîne de réentraînement du modèle afin d'améliorer les performances en accord avec le corpus²⁶. Cette méthode s'appuie sur le transfert d'apprentissage (transfert learning), qui consiste à *fine tuner* un modèle existant, c'est-à-dire de l'affiner, afin de l'adapter au corpus analysé²⁷. À défaut de réentraîner le modèle dans sa globalité, les prédictions réalisées à partir du jeu de données d'entraînement COCO sont conservées puis spécialisées sur un corpus donné²⁸. L'affinage du modèle via la rectification et l'annotation des données, constitue une étape de prétraitement, en amont

²⁰SO Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).

²¹S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

²²Label Studio, *Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).

²³S. Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline...*

²⁴S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

²⁵*Ibid.*

²⁶*Ibid.*

²⁷S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

²⁸*Ibid.*

de l'analyse des données, afin d'améliorer l'efficacité de la détection d'objets²⁹. Cette étape de pré-traitement, avant le processus d'analyse, implique la définition des types de mots-clés souhaités, pour l'indexation des séquences. En effet, les étiquettes associées aux objets au sein des images correspondent aux mots-clés qui seront prédits par le modèle lors de l'analyse. Dans le cadre du corpus étudié, il est pertinent d'extraire les mots-clés déjà indexés sur les séquences au sein du logiciel. Ces mots-clés varient selon le contenu de l'image et peuvent, par exemple, être les suivants : affiche, foule, policier, gendarme, drapeau, etc. Ces mots-clés, tout comme le jeu de données COCO, sont assez génériques. De fait, le pré-traitement est avant tout utile pour l'entraînement du modèle à pouvoir détecter des objets au sein d'images dont la qualité est compromise.

III. La mise en place d'un processus de validation technique

Afin de gérer les essais-erreurs de l'affinage du modèle sur les données spécifiques du corpus, il est pertinent de mettre en place un processus de validation technique du traitement. Ce processus permettrait d'une part de valider les résultats du modèle, et d'autre part, d'assurer la concordance entre les données produites par le modèle avec les données déjà existantes au sein du logiciel.

1. Validation et correction des prédictions

La validation des prédictions du modèle peut être effectuée au sein de la plateforme *Label Studio*. Les archives britanniques proposent notamment que le jeu de données test utilisé précédemment afin de corriger les prédictions, soit distinct d'un second jeu de données test, dédié à l'évaluation des performances du modèle, à différents niveaux de supervision humaine³⁰. Sur ce second jeu de données, sont notamment intégrées des métadonnées de supervision humaine. En effet, Kasturi explique l'introduction des notations "HIL-10 %, HIL-15 % et HIL-20 %, qui signifient respectivement que les utilisateurs ont corrigé 10 %, 15 % et 20 % des boîtes englobantes prédites peu performantes dans l'ensemble de données de test. [Traduction personnelle]" ³¹.

Le modèle ainsi affiné est finalement exécuté sur le second jeu de données, corrigé selon

²⁹S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

³⁰*Ibid.*

³¹ "HIL-10%, HIL-15%, and HIL-20%, which signify that users have corrected 10%, 15%, and 20% of poorly performing predicted bounding boxes in the test dataset, respectively" *Ibid.*

différents niveaux d'intervention humaine³². Pour chaque niveau de supervision, sont analysés les "scores moyens d'Intersection over Union (mIOU) et de précision moyenne (mAP), ainsi que de la précision et du rappel"³³. Les résultats obtenus montrent que les performances du modèle s'améliorent considérablement à mesure que le pourcentage d'images corrigées manuellement augmente³⁴. En effet, l'enrichissement du jeu de données permet au modèle d'appréhender l'analyse des images de manière plus précise. L'auteur note toutefois la nécessité de poursuivre l'évaluation du modèle sur d'autres données afin de vérifier son adaptabilité et ses performances pour la détection d'autres types d'objets³⁵. En effet, le modèle devrait être ré-entraîné constamment, à mesure qu'il est exécuté sur de nouvelles données.

2. Préparation de l'indexation des données produites

De plus, le processus de validation technique implique également la validation de l'indexation des données produites au sein du logiciel, en adéquation avec les règles métier en place. Au sein de l'espace de travail S-Movies dédié au corpus étudié, l'indexation des mots-clés est contrôlée par le thésaurus "keyword". Or, le modèle *YOLO* est nativement pré-entraîné sur un jeu de données généraliste dont les étiquettes produites ne correspondront pas directement aux autorités indexées dans la base de données.

Deux cas peuvent être gérés par l'utilisateur côté technique. D'une part, les mots-clés produits par le modèle peuvent déjà être indexés sous une forme contrôlée au sein du logiciel. Dans ce cas, il revient à l'utilisateur de vérifier que les mots-clés générés par le modèle concordent avec la forme indexée contrôlée au sein du logiciel. À terme, cette tâche de validation pourra être gérée par un *Large language model* (LLM), un grand modèle de langage, déjà employé par Skinsoft pour un outil de recherche en langage naturel par exemple, dont le détail peut être aperçu au sein de l'annexe B (chapitre B). Un LLM, fondé sur une IA générative, permet le dialogue avec l'utilisateur et de comprendre le contexte des demandes qui lui sont adressées. Ce LLM pourra être capable, à partir du thésaurus indexé dans le logiciel, de valider les formes contrôlées des mots-clés générés par *YOLO*, sur demande de l'utilisateur technique. Pour cela, un *mapping*, un tableau de correspondance, pourra être fourni au LLM entre les mots-clés que le modèle peut potentiellement générer, et leur forme contrôlée dans le thésaurus. Nous avons effectivement déjà élaboré un tel tableau au cours de notre stage dans le cadre de la mise en place de IA pour d'autres tâches, notamment la mise en place d'une recherche en langage naturel, développée en annexe B (B. Pour cette

³² *Ibid.*

³³ *Ibid.*

³⁴ *Ibid.*

³⁵ *Ibid.*

tâche tout à fait différente que celle que nous décrivons dans ce mémoire, nous avons effectué une table de correspondance entre les champs contrôlés pouvant être requêtés dans le logiciel et leur définition en langage naturel, préparant ainsi la gestion de synonymes et de termes employés par l'utilisateur potentiellement pour requêter ces champs. Sur le même principe, nous pourrions mettre en place une table de correspondance afin d'assurer la validation des données produites et d'assurer *in fine* leur indexation au sein de l'application. Un calcul de similarité aide le LLM à repérer les termes similaires et les rapprocher de leur forme contrôlée.

D'autre part, si les mots clés n'existent pas sous une forme contrôlée au sein du thésaurus et qu'aucune correspondance n'est détectée, un nouveau terme de thésaurus pourra être créé au sein du logiciel, avec l'accord de l'utilisateur.

L'approche retenue afin de décrire automatiquement le contenu des séquences est celle de l'implémentation du modèle *YOLO*, dont le temps de calcul et de prédiction est réduit par son application aux images-clés issues de la segmentation. L'efficacité du processus repose sur la supervision et la validation humaine, côté technique, des prédictions produites par le modèle, en accord avec les règles métier du logiciel. Toutefois, l'indexation définitive au sein du logiciel doit être validée par l'utilisateur métier via une interface dédiée, et au sein du modèle de données FRBR.

Chapitre 6

Indexation des données produites au sein du modèle de données

L'objet de notre étude est le reversement des données produites par l'indexation automatique au sein du modèle FRBR, adapté aux archives audiovisuelles. Si les outils d'extraction automatique tels que YOLOv8, nécessitent un réentraînement spécifique au corpus étudié, une seconde difficulté s'impose, celle de l'alignement de ces données avec un modèle de données personnalisé. Le modèle de données FRBR est, en effet, configuré selon les besoins métier de chaque institution et conditionne l'organisation des données pour l'utilisateur au sein de l'interface. Dès lors, comment reverser des données produites automatiquement, au sein d'un modèle de données configurable ? Ce reversement concrétise en effet l'indexation automatique, puisque les données deviennent visibles et requêtables par les utilisateurs, au sein de l'interface du logiciel.

I. Prévoir le reversement des données au sein du FRBR

Le processus automatisé proposé repose sur l'exécution de deux phases : d'une part la segmentation temporelle d'un flux vidéo (générant des time-codes et images-clé), et d'autre part la détection et la classification d'objets (générant des mots-clés). L'enjeu est de prévoir la structuration de ces différents types de données, chiffrées et textuelles, au sein du modèle FRBR existant.

1. La création d'une nouvelle entité

Les outils automatiques utilisés lors du processus ont extrait des données depuis un média, associé au niveau de l'Item numérique au sein du modèle de données préexistant.

Or, le niveau Item contient des éléments de description matérielle techniques, alors que les mots-clés et repères temporels relèvent d’une description intellectuelle et syntaxique. Dès lors, la création d’une entité intellectuelle dédiée à la séquence s’impose.

Afin d’illustrer l’intégration d’une entité de description intermédiaire, entre l’Œuvre et l’Item numérique, prenons l’exemple de la plateforme Okapi (*Open and Knowledge-based Annotation and Publishing Interface*), développée par le département Recherche et Innovation de l’INA¹. Afin de favoriser la description collaborative de contenus multimédias, la plateforme offre la possibilité aux utilisateurs de concevoir des modèles de description personnalisés². La plateforme permet notamment de séparer l’extrait audiovisuel du média, dont il constitue un niveau descriptif propre. Une strate supplémentaire de description est ainsi dédiée à la description intellectuelle du média. Le modèle FRBR tel que nous l’avons décrit ne propose, a priori, pas d’entité descriptive dédiée à la séquence. L’entité ”d’agrégats”, proposée par le manuel de la FIAF pourrait y correspondre. Toutefois, ceux-ci “sont conçus et créés dès le début pour rassembler plusieurs composantes individuelles formant un tout.”³. Or, au sein du corpus étudié, les *rushes* ne font pas partie d’un montage. Toute segmentation est une interprétation *a posteriori* de la construction de l’archive, et donc un remontage. L’entité de ”fragment d’expression” proposé par l’IFLA au sein du modèle FRBR bibliographique semble plus adéquate⁴. L’IFLA définit le fragment comme “des parties d’expressions qui ne constituent pas elles-mêmes des expressions autonomes.[...] Un « Fragment d’expression » n’est identifié qu’en fonction de son occurrence au sein d’un tout connu ou supposé.”⁵. Cette entité semble correspondre à la notion de séquence telle que nous l’avons décrite. Elle serait rattachée à l’Œuvre, conformément à l’adaptation du FRBR par les recommandations de la FIAF, et permettrait le reversement spécifique des times-codes et mots-clés. La figure fig. 6.1 ci-dessous illustre l’intégration de l’entité du Fragment d’oeuvre au modèle de données existant.

¹Steffen Lalande, Abdelkrim Beloued et Odile Farge, « La plateforme Okapi pour l’analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.

²*Ibid.*

³FIAF, *Le manuel de catalogage des images animées de La FIAF...*

⁴iflstandards.info, *Frbroo*, mars 2026, URL : <https://www.iflstandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).

⁵*Ibid.*




Figure 6.1 - Intégration du Fragment au modèle de données

Au sein de la plateforme Okapi, la création d’une entité intermédiaire de description, permet aux données descriptives produites à partir du média, d’être reversées au sein d’un niveau parent essentiellement descriptif, celui de l’extrait.

2. Application de l’indexation au sein du modèle de données

Au sein du modèle de données existant, adapté au corpus étudié, les time codes et les mots-clés sont déjà indexés manuellement en tant que données au sein de l’application. En effet, les times codes sont renseignés au niveau de l’item numérique, dans un champ notes, et l’Item comporte le champ type renseigné par la valeur “fichier time codé”, afin de signifier sa qualité d’extrait. De plus, les mots-clés sont renseignés au niveau de l’indexation de l’Œuvre, donc du *rushes* original. La modélisation de la segmentation au sein du modèle actuel implique un nombre conséquent de relations entre les éléments, complexifiant ainsi la navigation de l’utilisateur. En effet, une notice d’Item physique renseigne tous les extraits numériques (items numériques) qui lui sont liés. L’Item numérique (segment) renseigne le film physique duquel il est extrait, tandis que le niveau Œuvre renseigne uniquement les extraits numériques qui lui sont associés.

La création d’une nouvelle entité simplifierait la navigation au sein de l’interface et permettrait de séparer la description en différents niveaux, intellectuel et technique, conformément aux principes du FRBR. La nouvelle entité de Fagment permettrait éventuellement de préciser un contexte de segmentation et des champs dédiés aux mots clés et aux time codes. Le tableau 6.1 ci-dessous illustre la répartition de la description entre le fragment d’Œuvre et l’Item numérique. Pour des raisons de clarté, d’autres données descriptives ont

été intégrées afin d'illustrer la répartition entre la description intellectuelle et matérielle.

Entité FRBR	Champ / Attribut	Exemples de valeurs
Fragment d'Oeuvre (<i>Description intellectuelle</i>)	Contexte	Segmentation automatique de tel item physique
	Description générale	Description du contenu sémantique de la séquence
	Processus de segmentation	Automatique (Outil utilisé et paramètres appliqués)
	Time codes	Time codes de début et de fin de la séquence
	Mots-clés	Mots-clés extraits par YOLO
	Image-clé associée	Lien direct vers le fichier de l'image-clé
	Oeuvre parente	Identifiant de l'oeuvre associée, lien direct vers la notice
	Item physique associé	Identifiant de l'item physique associé dont est tirée la séquence, lien direct vers la notice
	Item numérique associé	Identifiant de l'item numérique associé, lien direct vers la notice
Item Numérique (<i>Description technique et matérielle</i>)	Fragment associé	Identifiant du fragment associé, lien direct vers la notice
	Données techniques	Résolution de l'image, taille, format
	Données de conservation	Emplacement, contenant
	Média associé	fichier média de la séquence

TAB. 6.1 : Attributs et exemples de valeurs associées aux entités Fragment d'Expression et Item Numérique.

Les métadonnées automatiquement produites seraient intégrées au niveau du Fragment, tandis que l'Item numérique contiendrait le média et les données techniques.

3. Adaptation des configurations

Une difficulté subsiste toutefois. En effet, les processus s'exécutent au niveau du fichier numérique et de son média, tandis que les métadonnées produites doivent pouvoir enrichir un niveau descriptif supérieur, celui du Fragment. Deux configurations peuvent être envisagées afin d'opérer ce reversement automatiquement. D'une part, l'application gère actuellement l'héritage des données d'un niveau supérieur à un niveau inférieur via la configuration de méta-masques, qui ciblent les niveaux inférieurs au sein desquels reverser les données. Néan-

moins, le processus automatisé décrit impliquerait la configuration de masques ascendants, permettant de reverser des métadonnées générées au niveau de l'Item, vers l'entité de Fragment. Cette configuration complexifie toutefois la compréhension du modèle de données. D'autre part, pourrait être envisagée la mise en place d'un tableau de correspondance ou d'un script permettant d'associer les sorties de données du processus aux entités dans lesquelles elles doivent être injectées. Une fois la modélisation du transfert établie entre les métadonnées automatiquement produites, et le modèle de données existant, le reversement définitif est toutefois laissé à l'utilisateur métier, au sein de l'interface du logiciel.

II. Proposer une interface de validation pour l'utilisateur

Si la redéfinition du modèle FRBR s'effectue en *backend* de l'application, par les équipes techniques et les équipes métiers du logiciel, afin de préparer l'implémentation de processus automatiques, les étapes de ces processus doivent toutefois être restituées au sein de l'interface auprès de l'utilisateur métier. Afin de donner à l'utilisateur le rôle de validation finale sur les données produites, l'espace de travail S-Movies doit permettre de visualiser les résultats afin de les valider.

1. Un enjeu de transparence

En effet, dans le cadre de l'implémentation de fonctionnalités automatiques, fondées sur l'intelligence artificielle, la Commission Nationale de l'Informatique et des Libertés (CNIL) recommande que les utilisateurs soient familiarisés au fonctionnement et aux limites de ces outils, par exemple "la manière dont sont produites les sorties, les éventuels transferts de données, ainsi que les usages autorisés et les usages interdits"⁶. Ces informations pourraient notamment guider l'utilisateur pour la validation des données produites par les modèles. Si l'exposition de ces étapes peut être effectuée au sein de modes d'emploi dédiés, comme Skinsoft le prévoit déjà, les informations relatives aux fonctionnalités automatiques devront toutefois être directement intégrées à l'interface pour un souci de transparence. Ainsi, la CNIL recommande que "l'intégration de briques d'IA générative dans un système d'information (SI) devrait être pensée avec des éléments de design informant clairement les utilisateurs de l'origine de la proposition [...]"⁷.

⁶CNIL, *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).

⁷*Ibid.*

De plus, en cas de non-validation des données produites par l'utilisateur, il pourrait être pertinent de proposer "un point de contact pour remonter des problèmes ou des difficultés d'ordre éthique"⁸. L'interface devra ainsi prévoir un formulaire décrivant la raison du refus des données, envoyé à l'équipe technique afin que l'algorithme puisse être amélioré, voire affiné. Au cours de notre stage, un système similaire a été proposé afin de prévoir la gestion des erreurs d'un outil de recherche en langage naturel, visible en Annexe B (B). Un formulaire est prévu pour l'utilisateur en cas de résultats non pertinents pour que le processus soit amélioré.

2. Développer une interface dédiée à la validation de l'utilisateur

Si notre étude ne relève pas de l'IA générative, il est toutefois pertinent d'offrir à l'utilisateur un niveau de transparence maximal au sein de l'interface, via la visualisation des données produites et leur validation finale. À l'image des deux phases de traitement automatiques développées dans les sections précédentes (segmentation et classification), la validation côté interface pourra prendre la forme de deux phases de décision. Il pourra d'abord être demandé à l'utilisateur d'actionner ou non le processus de segmentation puis de le valider ou de l'invalidier. Une fois le processus de segmentation finalisé, l'utilisateur pourra décider de déclencher le processus de détection d'objets sur les segments produits, puis de finalement les modifier ou de les valider.

Afin de concrétiser le processus de validation côté interface, nous nous appuyons sur l'exemple de la plateforme Amalia.js, développée par l'INA en 2015, conçue pour visualiser les résultats d'algorithmes d'analyse audiovisuelle⁹. Le besoin à l'origine d'Amalia.js est donc de permettre de visualiser les résultats divers issus de pipelines d'automatisation¹⁰. Cette interface permettrait d'une part de visualiser les résultats et d'autre part, de vérifier la conformité des données produites en lien avec les standards métiers en vigueur au sein du logiciel¹¹. L'interface permet également d'annoter directement le flux vidéo afin de corriger les données produites¹². La correction effectuée par l'utilisateur permet de constituer des données d'entraînement supplémentaires afin d'améliorer les algorithmes d'indexation automatique¹³. Amalia.js intègre notamment un *plugin* de *timeline* pour l'affichage des segments temporels et des images-clés associées, ainsi qu'un *plugin* de superposition (*overlay*) qui permettrait

⁸ *Ibid.*

⁹ INA, *Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).

¹⁰ Nicolas Hervé, Pierre Letessier, Mathieu Derval et Hakim Nabi, « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

¹¹ *Ibid.*

¹² *Ibid.*

¹³ *Ibid.*

l'affichage de l'encadrement des objets détectés¹⁴. Plutôt que de développer deux modules distincts, cette logique pourrait être combinée au sein de S-Movies sous la forme d'un module d'édition des données. Ce module présenterait d'abord à l'utilisateur la ligne temporelle des séquences associées aux images-clés, puis après leur validation, le module prévoierait l'ouverture d'une fenêtre d'édition latérale contenant les propositions de mots-clés et les objets détectés entourés au sein des images-clés. Ce module d'édition s'inspire du *plugin Editor* au sein d'Amalia.js dont la figure 6.2 ci-dessous illustre la disposition :




Figure 6.2 - *Plugin Editor* dans Amalia.js¹⁵

En cas de modification par l'utilisateur, l'interface pourrait enregistrer les données validées, tout en les envoyant en *backend*, afin que le processus soit amélioré. Le développement

¹⁴INA, *Amalia.Js - Metadata Enriched HTML5 Video Player...*

de l'interface serait ainsi conforme à la mise en place d'une automatisation facilitatrice de la création de données, en incitant l'utilisateur "à vérifier les données fournies en entrée et la qualité des sorties"¹⁶.

3. Déroulé du processus de validation

Concrètement, en *frontend*, dans l'interface de l'application prévue pour l'utilisateur, le processus suivant peut-être imaginé, illustré par un diagramme de décision (6.3) :

¹⁶CNIL, *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative...*




Figure 6.3 - Processus de validation de l'utilisateur métier

Ce processus permet de laisser l'utilisateur métier décider de l'indexation des données via l'actionnage ou non des fonctionnalités automatiques. L'utilisateur décide en amont du processus, et valide ensuite les données produites à es fins d'indexation.

III. Requêter les données produites

1. Une indexation fine du contenu

Une fois les données validées et indexées au sein du modèle de données, elles modifient l'accès au contenu des archives. L'indexation de séquences décrites par une nouvelle entité de description, permet à l'institution de non plus seulement avoir accès aux archives dans leur globalité, mais à une "indexation fine" de leur contenu¹⁷. Ainsi, par une recherche de mots-clés, l'utilisateur peut directement accéder aux segments d'archives concernés. La modélisation descriptive prévue par le FRBR permet de conserver le contexte du fragment, associé d'une part à l'Œuvre dont il est extrait, et d'autre part au média numérique associé. Les liens entre le fragment et les entités liées sont toujours requis, empêchant ainsi un risque de désolidarisation du contexte.

Les séquences créées par le processus automatique pourront ainsi être requêtées par l'utilisateur via les outils de recherche offerts par le logiciel développé par Skinsoft. En effet, le logiciel propose les modes de recherche suivants : recherche simple, recherche avancée, recherche plein texte ciblée, recherche par image. De plus, une recherche en langage naturel, basée sur le *Natural Language Processing* (NLP) et sur une génération augmentée de récupération (*Retrieval-Augmented Generation* (RAG)), imaginée au cours de notre stage, est en cours de développement au sein du logiciel (visible en annexe B (B)).

2. Requêter le contenu audiovisuel

Ce mode de recherche permet à l'utilisateur de formuler des requêtes complexes en langage naturel, afin d'améliorer l'expérience de navigation au sein de l'interface. L'utilisateur, via ce mode de recherche, n'a plus besoin d'employer les mots-clés exacts pour obtenir certains résultats. Par exemple, il peut formuler la requête suivante : "toutes les archives sur des défilés militaires". Le moteur effectue ensuite le lien entre la formulation de l'utilisateur en langage naturel, et les mots-clés indexés sur les séquences. Les résultats de recherche pourront par exemple présenter les séquences contenant les mots-clés suivants : "foule", "drapeau", "armée", "police". Une fois les résultats de recherche présentés, l'utilisateur peut cliquer sur une

¹⁷B. Bachimont, *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).

notice et accéder directement au média lié à une séquence spécifique, au sein d’une grille de recherche. Cela permet une large découvrabilité des archives, concrétisant ainsi les besoins utilisateurs fondateurs du modèle FRBR, de ”trouver, identifier, sélectionner, obtenir”¹⁸. Les résultats de recherche pourront présenter en vignette, l’image clé associée au segment décrit, sur laquelle l’utilisateur peut cliquer.

3. Perspectives d’outils de recherche innovants

Outre la recherche textuelle, l’indexation fine des contenus audiovisuels peut développer l’usage d’autres modes de recherche visuels innovants. Le moteur Snoop, développé conjointement par l’INA et l’Institut national de recherche en informatique et en automatique (Institut national de recherche en informatique et en automatique (INRIA)), permet de croiser une exploration fine des contenus audiovisuels avec une interactivité qui place l’utilisateur au centre¹⁹. Fondé sur un bouclage de pertinence, il permet, à partir d’une requête sur une caractéristique visuelle, de proposer à l’utilisateur des résultats pertinents que celui-ci peut annoter comme résultats pertinents ou non pertinents²⁰. Le moteur prend ces annotations en compte afin d’affiner la pertinence des résultats de recherche. Ce moteur innovant suit la même logique que l’interface de validation pensée sur le modèle d’Amalia.js, et que le mode de recherche en NLP, qui prévoit d’être affiné en fonction des retours utilisateurs. Les retours utilisateur, intégrés à l’interface, ne servent pas seulement à valider les données mais améliorent le fonctionnement du logiciel, fond sur des processus automatisés.

In fine, l’intégration de l’indexation automatique au sein d’un logiciel de gestion des collections exige une réadaptation du modèle de données via la création d’une nouvelle entité qui permet d’accueillir adéquatement les nouvelles métadonnées produites. De plus, l’implémentation du processus automatique implique la mise en place d’une interface de validation qui place l’utilisateur au centre de l’indexation définitive. Une fois indexées, la masse de données produites permet de concrétiser la finalité du FRBR, celle de la découvrabilité, via des outils de recherche innovants qui permettent d’explorer directement le contenu de l’image.

¹⁸Tillett, Barbara B., *FRBR Model...*

¹⁹INA, *Projet Snoop*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).

²⁰A. Joly, J-C Lombardo, J-P Moreux, Q Leroy et O Buisson, « Snoop, Un Moteur de Recherche Visuelle Interactif », *Culture et Recherche* (141)–141 (2020), p. 14-15.

Cette seconde partie a permis de poser les fondements d’une proposition d’un processus automatisé pour la segmentation et l’indexation des archives audiovisuelles au sein d’un logiciel de gestion des collections. Afin de répondre aux contraintes de sécurité des données et de la réduction du temps de traitement, nous avons proposé un processus en deux temps : une segmentation automatique exécutée par un outil de vision par ordinateur classique (*Pyscene-detect*), et une classification par mots-clés avec un outil de fondé sur la vision par ordinateur et l’apprentissage profond (*YOLO*). Enfin, l’adaptation du modèle de données afin d’accueillir ces nouvelles fonctionnalités automatiques a permis d’imaginer un processus de validation au sein duquel l’utilisateur reste décisionnaire de l’indexation. Toutefois, l’opérationnalité d’un tel processus réside moins dans la performance des outils employés que dans leur adaptation aux besoins documentaires. Ainsi, l’introduction de l’utilisateur au sein de toutes les étapes d’implémentation et de traitement automatique, permettrait la mise en place d’un processus modulable.

Troisième partie

Perspectives d'une intelligence hybride

Cette troisième partie explore les conditions d'implémentation du processus automatisé à une échelle plus globale que celle analysée, à celle de l'éditeur de logiciel et de l'ensemble des clients concernés. La généralisation de cette implémentation implique la mise en place d'une Intelligence hybride, qui articule l'efficacité technique aux besoins documentaires du milieu patrimonial. Le premier chapitre analyse le statut des données produites au cours du processus automatique, dont le statut fluide nécessite la traçabilité et un suivi exigeant. Le second chapitre analyse les évolutions de l'interface existante, afin d'impliquer l'utilisateur dans l'implémentation du processus, à travers l'annotation manuelle de données et une visualisation des données en graphe. Enfin, le troisième chapitre questionne la généralisation du processus proposé, via la constitution d'un jeu de données d'entraînement par l'éditeur, et par la proposition d'un module automatique paramétrable en détails.

Chapitre 7

Une intelligence hybride

L'intégration de l'apprentissage automatique aux processus d'archivage audiovisuel, relève d'un large potentiel de découvrabilité du contenu de ces archives. Toutefois, ces outils restent difficiles à mettre en application au sein d'un tel milieu, nécessitant la mise en place d'efforts communs afin de "redéfinir en permanence la répartition du travail en l'homme et la machine dans le sens d'un partenariat"¹. En effet, le processus tel que nous l'avons décrit ne saurait être entièrement automatisé, et laisserait plutôt la place à une cohabitation entre l'extraction automatique et l'indexation documentaire manuelle.

Cette cohabitation est illustrée par le concept d'"Intelligence hybride" définie par Zeynep Akata comme :

La combinaison de l'intelligence humaine et de l'intelligence des machines qui complète l'intellect et les capacités humaines, plutôt que de les remplacer, afin de prendre des décisions judicieuses, d'effectuer des actions appropriées et d'atteindre des objectifs qui ne peuvent être atteints ni par les humains ni par les machines seules [Traduction personnelle]"².

Ce concept implique notamment la mise en place de quatre étapes distinctes : la collaboration entre l'homme et la machine, l'adaptabilité, la responsabilité, et l'explicabilité³.

¹J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

²"the combination of human and machine intelligence, augmenting human intellect and capabilities instead of replacing them and achieving goals that were unreachable by either humans or machines." Zeynep Akata, Dan Balliet, Maarten de Rijke, Frank Dignum, Virginia Dignum, Gusztî Eiben, Antske Fokkens, Davide Grossi, Koen Hindriks, Holger Hoos, *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53-8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587

³*Ibid.*

I. Le nouveau statut des données

1. Assurer le suivi de données fluides

L'introduction de processus fondés sur l'intelligence artificielle au sein d'un logiciel de gestion des collections modifie la nature et le statut des données produites sur les documents. Comme le souligne Jonas Arnold dans le *Livre blanc sur l'apprentissage automatique dans les archives*, les données automatiquement produites possèdent une nature "fluide" puisqu'elles sont amenées à évoluer au rythme des améliorations des outils, internes ou externes⁴.

Cette nouvelle nature de données implique la mise en place d'une "Intelligence hybride" impliquant que l'utilisateur métier supervise la cohérence entre les entités du modèle⁵. Ainsi, tandis que le processus automatique nourrit les entités inférieures du modèle de données, celles du Fragment et de l'Item, il reviendrait à l'utilisateur de garantir les liens avec l'entité supérieure de l'Œuvre. Plus globalement, l'utilisateur pourrait assurer la cohérence du reversement final des données au sein de la structure prévue par le logiciel dans son ensemble. Ainsi, tandis que le modèle de données est modifié d'un point de vue technique afin de prévoir le reversement des données automatiquement produites (2.), la validation finale au sein de l'interface revient à l'utilisateur métier.

2. Mesures de traçabilité

Afin d'assurer la vérification de la cohérence du modèle de données, deux mesures pourront être mises en place au sein du logiciel. D'une part, afin de pouvoir garantir l'homogénéité de l'indexation de ces données, le logiciel doit prévoir leur traçabilité via une "historisation ou un contrôle des versions"⁶. Par exemple, Skinsoft prévoit déjà des champs de métadonnées de gestion au sein du logiciel, c'est-à-dire des informations décrivant la création des données d'indexation, contenant notamment la date de modification de la notice, et l'utilisateur concerné. Des métadonnées du même type pourront être indexées au sein de champs dédiés aux métadonnées de processus, telles que les outils utilisés, les paramètres appliqués, l'utilisateur ayant validé l'indexation, la date de l'indexation. Ces métadonnées pourront apparaître au niveau descriptif du Fragment, par exemple. L'indexation des métadonnées de processus permettrait ainsi à l'utilisateur de tracer les données produites automatiquement, de veiller à la conformité de leur structure, afin de les réemployer potentiellement pour le

⁴J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

⁵Z. Akata, D. Balliet, M. de Rijke, *et al.*, « A Research Agenda for Hybrid Intelligence... ».

⁶J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

réentraînement des modèles. Ainsi, si le choix se porte sur un modèle plus performant, les métadonnées de processus, renseignant le contexte d'utilisation du modèle, permettront une réadaptation efficace, sans pour autant modifier l'interface et le processus suivant. D'autre part, pour assurer la transparence et la visibilité de ces données au sein de l'interface, leur origine doit être explicitement signalée. Outre la mise en place de métadonnées de processus intégrées au sein des notices, les données issues de processus automatiques devront être identifiées d'emblée au sein de grilles de résultats de recherche, par exemple. L'identification de ces données pourra prendre la forme d'un code couleur ou de tags de provenance apposés sur les données. Ce système permettrait notamment à l'utilisateur d'identifier immédiatement la cohérence des données dans tel ou tel niveau du FRBR. Ainsi, la mise en place d'une "Intelligence hybride" consiste à permettre la production automatique de données patrimoniales, à la condition selon laquelle l'utilisateur garantit leur cohérence et leur validation au sein du modèle de données⁷. L'interface doit faciliter ce contrôle du nouveau statut des données.

II. Assurer la qualité des données

1. Supervision documentaire

Le contrôle de la cohérence des données au sein de la structure logicielle s'impose comme une tâche à part entière pour l'utilisateur, à laquelle s'ajoute le contrôle de la qualité des données en tant que telle. Si le processus de validation permet d'encadrer la création des données indexées, des erreurs peuvent persister et dépendent du temps dédié à la validation. Dès lors, l'évaluation de la qualité des données produites s'ajoute à la vérification de leur cohérence structurelle au sein du modèle de données.

À ce stade du processus, la qualité des données ne désigne pas de mesure technique mais plutôt une valeur métier, en lien avec les normes descriptives en vigueur. Deux niveaux d'exigence qualité peuvent être établis. Premièrement, les données produites doivent être évaluées en lien avec les normes de description employées au sein de l'espace de travail. Par exemple, S-Movies est fondé sur les règles de description des archives (RDA) conformément aux recommandations de la FIAF. Deuxièmement, les données pourront être vérifiées en accord avec les règles internes et propres à chaque institution patrimoniale. Par exemple, les thésaurus utilisés, les listes d'autorités, la saisie des dates. Comme nous l'avons mentionné, les mots-clés produits en seconde partie sont contrôlés par un thésaurus "keyword". Il s'agira alors de vérifier si les mots-clés versés dans l'application existent bien sous une forme contrôlée au sein d'un thésaurus dédié.

⁷Z. Akata, D. Balliet, M. de Rijke, *et al.*, « A Research Agenda for Hybrid Intelligence... ».

2. Mise à profit d'un LLM ?

Toutefois, ces vérifications dédiées à l'utilisateur métier peuvent s'avérer chronophages et ne permettent pas de couvrir l'entiereté de la masse de données produites automatiquement. Dans ce cadre, l'usage d'un grand modèle de langage (LLM) peut être envisagé, en tant qu'assistant critique de l'utilisateur, afin de contrôler la qualité des données au niveau institutionnel. Les LLM, fondés sur une architecture *transformers*, font partie d'une Intelligence artificielle générative, et permettent une communication en langage naturel⁸. Ces modèles sont capables de comprendre le contexte d'une demande et un raisonnement plus profonds que les modèles basés sur des algorithmes de correspondance⁹. Skinsoft développe actuellement l'intégration d'un LLM pour les fonctionnalités de recherche en langage naturel et d'un système de génération augmentée par récupération (RAG), alimenté par les règles d'indexation métier générales et spécifiques aux institutions (Voir Annexe B (B)).

Ainsi, à partir d'une requête en langage naturel élaborée par l'utilisateur, le LLM développé peut fournir des résultats de recherche cohérents en s'appuyant sur le RAG, constitué des champs de saisies disponibles et des règles métier. À terme, l'éditeur prévoit également le développement d'un *chatbot*, c'est-à-dire d'un agent conversationnel capable de guider l'utilisateur à travers les tâches prévues par le logiciel.

Ainsi, le même LLM pourra être utilisé afin de pointer les incohérences au sein des notices contenant des données indexées automatiquement et manuellement. Un tel outil permettrait également d'homogénéiser l'ensemble des données indexées. L'utilisation d'un modèle d'IA supplémentaire permettrait d'améliorer la production de données homogènes conformément aux normes en vigueur, contrairement aux données indexées manuellement, souvent hétérogènes. Dans ce contexte, l'IA limiterait ainsi la dégradation de la qualité des métadonnées en permettant la production de données homogènes et structurées.

Selon Nikki Wise, certaines études montrent même que les utilisateurs préfèrent "les métadonnées générées par des machines ou par des systèmes hybrides à celles créées par des humains, en invoquant leur contexte plus riche, leur spécificité et leur exhaustivité [Traduction personnelle]" ¹⁰. Les capacités d'interprétation et d'analyse des LLM s'avèrent en effet particulièrement efficaces pour assister l'utilisateur, et ce, même avec un entraînement limité, offrant ainsi "une perspective prometteuse pour les flux de travail hybrides associant humains

⁸C. Stryker, *Qu'est-ce qu'un LLM (Large Language Models) ?* / IBM, févr. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/large-language-models> (visité le 06/09/2026).

⁹*Ibid.*

¹⁰"human users preferred machine-and hybrid-generated metadata over human-generated content, citing its increased context, specificity, and comprehensiveness" Nikki Wise, Katrina Fenlon, Diana Marsh, Amanda Sorensen, Ugoma Smoke, Candy Navarette et Lucy Havens, « 'Appears to Be about' : An Evaluation of AI-generated Metadata Quality for Community Archives », *Information Research an international electronic journal*, 31-iConf (mars 2026), p. 417-437, DOI : 10.47989/ir31iConf64144

et IA dans la création et la correction des métadonnées. [Traduction personnelle]”¹¹.

Ce contrôle de la qualité des données ne peut toutefois pas s’effectuer sans leur traçabilité, prévue par les métadonnées de processus décrites précédemment, permettant d’avoir accès à l’historique des modifications et au contexte de création de ces données.

III. Explicabilité et transparence

Le contrôle de la structure et de la qualité des données dépend également de la responsabilité de l’éditeur logiciel via-à-vis d’une transparence et d’une explicabilité du processus mis en place. Comme le rappelle Jonas Arnold, la gestion de la qualité de l’indexation dépend des utilisateurs, ainsi ”la transparence envers ces derniers est primordiale.”¹². Afin de garantir cette transparence, les processus automatiques implémentés pourront être expliqués à deux niveaux au sein de l’interface.

Tout d’abord, via une note d’information en amont du déclenchement du processus, au sein du diagramme de décision schématisé précédemment (6.3). Avant le déclenchement du processus, l’interface devra indiquer que la fonctionnalité utilisée est fondée sur l’intelligence artificielle. Le même principe est prévu pour le développement de la recherche en langage naturel, via une infobulle qui en explique brièvement le fonctionnement à des fins de transparence (Voir Annexe B, fig. B.1). De plus, une documentation pourra être mise à la disposition des utilisateurs sous la forme d’un mode d’emploi explicatif de la fonctionnalité. Skinsoft prévoit déjà ce type de documentation à l’usage des utilisateurs métier, via un manuel *wiki* dédié à chaque espace de travail et ses fonctionnalités. Le mode d’emploi pourra mentionner de manière synthétique les critères d’extraction du modèle utilisé, justifier le choix des outils ainsi que la mention de leurs limites, pouvant guider les utilisateurs dans leur contrôle qualité des données. Il serait pertinent de mentionner également les limites liées à l’entraînement du modèle, qui apprend à extraire des informations brutes, mais qu’il n’apprend pas à les placer au sein d’une structure de données, en lien avec des normes métier.

Il s’agira également de mentionner le périmètre au sein duquel sont analysées les données, qui est celui de l’éditeur seul. En effet, l’une des réticences majeures identifiées face à l’implémentation de fonctionnalités automatiques réside dans la perte de souveraineté des données patrimoniales lors de leur injection au sein de solutions commerciales externes¹³. Pour un éditeur comme Skinsoft, l’enjeu consiste à garantir une architecture logicielle éthique, étanche et souveraine, au sein de laquelle les données du client ne sont jamais réutilisées à

¹¹ ”*suggest promise for hybrid human-AI workflows in metadata creation and remediation*” *Ibid.*

¹² J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives »...

¹³ *Ibid.*

son insu pour enrichir des réservoirs tiers.

L'”Intelligence hybride” telle que définie par Akata se concrétise ainsi à travers la mise en place de trois étapes intégrées à la validation du processus automatique : l'indexation du nouveau statut de données ”fluides” à travers des métadonnées de processus, le contrôle de la qualité de ces données au sein de la structure logicielle, et l'explicabilité du processus afin d'assurer sa transparence¹⁴. Le développement actuel de LLM par Skinsoft pourra être mis à profit afin d'assister l'utilisateur dans la mise en place d'un contrôle critique. Toutefois, la mise en place de cette ”Intelligence hybride” au profit de la qualité des données exige une innovation de l'environnement de travail lui-même¹⁵. Il convient ainsi d'étudier les évolutions requises au sein de S-Movies, afin d'assurer la fluidité du contrôle des données automatisées.

¹⁴Z. Akata, D. Balliet, M. de Rijke, *et al.*, « A Research Agenda for Hybrid Intelligence... » ; J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁵Z. Akata, D. Balliet, M. de Rijke, *et al.*, « A Research Agenda for Hybrid Intelligence... ».

Chapitre 8

Évolutions du système existant

L'implémentation de nouvelles fonctionnalités automatiques, reposant largement sur la validation de l'utilisateur, ne peut s'effectuer sans une amélioration de l'interface existante. En effet, le processus de segmentation et d'indexation automatiques produit des données en masse, ce qui risque de complexifier davantage une navigation dans l'interface déjà compliquée par le modèle de données. Or, la validation par l'utilisateur et le contrôle qualité des données prévue dans le chapitre précédent (III.) nécessite une interface transparente et intuitive, indiquant la structure globale des données de manière claire. L'éditeur logiciel aurait ainsi la responsabilité de préparer à la fois l'interface et les utilisateurs métier à l'implémentation de ces nouvelles fonctionnalités.

I. Visualisation des données en graphe

1. Un modèle de données complexifié

La ligne directrice actuelle prise par l'éditeur d'un logiciel de gestion de collections est celle de rendre l'interface la plus intuitive possible, à la manière des applications commerciales présentes sur le web que nous utilisons quotidiennement. Ces applications placent en effet au centre de leur interface l'expérience de l'utilisateur à tous les niveaux : ergonomie, intuitivité, facilité, visualisation. L'implémentation de fonctionnalités innovantes tend vers un objectif de productivité, sans toutefois compromettre l'ergonomie de l'interface. C'est dans ce contexte que l'espace de travail S-Movies est au coeur d'évolutions fonctionnelles, puisque la structure de données, comme évoqué en première partie, complexifie la navigation de l'utilisateur.

En effet, bien que le modèle FRBR soit élaboré afin d'optimiser la découvrabilité des collections, il complexifie toutefois la mise en place d'une interface intuitive et navigable, enjeu au coeur des préoccupations d'un éditeur tel que Skinsoft. L'implémentation de nouvelles

fonctionnalités automatisées accentue cette complexité, avec la mise en place d’une nouvelle entité, celle du Fragment d’oeuvre, et la génération massive de données supplémentaires, qui risque de rendre moins claires les relations entre les notices. Pour ne pas entraver la lisibilité des liens entre les niveaux de description, il est nécessaire de proposer une vue d’ensemble de la structure des données au sein de S-Movies. Cette visualisation globale des liens entre les données permettrait non seulement une amélioration de la compréhension de la structure logicielle, mais également de faciliter la validation des données produites automatiquement.

2. Mise en place d’une vue en graphe

Au cours de notre stage, au sein d’un document général d’améliorations de l’espace de travail S-Movies (Annexe 2.), nous avons proposé une visualisation de la structure de données sous la forme d’un graphe relationnel.

Cette proposition s’inspire notamment des travaux de la Bibliothèque Nationale Allemande qui ont amené à développer une visualisation en graphe du modèle FRBR afin de structurer les résultats de recherche indexés¹. En s’appuyant sur la plateforme *Culture Graph* et des outils de spatialisation tels que *Gephi*, des algorithmes regroupent les notices (Œuvres sous des clés uniques et cartographient leurs liens sémantiques². De plus, des mots-clés reliés aux entités sont également modélisés sous forme d’arrêtes au sein du graphe³.

Appliqué à une structure de données audiovisuelle, le même type de visualisation en graphe peut être imaginée, traduisant visuellement la densité des relations entre les entités du modèle. À terme, après l’implémentation des fonctionnalités automatiques d’indexation, les mots-clés générés et les *time-codes* pourront, de la même manière, alimenter le graphe afin d’améliorer le contrôle qualité sur les données. La visualisation en graphes représente ainsi un ”complément précieux” aux résultats de recherche traditionnels, permettant à l’utilisateur de comprendre beaucoup plus facilement le regroupement d’entités⁴. La visualisation en graphe n’est pas seulement utile pour l’amélioration de la visualisation des liens entre les entités dans les résultats de recherche, mais elle permet également d’évaluer la cohérence du modèle de données dans son ensemble. En effet, ”l’impression visuelle donnée par le graphe d’une oeuvre est très utile car elle attire l’attention sur les sommets qui sont cruciaux pour la structure d’un cluster d’oeuvres.”⁵. Le graphe permettrait ainsi d’identifier rapidement les erreurs d’association ou les ruptures de cohérence générées par les traitements automatiques

¹IFLA, *Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters*, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).

²*Ibid.*

³*Ibid.*

⁴*Ibid.*

⁵*Ibid.*

avant leur validation définitive.

Concrètement, au sein de S-Movies, nous proposons l'intégration d'une vue d'ensemble du modèle en graphe, jouxtant la vue des résultats de recherche classique. Cette vue pourra être étendue au sein de notices individuelles, permettant ainsi d'obtenir une granularité différente, au niveau de l'Item. Cette vue en graphe permettrait de faciliter la navigation entre les entités descriptives et de vérifier la cohérence des liens, dans le cadre de l'implémentation d'une indexation automatisée. Une description détaillée de cette proposition est présentée en annexe A (2.).

II. Segmentation et indexation manuelles

1. Préparer les tâches documentaires

Par ailleurs, outre la facilitation de la validation des données, l'amélioration fonctionnelle de l'espace de travail pourrait, en amont, préparer l'implémentation de la segmentation et de l'indexation automatique. La préparation d'une telle implémentation passe notamment par la mise en place d'habitudes et de pratiques au sein de l'interface, en lien avec la segmentation et l'indexation vidéo.

Au sein du même document dédié aux améliorations fonctionnelles de S-Movies, nous avons notamment proposé la mise en place d'un outil de visionnage vidéo, au sein duquel les utilisateurs pourraient segmenter et annoter l'image (voir Annexe 2.). Cet outil pourrait répondre à un double enjeu : encourager les pratiques d'annotation et de segmentation sur les fichiers numériques ; collecter les données produites afin de faciliter l'entraînement des modèles à implémenter. De plus, la mise en place d'un tel outil permettrait de faciliter le contrôle qualité, en produisant des données manuelles à comparer avec les données produites automatiquement.

Pour la proposition de cet outil, nous nous sommes appuyés sur l'exemple de Mediascope, un outil développé par l'INA à destination des chercheurs à l'INAthèque, pour l'aide à l'analyse des contenus audiovisuels. Il permet de structurer le développement temporel du document à l'aide d'annotations associées à des *time-codes* et à des images fixes⁶. L'utilisateur peut ainsi visionner un document audiovisuel, annoter des marqueurs temporels sur des images fixes, ainsi qu'y saisir du texte. L'outil permet également l'export des images, du texte, et de statistiques sur le contenu⁷. Mediascope unifie ainsi la lecture vidéo et l'indexation d'annotations au sein d'une même interface.

⁶INA, *Aide et FAQ Médiascope*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).

⁷*Ibid.*

Actuellement, au sein de l'application Skinsoft, la gestion des médias se limite à la visualisation simple d'un fichier multimédia lié à une notice. Afin d'améliorer cette visualisation, nous avons proposé au cours de notre stage, sur l'exemple du Médiascope, une visionneuse permettant le séquençage manuel et l'annotation vidéo (Voir Annexe A 2.).

2. Un dispositif de segmentation et d'annotation

Cette amélioration s'appuierait d'une part sur deux possibilités de séquençage manuel. L'utilisateur peut saisir des repères temporels sur un fichier vidéo sans pour autant le modifier. Ces repères sont reversés dans des champs prévus pour accueillir les *time codes* dans la notice de l'objet numérique. Au sein du fichier vidéo, les marqueurs sont matérialisés et visibles sur la barre de défilement de la vidéo, permettant une navigation interactive. De plus, la visionneuse permettrait à l'utilisateur de segmenter le fichier vidéo en plusieurs séquences distinctes, à partir de repères temporels placés. Cet aspect est développé au sein de l'annexe A (2.). Chaque séquence identifiée est reversée dans un fichier d'item numérique propre, lié à une notice descriptive du niveau Fragment.

D'autre part, cette amélioration permettrait deux niveaux d'annotations sur le média vidéo. Une annotation globale au niveau de la séquence qui prendrait par exemple la forme d'un résumé, de mots-clés généraux thématiques, inscrits au sein de marqueurs temporels. Une annotation précise de tags apposés sur des éléments de l'image tels que des objets, personnes, éléments de décor, similaire à la détection d'objet prévue par *YOLO*. Ces éléments seraient indexés dans un champ dédié avec un ancrage temporel et spatial. (développement en annexe) À la manière du Médiascope, cette amélioration du visionnement des médias permettrait de combiner visualisation, segmentation et annotation au sein d'un même outil.

La mise en place d'un tel outil permettrait également d'améliorer la recherche en la faisant porter sur des éléments précis dans le contenu des images. De plus, le séquençage et l'annotation manuelle sur les documents audiovisuels prépare les utilisateurs à la structure des données engendrées en masse par les algorithmes à implémenter. Enfin, la production manuelle de ces données (time codes et mots-clés) faciliterait l'entraînement et le réentraînement des modèles, ainsi que le contrôle qualité effectué par l'utilisateur. Les données produites en amont permettraient en effet de constituer un jeu de données d'entraînement pour les modèles implémentés. Ces données serviraient finalement de référence afin d'inspecter la qualité de celles produites automatiquement par les modèles.

Ainsi, l'intégration au sein de S-Movies d'un outil de visionnage vidéo permettant la segmentation et l'annotation, et d'une visualisation des données en graphe permet de faire évoluer l'interface vers l'implémentation de processus automatiques. Tandis qu'une vue des données en graphe permettrait de vérifier la cohérence globale des données, l'outil de vision-

nement amélioré permettrait à la fois la mise en place des pratiques manuelles et de données précieuses au processus de validation. Ces évolutions témoignent de la possibilité de préparer l'interface globale aux processus d'intelligence hybride. Toutefois, le processus automatique de segmentation et d'indexation proposé en seconde partie se heurte à l'hétérogénéité des corpus audiovisuels gérés et des normes et habitudes métier, qui limite les potentialités de l'évolution fonctionnelle de l'espace de travail. Ainsi, il s'agit de mettre en perspective le processus automatique proposé dans cette étude, en lien avec les pratiques de gestion des collections qui contraignent les nouvelles fonctionnalités fondées sur l'intelligence artificielle.

u

Chapitre 9

Généraliser le processus

L'éditeur logiciel aurait un rôle à jouer dans la mise à disposition de nouvelles fonctionnalités innovantes auprès d'institutions patrimoniales, d'autant plus lorsqu'il s'agit de collections audiovisuelles. En effet, selon Jonas Arnold,

Les institutions de mémoire contenant des contenus audiovisuels sont prédestinées à explorer les avantages du *Machine learning* (ML) ou de l'intelligence hybride pour la mise en valeur et l'accès à leurs contenus audiovisuels. [...] Dans ce cas, la collaboration avec des partenaires, tels que des prestataires de services ou des portails, s'impose.”¹.

Or, le processus décrit en seconde partie, centré sur une validation utilisateur, a été analysé à partir d'un corpus spécifique, choisi comme exemple de mise en application. Si le rôle de l'éditeur est celui de la mise à disposition de fonctionnalités innovantes pour le domaine patrimonial, celles-ci doivent pouvoir être généralisées à tous les types de corpus audiovisuels hébergés par le logiciel. Ce chapitre propose ainsi une mise en perspective des propositions élaborées au cours de notre étude.

I. Proposer un processus modulable

1. Un paramétrage trop spécifique ?

La proposition d'une nouvelle fonctionnalité au sein d'un logiciel de gestion des collections implique de concilier deux logiques distinctes : la logique industrielle de l'éditeur logiciel et la logique de préservation et de gestion des institutions patrimoniales. L'enjeu,

¹J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

pour un éditeur, n'est ainsi pas seulement de proposer des fonctionnalités performantes, mais surtout de proposer des fonctionnalités adaptatives à tous les besoins des types de collections gérées par les institutions clientes. Le premier obstacle à la généralisation d'une fonctionnalité fondée sur l'IA, réside dans le paramétrage des outils de vision par ordinateur. Comme nous l'avons évoqué dans les chapitres b. et 2., un *pipeline* de segmentation fondé sur *Pyscenedetect* et de détection d'objets fondé sur *YOLO* nécessite des ajustements spécifiques au corpus étudié. L'utilisation de *Pyscenedetect* pour la segmentation, vue dans la section b., nécessite d'adapter le seuil de séquençage de manière précise en fonction de la longueur des séquences identifiée au sein du corpus. De plus, l'ajustement de l'indexation effectuée par *YOLO* vue au chapitre 2., implique le réentraînement du modèle sur les nouvelles données étudiées afin d'obtenir des prédictions optimales. Le choix d'un pipeline léger, avec des temps de calcul réduits tel que nous l'avons proposé est ainsi limité par un temps d'adaptation considérable et une difficulté de généralisation. Dans le cas de *YOLO*, et d'une méthode d'apprentissage supervisé, la mise en place du processus d'indexation implique également un temps d'annotation des données qui se mesure au niveau de spécificité du corpus à analyser.

2. L'apprentissage auto-supervisé

Afin de proposer des processus adaptatifs, pour la segmentation automatique, les solutions commerciales s'orientent davantage vers des architectures performantes de type *transformers*, comme nous l'avons mentionné, qui peuvent être entraînés sur des jeux de données massifs grâce à un apprentissage auto-supervisé². L'apprentissage auto-supervisé est particulièrement utile dans le domaine de la vision par ordinateur, qui nécessite de larges quantités de données annotées afin d'entraîner des modèles, imposant ainsi des contraintes de temps et de coût³. L'apprentissage auto-supervisé n'utilise pas de données annotées en amont au cours du processus d'entraînement, puisque les modèles apprennent les caractéristiques des données au sein des données brutes elles-mêmes⁴. Toutefois, cette méthode d'apprentissage ajoute un temps de calcul supplémentaire considérable à l'entraînement du modèle, et peut générer de nombreuses erreurs qu'il est difficile de sourcer⁵. En effet, les modèles plus performants comme les *transformers* sont conçus comme des boîtes noires, ce qui entrave la visibilité et le contrôle de l'utilisateur sur les paramètres appliqués. Ces limites ont dirigé nos choix vers un processus plus léger et rapide qui permet à l'utilisateur de garder le contrôle sur les paramètres. Toutefois, il est important de noter qu'un modèle comme *YOLO*, plus

²C. Stryker et D. Bergmann, *Qu'est-ce qu'un modèle transformer ?...*

³*Ibid.*

⁴*Ibid.*

⁵Raphael Kassel, *L'apprentissage auto-supervisé : Qu'est-ce que c'est ? Comment ça marche ?*, janv. 2026, URL : <https://liora.io/apprentissage-auto-supervise-tout-savoir> (visité le 02/09/2026).

léger, ne permet pas de comprendre le contexte d'analyse des images⁶.

3. Un développement local

Par ailleurs, nos choix ont écarté les solutions commerciales pré-configurées afin de respecter les contraintes de sécurité des données. En tant que prestataire, l'éditeur logiciel porte la responsabilité de la sécurité des données de ses clients. Or, les solutions commerciales pré-existantes, telles que Video IA, développée par Goggle, ou Azure Video indexer développée par Microsoft, sont fondées pour la plupart sur une architecture infonuagique, qui implique de déplacer les données patrimoniales vers des prestataires externes et de perdre ainsi un certain contrôle.

Afin de garantir la sécurité des données et une transparence fonctionnelle à l'égard des institutions, les outils utilisés doivent être développés localement, au sein d'une infrastructure prévue par l'éditeur. En développant localement des outils en libre accès tels que *Pyscenedetect* et *YOLO*, Skinsoft pourrait garantir, d'une part la sécurité des données client, et d'autre part conserver une visibilité totale sur l'exécution du processus. Ainsi, plutôt que d'adapter simplement une solution commerciale préexistante, le rôle de l'éditeur serait de pouvoir proposer des modèles spécifiques au contexte patrimonial, modulables en fonction du type de données. Le rôle d'un éditeur comme Skinsoft serait particulièrement pertinent pour la proposition d'une segmentation vidéo en séquences, une fonctionnalité encore sous développée, y compris par des applications commerciales.

II. Constituer des données d'entraînement patrimoniales

1. Généraliser l'annotation des données

Afin de généraliser le processus, l'apprentissage du modèle de détection *YOLO* ne peut être effectué à partir du seul corpus que nous avons analysé. Le corpus étudié au cours de notre analyse comporte des caractéristiques bien spécifiques : archives audiovisuelles muettes, en noir et blanc, dont l'aspect de l'image est dégradé. Notre analyse s'est portée sur cette collection en raison d'une demande particulière de l'institution pour le déploiement de la segmentation et de l'indexation automatisées. De plus, l'analyse de ce corpus a pu mettre à l'épreuve le processus automatisé que nous proposons, face à la spécificité de ces archives.

⁶Sound & Vision, *AI in Audiovisual Archives*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).

Toutefois, la mise en application du processus à travers ce corpus d’archives ne permet pas sa généralisation à l’ensemble des types de collections audiovisuelles.

Afin d’écarter la nécessité de réentraîner systématiquement le modèle au cas par cas, il pourrait être pertinent d’annoter un jeu de données plus général, mais toutefois spécifique au contexte patrimonial. À cet effet, plusieurs jeux de données en accès libre pourraient être exploités. Le projet Dataset, développé par l’INA, met par exemple à disposition un serveur contenant divers corpus de ”collections audiovisuelles, de fiches documentaires et de métadonnées associées à ces documents [...] destinés à la mise au point, l’expérimentation et l’évaluation d’outils de recherche et d’analyse de contenus multimédias ”⁷. Ces corpus contiennent des images animées issues de la télévision telles que des journaux télévisés, des actualités, ou des captations. Si d’autres plateformes proposent une masse considérable de données patrimoniales telles que le Portail Open Data de la Plateforme Ouverte du Patrimoine (POP) du Ministère de la Culture ou les collections numérisées de Gallica (BNF), les données audiovisuelles y sont absentes.

Au sein du processus proposé dans cette étude, *YOLO* intervient après une étape de segmentation, et analyse uniquement des images fixes (images clés) issues de l’outil *Pyscenedetect*. Or, afin de généraliser la fonctionnalité de détection, et de pouvoir l’appliquer à diverses institutions, il est pertinent de pouvoir séparer les deux briques fonctionnelles. *YOLO* devrait ainsi pouvoir analyser directement des flux audiovisuels afin d’y détecter des objets et les indexer. C’est pourquoi nous proposons la généralisation du modèle à partir de jeux de données audiovisuels, tels que proposés par l’INA. Deux étapes d’entraînement pourraient être ainsi prévues. D’une part, un pré-entraînement généraliste du modèle à partir de données audiovisuelles patrimoniales. D’autre part, un affinage du modèle au cas par cas, via l’annotation de données spécifiques à une institution précise, comme c’est le cas de notre corpus, pour un usage spécifique du modèle.

2. Collections as data

Dans ce cadre, le rôle de l’éditeur pourrait être celui de constituer des jeux de données annotés, à partir de jeux de données ouverts, afin de pouvoir entraîner d’autres modèles à développer.

Une telle constitution pourrait également s’effectuer à partir de certaines données clients, avec leur accord, et concrétiserait ainsi l’idée de faire des collections des données ou ”collections as data”⁸. En effet, ”le mouvement « collections as data » vise à rendre les

⁷INA, *Projet Dataset*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).

⁸Giovanni Colavizza et Lise Jaillant, « AI Ready : How to Prepare Archives for Artificial Intelligence,

ressources du patrimoine culturel numérique accessibles à des fins informatiques, en encourageant les institutions LAM à fournir leurs fonds dans des formats exploitables par des machines”⁹. Un déplacement s’opère ici puisque c’est l’éditeur qui remplirait ce rôle et qui, avec l’accord de certains clients, constituerait un ou plusieurs jeux de données annotées dans l’optique de développer des fonctionnalités innovantes. Ces jeux de données pourraient par exemple être exploités pour d’autres tâches de traitement audiovisuel, dont notre étude n’a étudié qu’une petite partie : reconnaissance de personnes, transcription audio, reconnaissance de texte, etc.

Toutefois, transformer les collections en données serait réducteur et ommettrait le contexte des pratiques archivistiques propres aux institutions dont elles font l’objet. Comme l’explique Colavizza, ”cette structuration doit rester conforme aux principes archivistiques et aux communautés dont les vies et les histoires sont représentées dans les documents.”¹⁰.

Un double affinage serait alors nécessaire, sur le type de collection spécifique étudié, et sur les pratiques en vigueur au sein de l’institution. Par exemple pour le NLP : nous avons prévu un affinage du LLM à partir d’infobulles documentées à partir de la charte de saisie de chaque table : documentation de l’usage de certains champs spécifiques par exemple.

III. Une automatisation nécessaire ?

1. La réalité des besoins

Au delà des contraintes posées par la segmentation et l’indexation automatisées, se pose la question de la pertinence du déploiement de telles fonctionnalités, en lien avec les besoins professionnels actuels. En effet, un éditeur tel que Skinsoft est animé par une logique commerciale d’innovation qui contraste avec les habitudes métier de gestion des collections. Au sein d’un *guide pour une IA responsable dans le secteur culturel*, le Ministère de la Culture rappelle que dans le cadre d’une mise en place de fonctionnalités fondées sur l’IA, il s’agit ”d’examiner le besoin à couvrir et de vérifier la capacité des systèmes d’IA à satisfaire ce besoin dans des conditions optimales” ; le cas échéant, de favoriser des alternatives moins consommatrices que l’IA si elles sont suffisantes à répondre au besoin.”¹¹.

Dans le cadre de notre étude, notre proposition se limite à l’expérimentation d’un processus à partir d’un besoin précis identifié sur un corpus spécifique. Or, ce besoin fait partie

Improve Discoverability, and Enhance Access », *Archives and Records*, 0–0 (juin 2026), p. 1-22, DOI : 10.1080/23257962.2026.2675937.

⁹ *Ibid.*

¹⁰ *Ibid.*

¹¹ Ministère de la Culture, *La stratégie du ministère pour des intelligences artificielles culturelles et responsables...*

d’une réalité globale documentaire, celle de la nécessité d’exploiter davantage le contenu des archives audiovisuelles, dont le caractère temporel rend les caractéristiques inexploitées, inadaptées aux outils de recherche existants. Comme l’explique le chercheur Bruno Bachimont,

La temporalité des séquences audiovisuelles a pour conséquence qu’il est impossible de consulter rapidement un document, de le ”feuilleter” pour trouver un élément que l’on recherche : pour feuilleter une heure de vidéo, il faut une heure.¹².

L’automatisation permettrait alors d’agir comme accélérateur d’une découvrabilité fine des contenus audiovisuels et d’une accélération de leur numérisation, par le temps réduit de leur indexation. Dans ce contexte, l’éditeur de logiciel occupe un rôle d’intermédiaire technique entre le développement innovant de l’IA et les besoins patrimoniaux. À terme, les institutions culturelles occupent le rôle d’intermédiaire du contenu ainsi nouvellement indexé auprès du public.

2. Le coût matériel et humain de la supervision humaine

Toutefois, nous avons pu observer au cours de notre stage certaines institutions refuser le projet d’implémentation de l’IA au sein du logiciel, pour des raisons de perte de transparence sur le traitement des données et de réticences quant à la confidentialité des données exploitées. Notre proposition est précisément axée sur un processus régit par une transparence maximale, permise par la validation indispensable du processus par l’utilisateur. En effet, le processus proposé dans notre étude, fondé sur la vision par ordinateur via des méthodes d’apprentissage supervisé, est une alternative pertinente pour instaurer la transparence. Les outils que nous avons proposé permettent une liberté de configuration afin de conserver le contrôle sur les tâches automatisées. Les risques associés habituellement aux modèles d’IA tels que les risques d’hallucination, d’erreurs, de biais, seraient amoindris par le statut qui leur est donné : celui de facilitateur et d’assitant ponctuel, mais jamais celui de décisionnaire.

Or, si ce processus centré sur la supervision humaine paraît idéal, il impose des contraintes matérielles et financières importantes. D’une part, l’éditeur devra superviser le développement du processus via l’annotation de larges jeux de données, pour entraîner un modèle comme *YOLO*. D’autre part, l’institution cliente devra mettre en place des ressources dédiées à la validation du processus et au contrôle qualité des données automatiquement produites. L’implémentation de la segmentation et de l’indexation automatiques, devra ainsi s’effectuer au cas par cas, selon les besoins identifiés par les retours clients. Nous pouvons dès lors nous

¹²B. Bachimont, « Bibliothèques Numériques Audiovisuelles... ».

demander si l'implémentation du processus idéal tel que nous l'avons décrit, constitue un gain de temps de travail ou une charge supplémentaire.

Afin de satisfaire un besoin plus global, il est justement pertinent de mettre le modèle de données au premier plan de l'implémentation, afin de rappeler la capacité d'un modèle d'IA à s'adapter à des pratiques métier.

3. Proposer un module paramétrable

Afin de faire face à la disparité des besoins et des moyens entre les institutions, l'implémentation d'une segmentation et d'une indexation automatiques pourra s'effectuer sous la forme d'un module paramétrable et optionnel. En effet, étant donné la variabilité du modèle de données d'une institution à une autre, et des différences de configurations entre les espaces de travail, l'automatisation décrite pourra être intégrée à l'image du fonctionnement du logiciel, sous une forme paramétrable au cas par cas. De la même manière que l'éditeur propose la configurabilité de l'espace de travail par des masques, méta masques et menus, un dialogue en amont pourra être établi afin de définir les modalités d'implantation de la fonctionnalité. La modification du modèle de données par l'ajout d'une nouvelle entité pouvant recueillir les séquences pourra notamment être proposée comme une option. De plus, l'éditeur pourra prévoir un environnement logiciel de test afin de garantir une appropriation des fonctionnalités et d'en modifier le paramétrage au cours des pratiques.

Ainsi, la segmentation et l'indexation automatiques pourront être fondées sur une architecture paramétrable, de la même manière que l'ensemble du logiciel. Le mode configurable de ces fonctionnalités par l'éditeur auront pour but d'une part de soulager les institutions de la mise en place de moyens coûteux, et d'autre part de garantir la mise en place d'une IA comme outil d'assistance pour l'utilisateur.

La nécessité d'implémenter une segmentation et une indexation automatiques est remise en perspective par la disparité des besoins patrimoniaux. Si la constitution de jeux de données d'entraînement patrimoniaux permettrait d'améliorer la qualité des prédictions, et la généralisation de l'automatisation à d'autres institutions clientes, la supervision humaine décrite au sein de notre processus implique des besoins et des coûts considérables. Ainsi, la pertinence d'une telle automatisation résiderait dans une implémentation configurable, adaptée aux besoins et aux moyens de chaque institution.

L'implémentation de l'intelligence artificielle au sein d'un logiciel de gestion des collections, ne se substitue pas au rôle de l'utilisateur technique ou métier, mais elle redéfinit de nouvelles tâches, notamment pour assurer la qualité des données produites. Les améliorations d'interface pour la gestion des archives audiovisuelles, développées en parallèle, contribuent à mettre en place un rôle décisif pour l'utilisateur, en amont de l'implémentation de fonctionnalités automatiques. Le processus implémenté serait alors le fruit d'une Intelligence hybride qui permet de mettre en application de nouvelles fonctionnalités en accord avec les besoins métier, notamment de modélisation. Si la généralisation du processus soulève des enjeux de coûts et de besoins, l'implémentation du processus comme module paramétrable, en dialogue avec l'institution concernée, peut constituer une solution durable, plaçant encore l'utilisateur métier au coeur des choix.

Conclusion

À travers le point de vue d'un éditeur de logiciel de gestion des collections, ce mémoire a eu pour objet la proposition d'un processus d'automatisation de l'indexation pour les archives audiovisuelles, via leur segmentation, au sein d'un modèle de données représentatif des pratiques métier des institutions. Notre réflexion s'est ainsi concentrée autour de la difficulté d'implémenter un processus automatique fondé sur l'intelligence artificielle et dédié aux collections audiovisuelles, alors même que l'architecture logicielle est contrainte par des normes documentaires, matérialisées notamment par le modèle de données FRBR.

En amont de la proposition concrète d'un processus, nous avons analysé l'architecture d'une interface dédiée aux archives audiovisuelles, à travers l'étude de l'indexation d'un corpus audiovisuel spécifique. Fondée sur le FRBR, modèle de données issu du milieu des bibliothèques et adapté par la FIAF aux archives audiovisuelles, l'interface permet ainsi de structurer l'indexation du contenu en différents niveaux de description, séparant le contenu intellectuel du contenu matériel. Toutefois, la spécificité du corpus étudié a soulevé les limites de l'adaptation du FRBR, d'une part à l'ensemble des archives audiovisuelles, et d'autre part à une interface dont l'objectif est celui de la fluidité de l'expérience utilisateur. En effet, l'indexation fine imposée par des collections spécifiques, notamment à travers la segmentation d'oeuvres en séquences, s'avère déjà restreinte par la verticalité instaurée par le modèle de données. Dans ce contexte, le besoin d'automatiser les tâches d'indexation, dont la segmentation, face au volume des collections et du temps qui y est dédié, est contraint par les difficultés d'adapter le modèle de données à différentes collections et à différentes pratiques documentaires.

Par ailleurs, si les outils d'intelligence artificielle appliqués au traitement audiovisuel sont nombreux, les outils dédiés à la segmentation du flux audiovisuel en différentes séquences restent insuffisants pour répondre aux besoins identifiés. Les modèles d'IA les mieux adaptés à la compréhension du langage cinématographique, fondés sur une architecture de type *transformers*, sont écartés en raison de leur opacité et de leur puissance de calcul élevée, difficilement conciliable avec les exigences de transparence documentaire. De ce fait, le processus proposé au cours de ce mémoire de recherche repose sur l'adaptation d'outils en accès libre

et modulables en fonction des besoins identifiés, ceux de segmenter les archives et d'indexer les séquences produites par mots-clés.

Afin de paramétrer le modèle de segmentation *Pyscenedetect* pour la détection de séquences et non de plans, le flux audiovisuel a fait l'objet d'une décomposition de sa syntaxe, pour n'en tirer que des images clé. Ce procédé permet notamment d'articuler la classification automatique des segments de manière plus efficace, en ne donnant en entrée au modèle *YOLO* que des images clés représentatives. La modularité du processus proposé repose nécessairement sur une supervision humaine à toutes les étapes d'analyse, à la fois du côté technique pour superviser les prédictions et le paramétrage, et à la fois côté métier, pour la validation des données produites et l'actionnement du processus. Ainsi, le rôle de l'utilisateur est central non seulement pour l'implémentation du processus mais également pour le reversement des données produites en masse au sein d'un modèle élargi par la notion de Fragment.

La proposition de l'implémentation d'un processus d'automatisation de l'indexation au sein d'un logiciel de gestion des collections est finalement fondée sur une intelligence hybride homme-machine, à toutes les étapes de traitement. Afin d'intégrer l'utilisateur à travers l'ensemble des étapes du processus proposé, l'amélioration de l'interface de gestion existante s'impose comme la condition préalable à tout ajout de fonctionnalité. En effet, l'évolution de l'interface vers une visualisation globale du modèle de données permettrait d'intégrer l'utilisateur au contrôle de la structure des données avec davantage de facilité. De plus, encourager l'indexation de données temporelles et sémantiques sur les collections, en amont de leur automatisation, permettrait d'établir un contrôle qualité des données plus solide, et de mettre à profit ces données pour l'entraînement du modèle *YOLO*.

Notre étude se limite à l'expérimentation théorique d'un processus à un corpus d'archives audiovisuelles unique. L'adaptation fine des outils proposée, impliquant leur paramétrage (*Pyscenedetect*) et leur entraînement (*YOLO*) paraît difficilement généralisable à une fonctionnalité commune à divers besoins. Ainsi, les perspectives de généralisation du processus à d'autres institutions sont restées à l'état de réflexions. Toutefois, la notion d'intelligence hybride permettrait de répondre aux enjeux de généralisation du processus à d'autres collections audiovisuelles, inscrites dans des pratiques documentaires différentes. En effet, en amont du processus, la proposition d'une fonctionnalité paramétrable et modulable peut s'effectuer en dialogue avec les besoins institutionnels au niveau du contenu des collections et du modèle de données implémenté. Si l'analyse détaillée des besoins et l'adaptation fine du processus nous a permis d'en analyser les enjeux d'implémentation, la logique d'un éditeur est généralement inverse. Le développement de moteurs globaux permet ensuite une adaptation au cas par cas, selon les besoins.

Ce mémoire de recherche s'inscrit dans le contexte d'un stage consacré au large projet

IA chez l'éditeur logiciel Skinsoft, actuellement au coeur de réflexions et de développements, dont l'indexation automatique n'est qu'une composante. Les perspectives de l'IA appliquées à la gestion des collections sont en effet nombreuses et placent l'éditeur au sein d'un rôle déterminant pour faciliter le développement de fonctionnalités innovantes accessibles aux institutions patrimoniales. Le rôle de l'éditeur est d'autant plus important pour améliorer l'efficacité de la gestion des fonds audiovisuels, dont le traitement manuel chronophage limite l'accès au contenu et sa valorisation. Ainsi, notre réflexion s'inscrit dans un questionnement plus large, dont les archives audiovisuelles et le FRBR ne sont que les éléments révélateurs, celui d'adapter l'IA aux besoins et aux pratiques du patrimoine.

Annexes

Annexe A

Améliorations fonctionnelles - S-Movies

Le présent document a été élaboré à la demande de Skinsoft afin de réfléchir à des évolutions d'interface pour l'espace de travail S-Movies, à partir de la structure fondée sur le FRBR. Le document a été réduit pour les besoins de cette étude, et fait en réalité partie d'une proposition plus large, rendue en tant que livrable technique et disponible à cette adresse : [Le document est structuré en deux parties principales, présentant d'abord l'amélioration des éléments existants, puis la propositions de nouvelles fonctionnalités.](#)

I. Améliorations

1. Amélioration des liens

Actuellement, le parcours utilisateur de navigation entre les niveaux du WEMI dans S-Movies pourrait être amélioré. Plusieurs éléments faisant l'objet de liens sont ici proposés et soumis à des améliorations :

a. Contraindre les liens entre les niveaux depuis les tables

Actuellement, lorsque l'utilisateur crée un élément du WEMI depuis une table (Item, Manifestation, Œuvre), la création supplémentaire d'un lien avec les autres niveaux du WEMI n'est pas rendue obligatoire par l'application.

Par exemple, lorsque l'utilisateur crée une Manifestation depuis la table dédiée –bien qu'il ne s'agisse pas du parcours le plus courant, la création d'un lien entre cette Manifestation et une œuvre ou un Item film n'est pas obligatoire. Or, une Manifestation est toujours reliée, a minima, à une œuvre cinématographique. Il faudrait pouvoir contraindre l'utilisateur à relier

la notice de Manifestation à une œuvre, et que les champs œuvre de la notice Manifestation héritent automatiquement des données de l'œuvre liée (titre, auteur, contexte de création...).

C'est le même problème pour la création d'un Item film et pour la création d'une Œuvre.

L'encart qui apparaît en haut à droite de la notice pour proposer à l'utilisateur de créer un lien avec une autre notice n'est pas suffisant. Il faudrait contraindre l'association de liens entre les niveaux du WEMI par une fenêtre pop-up qui bloquerait la saisie momentanément. Ainsi, à la création d'un Item film par exemple, une fenêtre pop-up s'ouvrirait pour demander à l'utilisateur de lier cet Item à une Manifestation et/ou une Œuvre.

Si la collection est particulière, par exemple pour une institution qui ne décrit pas la Manifestation, il faut permettre la possibilité d'enlever cette obligation de lien entre les trois niveaux et laisser seulement l'encart existant.

b. Améliorer les liens depuis les notices

Les liens rendus possibles depuis les menus des notices pourraient aussi être améliorés.

Par exemple, depuis une notice œuvre, il faudrait proposer un bouton d'action qui permette de créer un Item et une Manifestation liés, et non plus seulement un Item. En effet, proposer à l'utilisateur de créer un Item et sa Manifestation serait conforme à la logique déjà mise en place dans l'application du lien indissociable entre un Item et sa Manifestation.

De plus il faudrait, depuis une notice œuvre, pouvoir créer directement sa Variante. Il faudrait ajouter au bouton d'action : ajouter et créer une Œuvre Variante, et par conséquent, ajouter un onglet de menu qui affiche les Variantes associées à l'Œuvre.

2. Modifier la hiérarchie d'affichage

Actuellement, la hiérarchie d'affichage des niveaux dans le menu burger se fait du plus petit niveau en haut (films) au plus grand niveau en bas (œuvres). Cet affichage est contre intuitif puisqu'il induit une hiérarchie inversée. Il faudrait que l'œuvre soit affichée comme le niveau le plus haut de la hiérarchie, suivi par la Manifestation et enfin, par l'Item-film.

Il pourrait également être plus intuitif de contraindre l'affichage correct de la hiérarchie dans les menus des notices. Par exemple dans une notice Œuvre, l'onglet "Manifestations liées" apparaît au-dessus de l'onglet "Items-films liés". Cela pourrait prendre la forme d'une fenêtre de suggestion à l'utilisateur lors de la configuration du menu d'une notice afin de produire un affichage conforme à la hiérarchie du modèle FRBR.

Par ailleurs, la page d'accueil de S-Movies a été configurée de telle sorte que ce sont toutes les Œuvres cinématographiques qui apparaissent. Or, ce sont bien les Items qui composent véritablement la collection. Il serait pertinent de proposer une amélioration, en pro-

posant par exemple d'afficher les Items contenus dans chaque œuvre, pour avoir un aperçu réaliste de la collection.

3. Corrections terminologiques

Cela peut paraître anodin, mais corriger la terminologie à certains endroits permettrait d'améliorer la compréhension des nuances et des liens entre les niveaux du FRBR.

Par exemple, actuellement depuis une notice film (Item), le bouton d'action propose à l'utilisateur d'ajouter "des œuvres/expressions". Il faudrait modifier la conjugaison pour mettre le terme au singulier : un Item ne peut être lié qu'à une seule œuvre/expression.

Par ailleurs, il peut y avoir confusion de compréhension autour du terme film. En effet dans un contexte cinématographique, le film peut désigner à la fois l'œuvre, la Manifestation et l'exemplaire. Il faudrait proposer un terme qui pointe cette notion d'exemplaire individuel qui découle d'une œuvre puis d'une Manifestation, tel qu'Item-film par exemple.

De plus, à plusieurs endroits, le terme d'œuvre est privilégié alors qu'à d'autres c'est celui d'expression qui est utilisé. Il faudrait normaliser l'emploi d'œuvre/expression ou d'œuvre en tout temps. C'est le cas dans certains masques comme celui d'expression référente, qui peut être utilisé au détriment de celui d'œuvre associée. Dans ce message d'erreur ci-dessous, c'est également le terme d'expression qui est employé :




Figure A.1 - Message de suppression d'une notice d'Œuvre

Cette proposition rejoint l'idée de supprimer la table œuvre cinématographique dans la

gestion des masques alors que c’est la table œuvre/expression qui est couramment utilisée.

Enfin, une confusion peut également s’installer entre les termes “œuvre liée” et “œuvre associée” dans les masques qui décrivent la Manifestation par exemple. Le terme d’œuvre liée pourrait être corrigé en “œuvre parente” pour que la nature du lien soit plus claire entre les deux entités.

II. Nouvelles fonctionnalités

1. Annotation de séquences sur un fichier vidéo numérique

La table média actuelle permet seulement de visualiser une photo ou une vidéo, au clic sur la notice. Toutefois, il serait intéressant de développer une visionneuse spécifique à la vidéo qui permettrait non seulement de la visionner, mais également d’y placer des repères, des marqueurs, et de pouvoir l’annoter.

Tout d’abord, deux possibilités de “séquençage” manuel seraient possibles :

- L’utilisateur saisit des repères temporels sur la vidéo sans la modifier. Ces repères sont reversés dans des champs prévus pour accueillir les “time codes” dans la notice de l’objet numérique. À l’ouverture du fichier numérique, les marqueurs laissés par l’utilisateur apparaissent, visibles sur la barre de défilement de la vidéo. L’utilisateur peut alors cliquer sur ces marqueurs pour naviguer au sein de la vidéo comme il le souhaite, et y voir les annotations associées.
- L’utilisateur pourrait aussi vouloir segmenter le fichier vidéo en plusieurs séquences distinctes à partir de time codes précis. Dans ce cas-là, à la manière d’un logiciel de montage, l’utilisateur peut créer des cuts sur la vidéo et ainsi créer plusieurs fichiers numériques à partir de celle-ci, mais qui lui sont toujours liés. En effet, ces nouveaux objets, fragments du fichier vidéo d’origine, auraient leur propre notice de description mais resteraient rattachés à la notice principale, à la manière d’un ensemble.

Cette nouvelle fonctionnalité permettrait d’apprécier l’hétérogénéité des collections, et s’avèrerait utile dans le cas, par exemple, de rushes documentaires non édités que l’utilisateur souhaiterait diviser par mots clés ou thématiques. La description des médias vidéo n’en serait que plus affinée et précisée.

Par ailleurs, ce séquençage devra être effectué dans une optique d’annotation “sur” l’image, permettant ainsi d’associer des séquences plus précises à une description thématique. Concrètement, deux cas d’annotation sont possibles :

- L'utilisateur pourrait être capable de placer des tags sur des éléments de l'image (objets, personnes, éléments techniques, contenu...) et d'en décrire le contenu dans les champs prévus. La notice du média prévoit alors l'affichage d'une description par time codes, sur lesquels l'utilisateur peut cliquer pour accéder directement à l'image en question.
- L'utilisateur peut également vouloir décrire une séquence dans sa globalité, à l'intérieur d'un time code précis. Dans ce cas, les champs sont saisis à partir d'un tag sur le time code, et non plus sur un élément précis de l'image. L'affichage de la description dans la notice peut rester le même que le précédent.

À l'ouverture du fichier vidéo, les annotations saisies apparaissent à droite de la visionneuse, et les times codes superposés à la barre de défilement de la vidéo.

La description précise sur des séquences vidéo permettrait à la recherche d'être plus performante : l'utilisateur pourrait, en cherchant certains mots clés, tomber directement sur les séquences numériques associées, aux time codes correspondants.

Il est intéressant de penser également à la mise en place d'une recherche par mots clés au sein du fichier numérique vidéo. La recherche d'un mot clé amène l'utilisateur à une séquence décrite par ce mot clé.

2. Mise en place d'une visualisation des liens entre entités du FRBR

Cette idée s'inspire visuellement de la "balade intuitive" proposée par la bibliothèque Kandinsky dont voici un exemple :




Figure A.2 - Vue "balade intuitive" proposée par la bibliothèque Kandinsky¹




Figure A.3 - Vue en graphe de la balade intuitive²

Lorsque l'utilisateur ouvre S-Movies, ce sont les œuvres qui apparaissent sous la forme de résultats de recherche. Les liens avec d'autres notices (Manifestations et Items) n'apparaissent pas à première vue. Il faut ouvrir une notice pour voir la liste des entités qui y sont liées, si toutefois ces liens sont configurés dans le menu de la notice. Or, la visualisation de liens entre les entités d'une collection est primordiale dans la logique d'une structuration selon le modèle FRBR. Pouvoir avoir un aperçu de ces liens pourrait améliorer la compréhension de la hiérarchie entre les niveaux du FRBR et leur délimitation, et ainsi améliorer les pratiques de saisie selon les cas d'indexation. De plus, visualiser rapidement les liens entre entités permettrait d'identifier les incohérences et les erreurs de données plus facilement, comme par exemple, des éléments vides ou isolés.

Les entités principales du FRBR étant au nombre de trois, la représentation choisie pourrait être celle d'une représentation en graphes de connaissances, modélisant ainsi les relations entre entités. Cette représentation s'appuie sur le modèle de graphe RDF (sujet-prédicat-objet) qui permet également l'interopérabilité des données.

Pour penser la place que pourrait prendre cette visualisation des liens dans l'application, il faut se poser les questions suivantes : quel niveau du FRBR les utilisateurs préfèrent-ils visualiser ? Dans quel contexte ? Autrement dit, il faut se demander quel niveau de granularité choisir pour mettre en place cette visualisation et à quel endroit de l'application.

Puisque la page d'accueil de l'espace de travail S-Movies présente les œuvres, la représentation en graphe pourrait dans un premier temps permettre de visualiser les œuvres

présentes dans la collection.

Le premier niveau permettrait donc à l'utilisateur de visualiser la liste des œuvres préservées sous formes de cercles, plus ou moins gros selon le nombre de sous-niveaux qu'elles contiennent. Ainsi, une œuvre qui contiendrait deux Variantes, quatre Manifestations, 12 Items sera plus grande qu'une Œuvre qui contient 1 Manifestation et 1 Item.

Au clic sur l'Œuvre, le détail de ses relations avec des sous-éléments apparaît : Variantes, Manifestations, Items.

Ce mode d'affichage pourrait être disponible de la même manière que les modes d'affichage déjà présents dans l'application. Il faudrait ajouter un mode d'affichage en "graphe".



Figure A.4 - Modes d'affichage disponibles dans l'application

Ce mode d'affichage, établi au niveau des tables, pourrait également être disponible au niveau des notices. Par exemple dans une notice d'Item, un onglet de menu pourrait être configurable pour faire apparaître, en graphe, les relations de l'Item avec les niveaux parents du FRBR.

Il serait intéressant d'intégrer à ces visualisations en graphes les médias, d'autant plus dans le cas de la mise en place d'une segmentation vidéo, pour pouvoir visualiser les différents segments reliés à l'Item.

Concrètement, le parcours utilisateur de cet affichage serait le suivant :

- Que ce soit depuis une table ou depuis une notice, l'utilisateur clique sur le mode d'affichage en graphe
- Les entités concernées s'affichent sous la forme de cercles, proportionnels aux nombres de liens qu'ils entretiennent avec les autres niveaux du FRBR. Les cercles comportent des informations minimales selon le niveau : le titre et la date pour les œuvres, le titre le format et la date pour les Manifestations, le titre, le format, la date et l'identifiant pour l'Item.
- Une légende s'affiche en bas de l'écran avec un code couleur pour chaque entité, et le nombre d'entités présentes.
- Au clic de l'utilisateur sur l'un des cercles, le détail des relations de l'entité avec d'autres entités s'ouvre en mode graphe. Le résumé de la notice s'affiche en barre latérale sur le côté.

- Au clic sur une entité liée, le graphe se reforme et l'entité choisie devient le centre du graphe.

On pourrait également ajouter au graphe les lieux et les personnes (intervenants) liés à chaque entité du FRBR.

Annexe B

Spécification fonctionnelle : Recherche en langage naturel à l'appui de l'intelligence artificielle

Cette seconde annexe, présente une spécification fonctionnelle pour la mise en place d'un outil de recherche en langage naturel, fondé sur l'intelligence artificielle, rédigée à la demande de Skinsoft dans le cadre de notre stage. Cet outil est actuellement en cours de développement. L'implémentation de la recherche en langage naturel a fait l'objet de recherches et de réflexions parallèles à celles de la segmentation et de l'indexation automatisées. Le document est structuré en deux parties : les principes d'usage théoriques, la spécification fonctionnelle détaillée à l'appui de maquettes visuelles.

Cette spécification a été rédigée conjointement avec Florian Martin, également stagiaire chez Skinsoft. Réduite pour les besoins de notre étude, cette annexe fait en réalité partie d'une spécification plus large rendue avec ce mémoire comme livrable technique.

I. Le besoin utilisateur

L'application doit proposer un mode de recherche alternatif à la recherche simple, basé sur l'intelligence artificielle. Cela doit permettre de questionner l'application en langage naturel dans un double objectif :

Rendre chaque table interrogeable sans utilisation de vocabulaire contrôlé ou de la recherche avancée : une simple phrase suffit

Par exemple :

- “Tous les films réalisés par David Lynch en 1987”

- “Tous les films numériques”
- “Toutes les photos au format dng”

Agir comme un générateur de requête exécutable par l'utilisateur sur la table interrogée ET la recherche fédérée.

II. Principes d'usage

1. Mode de "recherche augmentée" alternatif

Dans les outils de recherche, à côté de la barre de recherche je clique sur le bouton de recherche augmentée. La barre de recherche passe de la fonctionnalité “recherche simple” à la “recherche augmentée” : on peut interroger la table en question à l'aide de phrases.

Il y a une distinction visuelle établie dès le clic :

- Le fond du bouton se colorie selon la couleur de l'interface définie dans la notice d'établissement. Fonctionnement actuel des autres boutons
- Apparition d'un symbole warning dans la barre de recherche, à son extrémité droite. Au survol avec la souris, une infobulle s'ouvre avec le message : “Recherche augmentée activée, vous utilisez l'intelligence artificielle. Fonctionnalité limitée à l'usage des données existantes.”

Changement du message inscrit dans la barre de recherche :

- Recherche simple : “Recherche”
- Recherche augmentée : “Interrogez-moi”

2. Gestions des erreurs

Deux logiques :

- La possibilité pour le processus d'indiquer qu'il ne comprend pas la requête utilisateur afin d'éviter la création d'une requête erronée.
- La possibilité pour l'utilisateur de signaler un problème.

En cas d'incompréhension de la requête utilisateur et d'incertitude sur la requête à générer. La fonctionnalité doit :

- Ne pas lancer la requête car il n'est pas certain.
- Identifier le point bloquant
- Signaler l'erreur par un code couleur :

Le mot posant un problème est surligné en rouge lorsque incompréhension totale.

Le mot pose un problème est surligné en orange lorsqu'il y a une incertitude sur le sens.

L'utilisateur doit pouvoir écrire dans la barre de recherche un complément à la requête d'origine.

- Le complément s'envoie au processus comme une requête classique. C'est l'interprétation qui change.
- S'il y a toujours une erreur, on revient à l'étape précédente jusqu'à résolution de l'erreur.
- Si l'utilisateur tombe dans une boucle infinie et décide d'arrêter le traitement, l'absence d'activité dans la barre de recherche dans les 30 secondes met fin au processus.
- Si le complément amène à résoudre l'erreur, le processus suit son cours.

En cas d'une requête générée mais invalide selon l'utilisateur, ce dernier peut la reporter afin que le modèle enregistre l'incident, comprenne l'erreur et s'affine.

À côté du résumé se trouve un bouton "Reporter une erreur"

Au clic sur le bouton, ouverture d'un formulaire afin de reporter une erreur. S'ouvre comme une notice.

Quatre champs sont affichés :

- Champ Titre du rapport : l'utilisateur saisi un titre pour le rapport d'erreur. Permet de le rendre traçable.
- Champ requêtes : rempli automatiquement, il contient la requête utilisateur (la phrase de départ) + le résumé de la recherche générée par IA. Non visible par l'utilisateur, y figure aussi la requête Elasticsearch générée.
- Champ date : rempli automatiquement avec le jour de requêtage
- Champ description : l'utilisateur explique pourquoi cela ne lui convient pas et ce qu'il attendait.

Deux boutons sont disponibles :

- “Envoyer” :

Envoie le rapport d’incident au LLM, l’historise et l’intègre dans une base de données pour entraînement.

Génère une notification verte à l’endroit habituel : “Rapport d’erreur envoyé et enregistré”.

- “Annuler” : Annule l’opération en cours.

Génère une notification orange à l’endroit habituel : “Rapport d’erreur annulé”.

III. Fonctionnalité détaillée

1. Infobulle

Au survol de la souris, le symbole affiche une infobulle contenant un court message qui informe l’utilisateur de l’utilité de la recherche activée. Le symbole est affiché en tout temps lorsque la recherche augmentée est activée.



Figure B.1 - Infobulle d’activation

2. Requête mal formulée ou incertaine

Si la requête de l’utilisateur est mal formulée ou incorrecte, empêchant la recherche augmentée d’être lancée, deux options sont possibles.

Si l’outil est incertain quant à l’interprétation d’un terme utilisé dans la requête, celui-ci est surligné en couleur orange :

Si l’outil ne comprend pas la requête, parce qu’elle est incohérente ou inadaptée, celle-ci est surlignée en rouge :



Figure B.2 - Incertitude quant au terme utilisé



Figure B.3 - Incohérence du terme utilisé

3. Résultats de recherche invalides :

Si les résultats de recherche retournés par la recherche augmentée sont erronés selon l'utilisateur, et ne correspondent pas à la requête qui a été formulée, il peut signaler l'incident dans un formulaire prévu à cet effet, via un bouton "reporter un problème" dans l'onglet de résumé :



Figure B.4 - Reporter un problème

Au clic sur ce bouton, un formulaire s'ouvre sous la forme d'une notice que l'utilisateur peut remplir pour décrire le problème détecté. Les champs "date" (format calendaire) et "requête effectuée" sont automatiquement remplis :

Au clic sur "envoyer", un message de validation apparaît :

The screenshot shows a web application interface for reporting a problem. At the top, there is a navigation bar with the 'skin' logo and links to 'S-Museum', 'SKINilbris', 'SKINarchives', and 'S-Movies'. Below this is a search bar with a magnifying glass icon and a tab labeled 'Problème' with a close button 'x'. The main heading is 'Reporter un problème'. The form contains four input fields: 'Date' with the value '28/08/2026', 'Titre' (empty), 'Requête effectuée' with the text 'Tous les films créés par David Lynch en 1987', and 'Description du problème (champs erronés, mauvais résultats...)' (empty). At the bottom, there are two buttons: 'Envoyer' (orange) and 'Annuler' (grey). On the left side, there is a vertical orange sidebar with several icons representing different functions.

skin S-Museum SKINilbris SKINarchives S-Movies

Q Problème x

Reporter un problème

Date 28/08/2026

Titre

Requête effectuée

Tous les films créés par David Lynch en 1987

Description du problème (champs erronés, mauvais résultats...)

Envoyer Annuler

Figure B.5 - Formulaire d'erreur

S-Museum S-Museum S-Museum S-Museum

FR

Problème

Rapport d'erreur envoyé et enregistré

Reporter un problème

Date: 28/08/2026

Titre: Champ créateur non pris en compte

Requête effectuée: Tous les films réalisés par David Lynch en 1987

Description du problème (champs erronés, mauvais résultats...): L'outil n'a pas pris en compte le champ "Création/conception/réalisation > créateur" et n'a pas renvoyé les bons résultats. Voici le résumé obtenu : Création / Conception / Réalisation ((Date(s) de création (Date est égal à 1987))

Envoyer Annuler

Figure B.6 - Message de validation

Glossaire

archives audiovisuelles Désigne l'ensemble des documents audiovisuels (composés de son et/ou d'images fixes ou mouvantes) enregistrés sur un support physique ou numérique et préservés pour leur valeur patrimoniale.. 3, 5, 10–13, 15, 16, 30, 31, 47, 50, 51, 75, 101, 103, 133

Expression Selon l'IFLA, l'Expression est la réalisation intellectuelle ou artistique d'une œuvre. 6, 7, 10–12, 20, 22, 27

Manifestation D'après le manuel de la FIAF, une Manifestation est la matérialisation d'une Œuvre/Variante. Les Manifestations englobent tous les médias analogiques, numériques et en ligne. L'information sur la Manifestation peut comprendre une description de ce que la Manifestation devrait idéalement contenir quels que soient les Items conservés par l'institution.. 6, 7, 10, 13, 17–20, 24, 25, 27, 28, 107–110, 112, 113, 131

Item D'après le manuel de la FIAF, un Item est l'exemplaire physique de la Manifestation d'une Œuvre ou d'une Variante, c'est-à-dire la copie physique d'une Œuvre ou d'une Variante.. 6, 7, 10, 12, 13, 17, 19, 20, 22, 24, 25, 27, 28, 66, 82, 107–109, 112, 113, 131

Œuvre D'après le manuel de la FIAF, l'Œuvre est une entité comprenant le contenu intellectuel ou artistique ainsi que le processus de réalisation sous une forme cinématographique.. 7, 10–13, 17–20, 22, 24–28, 30, 66, 67, 74, 82, 88, 107–109, 113, 131

rushes Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant généralement le matériau source d'un film.. 11, 24, 26, 30–32, 35, 66, 67

Variante D'après le manuel de la FIAF, une entité qui peut être utilisée pour indiquer tout changement dans les caractéristiques liées au contenu mais qui n'affecte pas de manière significative le contenu global d'une Œuvre dans son ensemble.. 12, 24, 108, 113

segmentation temporelle Désigne un type de segmentation automatique prenant en compte la temporalité du flux audiovisuel (à l'inverse d'une segmentation sémantique qui isole

les éléments au sein même de l'image). Dans le cadre de notre étude, elle désigne une segmentation en différentes séquences.. 30, 32, 41, 42, 47

séquence Unité syntaxique cinématographique au sein d'un flux audiovisuel. La séquence désigne une unité d'action, un fragment du film qui raconte en plusieurs plans une suite d'événements isolable dans la construction narrative. Elle est à la fois sémantique et temporelle.. 30–32, 35, 36, 42, 47–52, 54–58, 60–64, 66, 74, 135

Pyscenedetect Outil en accès libre fondé sur des tâches de vision par ordinateur classique, permettant la détection automatique de changements de plans ou de scènes dans un fichier vidéo. 39, 48–54, 57, 75, 94–96, 102, 124, 131, 134

vision par ordinateur Désigne l'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo).. 39, 41, 43, 44, 46–48, 50, 56, 75, 76, 94, 98, 124, 134

traitement audiovisuel Désigne l'ensemble des technologies appliquées à l'analyse de contenus audiovisuels.. 41

apprentissage machine Désigne une branche de l'IA regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent.. 43, 44

apprentissage profond L'apprentissage profond est un sous-domaine de l'intelligence artificielle qui utilise des réseaux de neurones artificiels afin d'entraîner des machines à apprendre à partir de données complexes. 44, 45, 47, 48, 50, 55, 56, 58, 59, 76, 134

réseaux de neurones profonds Modèle informatique composé de plusieurs couches de "neurones" interconnectées qui imitent le cerveau humaine afin de traiter des données complexes. 44

transformers Type d'architecture de réseaux de neurones profonds basé sur un mécanisme d'auto-attention qui permet notamment de détecter les relations et dépendances entre les données.. 44–47, 56, 84, 94, 101, 134

plans Le plan désigne la plus petite unité syntaxique au cinéma, délimité par deux coupes au montage ou au tournage.. 47–49

images-clés Image fixe extraite d'un flux audiovisuel et représentative d'une séquence segmentée par l'outil *Pyscenedetect*.. 48, 49, 54, 55, 57, 60, 63

apprentissage supervisé Technique d'apprentissage machine fondée sur l'utilisation de données annotées pour entraîner des modèles d'IA. 58, 59, 94, 98, 135

apprentissage non supervisé Technique d'apprentissage machine fondée sur l'analyse, par des modèles d'IA, de jeux de données bruts, non annotés. . 59

Label Studio Plateforme en libre accès d'annotation de données. Elle permet de préparer des jeux de données d'entraînement pour l'apprentissage des modèles d'IA.. 60, 61

Intelligence hybride Désigne la combinaison de l'intelligence humaine et de l'intelligence des machines qui complète l'intellect et les capacités humaines, plutôt que de les remplacer, afin de prendre des décisions judicieuses, d'effectuer des actions appropriées et d'atteindre des objectifs qui ne peuvent être atteints ni par les humains ni par les machines seules. 79, 99

apprentissage auto-supervisé Technique d'apprentissage machine qui préconise l'entraînement et les prédictions de modèles d'IA à partir de données brutes, non annotées, pour des tâches qui, habituellement nécessitent une supervision.. 94

Liste des acronymes

FRBR *Functional Requirements for Bibliographic Records*. xvii, 3, 5–15, 17–24, 26–30, 32, 33, 36, 63, 65–67, 69, 74, 75, 83, 87, 88, 101, 103, 107, 108, 113, 114, 131, 133–135

FIAF Fédération Internationale des archives du film.. 3, 10–13, 15–18, 22–25, 27, 66, 83, 101, 123

IFLA *International Federation of Library Associations and Institutions*. 6, 66, 123

FRAD Fonctionnalités requises des données d'autorité. 9

FRSAD Fonctionnalités requises des données d'autorité matière. 9

IFLA-LRM *Library reference model*. 9

FRBRoo FRBR orienté objet. 9, 10, 13

CIDOC-CRM object-oriented Conceptual Reference Model. 9

WEMI *Work, Expression, Manifestation, Item*.. 11, 12, 107, 108, 133

WVMI *Work, Variant, Manifestation, Item*.. 11, 12, 133

RDA Règles de description des archives. 11, 17, 83

IA Intelligence artificielle. 33–36, 43, 55, 57, 63, 70, 94, 101, 103, 124, 134, 135

YOLO *You only look once*. 39, 54–60, 62, 63, 76, 90, 94–96, 98, 102, 131, 135

INA Institut National de l'Audiovisuel. 42, 66, 70, 75, 89, 96

CNN réseaux de neurones convolutifs. 44–46, 48, 55, 56, 58, 134

LLM *Large language model*. 62, 63, 84, 86, 136

CNIL Commission Nationale de l'Informatique et des Libertés. 69

NLP *Natural Language Processing.* 74, 75, 97

RAG *Retrieval-Augmented Generation.* 74, 84

INRIA Institut national de recherche en informatique et en automatique. 75

ML *Machine learning.* 93

Liste des tableaux

4.1	Comparatif des approches de traitement audiovisuel automatique	50
6.1	Attributs et exemples de valeurs associées aux entités Fragment d'Expression et Item Numérique.	72

Table des figures

1.1	Entités principales du modèle FRBR	6
1.2	Entités de second et troisième groupes du modèle FRBR	8
2.1	Espaces de travail	16
2.2	Menu de l'espace de travail S-Movies	17
2.3	Lien vers des notices de Manifestation depuis une notice Œuvre	18
2.4	Configuration de masques de saisie pour une notice de film physique	19
2.5	Configuration du menu d'une notice de film physique	20
2.6	Affichage du menu d'une notice de film physique à la saisie	20
2.7	Configuration de grilles de recherche pour l'affichage des éléments liés	21
2.8	Configuration d'un méta-masque au niveau Item	22
4.1	Schéma du processus de détection de coupures par <i>Pyscenedetect</i>	53
4.2	Mise en application de <i>Pyscenedetect</i>	57
5.1	Processus de détection d'objets de <i>YOLO</i>	62
6.1	Intégration du Fragment au modèle de données	71
6.2	<i>Plugin Editor</i> dans <i>Amalia.js</i> ¹	75
6.3	Processus de validation de l'utilisateur métier	77
A.1	Message de suppression d'une notice d'Œuvre	113
A.2	Vue "balade intuitive" proposée par la bibliothèque Kandinsky ²	115
A.3	Vue en graphe de la balade intuitive ³	116
A.4	Modes d'affichage disponibles dans l'application	117

¹INA, *Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-editor-options.html> (visité le 30/08/2026).

²Bibliothèque Kandinsky, *Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).

³Id., *Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).

B.1	Infobulle d'activation	122
B.2	Incertitude quant au terme utilisé	123
B.3	Incohérence du terme utilisé	123
B.4	Reporter un problème	123
B.5	Formulaire d'erreur	124
B.6	Message de validation	125

Table des matières

Résumé	i
Remerciements	iii
Introduction	xiii
I Modéliser les données audiovisuelles	1
1 Le FRBR, un modèle de données bibliographique	5
I. Un modèle conceptuel fondé sur les besoins utilisateurs	5
1. Une structure entité-relation	5
2. Entités de second et troisième groupes	7
3. Localiser, identifier, sélectionner, accéder	8
II. Extension et adaptation du FRBR	9
1. Le FRBR pour la gestion de collections	9
2. Le cas des archives audiovisuelles	10
III. Une adaptation spécifique aux archives audiovisuelles	11
1. Du WEMI au WVMI	11
2. Exemple de modélisation descriptive	12
2 Modéliser un logiciel pour la gestion des collections audiovisuelles	15
I. Configuration du FRBR au sein d’une interface logicielle	15
1. Architecture du logiciel développé par Skinsoft	15
2. L’espace de travail S-Movies	17
a. Structure fonctionnelle	17
b. Configurations spécifiques	18
c. Méta-masques de saisie	21
II. L’inscription de corpus de données audiovisuelles au sein de S-Movies	23

1.	Implémentation d'un corpus audiovisuel classique	23
2.	Implémentation d'un corpus audiovisuel spécifique	24
a.	Une modélisation descriptive à deux niveaux ?	24
b.	Analyse des pratiques métiers	25
III.	Les complexités d'interface soulevées par la modélisation FRBR	27
1.	Affichage hiérarchique et terminologie	27
2.	Configuration et visualisation des liens	27
3	Le projet d'automatiser l'indexation des archives audiovisuelles	31
I.	Les enjeux de l'indexation audiovisuelle	31
1.	Définition de l'indexation	31
2.	Indexer les collections audiovisuelles	32
II.	La nécessité de segmenter	33
1.	Une tâche préalable à l'indexation	33
2.	Une segmentation temporelle	34
III.	Le projet IA chez Skinsoft	35
1.	Un projet global	35
2.	Identifier le besoin pour instaurer un cadre éthique	36
3.	Le besoin d'une segmentation et d'une indexation automatisées . . .	37

II Implémenter une segmentation et une indexation automatiques des archives audiovisuelles 41

4	Application d'une segmentation temporelle automatique	45
I.	Traitement audiovisuel automatique	45
1.	État des lieux	45
2.	La vision par ordinateur	47
a.	La vision par ordinateur classique	47
b.	Vision par ordinateur fondée sur l'apprentissage profond . .	48
3.	Transformers et réseaux de neurones convolutifs (CNN)	48
II.	Outils de segmentation automatique	51
1.	Décomposer le mouvement	51
2.	PySceneDetect	52
3.	Fonctionnement	52
a.	Paramétrages	52
b.	Limites	54

III.	Mise en application	54
1.	Spécificités du corpus traité	54
a.	Paramètres appliqués	55
b.	Données produites	56
5	Décrire et indexer les séquences automatiquement	59
I.	Choisir un modèle d'IA adapté	59
1.	Appliquer les algorithmes aux données	59
2.	<i>YOLO</i>	60
3.	Intégration au processus	61
II.	Entraînement du modèle YOLO	62
1.	Apprentissage supervisé et non supervisé	62
2.	Annotation des données	63
3.	Affinage du modèle	64
III.	La mise en place d'un processus de validation technique	65
1.	Validation et correction des prédictions	65
2.	Préparation de l'indexation des données produites	66
6	Indexation des données produites au sein du modèle de données	69
I.	Prévoir le reversement des données au sein du FRBR	69
1.	La création d'une nouvelle entité	69
2.	Application de l'indexation au sein du modèle de données	71
3.	Adaptation des configurations	72
II.	Proposer une interface de validation pour l'utilisateur	73
1.	Un enjeu de transparence	73
2.	Développer une interface dédiée à la validation de l'utilisateur	74
3.	Déroulé du processus de validation	76
III.	Requêter les données produites	78
1.	Une indexation fine du contenu	78
2.	Requêter le contenu audiovisuel	78
3.	Perspectives d'outils de recherche innovants	79
III	Perspectives d'une intelligence hybride	81
7	Une intelligence hybride	85
I.	Le nouveau statut des données	86
1.	Assurer le suivi de données fluides	86

2.	Mesures de traçabilité	86
II.	Assurer la qualité des données	87
1.	Supervision documentaire	87
2.	Mise à profit d'un LLM ?	88
III.	Explicabilité et transparence	89
8	Évolutions du système existant	91
I.	Visualisation des données en graphe	91
1.	Un modèle de données complexifié	91
2.	Mise en place d'une vue en graphe	92
II.	Segmentation et indexation manuelles	93
1.	Préparer les tâches documentaires	93
2.	Un dispositif de segmentation et d'annotation	94
9	Généraliser le processus	97
I.	Proposer un processus modulable	97
1.	Un paramétrage trop détaillé ?	97
2.	L'apprentissage auto supervisé	98
3.	Un développement local	99
II.	Constituer des données d'entraînement patrimoniales	99
1.	Généraliser l'annotation des données	99
2.	<i>Collections as data</i>	100
III.	Une automatisation nécessaire ?	101
1.	La réalité des besoins	101
2.	Le coût matériel et humain de la supervision humaine	102
3.	Proposer un module paramétrable	103
	Conclusion	105
	Annexes	111
A	Améliorations fonctionnelles - S-Movies	111
I.	Améliorations	111
1.	Amélioration des liens	111
a.	Contraindre les liens entre les niveaux depuis les tables . . .	111
b.	Améliorer les liens depuis les notices	112
2.	Modifier la hiérarchie d'affichage	112

3.	Corrections terminologiques	113
II.	Nouvelles fonctionnalités	114
1.	Annotation de séquences sur un fichier vidéo numérique	114
2.	Mise en place d'une visualisation des liens entre entités du FRBR	115
 B Spécification fonctionnelle : Recherche en langage naturel à l'appui de l'intelligence artificielle		119
I.	Le besoin utilisateur	119
II.	Principes d'usage	120
1.	Mode de "recherche augmentée" alternatif	120
2.	Gestions des erreurs	120
III.	Fonctionnalité détaillée	122
1.	Infobulle	122
2.	Requête mal formulée ou incertaine	122
3.	Résultats de recherche invalides :	123
 Glossaire		127
 Liste des acronymes		131