

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- Apprentissage profond (deep learning)*, URL : <https://www.cnil.fr/fr/definition/apprentissage-profond-deep-learning> (visité le 18/07/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BASSAÏSTEGUY (Sidonie), *Le Médium, c'est La Mémoire : Archivages Du Document à l'Institut National de l'audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).

- BENJAMIN (Walter), *L'oeuvre d'art à l'époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conférence Nationale Sur Les Applications de l'Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/authorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive | Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

- CHAMBONNET (Sébastien), « Définir une architecture de l'information pour la sauvegarde du patrimoine scientifique et technique contemporain (Patstec), à l'heure du web de données » (, 2015).
- Command-Line - *PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- Command-Line - *PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ?* | IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).
- DU (Lin), LE (Brandon) et HONIG (Edouardo), « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.
- Explorer *Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA *Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- FICK (Hanna), FREDRIKSSON (Anneli), LINDBLOM (Helena), FREDRIKSSON (Anneli) et LINDBLOM (Helena), « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.
- France 2030 : un plan d'investissement pour la France | *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GILL (Sandrine), « Les archives audiovisuelles au tamis des archivistes », dans *Les nouveaux paradigmes de l'archive*, dir. Claire Scopsi, Clothilde Roullier, Martine Sin Blima-Barru et Édouard Vasseur, Pierrefitte-sur-Seine, 2024 (Actes), DOI : 10.4000/books.pan.7249.
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar>.

- org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2 (visité le 08/07/2026).
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HERVÉ (Nicolas), LETESSIER (Pierre), Derval (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- Home - PySceneDetect, URL : <https://www.scsenedetect.com/> (visité le 25/07/2026).
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables | Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), DERVAL (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.
- LIU (Haotian), LI (Chunyuan), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).
- Modèles FRBR, FRAD et FR SAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].

- MORSE (Christopher), « Les musées et l'expérience utilisateur (UX) », *La Lettre de l'OCIM. Musées, Patrimoine et Culture scientifiques et techniques*-200 (2022/mars/01), p. 38-43, DOI : 10.4000/ocim.4777.
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).
- PAILLARD (Isabelle), « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).

- Qu'est-ce qu'un réseau de neurones convolutifs ?* / IBM, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ?* / IBM, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SCHIAPPA (Madeline C.), RAWAT (Yogesh S.) et SHAH (Mubarak), « Self-Supervised Learning for Videos : A Survey », *ACM Computing Surveys*, 55–13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].
- SIGNOLES (Aurélié Bergonnier), « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.
- Systèmes et données*, URL : <https://www.transition-bibliographique.fr/systemes-et-donnees/> (visité le 08/07/2026).
- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLETT, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsol/frbreng.pdf>.
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*–hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

[L’indexation] est le fait de dresser un répertoire ou une liste, généralement alphabétique, des sujets traités, des noms cités dans un ouvrage, suivis des références aux pages, aux paragraphes (Rolland-Coul. 1969).¹

Cette citation décrit l’indexation comme un travail répétitif d’extraction d’informations directement à partir de la forme et du contenu d’un document. Ce document, ici textuel, contiendrait en lui-même ces informations dès le premier coup d’œil d’après sa couverture, ses numéros de page, sa table des matières... Ce travail tel qu’il est décrit ici, est aujourd’hui facilement automatisable grâce à des modèles d’apprentissage automatique, capables de lire les documents et en d’extraire les métadonnées pertinentes à indexer pour ensuite les relier à des référentiels.

Or, d’autres types de documents et en particulier les archives audiovisuelles, qui constituent l’objet d’étude de ce mémoire de recherche, résistent à cette automatisation en raison de l’opacité de leur forme, conçue comme une boîte noire. En effet, contrairement à la plupart des supports textuels, les archives audiovisuelles ne révèlent, le plus souvent, rien à la lecture de leur contenant. Le contenu apparaît au moment de la projection. Ainsi, cette particularité formelle les rend en quelque sorte hermétiques aux pratique d’indexation telles que définies par Rolland-Coul et d’autant plus pour l’automatisation de ces pratiques.²

En effet, la mise en place d’une indexation automatisée pour ce type d’archives suppose que les modèles d’intelligence artificielle sachent lire l’enchaînement des images animées et la bande sonore, et en comprennent le langage du montage composé de séquences, de plans, de transitions... Ce langage spécifique n’est pas encore analysé ni compris de manière satisfaisante par les modèles d’intelligence artificielle, surtout dans le cadre de corpus patrimoniaux anciens aux sujets historiques, dont la qualité de l’image et du son est compromise.

¹*INDEXATION : Définition de INDEXATION*, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).

²Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

À cette difficulté d'extraire automatiquement des métadonnées depuis un contenu audiovisuel, une autre difficulté s'ajoute, celle de leur modélisation. En effet, dans un contexte de gestion patrimoniale des collections audiovisuelles, c'est le modèle FRBR qui est utilisé, issu du milieu des bibliothèques et élaboré par l'IFLA en 1998. IL propose une indexation à quatre niveaux : oeuvre, expression, manifestation, item. Cette indexation par niveaux permet de distinguer les métadonnées relevant de l'oeuvre intellectuelle, des métadonnées physique issues de son contenant. En 2016, la Fédération internationale des archives du film (FIAF) adapte le modèle aux archives audiovisuelles, en fusionnant le niveau Oeuvre/Expression et en ajoutant celui de Variante. Le FRBR n'est plus fondé sur un WEMI mais désormais sur un WVMI. En effet, une oeuvre cinématographique est nécessairement exprimée, mais comporte souvent des variantes : montage différent, changement de personnage, des dialogues. Or, si la FIAF propose un modèle nourri d'exemples et de cas d'application, le FRBR reste un modèle conceptuel flexible, repensé dépendamment du type de corpus indexé et qui diffère ainsi d'une institution à l'autre.

Ainsi, l'automatisation de l'indexation des archives audiovisuelles se heurte à une double difficulté, celle de la compréhension du langage cinématographique et d'un modèle d'indexation de données hautement dépendant du contexte dans lequel il est utilisés. Réalisé dans le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, qui propose des solutions logicielles de gestion des collections, ce mémoire analyse les possibilités d'implémentation d'une indexation automatique au sein d'un espace de travail dédié à la gestion de collections audiovisuelles, fondé sur un modèle de données flexible.

Dans quelle mesure la variabilité institutionnelle et sémantique du modèle de données FRBR adapté aux archives audiovisuelles limite-t-elle la mise en place d'une indexation automatique pour ce type d'archives ?

Dans un premier temps, nous analyserons le modèle conceptuel du FRBR, un modèle de données issu des bibliothèques, et les modalités de son adaptation aux archive audiovisuelles. Nous verrons quelles questions pose l'implémentation de ce modèle dans le cadre d'une mise en place de l'indexation automatique. Dans un second temps nous proposerons une implémentation concrète d'indexation automatique des archives audiovisuelles au sein de ce modèle de données, dans le cadre du projet IA chez skinsoft. Nous analyserons plus spécifiquement la mise en place de la segmentation vidéo en séquences, une fonctionnalité priorisée dans la mise en place de l'indexation automatique, et sa compatibilité avec le FRBR. Enfin, nous analyserons les biais et limites techniques posés par les lacunes des données d'entraînement des modèles d'intelligence artificielles, difficilement adaptables au contexte patrimonial. Ces limites permettront d'orienter notre réflexion vers une indexation augmentée plutôt qu'automatisée, qui permettrait également d'améliorer la compréhension du FRBR.

Première partie

Indexer les archives audiovisuelles

1. Le FRBR, modèle d'indexation conçu pour les bibliothèques

le FRBR est issu de la nécessité d'une modélisation permettant de localiser plus facilement des contenus.

l'IFLA A DU Évaluer la pertinence de chaque attribut, de chaque entité et de chaque relation par rapport à ces « tâches utilisateurs ».³

glissement : quand le FRBR été créé c'était pour améliorer les besoins utilisateurs pour trouver l'information. Aujourd'hui, maintenant que les notices sont pour la plupart basées sur ce modèle, il faut trouver des moyens de non plus seulement trouver mais visualiser els données pour se repérer dans le modèle. pourquoi ce besoin ? développer

a. Un modèle conceptuel fondé sur les besoins utilisateurs

Le FRBR, Functional Requirements for Bibliographic Records, est un modèle conceptuel de données bibliographiques élaboré par l'IFLA de 1992 à 1996 et fondé sur le ISBD (à définir).⁴ Ce modèle établit la mise en place de quatre niveaux hiérarchiques pour le catalogage d'un document : le niveau décrivant les caractéristiques individuelles du document en tant qu'exemplaire (item), le niveau décrivant les caractéristiques de sa publication (manifestation), le niveau décrivant les caractéristiques de son contenu intellectuel expression), et le niveau décrivant les caractéristiques de la création abstraite à laquelle il se rattache (oeuvre).⁵ (donner un exemple ? schéma) Il s'agit d'un modèle entité-relation qui modélise précisément les relations qui peuvent exister entre les éléments d'une base de données pour pouvoir ainsi les retrouver plus facilement. De plus, à ces entités du premier groupe au sein du modèle (oeuvre, expression, manifestation, item), s'ajoutent des entités de deuxième groupe : personnes et collectivités. Elles expriment le rôle joué par ces entités sur la production ou le contenu d'une ou plusieurs entités du premier groupe.⁶ (ajouter au schéma les entités de 2e groupe) Enfin, il existe des entités de troisième groupe intégrées au modèle, qui correspondent à des concepts, objets, événements ou lieux liés aux entités de premier et de second groupe.⁷

Ce modèle entité-relation, nous l'avons évoqué, a été mis en place afin de faciliter la navigation de l'utilisateur au sein d'un catalogue, entre les liens qui régissent les différents

³Isabelle Paillard, « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.

⁴*Modèles FRBR, FRAD et FR SAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).

⁵*Ibid.*

⁶IFLA Study Group on the Functional Requirements for Bibliographic Records, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).

⁷*Ibid.*

éléments d'une collection. Ainsi, le FRBR prétend répondre à quatre principaux besoins utilisateur : trouver, identifier, sélectionner, obtenir.⁸ Il permet donc à l'utilisateur de localiser la ressource, d'identifier si elle correspond à bien ce qu'il cherche, de sélectionner la ressource selon ses besoins, et d'accéder finalement à son contenu. Nous ajouterons que le besoin fondateur de la création d'un tel modèle est surtout celui de pouvoir visualiser et explorer les liens de la ressource identifiée avec d'autres ressources pertinentes qui y sont directement associées.⁹ Nous pouvons ainsi établir que le modèle FRBR se situe à l'intersection de deux besoins principaux : celui d'améliorer la connaissance sur une ressource donnée en visibilisant ses relations (et d'assurer sa conformité, à terme, avec le web sémantique), et celui d'améliorer l'expérience utilisateur en proposant une interface navigable et intuitive. Notons que ces besoins s'appliquent non seulement à l'utilisateur faisant partir d'un "public", au sein d'un catalogue ou d'une base de données en ligne, mais aussi à l'utilisateur métier, interne à l'institution. C'est précisément sur les besoins métier de ce dernier que se concentre l'analyse de ce mémoire de recherche. De fait, les enjeux de l'implémentation et de l'adaptation du modèle FRBR se situent au coeur des ambitions d'un logiciel de gestion des collections tel que celui proposé par skinsoft.

Le FRBR comme modèle :

Le FRBR, nous l'avons défini, est bien un modèle. Il se place comme un cadre d'affichage des données, sans prétendre à normaliser leur description. C'est pourquoi les entités qu'il propose sont remises en question pour leur caractère trop "générique".¹⁰ Ainsi, comme tout modèle, faute de pouvoir être implémenté tel quel, il est soumis à une redéfinition à chaque implémentation selon le contexte donné. Cette flexibilité ne doit toutefois pas nuire à l'objectif principal, celui de faciliter la navigation de l'utilisateur, en explicitant les "interrelations" entre les notices et les données produites.¹¹

b. Son adaptation à l'archivistique et au contexte muséal

Notons en effet que le modèle FRBR est un modèle conçu par et pour les bibliothèques, du moins au départ. À ce jour, les bibliothèques n'utilisent plus seulement le modèle FRBR mais la somme du FRBR et de ses modèles étendus : le FRAD pour les autorités, et le FRSAD

⁸Tillett, Barbara B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

⁹*Ibid.*

¹⁰Patrick Boeuf, « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code*, 5 : *Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code*, Pretoria, South Africa, 2007, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/authorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).

¹¹*Ibid.*

pour les sujets.¹². La somme de ces modèles constituent finalement le modèle IFLA-LRM, présenté en successeur du FRBR. Or, dans le contexte de ce mémoire de recherche, notre objet d'étude est celui des archives audiovisuelles. Ainsi, comment adapter un modèle de données conçu pour les bibliothèques à un contexte de gestion des collections d'archives et plus spécifiquement d'archives audiovisuelles ? Premièrement, tentons d'analyser son adaptation au milieu archivistique. La difficulté principale de l'adaptation du modèle FRBR aux collections d'archives est que le niveau Oeuvre (work) ne peut contenir le plus haut niveau archivistique : le fonds d'archives. En effet, un fonds d'archive ne peut pas être considéré systématiquement comme une oeuvre, puisque dans la plupart des cas, il s'agit plutôt d'une aggrégation naturelle d'éléments quotidiens produits par une personne morale ou physique. Ainsi, un fonds d'archives ne peut pas être intégré à la définition d'une oeuvre comme création intellectuelle et artistique distincte.¹³. Un fonds d'archives correspondrait plutôt à un agrégat d'oeuvres ou de travaux, niveau intermédiaire décrit par le modèle FRBR : "un ensemble de documents privés classés par des archives en un seul fonds"(traduction).¹⁴ Le modèle de données FRBR a également été adapté dans le milieu muséal à travers une version orientée objet (FRBRoo), issue d'une fusion avec le modèle de données spécifique au milieu muséal, le CIDOC-CRM (object-oriented Conceptual Reference Model).¹⁵ Ce dernier modélise la temporalité de la vie de l'objet de collection avec les événements et l'espace temps qui lui sont liés. Ainsi, le FRBRoo est adopté en fonction de la nature de la collection. En effet, le modèle s'adapte mal à une collection picturale par exemple, puisque l'oeuvre et l'item se réalisent dans le même support, unique. Un tableau est à la fois l'oeuvre et l'exemplaire original. Ce type de collection s'inscrit plutôt dans une modélisation du CIDOC-CRM. Ainsi, notons que le modèle FRBR est particulièrement bien adapté aux médiums artistiques qui font l'objet d'une reproductibilité technique, comme c'est le cas du cinéma, notre objet d'étude.¹⁶

c. Un modèle adapté aux archives audiovisuelles

En effet, une distinction claire peut être établie entre l'expression de l'oeuvre cinématographique au moment du tournage et du montage, et sa reproduction en différents exemplaires selon différents contextes de diffusion. Ce processus de reproduction, propre au

¹² *Modèles FRBR, FRAD et FRSAD...*

¹³ Hanna Fick, Anneli Fredriksson, Helena Lindblom, A. Fredriksson et H. Lindblom, « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.

¹⁴ *Ibid.*

¹⁵ Sarah L. Gillis, « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Appling-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).

¹⁶ Walter Benjamin, *L'oeuvre d'art à l'époque de Sa Reproductibilité Technique*, 1935.

caractère industriel du cinéma, peut notamment s'apparenter à celui du milieu littéraire. C'est pourquoi les centres d'archives audiovisuelles se tournent vers le FRBR comme modèle privilégié pour leurs données. Toutefois, l'adéquation du modèle FRBR dépend de la nature du corpus audiovisuel appréhendé. En effet, le modèle s'applique particulièrement bien aux corpus de cinéma "classiques" dont la chaîne de production industrielle est respectée : un film est réalisé à l'issue d'un tournage et d'un montage (oeuvre), distribué (manifestation), et visionné (item). Or, dans le cas de corpus spécialisés, expérimentaux, personnels, ou amateurs, la modélisation FRBR s'assimile difficilement. Ce type de films n'est souvent pas distribué, rendant ainsi, par exemple, le niveau de manifestation obsolète. C'est pour répondre à ces particularités propres au médium cinématographiques que la Fédération internationale des archives du film (FIAF) rédige un manuel de catalogage qui adapte le modèle FRBR aux collections audiovisuelles.¹⁷

Le manuel s'adresse en effet aux institutions qui possèdent des collections d'images animées, définies ainsi : "Les images animées comprennent une gamme de matériaux différents sur lesquels des séquences d'images ont été enregistrées et qui créent l'illusion du mouvement lorsqu'ils sont projetés, diffusés ou lus (à l'aide d'un projecteur, d'un téléviseur, d'un ordinateur, d'un logiciel ou de dispositifs équivalents). Ces images peuvent être accompagnées ou non de son."¹⁸ Il propose d'adapter des normes, modèles et schémas documentaires suivants : le FRBR, le RDA (ressources, description, accès), qui applique les concepts et la terminologie FRBR, et les normes sur les oeuvres cinématographiques EN 15744 / EN 15907 du Comité européen de normalisation (CEN).¹⁹ Bien que le FRBR tel que conçu pour les bibliothèques décrive des entités dispersées en trois groupes différents (entité, personnes, sujets), le manuel de la FIAF choisit d'adapter uniquement les entités de premier groupe au contexte de gestion des images animées. Au sein de ces entités de premier groupe, qui comprennent, rappelons le, les entités d'Oeuvre, d'Expression, de Manifestation et d'Item, la FIAF propose ainsi quelques modifications. La notion d'Expression est notamment fusionnée dans celle de l'Oeuvre. En effet, les auteurs du manuel expliquent que les entités Oeuvre et Expression, respectivement l'idée artistique abstraite, conceptuelle, et son expression sur un support, ne sont pas adaptés à la nature du médium cinématographique. Une oeuvre filmique ne devient Oeuvre qu'à l'issue d'un processus technique de réalisation et de montage, c'est ainsi qu'elle est "plus aisément conceptualisée comme [une] entité concrète". Une oeuvre filmique n'existe pas réellement tant qu'elle n'est pas tournée et montée. De plus, le concept d'idée, d'oeuvre

¹⁷Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

¹⁸FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

¹⁹*Ibid.*

originale et conceptuelle avant son expression sur un support n'existe pas dans un contexte cinématographique, puisque le cinéma, nous l'avons évoqué, est un médium caractérisé par sa reproductibilité technique. C'est pourquoi le manuel de la FIAF propose de fusionner les niveaux Oeuvres/expression. De plus, une entité est ajoutée : la variante, qui correspond à toute expression différente de l'oeuvre. Par exemple, une version colorisée d'un film, un montage différent, un changement dans les personnages ou les acteurs, qui n'altère pas le sens essentiel de l'oeuvre. Les sous-entités restantes, Manifestation et Item, sont conservées mais redéfinies. La notion de manifestation, comprise dans un contexte cinématographique, est la "matérialisation d'une Œuvre/Variante" sur tout support, numérique ou analogique.²⁰ La notion d'item fait finalement référence à une copie physique de la Manifestation d'une Œuvre ou d'une Variante. Ainsi, la description, au lieu de s'inscrire dans une seule notice, est scindée en différents niveaux. La notice Oeuvre contient les informations liées au contexte de création et au contenu. La notice Variante contient les informations de variations de l'oeuvre, tandis que la notice de Manifestation contient les informations de ses modalités d'édition et de distribution. La notice Item contient une description relative à un exemplaire unique telle que la présence de marques, d'inscriptions, son état physique, etc. Enfin, nous avons mentionné les besoins utilisateurs auxquels prétend répondre le modèle FRBR tel que décrit pour le milieu des bibliothèques. Le manuel de la FIAF propose une adaptation de ces besoins aux catalogues d'images animées : "identifier, sélectionner et acquérir : toutes les versions (variantes) d'une oeuvre recherchée, [...], toutes les copies (manifestations ou items) d'une version particulière d'une oeuvre, [...] toutes les oeuvres d'une personne en particulier [...], toutes les oeuvres sur un sujet [...], toutes les oeuvres dans une forme ou un genre particulier."²¹ Ainsi, le manuel de catalogage des images animées proposé par la FIAF repense la structure du modèle de données FRBR, établi pour des besoins bibliographiques, pour pouvoir l'adapter au contexte de gestion des collections audiovisuelles. Les niveaux descriptifs qualifiés de WEMI (Work, Expression, Manifestation, Item), sont désormais contenu dans l'acronyme WVMI (Work, Variant, Manifestation, Item). Un tel changement s'explique principalement par les différences de besoins liées à la gestion des collections d'images animées et audiovisuelles. Toutefois, il s'agit bien toujours d'un cadre de modélisation de description des données, dont l'implémentation dans un logiciel de gestion des collections peut être compliquée par la nature du corpus catalogué.

2. Adapter le FRBR aux archives audiovisuelles

Mentionner la fonctionnalité intéressante de l'héritage des identifiants

²⁰ *Ibid.*

²¹ *Ibid.*

a. Un espace de travail dédié à la gestion de collections audiovisuelles : S-Movies

Si le manuel de la FIAF pose les fondations de l'adaptation du modèle FRBR aux archives audiovisuelles, il s'agit désormais d'en analyser une implémentation concrète, celle proposée par Skinsoft dans son logiciel de gestion des collections, à travers l'espace de travail S-Movies. L'enjeu de cet espace de travail, dédié à la gestion des collections audiovisuelles, est de proposer une adaptation cohérente des préconisations de la FIAF concernant le modèle FRBR.

L'application développée par Skinsoft, divisée en espaces de travail dédiés à chaque type de collection, permet justement d'adapter le modèle à chaque type de données. En effet, au sein de la structure de chaque espace de travail, Skinsoft permet une haute configurabilité impliquant le paramétrage de champs de saisie pour chaque type de notice, de l'organisation de ces champs dans des grilles de résultats de recherche, et de l'assemblage des champs et des grilles de recherche dans des menus navigables pour chaque type de notice. (schémas explicatifs ?) Ainsi, une double adaptabilité est proposée : un espace dédié et conforme au type de données issue indexées (espaces de travail : S-Movies), et un paramétrage propre au type de corpus géré par l'institution cliente (la collection audiovisuelle d'une institution spécifique, avec ses caractéristiques propres). Plus précisément, les archives audiovisuelles possèdent un socle normatif commun, nous l'avons évoqué, celui du modèle FRBR qui conditionne la structure des données produites mais également leur description. Ce socle est stable et inchangé dans la gestion de collections d'une institution à l'autre, ce qui permet à Skinsoft de proposer un espace de travail prédéfini. En revanche, les corpus audiovisuels entre les institutions peuvent être de toutes sortes, sur différentes thématiques, sous différents formats. Cette hétérogénéité suppose des règles métiers différentes entre institutions, qui sont la conséquence de besoins, eux aussi, bien différents. Ainsi, par exemple, une collection audiovisuelle expérimentale n'aura pas besoin des mêmes champs de saisie, des mêmes thésaurus, ou de la même disposition des résultats de recherche, qu'une collection audiovisuelle grand public. Nous avons mentionné la possibilité de paramétrer des champs de saisie adaptés pour chaque type de collection audiovisuelle. Ces champs, s'ils sont paramétrables individuellement, font en réalité partie d'une structure plus large, à l'échelle de l'espace de travail dans lequel ils se situent. En effet, ces champs sont regroupés dans des masques, qui correspondent à des formulaires de saisie spécifiques au type de notice concerné. Par exemple, une notice "Restauration" pourra contenir un masque "Description", contenant des champs de saisie liés à la description : titre, numéro d'identification, responsable(s) interne(s), intervenant(s), etc. Ce masque pourra ensuite être assemblé dans le menu d'une notice de restauration, qui comportera alors un onglet "Description", permettant à l'utilisateur d'y remplir les champs que nous avons mentionnés. Tous les espaces de travail sont fondés sur l'organisation des champs de

saisie en différents masques, afin de pouvoir configurer les notices. Toutefois, les espaces de travail structurés sur le modèle FRBR, comme c’est le cas de S-Movies, requièrent un niveau de configuration supplémentaire, afin d’illustrer le découpage de la description en quatre niveaux hiérarchiques. C’est le rôle des méta-masques, des formulaires qui peuvent pointer sur les champs de plusieurs types de notices à la fois, afin d’imbriquer ces niveaux de description. Ce système permet à l’utilisateur de saisir, sans qu’il s’en rende compte, des informations sur plusieurs niveaux du FRBR en une seule notice. Concrètement, dans S-Movies, la notice d’Oeuvre/Expression pointe sur les champs de l’Oeuvre et de l’Expression, la notice de Manifestation pointe sur les champs de l’Oeuvre, l’Expression et la Manifestation, la notice de l’Item pointe sur l’Oeuvre, l’Expression, la Manifestation et l’Item. **(Faire un schéma explicatif) (citer le mode d’emploi interne ?)** D’autres types de notices font appel aux méta masques, comme les notices de médias, nous y reviendrons.

Nous l’avons évoqué, ces masques et métamasques constituent une structure pérenne qui fait l’objet d’un paramétrage individuel, en fonction du type de collection et des usages métiers du client institutionnel. Dans le cas d’une migration de données depuis une autre base de données, un travail de mapping s’effectue alors afin de trouver un accord sur les nouveaux champs qui remplaceront les anciens. L’équipe de Skinsoft organise ensuite ces champs dans des formulaires de saisie (masques et méta masques), eux-mêmes organisés pour constituer des menus de notice et des grilles de résultats de recherche. L’équipe produit également des imports de thésaurus propres aux usages de l’institution en question, afin d’assurer l’interopérabilité des données saisies. Entre autres fonctionnalités, S-Movies permet spécifiquement de gérer les entrées des collections films (via la table Entrées), de gérer les médias numériques, de regrouper les collections par thématiques, de gérer les projets et mouvements. Mais surtout, l’espace de travail contient trois tables, correspondant chacune à un niveau de description du modèle FRBR : Films (items), Manifestations, Oeuvres. Dans chacune de ces tables l’utilisateur peut créer des notices, et y associer des notices des autres tables. Par exemple, depuis la table des Oeuvres, l’utilisateur peut créer une notice Oeuvre et y associer les notices de Manifestations et d’Items qui y sont directement liées. Les bases de la structure S-Movies ainsi décrite, nous pouvons déjà établir que cette architecture normée, synthèse du modèle FRBR et des normes en vigueur, ainsi que le paramétrage personnalisé, sont la condition de la qualité de l’expérience utilisateur et ainsi de celle des données. L’enjeu de l’espace de travail est d’offrir une interface qui permette à l’utilisateur de comprendre les délimitations entre les niveaux du FRBR et les liens qu’ils entretiennent, afin de saisir les données pertinentes au bon endroit. Une expérience utilisateur intuitive permet une meilleure structure des données et assure leur interopérabilité. Tout au long de cette étude, l’expérience utilisateur sera d’ailleurs au coeur des enjeux fonctionnels de l’application. Toutefois, l’analyse, en stage,

de corpus audiovisuels spécifiques ajoute une difficulté supplémentaire à rendre l'espace de travail intuitif et navigable selon sa structure propre. Ainsi, l'adaptabilité du paramétrage et la nature de l'interface sont remis en question par la capacité du FRBR à s'adapter à des corpus audiovisuels hétérogènes.

b. L'inscription des corpus de données dans la remodelisation du FRBR

En effet, la nature du corpus audiovisuel complexifie le paramétrage puisqu'elle conditionne la capacité des données à s'adapter et s'intégrer au sein du modèle FRBR. Le modèle FRBR fait partie d'une structure fixe de l'espace de travail, avec cette séparation en trois tables de saisie (Oeuvres, Manifestations, Items), dont le paramétrage peut toutefois amoindrir la rigidité. Afin d'analyser la mesure dans laquelle les corpus s'intègrent au sein du modèle FRBR, nous analyserons dans cette sous partie deux corpus de données différents.²² Ces deux corpus n'ont pas été sélectionnés ici volontairement, puisqu'ils sont simplement les corpus audiovisuels principaux gérés par l'application Skinsoft à ce jour. Il est justement intéressant d'en analyser la nature tout à fait différente. Premièrement, analysons l'intégration d'un corpus de cinéma dit "classique", au sein de l'espace de travail S-Movies. Cette collection est gérée par une institution qui préserve essentiellement des films de fiction issus d'une production commerciale "grand public" depuis les débuts du cinéma jusqu'à nos jours. La production cinématographique étant une production industrielle, les films qui en sont issus s'adaptent bien à un modèle de données par niveaux, ces différents niveaux correspondant aux étapes de production. Ces films, après leur création, ont donc été produits et distribués à une échelle plus ou moins large. Ainsi, dans ce cas précis, le modèle FRBR est plutôt bien adapté. La réalisation du film par le montage et le tournage est décrite au niveau Oeuvre, ses versions sont décrites au niveau variante, son édition et sa distribution sont décrites au niveau Manifestation, et l'exemplaire individuel du film, conservé par l'institution est décrit au niveau Item.

Deuxièmement, analysons l'implémentation d'un corpus plus spécifique, celui d'une collection de films documentaires muets et non montés, tournés des années 1910 à 1920. Ces films, qui sont en réalité des *rushes* bruts (à définir), ont été tournés dans une optique de documentation par sujets, et n'ont donc pas été destinés à une projection grand public. Ainsi, l'absence de montage et de distribution commerciale rend difficile l'adaptation du corpus au modèle FRBR. Le tournage peut être décrit au niveau Oeuvre : contexte, réalisateur, date, lieu... Toutefois, certains des niveaux sous-jacents à l'Oeuvre deviennent obsolètes. La Variante n'existe pas puisque

²²Notons que pour des raisons de confidentialité, nous décrirons les corpus de ces institutions sans les nommer de manière explicite.

chaque *rush* est unique et non monté. Ainsi, il n'existe pas différentes versions d'un même film qui justifierait la création d'une variante. De la même façon, le niveau Manifestation n'est plus pertinent puisque ces *rushes* ne sont ni produits ni distribués auprès d'un public quel qu'il soit. L'inscription de l'oeuvre sur un support s'effectue ici de manière unique, dont ce support en est le seul exemplaire. Les caractéristiques matérielles pourraient donc être décrites directement au niveau de l'item. Ainsi, d'un modèle à quatre niveaux, il ne reste, dans ce cas précis, plus que deux niveaux de descriptions exploitables : Oeuvre et Item. Toutefois, une oeuvre peut se matérialiser dans différents supports, physiques et numériques, pour des raisons de conservation et de diffusion patrimoniales. Par exemple, l'institution peut créer des copies de l'oeuvre sur des supports plus stables afin de mieux la préserver, et la numériser pour pouvoir la diffuser en ligne, par exemple. Ces différentes matérialisations, bien qu'elles ne soient pas issues d'un processus de distribution commercial, pourraient être considérées comme des Manifestations. Telle que définie par le manuel de la FIAF, une manifestation induit, en effet, "tous les médias analogiques, numériques et en ligne associés à une matérialisation particulière d'une Œuvre/Variante."²³ Sa description pourrait être justifiée par des objectifs de conservation : copie, numérisation, restauration. Toujours selon le manuel, sa description pourrait inclure les attributs suivants, sélectionnés selon leur niveau de pertinence pour un tel corpus : type de manifestation, format (incluant les champs suivants : type de support, caractéristiques sonores, caractéristiques de couleur), Notes. Les autres attributs du niveau Manifestation ne sont pas mentionnés ici car indaptables à la nature des films conservés par cette institution précise. De plus, les champs de caractéristiques sonores et couleurs pourront seulement mentionner que les films sont muets et en noir et blanc. Confrontons maintenant ce modèle défini par la FIAF à l'implémentation concrète de la collection au sein de l'espace de travail S-Movies. Il sera particulièrement intéressant d'y analyser la manière dont les limites du niveau Manifestation dans ce cas précis sont appréhendées. (la FIAF propose une indexation à deux niveaux : Oeuvre > manifestation/item) Au sein de la table Oeuvres, les notices sont réparties en différentes catégories : toutes les oeuvres, tous les montages contemporains, tous les montages d'époque, toutes les actualités, tous les *rushes*. La catégorie "tous les *rushes*" est en réalité la même celle intitulée "toutes les oeuvres". Les autres sections ont été créées en raison de montages contemporains ou d'époques à partir de ces *rushes*. (agrégats?). Au sein d'une notice d'oeuvre, les éléments suivants sont décrits : identification, titre, créateur, description (sujet de la prise de vue), mots clés, films associés, manifestations associées, matériel non film associé, archives associées, bibliographie, médias, données de gestion. La table Manifestations, en revanche contient des notices "fantômes" sans contenu descriptif. En effet, l'application Skinsoft crée automatiquement une notice de manifestation

²³ *Ibid.*

liée lorsque l'utilisateur crée une notice d'item. Dans ce cas, la manifestation devient une condition structurelle pour maintenir la cohérence du modèle, mais elle perd son sens dans un contexte d'indexation concret. La table des items est répartie en trois catégories d'objets : bobines, cassettes —qui constituent les films physiques— et films numériques. Lorsqu'un même film physique est présent en plusieurs exemplaires dans la collection, les notices sont distinguées par la mention "bobine originale" et "reproduction". Les notices de films physiques contiennent une description matérielle sur le support et la condition de ce support. Elles mentionnent également les collections liées vers d'autres items et oeuvres, vers des médias et des documents. La manifestation référente est tout de même mentionnée mais il s'agit, nous l'avons évoqué, d'une notice fantôme. Enfin, les films numériques décrivent le support original depuis lequel la numérisation a été effectuée, les raisons de la numérisation —par exemple, copie de sauvegarde—, l'item physique qui a fait l'objet de ladite numérisation. Par ailleurs, un élément précis a retenu notre attention : la présence de *time-codes* ou marqueurs temporels, traduisant la présence du film numérique dans des items plus longs. En effet, certains films physiques, qui sont en réalité des *rushes*, ont été découpés en extraits et numérisés, pour des objectifs de diffusion en ligne, afin de les rendre intelligibles. La plupart des films numériques de la collection sont le résultat de ce montage à but patrimonial. Les repères temporels expriment le rattachement précis de l'item numérique au sein d'un item physique. Ainsi, s'apparente à un modèle hiérarchique à deux niveaux, celui d'une Oeuvre matérialisée dans une Manifestation/Item, fusionnés en une seule entité. Cette hiérarchie à deux niveaux est brièvement décrite dans le catalogue de la FIAF en tant qu'exemple, mais ses modalités ne sont pas détaillées. Si l'espace de travail S-Movies parvient à maintenir le modèle du FRBR en trois niveaux principaux, la réalité métier de l'institution éclipse le niveau Manifestation pour n'en conserver que deux, pertinents pour décrire les collections documentaires de l'institution. Nos remarques se concentrent alors désormais sur les fonctionnalités proposées par l'espace de travail S-Movies, au regard du corpus spécifique analysé jusqu'ici. Les particularités de cette collection confrontées à la rigidité relative de l'application, pousse notamment Skinsoft à initier, d'une part, la refonte de l'interface et de la navigation entre les niveaux hiérarchiques, et d'autres part, la mise en place de nouvelles fonctionnalités afin d'y automatiser l'indexation.

Le besoin de l'IA vient de ce client pour la collection : rushes opaques qui ont besoin d'être davantage décrits en précision pour recréer un "montage" descriptif et intelligible pour savoir ce que contiennent les rushes.

c. Vers une refonte de S-Movies

la nature du modèle FRBR pose des difficultés d'interface utilisateur (+ de sources ?)

Si nous avons établi un aperçu des limites de l'espace de travail pour l'indexation de col-

lections particulières telles que celle que nous avons décrites, d'autres problèmes, concernant tous types de collections, freinent en réalité une navigation fluide des liens entre les notices issues des niveaux du FRBR. L'interface actuelle ne permet pas de guider efficacement l'utilisateur au sein du modèle FRBR et d'en comprendre les différents niveaux. En effet, le modèle FRBR, dont la hiérarchie paraît, a priori plutôt simple à comprendre, est en réalité difficile à modéliser au sein d'une interface fonctionnelle. Ces difficultés sont principalement liées à la représentation des liens qui régissent les différentes entités du modèle et qui sont essentiels à l'efficacité du principe de l'héritage des données. Parmi les dysfonctionnements révélés par l'expérience utilisateur, nous pouvons par exemple citer des éléments qui paraissent anodins tels qu'un affichage inversé de la hiérarchie des niveaux FRBR dans le menu des tables de l'espace de travail. En effet, au sein du menu, les tables sont présentées de telle manière à ce que le plus bas niveau du FRBR (l'item) apparaisse en haut, suivi de la manifestation et du plus haut niveau (l'oeuvre). Cet affichage descendant induit visuellement en erreur l'utilisateur sur la navigation hiérarchique à employer. De plus, si nous désignons depuis le début de notre analyse le plus bas niveau de la hiérarchie par la notion d'item —tout comme le manuel de la FIAF—, il est désigné par la notion "film" au sein de S-Movies. Or, dans un contexte cinématographique, le film peut communément désigner à la fois une oeuvre et un item individuel. La notion de "film" n'évoque pas le caractère unique et individuel de l'exemplaire tel qu'il est définit dans le manuel de la FIAF. Une autre confusion terminologique traverse l'espace de travail, celle de la présence de la notion d'expression, alors même que ce niveau, issu du modèle FRBR nous l'avons vu, est fusionné dans celui d'oeuvre. D'autres difficultés de navigation, plus larges, sont également soulevées par notre analyse. En effet, la notion de lien entre les niveaux hiérarchiques du FRBR, et donc, entre les notices, est primordiale. Or, l'interface actuelle ne permet pas, ou peu, de visualiser l'ensemble des liens dont une notice fait l'objet. Par exemple, il serait pertinent de pouvoir visualiser d'un seul coup, à partir d'une notice d'oeuvre, toutes les manifestations dans lesquelles elle s'est matérialisée ainsi que tous les exemplaires issus de ses manifestations respectives. Par ailleurs, les liens indispensables qui doivent être établis entre les notices de chaque niveau hiérarchique ne sont pas toujours rendus obligatoires par l'application. Malgré le découpage inévitable des niveaux de descriptions en plusieurs notices différentes, induit par le modèle FRBR, les notices rattachées à une même oeuvre devraient être indissociablement liées. Ainsi, les notices d'item et de manifestations font toujours partie d'un tout, celui de l'oeuvre, dont elles ne sont que les parties. Il faudrait pouvoir modéliser l'indissociabilité des notices d'une oeuvre à travers l'interface de l'application. D'autres problèmes subsistent : l'utilisateur peut, par exemple, supprimer une notice d'oeuvre, ce qui entraîne la suppression de tous les manifestations et films qu'elle contient, sans que l'application ne lui signale. Plus globalement, il serait

pertinent pour l'utilisateur de visualiser les liens entre les notices dès la page d'accueil de l'application. Actuellement, la page d'accueil montre les notices d'oeuvres. Ces problématiques d'interface, si elles semblent parfois insignifiantes, peuvent en réalité faire perdre les données en qualité. L'établissement des liens entre les notices est en effet la condition essentielle de la qualité du schéma de données et des données elles-mêmes. La création de notices dépourvues de tout lien —ce qui est actuellement possible dans l'application— empêche l'héritage des données des niveaux parents. Ainsi, l'utilisateur pourrait créer une notice d'item sans la rattacher nécessairement à une oeuvre ou à une manifestation. Cette notice n'hériterait pas des informations descriptives de la manifestation ni de l'oeuvre. Même si la création d'une notice d'item seule, sans rattachement à une oeuvre liée paraît peu probable de la part de professionnels de la documentation, l'application doit tout de même s'attacher à limiter les risques en matière de qualité des données.

Transition interface utilisateur > et projet IA :

Parallèlement, l'espace de travail S-Movies fait l'objet de projets dédiés à l'ajout de nouvelles fonctionnalités. Parmi elles, l'automatisation de l'indexation des archives audiovisuelles, fondée sur l'intelligence artificielle. Plus précisément, Skinsoft souhaiterait mettre en place une segmentation automatique des fichiers numériques vidéo, pour pouvoir ensuite les décrire et les indexer automatiquement. Or, pour pouvoir mettre en place un modèle d'intelligence artificielle qui automatiserait des pratiques métier d'indexation, il est nécessaire de clarifier en amont la définition de la hiérarchie des niveaux FRBR au sein de l'application, et des liens qu'ils entretiennent. En effet, l'interface graphique constitue bien une définition et une traduction du modèle FRBR pour les utilisateurs. Si un modèle d'IA est mis en place alors que des incohérences subsistent, l'automatisation de l'indexation qui, de fait, accélère son processus, produira des erreurs de données à plus large échelle.

3. Le projet d'une indexation automatisée des archives audiovisuelles, conditionnée par le modèle en place

Le catalogage et l'indexation des archives audiovisuelles est une opération laborieuse, particulièrement sur des archives spécifiques telles que nous avons décrites. Cela présuppose un travail d'analyse et du contenu du document. Or, l'image animée est conçue comme une boîte noire : il faut détenir le matériel adéquat pour pouvoir lire ce qu'elle contient et ainsi la décrire. En effet, la plupart des images animées ne comportent pas de métadonnées visibles sur leur contenant ou support, qu'il soit numérique ou physique. Il faut les trouver dans leur contenu, via le générique de fin par exemple, quand il existe. La mise en place d'une indexation automatique viserait ainsi à faciliter le travail des utilisateurs et à le rendre plus efficace pour

la production de connaissances. Cette fonctionnalité s’inscrit dans un projet de mise en place de l’intelligence artificielle à une plus large échelle au sein de l’application Skinsoft, afin d’automatiser et de faciliter les pratiques de gestion des collections. L’intelligence artificielle (IA) peut être définie ainsi :

Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement.²⁴

L’objectif est alors de rendre ces systèmes capables de pouvoir raisonner afin d’effectuer les mêmes actions que l’homme. Dans le cadre d’un système de gestion des collections, cela signifie que les systèmes d’intelligence artificielle devront effectuer des tâches documentaires complexes. Cette implémentation doit alors s’inscrire dans cadre défini par l’entreprise, qui donne la direction de développement de ces ”machines”, dans un contexte patrimonial.

a. Projet SKAI

L’implémentation de l’IA au sein de l’application n’est pas seulement issue d’une logique produit, elle est davantage centrée sur l’amélioration de l’expérience utilisateur. L’une des caractéristiques majeures de l’application, nous l’avons dit, est sa flexibilité et son adaptabilité. La mise en place de l’IA permettrait de mettre cette adaptabilité en place plus efficacement et à plus large échelle. Automatiser la migration de données, le paramétrage de l’application, la navigation dans l’application permettrait à l’entreprise de satisfaire ses clients plus rapidement et de gérer ainsi plusieurs contrats à la fois. Cette volonté d’implémenter l’IA s’inscrit dans l’appel à projets ”France 2030” qui couvre notamment la maîtrise des technologies numériques et le ”déploiement de l’innovation”.²⁵ Ce projets finance des initiatives à l’intersection de la culture, du numérique et de l’IA. Toutefois, la question du besoin est centrale, pour une utilisation de l’IA éthique. En effet, l’IA est-elle une fonctionnalité attendue côté client ? Comme le mentionne le ministère de la culture : ”il ne s’agit pas d’utiliser l’IA par défaut, mais d’abord d’examiner le besoin à couvrir et de vérifier la capacité des systèmes d’IA à satisfaire ce besoin dans des conditions optimales ; le cas échéant, de favoriser des alternatives moins consommatrices que l’IA si elles sont suffisantes à répondre au besoin”.²⁶ L’objectif est double pour Skinsoft. La mise en place de l’IA dans l’application

²⁴Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

²⁵France 2030 : un plan d’investissement pour la France / [economie.gouv.fr/france-2030](https://www.economie.gouv.fr/france-2030) (visité le 20/06/2026).

²⁶La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la->

permettrait d'autonomiser les institutions sur leur usage du logiciel et d'être plus productifs dans l'indexation de leurs collections. Ainsi, les équipes Skinsoft seraient moins sollicitées pour des difficultés liés à l'usage de l'application qui pourraient être réglés par une machine intelligente. Pour répondre à ces objectifs, Skinsoft prévoit notamment la mise en place d'une recherche en langage naturel, c'est-à-dire de permettre à l'utilisateur d'effectuer des recherches plus facilement en utilisant un langage naturel—son propre langage— plutôt qu'un langage contrôlé. L'objectif est ainsi de rendre l'utilisation de l'application plus simple, et d'améliorer l'efficacité de la gestion de collections. Toutefois, l'implémentation de l'IA pour la création de contenus structurés soulève des questions éthiques dès lors que l'objectif de l'indexation est de produire des connaissances pour la transmission auprès du public. De plus, les pratiques documentaires, nous l'avons vu, sont des pratiques normalisées par des modèles de données (FRBR), des normes, des référentiels, afin d'assurer leur interopérabilité. Ainsi, Skinsoft porte des points d'attention au projet. Les moteurs d'intelligence artificielle implémentés devraient faciliter le travail des utilisateurs et être construits comme des outils de proposition, sans réaliser entièrement eux-même la production de connaissance. L'humain est toujours intégré au sein de la chaîne de travail dans la définition du projet, en étant le décisionnaire de ce que produit l'IA. Concrètement, Skinsoft souhaite mettre en place différents moteurs d'intelligence artificielle, entraînés sur des données patrimoniales, et dédiés à l'automatisation partielle de tâches métier dans l'application. Parmi ces tâches, il est prévu l'automatisation de l'indexation au sens large au sein de l'application, et notamment appliquée aux archives audiovisuelles, dans S-Movies. Si, pour les images fixes, peut être mise en place une analyse automatique de leur contenu afin de l'indexer, l'indexation automatique des archives audiovisuelles se découpe, elle, en plusieurs sous-tâches, propres à la nature du médium cinématographique. Ainsi, le moteur d'intelligence artificielle dédié à l'indexation des archives audiovisuelles se divise en plusieurs sous-moteurs, dédiés à l'analyse de la coordination du son avec le mouvement des images et leur contenu. Concrètement, cela désigne les tâches automatiques suivantes : transcription et analyse du son, reconnaissance des locuteurs, segmentation et analyse des images en mouvement, qui induit à elle-même, nous le verrons d'autres sous-tâches, une reconnaissance des voix des interlocuteurs, transcription du texte présent dans l'image. Les données extraites de ces tâches automatiques devront être automatiquement inscrites dans des référentiels (thésaurus) afin d'assurer leur interopérabilité. Par exemple, lors de la reconnaissance d'un locuteur, son nom doit pouvoir être relié à sa notice d'autorité dans l'application. La segmentation désigne la division d'images en mouvements en plusieurs séquences. Une séquence au cinéma peut être définie comme suit : "La séquence

strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables (visité le 20/06/2026).

est une unité d' action, un fragment du film qui raconte en plusieurs plans une suite d' événements isolable dans la construction narrative.”²⁷ Ce besoin de séparer un film en différentes séquences est issue d'un besoin client, celui du second corpus d'archives audiovisuelles que nous avons décrit. En effet, ce corpus contient essentiellement des *rushes*, donc des images en mouvement brutes dépourvues de montage. Le client souhaiterait ainsi avoir un outil qui détecterait automatiquement les changements de séquences, pour pouvoir les décrire individuellement, et ainsi éviter de décrire des *rushes* dans leur entiereté. Des marqueurs temporels sont déjà présents dans les données de ce client, au sein des notices Oeuvres, afin de délimiter les *rushes* en séquences pertinentes. L'objectif est alors d'automatiser l'apposition de marqueurs temporels sur la vidéo en détectant les changements d'actions, de lieu, d'objets ou de personnages, marquant le passage d'une séquence à une autre. Si elle est dédiée au besoin d'un client précis, cette fonctionnalité pourra être toutefois étendue à toutes les institutions préservatrices de collections audiovisuelles.

b. Segmentation

Toutefois, avant de développer la manière dont une machine pourrait segmenter une vidéo, il s'agit de comprendre l'utilité de la segmentation et ses modalités, lorsqu'elle est effectuée par un humain. Ainsi, des questions préalables d'analyse se posent :

”Quels sont les mécanismes qui permettent d'in-terpréter cette longue séquence d'images [...] en une séquence d'actions dramatiques, reliées entre elles par des liens de causalité, et qui nous permettent d'en comprendre le sens (l'histoire) ? Et comment reproduire cette capacité dans un programme informatique de vision par ordinateur ?”²⁸

Il faut comprendre comment un film, un *rushe* s'analyse, pour pouvoir comprendre comment s'opèrera une analyse automatique. Tout d'abord, la segmentation, au sens large, peut être définie par la division de l'image en groupes de pixels selon certains critères. Or, pour l'image animée, la segmentation prend une dimension temporelle, puisqu'il s'agit plutôt de découper la vidéo en différents mouvements selon certains critères. Il s'agit d'un découpage conceptuel et non d'un montage technique qui modifie l'image animée. Dans ce contexte la segmentation serait la condition d'une indexation puisqu'en apposant sur des séquences, des balises temporelles, elle permettrait de rendre possible ”la production de descriptions structurées”.²⁹ Ces balises temporelles délimitent des ensembles homogènes au sein d'une archive audiovisuelle,

²⁷Marie-Thérèse Journot, *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.

²⁸Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions...*

²⁹Peter Stockinger, *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).

un peu à la manière de chapitres dans un ouvrage textuel.³⁰ (**donner un exemple**) La segmentation est issue de l'objectif donné par l'indexation, qui définit les thèmes et l'analyse que l'on souhaite produire de tel ou tel document. Pour pouvoir pratiquer la segmentation, il faut également pouvoir définir sa granularité (analyse au niveau du plan, du changement de plan, de scènes, de séquences...), et le niveau de description attendu.³¹ Ainsi, en définissant des critères de segmentation, l'utilisateur choisit un point de vue sur l'image, en choisissant à quel niveau agit la segmentation et sur quels éléments elle doit pointer, ce qui deviendra l'objet d'analyse et de description. La segmentation "agit comme un filtre de pertinence" sur les éléments indexables.³² Le choix du niveau de granularité, notamment, détermine le niveau de FRBR auquel l'analyse se rattache. (à placer dans une sous partie de II). Par ailleurs, la segmentation, nous l'avons dit, suppose de découper conceptuellement une vidéo. La suite logique de cette étape est celle d'un "découpage" physique, qui crée de nouvelles séquences partie de la vidéo "mère", permettant de mettre en avant des séquences qui se suffisent à elles-mêmes, par exemple.³³ Ainsi, la segmentation modélise l'archive audiovisuelle et les données qui en découlent, en en faisant un "objet de connaissance".³⁴ Cette segmentation temporelle ne s'applique pas seulement à l'image, mais également au son et au langage. Il s'agit d'une segmentation audio appliquée à la parole ou la musique, par exemple.³⁵ La segmentation temporelle suppose ensuite une segmentation spatiale, qui induit l'analyse de la place des éléments dans l'image, également applicable à l'image fixe.³⁶ Enfin, une segmentation sémantique intervient, apposant une signification et une description sur ces objets.³⁷ Les catégories sémantiques sont prédéfinies par l'utilisateur et peuvent être de plusieurs types concernant l'image animée : technique, contenu, relation, mouvement... Parmi ces trois types de segmentation, seule la segmentation temporelle est spécifique à l'image animée, puisqu'elle analyse la différence de temps et de mouvement entre les plans et leur relations pour pouvoir en extraire des séquences distinctes. Les segmentations spatiales et sémantiques sont, en revanche, également applicables à l'image fixe. Si la structuration d'éléments vidéos tels que les journaux télévisés, le sport, la publicité, sont "relativement stable et explicite de leur structure", et peuvent alors facilement être segmentés, les archives audiovisuelles regroupent

³⁰ *Ibid.*

³¹ *Ibid.*

³² *Ibid.*

³³ *Ibid.*

³⁴ *Ibid.*

³⁵ Jean Carrière, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

³⁶ Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

³⁷ *Ibid.*

des corpus divers et variés, allant de films expérimentaux à des bandes annonces, en passant par des films de famille, parfois en noir et blanc et muettes.³⁸ Ainsi, il s'agit d'analyser un film selon une granularité choisie, plan par plan, scène par scène, ou séquences par séquence, et d'en analyser le langage cinématographique : montage, mouvement, placement des objets et des personnages, musique, paroles, et la relation que ces éléments entretiennent entre eux dans l'image. La segmentation permet une analyse plus fine et détaillée du film, dépassant la paradigme de la boîte noire qui caractérise l'archive audiovisuelle. Ce processus d'analyse, lorsqu'il est réalisé dans une logique documentaire, produit des mots-clés, des descriptions, des noms de personnes, etc. Ces termes s'inscrivent dans le cadre d'une indexation normalisée et d'un modèle de données, le FRBR. La segmentation est ainsi une étape pour l'indexation des archives audiovisuelles. L'indexation permet quant à elle, de rendre l'analyseinteropérable et de veiller au bon fonctionnement du modèle de données.

c. Indexation

Les tâches d'analyse que nous avons décrites, qui font l'objet d'un projet d'automatisation, convergent vers une pratique globale d'indexation, elle aussi, à terme, automatisée. De même, il est important de comprendre ce qu'elle implique avant de pouvoir développer son automatisation. L'indexation pourrait être définie ainsi :

”L'indexation est cette technique consistant à caractériser le contenu d'un document et l'information qu'il détient de manière à le retrouver quand on effectue des recherches sur l'un des sujets dont il traite. La difficulté est donc de savoir caractériser et représenter l'information documentaire pour qu'il soit aisé de la mettre en rapport avec des sujets d'investigation. [...] L'indexation permet de s'orienter dans la masse des documents et d'organiser ses connaissances. ”³⁹

Afin de ”fournir un point d'accès sûr et vérifié à l'information”, l'indexation implique la mise en relation des termes produits avec des référentiels, des thésaurus et des listes d'autorité, pour pouvoir constituer un modèle de données.⁴⁰ Cette pratique permet ainsi d'améliorer notamment la découvrabilité des données et la navigation entre les différentes connaissances produites.⁴¹ Une indexation conforme est ainsi la condition de la mise en place de nouvelles fonctionnalités telles que celles fondées sur l'intelligence artificielle. À terme, elle permet le

³⁸J. Carrive, « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels »...

³⁹B. Bachimont, *Indexation et archivage de contenus multimédias...*

⁴⁰*Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).

⁴¹*Ibid.*

partage et la publication des données sur le web.⁴² Pour que ce partage soit fonctionnel, le modèle de données est une condition préalable, dans laquelle doit s'inscrire l'indexation. Le processus de segmentation que nous venons de décrire, permet de rendre le contenu d'un *rush* intelligible et diffusable à terme auprès du public. Elle crée des points de repères sur lesquels l'indexation va pouvoir se focaliser. L'indexation de ces segments s'inscrirait dans la hiérarchie du modèle FRBR. Selon Attard, l'automatisation pourrait homogénéiser les pratiques : "automated segmentation accelerates the processing of large volumes of video content and ensures consistency and accuracy in the segmentation process."⁴³ Mais cet aspect sera comblé uniquement si les moteurs IA dédiés à l'indexation sont entraînés sur les normes professionnelles qui régissent les pratiques patrimoniales, nous y reviendrons. La volonté d'automatiser les pratiques documentaires vise à faciliter l'expérience utilisateur, mais elle ne répond pas pour l'instant aux problèmes soulevés par la modélisation de S-Movies par le FRBR. La mise en place de l'IA ajoute simplement de nouvelles fonctionnalités afin de fluidifier le travail documentaire. Ainsi, il s'agit de proposer dans un premier temps des améliorations d'interface relatives au modèle FRBR pour pouvoir, à terme, y inscrire une indexation automatique fondée sur un processus de segmentation. Il s'agit également d'analyser la manière dont l'automatisation pourrait modifier les pratiques et le modèle de données au sein de l'interface, et penser les améliorations en fonction de ces éléments.

segmentation » découper la vidéo en segments analysables » pour pouvoir les décrire et ainsi les indexer » inscrire ces descriptions dans la hiérarchie documentaire » mais cette hiérarchie n'est pas claire pour le moment (II)

⁴² *Ibid.*

⁴³ Jonathan Attard et Dylan Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].

Deuxième partie

**Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR**

4. Traitement audiovisuel

dans la première sous partie : considérations technique : intégrer les contraintes du corpus et voir comment ils s’y inscrivent

”However, while shotboundary detection is certainly useful, reliably being able to detect scene boundaries would be an incredible technical feat, whichwould create tremendous potential for semantic and narrative analysis of video and film material”⁴⁴

Les tâches automatiques pouvant être appliquées à l’audiovisuel sont multiples avec d’un côté les tâches pouvant être appliquées à l’image, et de l’autre, les tâches pouvant être appliquées au son. Citons par exemple la reconnaissance de locuteurs, la segmentation, transcription et classification audio, la reconnaissance de visages, l’identification et la classification d’objets, la transcription de textes dans l’image...

Nous nous concentrerons dans cette partie sur la mise en place d’un processus de segmentation temporelle de l’image en différentes séquences, puis de leur indexation. En effet, chez Skinsoft, le besoin de segmentation est issu d’un corpus d’archives audiovisuelles muettes, de rushes, que la segmentation permettrait de diviser en séquences thématiques afin de les rendre intelligibles. Bien que la segmentation est souvent la condition préalable à un objectif de segmentation, par exemple, la vidéo doit être segmentée avant de pouvoir en extraire le contenu automatiquement (personnes, objets...), il s’agit ici d’une fonctionnalité à part entière à laquelle pourra être combinée une indexation.

Très important : la définition des séquences comme quoi ce sont des segments pas seulement syntaxiques mais surtout sémantiques : donc il faut non seulement les segmenter mais aussi en extraire le sens. : doit être le fil conducteur de ma partie justifier davantage le choix des outils : Les institutions patrimoniales n’ont pas de GPU dédiés ni d’infrastructure cloud. Cela conditionne directement le choix des outils : un modèle léger comme PySceneDetect ou 2SDS sera préférable à ViViT ou TDSNet dans ce contexte, même si ces derniers sont plus performants. Attard et Seychell (2025) montrent que les architectures séparées et légères donnent de meilleurs résultats pratiques que les modèles multimodaux complexes

les archives ne peuvent pas être envoyées vers des services cloud pour des raisons de droits de propriété intellectuelle et de sécurité des données. L’algorithme doit être déployé localement dans l’infrastructure de l’application Skinsoft. C’est une contrainte technique majeure qui doit apparaître dans ta sous-partie car elle élimine d’emblée certaines solutions (APIs cloud comme AWS Rekognition ou Google Video Intelligence) et oriente vers des solutions déployables en local.

⁴⁴Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC ’19), p. 61-68, DOI : 10.1145/3347317.3357240.

Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées, à notre connaissance, au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

De plus, la segmentation des archives audiovisuelles n'est jamais mise en place de manière isolée, puisqu'elle est plutôt la première étape d'un processus global. Ainsi, nous intégrerons également un processus automatique afin de pouvoir les décrire et les indexer au sein d'un système de gestion des collections.

Les chercheurs qui analysent les objets visuels s'attachent de plus en plus à l'analyse vidéo car la détection du mouvement aide d'autres tâches d'analyse automatique de détection et de reconnaissance d'objets.⁴⁵

a. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont désignées sous le terme de Audiovisual Processing (AVP).⁴⁶ aussi désigné sous les termes suivants : Audiovisual Processing technologies, Automatic Metadata Extraction, Metadata Generation Mechanisms, Machine Learning Applications for Visual/Audio Data Annotation.

L'avantage de ces technologies est le suivant : appliquées à un grand nombre de données, elles permettent de passer du "close" au "distant" viewing, c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble.⁴⁷ Ainsi, l'automatisation permettrait de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données afin d'en observer les tendances globales. L'application du traitement audiovisuel permettrait donc de changer notre rapport aux archives audiovisuelles.

L'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de computer vision, ou de vision par ordinateur. Le terme définit un sous-domaine d'application de l'intelligence artificielle qui permet d'entraîner un système d'intelligence artificielle à l'analyse des images fixes ou en mouvement⁴⁸ La vision par ordinateur s'appuie largement sur des modèles de machine learning, l'apprentis-

⁴⁵Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁴⁶Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

⁴⁷*Ibid.*

⁴⁸Rina Diane Caballar Stryker Cole, *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

sage machine, qui désigne une branche de l'intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent.⁴⁹ Le machine learning permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, pour ensuite prédire ou prendre des décisions sur de nouvelles données.⁵⁰ La vision par ordinateur s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques.⁵¹ Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes de machine learning.⁵²

De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut pas être mis en place sur l'ensemble des données mais seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds.⁵³ La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de deep learning, apprentissage profond, une sous-catégorie du machine learning. Le deep learning est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'agir sans supervision humaine, améliorant ainsi le rapport cout-efficacité.⁵⁴ Il suffit presque de fournir au modèle quelques images annotées, et le réseau

⁴⁹J. Arnold, M. Lûpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

⁵⁰*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

⁵¹Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

⁵²*Ibid.*

⁵³Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

⁵⁴N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

de neurones permet au modèle de repérer lui-même les caractéristiques qu’il doit analyser sur de nouvelles données.⁵⁵ Par rapport aux techniques traditionnelles de vision par ordinateur, le deep learning permet d’obtenir une plus grande précision dans les tâches d’analyse audiovisuelle telles que la classification d’images, la segmentation, la détection d’objets.⁵⁶

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la computer vision pour la classification d’images et la reconnaissance d’objets, est celui le réseau de neurones convolutifs (CNN). Appliqués à des corpus d’images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d’en extraire les couleurs et les contours.⁵⁷ Les tâches que permettent les CNN sont plutôt bien adaptées à l’image fixe, puisqu’ils extraient des éléments fixes de l’image.

Néanmoins, d’autres modèles issus du deep learning tels que les transformers s’avèrent davantage efficace sur des tâches dédiées à l’image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent sur un mécanisme d’auto-attention qui leur permet de détecter les relations et dépendances entre les données.⁵⁸ Tandis que les CNN analysent les données de manière sérielle, sans prendre en compte les interdépendances qui les régissent, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d’entre elles.⁵⁹ Les CNN ne permettent pas, par exemple, de discerner les “dépendances à longue portée” telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins.⁶⁰ Ainsi, ils seraient davantage adaptés à l’analyse d’images en mouvement puisqu’ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d’une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l’intelligence artificielle possèdent leur lot de limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d’interpréter les analyses qui sont produites.⁶¹ En effet, une fois entraînés, il est difficile d’en modifier les paramètres puisqu’ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi difficile à comprendre et à exposer.⁶² Deuxièmement, les algorithmes de type transformers

⁵⁵ *Ibid.*

⁵⁶ *Ibid.*

⁵⁷ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

⁵⁸ Cole Stryker Bergmann Dave, *Qu’est-ce qu’un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

⁵⁹ *Ibid.*

⁶⁰ *Ibid.*

⁶¹ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

⁶² N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*




FIG. 1 : mahony2020

sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe.⁶³ Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d'un large jeu de données d'entraînement afin d'éviter un trop grand nombre de biais.⁶⁴ les modèles de détection neuronaux sont entraînés sur des datasets de clips courts. Or, la réalité audiovisuelle est bien différente.⁶⁵ Des approches algorithmiques non neuronales ou hybrides seraient donc plus adaptées car fondée sur des calculs et des seuils mathématiques : plus stable.

Les approches hybrides : un algorithme de vision par ordinateur peut détecter des caractéristiques qui peuvent ensuite être transmises à des réseaux de neurones profonds pour la classification.

Mais tout dépend de la tâche à effectuer : peut être effectué à partir de la computer vision si c'est juste un seuil à calculer.

transition vers la prochaine sous partie : parler des données d'entraînement (cf fichier IAvideo pattichis)

Toutes les tâches automatiques qui peuvent être appliquées à la vidéo nécessitent un entraînement multimodal : entraînement multimodal : When we refer to multimodal or cross-modal learning, we are referring to learning using video, audio and/or text. These approaches generalize to a greater variety of visual tasks including action step localization, action segmentation, text-to-video retrieval, video captioning.⁶⁶

⁶³Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

⁶⁴Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

⁶⁵*Ibid.*

⁶⁶Madeline C. Schiappa, Yogesh S. Rawat et Mubarak Shah, « Self-Supervised Learning for Videos : A

b. Outils et modèles disponibles

Différents projets ont tenté de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets ne soient pas appliqués à des archives audiovisuelles, mais des corpus de vidéos moins spécifiques, il est tout de même intéressant d'en analyser la structure pour éventuellement les implémenter dans un contexte patrimonial. De plus, il est intéressant de comprendre sur quelles technologies s'appuient ces algorithmes. En effet, face aux limites de réseaux neuronaux et des algorithmes fondés sur le mécanisme d'auto attention, nous tenterons d'analyser des architectures plus simples et également plus fiables afin de les appliquer aux archives. Les modèles de détection neuronaux sont entraînés sur des datasets de clips courts. Or, la réalité audiovisuelle est bien différente.⁶⁷ Des approches algorithmiques non neuronales ou hybrides seraient donc plus adaptées car fondée sur des calculs et des seuils mathématiques : plus stable.

Nous analyserons la structure de ces algorithmes sans en mentionner les détails mathématiques et techniques puisque notre objectif est d'en proposer une implémentation métier, au sein d'un système de gestion des collections. Nous analyserons davantage leur adaptabilité aux données et leur capacité d'entraînement sur des données complexes.

Une des solutions, afin de pouvoir implémenter des algorithmes plus légers, serait de ramener l'image en mouvement à l'image fixe. En effet, le cinéma est généralement caractérisé par l'enchaînement de 24 images par seconde afin de produire une illusion du mouvement pour l'oeil humain. Nous pouvons éventuellement imaginer un outil qui puisse découper le mouvement en des images fixes qui le composent afin de pouvoir les analyser plus facilement, au lieu d'implémenter une architecture complexe fondée sur la compréhension des relations et du mouvement entre les images. Les images fixes seraient ensuite regroupées en séquences après une analyse de leurs différences. Grâce à ce procédé, nous pourrions finalement appliquer les mêmes procédés d'analyse que sur l'image fixe, relativement plus légers, fondés sur la vision par ordinateur.

C'est ce que fait la bibliothèque python `pyscenedetect` avec différentes méthodes de détection.⁶⁸ Après, les plans sont regroupés de manière thématique après une analyse entre leurs différences : plus simples.

Dans leur article, Xin présente les principes de segmentation appliqués à la vidéo, prônant le découpage syntaxique préalable à l'analyse sémantique par des modèles d'intelligence

Survey », *ACM Computing Surveys*, 55–13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].

⁶⁷M. S. Pattichis, V. Jatla et A. E. U. Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems...*

⁶⁸*Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

artificielle.⁶⁹ Ainsi, il faudrait détecter les changements entre les scènes d’une vidéo en analysant préalablement les différences entre les images fixes qui la composent. Si deux images sont jugées suffisamment différentes selon un seuil prédéfini, elles appartiennent à des scènes distinctes.⁷⁰ Une ou plusieurs images clés pour chaque séquence sont retenues, puisque l’algorithme élimine les images en double, proches, et retient celle qui est représentative de la présence des éléments dans l’image (data selection).⁷¹ Ce principe permet d’alléger nettement la puissance de calcul et la structure des algorithmes. Ces images clés seraient ensuite passées dans un algorithme fondé sur un réseau neuronal pour effectuer une analyse sémantique.

PyScene Detect est un outil opensource et en libre accès fondé sur des tâches de computer vision classique, qui matérialise concrètement ce principe de comparaison première des images fixes. Il utilise des détecteurs mathématiques pour analyser les différences entre les images tirées d’une vidéo.⁷² Il s’agit ainsi d’un outil basé sur des seuils et mesures visuelles mathématiques et paramétrables qui ne nécessitent pas d’entraînement particulier. L’outil permet donc d’isoler les images fixes de l’image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l’outil : une détection des fondus entrants et sortants qui repère les niveaux de noir dans l’image, une détection de coupes rapides qui repère les changements de contenu entre images, une détection de coupes fondée sur la différence d’un plan avec les plans adjacents.⁷³ La méthode utilisée dépend de la nature du corpus analysée. Si les changements entre les séquences sont peu marqués, peu évidents, la méthode detect-adaptative sera plutôt employée. Une fois la méthode choisie, il est possible de générer un fichier statistique afin de déterminer les paramètres à appliquer. Il est notamment possible de paramétrer la valeur du seuil voulu, selon la détection de changement souhaitée entre les différents plans.⁷⁴ La méthode de détection fondée sur le contenu analyse la différence entre chaque paire d’images adjacentes et déclenche un changement de scène lorsque cette différence dépasse la valeur seuil. Cette valeur doit être très faible entre des images similaires et augmenter lorsqu’un changement important de contenu est détecté. La valeur seuil doit être définie de manière à ce que la plupart des scènes se situent en dessous de cette valeur, tandis que les scènes où des changements se produisent doivent la dépasser (déclenchant ainsi un changement de scène).⁷⁵ L’outil retourne ensuite des marqueurs temporels associés à la vidéo correspondant aux coupures détectées. Un détail

⁶⁹Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

⁷⁰*Ibid.*

⁷¹*Ibid.*

⁷²*Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

⁷³*Ibid.*

⁷⁴*Ibid.*

⁷⁵*Ibid.*

important de l'outil est sa capacité à enregistrer automatiquement une image clé pour chaque scène détectée, associée au fichier vidéo d'origine. C'est cette image clé qui sera réemployée au sein du processus suivant, celui de l'analyse sémantique de la séquence, afin de ne pas transmettre une multitude d'images aux algorithmes. Toutefois, certaines mises en application de l'outil soulignent ses limites. Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein d'archives du cinéma des premiers temps.⁷⁶ Un problème qui peut être lié à la qualité amoindrie de ces archives, même numérisées.⁷⁷ En effet, selon Norindr, la qualité détermine la performance de l'outil utilisé et des résultats reçus sur l'analyse de l'image.⁷⁸ De plus, Bhargav souligne la nécessité de savoir comment paramétrer l'outil de manière adaptée au corpus analysé.⁷⁹ Toutefois, un des avantages majeurs de l'outil *pyscene detect* est sa disponibilité et la possibilité de le mettre en œuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de vision par ordinateur analytiques qui n'ont pas besoin d'entraînement particulier sur des données annotées. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

Après *pyscenedetect* : apposer une analyse sur les séquences. Pas adapté pour des archives plus complexes. Sur notre corpus : ancien donc ruptures moins visibles avec la dégradation. Pourrait convenir, mais pour d'autres corpus, appliquer un pipeline basé sur des mécanismes plus lourds d'auto-attention.

Quand déclencher le processus??? réalité métier : application de l'IA : à la demande du client ? Sur certaines archives ? À l'ingest d'un fichier numérique ? Sur tous les fichiers numériques ?

5. Mise en application

Mettons à l'épreuve l'adaptabilité de l'outil *pyscenedetect* pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus, rappelons-le, est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, à plans fixes, en noir et blanc et muettes. Nous imaginerons ici ce que pourrait produire l'outil sur un tel corpus et quelle seraient les données générées par le processus, avant même de réfléchir à une interface entre l'outil et l'utilisateur. Le corpus pris comme exemple se caractérise par son ancienneté, et donc son indéniable dégradation de la qualité de l'image. L'outil pourrait rencontrer des difficultés afin d'identifier les changements de plans

⁷⁶S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

⁷⁷*Ibid.*

⁷⁸J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁷⁹S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

et les coupures. Toutefois, la structure de ces archives en une succession de plans fixes, dont les coupures sont marquées, en fait un corpus relativement bien adapté à l'outil, qui pourrait identifier les coupes plus facilement. Par ailleurs, *pyscenedetect* est un outil davantage utilisé pour la détection de plans différents au sein d'une image animée. Or, dans ce mémoire, nous cherchons à savoir comment segmenter une archives audiovisuelle en séquences. Dès lors, comment paramétrer un tel outil pour la détection d'éléments syntaxiques plus larges que ceux des plans ? Une des solutions est d'augmenter la valeur du seuil de coupures (*threshold*), pour que l'outil ne détecte plus des micro coupures entre les images mais des coupes plus larges, à l'échelle de séquences.⁸⁰ L'outil enregistrerait un changement seulement lors d'un changement radical d'espace temps à l'image, lorsque l'image change significativement. Ce paramètre reste limité puisque plusieurs plans peuvent être radicalement différents mais appartenir à la même séquence. Par exemple, un gros plan et un plan d'ensemble. Dans le cas du corpus d'archives décrit, les plans restent larges pour la grande majorité, montrant l'ensemble du décor dans lequel ils s'inscrivent. Par ailleurs, il est possible de paramétrer une durée minimale de scène à détecter avec le paramètre "*min-scene-len*", pour diriger la coupure seulement après un laps de temps défini.⁸¹ Ce paramètre suppose une analyse statistique du corpus afin de définir la durée moyenne d'une séquence au sein des archives. L'institution conservatrice de ce corpus documente justement déjà les séquences sur ses archives audiovisuelles à l'aide de *time codes* pour en déterminer les séquences. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de *time codes* afin de déterminer la durée moyenne d'une séquence au sein du corpus. Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d'images plus importante.⁸² Ainsi, il est possible de paramétrer le mode de détection de telle manière à ce que l'outil compare le contenu visuel d'une image par rapport à une plus grande variété des images qui l'entourent. Ce paramétrage permettrait à l'outil de détecter uniquement les changements majeurs dans l'image, et donc les séquences. Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données. Il produit un fichier *json* ou *csv* contenant les *time codes* de début et de fin identifiés comme séquences au sein de chaque fichier vidéo ingéré. Chaque séquence possède donc un identifiant unique associé à des *time codes* de début et de fin. L'outil permet également d'extraire pour chaque séquence un fichier image, qui correspond à l'image fixe médiane, censée être la plus représentative de la séquence et que nous désignerons sous le terme d'image clé.⁸³

Toutefois, si ce paramétrage permettrait une plus grande précision dans la détection

⁸⁰ *Command-Line - PySceneDetect...*

⁸¹ *Ibid.*

⁸² *Ibid.*

⁸³ *Ibid.*

de séquences, il comporte des limites. Ces limites sont dûes à la définition d'une séquence, qui ne se définit pas seulement comme une caractéristique syntaxique au cinéma, comme c'est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence est un choix narratif, un choix de sens au sein du flux animé. C'est pourquoi un outil fondé sur des seuils mathématiques appliqués au contenu visuel comporte des limites. Nous proposons alors de réaliser une analyse sémantique sur les séquences détectées, afin de ré associer la syntaxe au sens, qui en fait une séquence, en réutilisant les données produites par le processus : les times codes et l'image clé.

Il est courant d'utiliser des modèles préentraînés sur un grand jeu de données et de le réajuster ensuite au jeu de données en question, au sein d'un contexte précis.⁸⁴ Ce modèle peut justement servir de modèle de caractéristiques à analyser sur les vidéos, un second entraînement, dans le contexte peut aider à l'affiner et à l'adapter au corpus spécifique. Le rendre d'abord familier au langage audiovisuel.

Malgré de grandes avancées dans le processing audiovisuel, avec des outils comme la computer vision appliquée à la vidéo, et la reconnaissance de discours automatique (ASR), ces outils restent largement inaccessibles et hors de portée pour les institutions patrimoniales.⁸⁵ Ils sont utilisés par des entreprises commerciales pour du montage vidéo par exemple. Le manque d'utilisation de ces outils dans le domaine des sciences humaines expliquent l'inexistence de données d'entraînement adaptées au secteur.⁸⁶ L'analyse vidéo par un processus humain prend un temps considérable, puisqu'il faut lire le fichier audiovisuel et en analyser les composants, le langage. Ainsi, l'indexation des archives audiovisuelles se cantonne souvent aux métadonnées, sans en exposer les données, le contenu.

Et donc en pratique, comment appliquer le traitement audiovisuel à des corpus d'archives audiovisuelles patrimoniales ?

a. entraîner ces outils et ces modèles

les modèles de détection neuronaux sont entraînés sur des datasets de clips courts. Or, la réalité audiovisuelle est bien différente.⁸⁷ Des approches algorithmiques non neuronales ou hybrides seraient donc plus adaptées car fondée sur des calculs et des seuils mathématiques : plus stable.

⁸⁴J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁸⁵N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁸⁶*Ibid.*

⁸⁷M. S. Pattichis, V. Jatla et A. E. U. Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems...*

détection des coupures : approche algorithmique non neuronale (2SDS, pyscenedetect), (xin et attard) pipeline technique en 4 étapes (down sampling (miniaturisation), conversion en niveaux de gris, calcul d’empreinte numérique par hachage binaire des pixels, et calcul de la distance de Hamming pour marquer la rupture visuelle (xin2023)

efficace sur les plans fixes et mvts lents

mettre en rapport avec les travaux d’Arnold Tilton (2019), qui utilisent une méthode similaire combinant différences d’histogrammes et réduction de résolution des pixels (down-sampling) pour mesurer les ruptures de palettes de couleurs et de luminosité d’une frame à l’autre, complétée par des règles logiques pour éviter les faux positifs lors des fondus (fade-in/fade-out).

L’apport de l’IA (Vers la classification sémantique) : La détection brute des coupures ne suffit plus ; l’enjeu actuel est la Shot semantics (décrire le contenu d’un plan et sa typologie) (Arnold Tilton, 2019).

Le rôle des modèles (CNN et Détecteurs) : Pour analyser le contenu de ces plans, on utilise l’apprentissage supervisé (Supervised Learning), où des algorithmes apprennent à partir de données labellisées par l’humain (DeLua, 2024). C’est le cas des réseaux de neurones convolutifs (CNN) comme Faster R-CNN ou YOLO (un détecteur de type Single Shot qui prédit et classe ”en une seule fois”) pour la détection d’objets ou de visages (Arnold Tilton, 2019 ; Robert, 2026).

Le méta-algorithme de classification : Arnold Tilton (2019) montrent qu’en combinant la position des visages détectés et les coupures de plans, on peut créer un méta-algorithme capable de classer automatiquement le type de plan (gros plan/close-up, plan amorce/over the shoulder), permettant de comprendre comment le cadrage construit le récit.

b. analyse du mouvement

au lieu d’utiliser des larges modèles qui tentent de tout classer, plutôt utiliser des modèles ”low parameter”, c’est-à-dire des modèles 3D-CNN légers, avec moins de paramètres dédiés à la reconnaissance d’une seule activité précise. prennent moins de mémoire vidéo.⁸⁸

stratégie de réduction de l’annotation humaine : self supervised learning, semi supervised, active learning, zero shot⁸⁹

confronter les architectures de réseaux de neurones (CNN vs. Transformers), introduire l’apprentissage non supervisé (Unsupervised Learning / DeepCluster),

Les limites des CNN 2D classiques (comme ResNet) : ils analysent la vidéo comme des

⁸⁸ *Ibid.*

⁸⁹ *Ibid.*

images discrètes et indépendantes, ignorant la continuité du mouvement⁹⁰. Se tourner vers les vision transformers : CLIP, ViViT (bergmann et al), mécanismes d'auto attention qui analysent l'intégralité d'une séquence

Les modèles de Video Semantic Segmentation (VSS) et le dilemme entre les méthodes orientées "vitesse" (approche par keyframes peu précise) et orientées "précision" (TDNet, flux optique, mécanismes d'auto-attention)⁹¹.

La gestion du coût de calcul : présentation de TDSNet (TFRM pour extraire les zones dynamiques par soustraction d'images consécutives, et MMRM pour pondérer selon la magnitude réelle du mouvement)⁹². règle ce dilemme

alternatives non supervisées : la supervision demande des données annotées (caron et al), l'apprentissage non supervisé (Unsupervised Learning) comme DeepCluster (Caron et al., 2018). Ce type de modèle regroupe les images ou frames similaires en "clusters" algorithmiques (via K-means) pour s'auto-entraîner sans intervention humaine (Caron et al., 2018). Si DeepCluster s'avère robuste face à des changements de distribution d'images (ce qui est prometteur pour des archives spécifiques), il présente deux limites majeures : il introduit des biais imprévisibles en remplaçant les labels par des métadonnées brutes (inacceptable pour la rigueur historique) et a été conçu sur des bases gigantesques (ImageNet, 1.28 million d'images), le rendant difficilement transposable à des collections d'archives réduites (Caron et al., 2018 ; Norindr, 2023).

infrastructure locale : amener l'algorithme aux données : C'est la discussion centrale de votre partie. Les outils d'AVP commerciaux (souvent basés sur le Cloud) sont inutilisables pour les archives en raison des droits de propriété intellectuelle et de la sécurité des données (van Noord et al., 2021). La solution réside dans des architectures locales comme DANE (projet CLARIAH), basées sur un système décentralisé de workers (van Noord et al., 2021). Ce type d'infrastructure produit des métadonnées exploitables, mais aussi des vecteurs de caractéristiques (représentations abstraites) ouvrant la voie à la recherche par similarité visuelle ou sonore (van Noord et al., 2021).

La note finale sur l'explosion des données : L'indexation automatique par IA (comme avec DigInPix ou les modèles de type VLM) génère une masse d'informations locales phénoménale : les bases de données constituées peuvent être plus lourdes en taille que les fichiers vidéos d'origine (Moiraghi Letessier, 2018).

transition : nécessité d'un mapping vers le FRBR : faire correspondre la sortie de ces pipelines avec un modèle de données.

⁹⁰Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*

⁹¹T. Zhou, F. Porikli, D. Crandall, *et al.*, *A Survey on Deep Learning Technique for Video Segmentation...*

⁹²H. Yuan, J. Peng et Z. Cai, « TDSNet... ».

6. Description et indexation automatique

Quoi décrire ?

Si la segmentation temporelle syntaxique permet de diviser une archive audiovisuelle en segments différentes les uns des autres, elle reste incomplète sans description sémantique. La séquence est en effet le résultat d'un choix sémantique dans la construction, au montage, d'un film. La re division d'une archive audiovisuelle en séquences doit ainsi être décrite et justifiée afin d'en comprendre l'essence : pourquoi la séquence est-elle une séquence ? Ainsi, un second processus s'ajoute à celui de la segmentation, celui de la description automatique des séquences extraites. La description automatique peut se focaliser sur de nombreux éléments possibles au sein d'une séquence de film : dialogues, ambiance sonore, visages, objets, spatialité de ces visages et objets, actions, émotions... La multiplicité de ces éléments descriptibles résulte de la multimodalité du cinéma, regroupant caractéristiques visuelles et sonores. Toutefois, nous nous concentrerons dans cette étude sur la description automatique d'éléments visuels, puisque le corpus pris comme exemple applicatif est composé d'archives audiovisuelles muettes. Au sein de la description automatique d'éléments visuels, nous nous concentrerons sur la reconnaissance d'objets afin de produire des mots-clés associés aux séquences, afin de les différencier facilement. Ce processus paraît faisable et relativement léger pour une mise en place au sein du logiciel de gestion des collections. D'autres types de descriptions telles que la génération de résumé à partir du contenu de l'image supposerait l'implémentation de grands modèles de langage, reposant sur de l'Intelligence artificielle générative, un processus beaucoup plus lourd et coûteux à mettre en place.

a. Outils utilisés

Si pour la segmentation, nous avons éliminé les modèles d'intelligence artificielle fondés sur les réseaux de neurones, la reconnaissance d'objets dans l'image suppose un "raisonnement" rendu possible par l'apprentissage machine en profondeur des réseaux de neurones. En effet, la plupart des outils de reconnaissance d'objets dans l'image sont fondés sur des modèles de réseaux de neurones convolutifs (CNN) dont nous avons exposé le fonctionnement dans la section précédente. C'est le cas de l'outil Snoop créé par l'Institut National Audiovisuel, fondé sur le modèle CNN ResNet. Nous prendrons toutefois l'exemple du modèle YoLo, qui est l'un des plus documenté, y compris dans le domaine des sciences humaines. Il s'agit d'un modèle de vision par ordinateur fondé sur le deep learning, en accès libre, qui permet notamment la détection d'objets et la classification d'images.⁹³ Le modèle extrait dans un premier temps les caractéristiques visuelles de l'image qui lui est donnée, les agrège, afin

⁹³Glenn Jocher, *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.

de finalement proposer une détection d'objets.⁹⁴ Les versions récentes du modèle telles que YoLo12 sont désormais basées non plus seulement sur des CNN mais sur des mécanismes d'auto attention similaires à ceux des transformers dont nous avons évoqué l'architecture.⁹⁵ Toutefois, comme nous l'avons évoqué pour les transformers, cette architecture demande une consommation de mémoire élevée et une puissance de calcul lourde.⁹⁶ Ultralytics, créateur du modèle, recommande des versions moins avancées pour une mise en application telles que la version YOLOv8 fondée sur un réseau de neurones convolutif.⁹⁷ YOLOv8 propose une version optimisée de cette architecture en trois temps (extraction, aggrégation, détection).⁹⁸ Le modèle se caractérise par sa capacité à analyser l'image en une seule fois, contrairement à d'autres modèles qui analysent plusieurs fois certaines parties de l'image.⁹⁹

Si Yolo peut être appliqué à des vidéos, nous souhaitons l'intégrer comme composant complémentaire au processus de segmentation précédemment décrit. De fait, il peut être pertinent de réutiliser l'image clé fixe, produite et sauvegardée par l'outil pycenedetect pour la faire analyser par yolo. Ceci permettrait de réduire le temps de calcul du processus et d'améliorer l'efficacité des prédictions. Les archives audiovisuelles de notre corpus sont assez larges et longues. Les mots clés seraient également directement reportés sur les times codes associés à l'image clé.

limites de détection de Yolo : "YOLO imposes strong spatial constraints on bounding box predictions since each grid cell only predicts two boxes and can only have one class. This spatial constraint limits the number of nearby objects that our model can predict. Our model struggles with small objects that appear in groups, such as flocks of birds."¹⁰⁰

Intégration dans le processus :

Ainsi, le modèle Yolo intervient comme la suite logique du pipeline de segmentation produit précédemment, puisqu'au lieu de soumettre de longues séquences vidéo, nous lui soumettons une ou plusieurs images clés par séquences pour en extraire les caractéristiques sémantiques. Si le premier processus de segmentation produit des données temporelles pour chaque séquences sous la forme de time codes, yolo produit des données sémantiques et spatiales. À l'issue de l'analyse d'une image clé, yolo produit trois types de données : des

⁹⁴J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁹⁵YOLO12 : Détection d'objets centrée sur l'attention, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).

⁹⁶*Ibid.*

⁹⁷Explorer Ultralytics YOLOv8, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).

⁹⁸Muhammad Yaseen, *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].

⁹⁹Joseph Redmon, Santosh Divvala, Ross Girshick et Ali Farhadi, *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

¹⁰⁰*Ibid.*

étiquettes sur les objets identifiés (ce sont nos mots clés), un score de confiance qui indique l'indice de certitude concernant la prédiction, des coordonnées spatiales de localisation de l'objet détecté dans l'image.¹⁰¹ Ces données peuvent ensuite être reportées sur les time codes correspondant à chaque séquences. De fait, chaque séquence contiendrait des time codes qui l'identifient, des étiquettes sur les objets qu'elle contient, et des données qui permettraient aux utilisateurs de vérifier la prédiction et de la valider. En effet, le score de confiance permet d'indiquer à l'utilisateur la certitude de l'objet détecté, et les coordonnées spatiales lui permettent d'aller vérifier dans l'image si l'objet détecté et étiqueté est adéquat.

avantage de placer un réseau de neurones qu'à cette étape là du processus (cf article 2sds)

jeu de données d'entraînement de yolov8

7. Entraînement

Toutefois, l'efficacité des modèles basés sur l'apprentissage profond dépend fondamentalement de nature et de la qualité de leur données d'entraînement. Yolov8 a fait l'objet d'un entraînement préalable en amont de sa mise à disposition, sur le jeu de données COCO, un jeu de données prévu notamment pour la détection d'objets, composé d'objets du quotidien en tous genres.¹⁰² Il est composé de 200 000 images annotées où les objets sont entourés et décrits. Il s'agit d'un jeu de données généraliste qui permet au modèle de détecter des objets communs tels qu'une voiture, un chat, un parapluie. Or, notre corpus d'archives audiovisuelles est spécifique par sa période de création et par la qualité de l'image. Afin d'adapter le modèle à notre corpus et ainsi d'en améliorer l'efficacité, une phase de pré traitement est nécessaire sur les données du corpus, au cours de laquelle il est sélectionné des données à être annotées et testées.¹⁰³ Le rôle de "l'humain" est déterminant dans ce processus, particulièrement dans les domaines dans lesquels les données d'entraînement sont insuffisantes comme c'est le cas dans le domaine des archives audiovisuelles.¹⁰⁴ Les british online archives implémentent par exemple les tâches humaines en deux étapes dans la mise en place de la détection d'objets dans les images d'archives. Des archives sont sélectionnées et annotées à

¹⁰¹ *Ibid.*

¹⁰² *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

¹⁰³ Surya Kasturi, Alex Shenfield, Chris Roast, Danny Le Page et Alice Broome, « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

¹⁰⁴ *Ibid.*

l'aide de la plateforme label studio.¹⁰⁵ La méthode du transfert learning est ensuite employée, les données annotées servent d'entraînement supplémentaire au modèle.¹⁰⁶ Le transfert learning est une technique qui permet de "fine tuner" un modèle existant, de l'adapter à une tâche différente dans un domaine similaire.¹⁰⁷ Ainsi, il s'agit d'affiner le modèle existant déjà entraîné sur de large données, sur un jeu de données restreint plus spécifique.¹⁰⁸ Nous pouvons définir ces étapes comme des étapes de pré traitement des données, en amont de leur analyse par le modèle, afin d'améliorer l'efficacité de la détection.¹⁰⁹ Concrètement, par exemple, il s'agirait d'annoter certaines des images clés produites par le processus de segmentation en entourant les objets que l'on souhaite que le modèle détecte.¹¹⁰ L'outil label studio permet notamment de réaliser de telles annotations sur les images. À partir de ces images annotées, le modèle Yolo est ensuite entraîné à identifier les objets entourés et étiquetés. Cette étape de pré traitement, avant la mise en place du processus d'analyse par le modèle suppose donc de connaître les types de mots clés que l'on souhaite indexer sur les séquences pour ainsi annoter les images en conséquence avant de les donner au modèle. L'annotation de certains objets dans les images avec leur étiquette, leur catégorie, seront les mots clé indexés au sein du logiciel. Pour cela, il serait pertinent, dans le cas de skinsoft, d'extraire les mots clés déjà indexés sur les fichiers numériques de l'institution. Nous pouvons retrouver des mots clés tels que affiche, foule, policier, gendarme, drapeau... Il sera important d'entourer dans l'image les objets qui font l'objet de l'indexation de ces mots-clés, afin d'affiner la détection du modèle.

a. Interface de validation technique

Afin de gérer les essais-erreurs de l'affinage du modèle sur les données du corpus, il serait pertinent de mettre en place une interface de validation technique et d'amélioration du modèle, non visible par l'utilisateur métier. Cette interface permettra notamment d'assurer le lien entre les données produites par le modèle et leur concordance avec les données déjà existantes au sein du logiciel. Premièrement, suite à l'affinage du modèle avec l'annotation de données spécialisées, les archives britanniques en ligne préconisent des étapes supplémentaires de validation des données produites.¹¹¹ Ces étapes sont les suivantes : l'analyse des données

¹⁰⁵ *Ibid.*

¹⁰⁶ *Ibid.*

¹⁰⁷ S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

¹⁰⁸ *Ibid.*

¹⁰⁹ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

¹¹⁰ Lin Du, Brandon Le et Edouardo Honig, « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.

¹¹¹ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

produites par le modèle, la modification et la correction de ces données, le potentiel réentraînement du modèle avec de nouveaux paramètres et de potentielles nouvelles annotations, et enfin, l'évaluation des résultats sur les données de test.¹¹² Cette validation peut s'affectuer sur la même interface que celle proposée pour l'annotation des données, label studio, qui permet la modification et la correction des annotations. Les modifications des annotations sont réinjectées dans le modèle afin d'améliorer ses performances.¹¹³ Deuxièmement, afin de pouvoir valider les données produites par le modèle, il s'agit d'observer leur adéquation avec le modèle de données du logiciel d'indexation. Chez skinsoft, au sein de l'application dédiée au client préservant le corpus étudié, l'indexation des mots-clés est contrôlée par le thésaurus "keyword". L'affinage et la correction des données produites par le modèle devra ainsi prendre en compte la concordance des mots-clés générés avec le thésaurus de mots clés contrôlés dans l'application. Or, le modèle Yolo est nativement pré entraîné sur un jeu de données généraliste duquel la majorité des prédictions seront puisées. Ainsi, afin d'éviter la génération de mots clés trop éloignés des termes du thésaurus dans l'application, il pourrait être pertinent d'établir un mapping, c'est-à-dire une table de correspondance entre les mots clés que le modèle peut potentiellement générer, et leur forme contrôlée dans le thésaurus, pour aider la validation technique des données produites par le modèle. Nous avons effectivement déjà mis ce procédé en place au cours de notre stage dans le cadre de la mise en place de l'intelligence artificielle pour d'autres tâches, notamment la mise en place d'une recherche en langage naturel. (mettre une note de bas de page pour expliquer). Pour cette tâche tout à fait différente que celle que nous décrivons dans ce mémoire, nous avons effectué une table de correspondance entre les champs contrôlés pouvant être requêtés dans le logiciel et leur définition en langage naturel, préparant ainsi la gestion de synonymes et de termes employés par l'utilisateur potentiellement pour requêter ces champs. Sur le même principe, nous pourrions mettre en place une table de correspondance afin d'assurer la validation des données produites et d'assurer *in fine* leur indexation au sein de l'application.

citation supplémentaire sur les détails des corrections d'entraînement : "The evaluation employs two distinct test datasets, namely test-1 and test2. One of these datasets will be utilised for the purpose of rectifying the predictions, while the other dataset will be exclusively utilised for evaluating the model's performance across varying levels of HIL. Upon the user's modification of the bounding boxes on one of the test dataset, the corresponding corrected images will replace some random images in the initial training dataset which then becomes a new training dataset. A small learning rate of 0.00005 (in our case) is employed to retrain the model using the new training dataset. To retain previously learned information while

¹¹² *Ibid.*

¹¹³ *Ibid.*

incorporating the user-provided data, we utilize transfer-learning techniques that load the pre-trained weights of the model from HIL-0the model's weights, ensuring the assimilation of the new data without compromising the existing knowledge"¹¹⁴

Suite : voir si j'ai rien oublié sur l'entraînement dans fichier word

Transition avec la partie suivante : la validation finale est laissée à l'utilisateur métier : interface de validation livrée au client, une fois ue les entraînements et affiages sont concluants.

généralement, un algorithme de machine learning comprend trois étapes : data pre processing, data modelling, process optimisation. Dans le pre processing : humain requis pour transformer des données non structurées en données structurées et annotées¹¹⁵

8. plateforme de validation humaine

SOUS PARTIE 3 :

"A major challenge for making AVP tools available is that the underlying algorithms need direct access to the data, yet due to strict IPR regulation this data often cannot leave the archives' digital environment. A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms."¹¹⁶. Solution : projet CLARIAH

"Moreover, DANE is designed to be able to function in environments where there are fewer compute resources, or environments where access to the data is rate limited, as is typical for AV archives. To make this possible, the DANE architecture (as shown in Figure 2) divides the tasks to be performed over different workers that perform one specific type of analysis, where the work is assigned to a worker by means of message broker queuing system. The results of the analyses are communicated back to the server by the workers, and made available via an API to clients (e.g., other services or individual users)."¹¹⁷ (+ schéma qui montre l'architecture)

"To enrich the AV collections in the Media Suite with automatically generated (and time-coded) metadata an assortment of AVP tools had been added to DANE, ranging from Semantic Object Detection, to colour analysis, to Automatic Speech Recognition."¹¹⁸

"These tools generate two types of metadata : (i) structured data which can be inte-

¹¹⁴ *Ibid.*

¹¹⁵ *Ibid.*

¹¹⁶ N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

¹¹⁷ *Ibid.*

¹¹⁸ *Ibid.*

grated into the existing metadata systems, and (ii) feature vectors which describe the data on a more abstract level, but which can be integrated in new types of interfaces and search systems. For instance, with an Object Recognition model it is possible to recognise which objects are present in an image, but the output of such a model can also be used to perform more abstract visual similarity queries”¹¹⁹

SOUS PARTIE 3

9. La nécessaire refonte de S-Movies pour la mise en place d’un tel projet

La question de l’automatisation d’une indexation fondée sur le FRBR n’est pas nouvelle, comme le pose Signoles en 2012, face à la complexité d’adapter une interface au modèle : ”Suffira-t-il « un jour » d’appuyer sur un bouton pour extraire d’une notice des données automatiquement FRBRisées ?”¹²⁰. La mise en place d’une telle automatisation se précise à travers le projet IA chez Skinsoft. Toutefois, l’automatisation est conditionnée par une interface utilisateur fluide et navigable, surtout lorsque celle-ci s’appuie sur le modèle FRBR. Or, nous avons vu que l’espace de travail S-MOVies faisait l’objet d’un projet pour améliorer la navigation de l’utilisateur au sein du modèle de données afin d’en comprendre les liens. Ce projet permettra, à terme, d’éviter une diffusion d’erreurs à trop grande échelle liées à l’automatisation. Étant donné la complexité des liens induits par le modèle de données FRBR, l’interface doit prévoir les complexités et les confusions. Si les liens entre niveaux sont confus pour l’utilisateur, ils le seront pour un algorithme d’intelligence artificielle, et pour la vérification humaine derrière. Rappelons les complexités d’interface auxquelles fait face l’espace S-Movies. IL n’existe pas actuellement d’affichage des liens entre les entités du FRBR et de leur hiérarchie. Par ailleurs, la conception d’un espace de travail divisé en tables au sein desquelles l’utilisateurs peut créer des notices limite notamment la porosité des liens entre les notices et rend la création de celles-ci hermétique. Durant notre stage, nous avons proposé des propositions d’optimisation de l’interface en lien avec le FRBR sous la forme d’une spécification fonctionnelle (Voir la spécification détaillée en annexe). L’amélioration des liens et la modification de l’affichage adéquat de la hiérarchie FRBR sont les conditions d’un reversement automatique des métadonnées. Ces propositions s’inscrivent, d’une part, en amont de la mise en place de l’intelligence artificielle, afin d’instaurer une interface lisible entre l’utilisateur et la machine. La vérification des données produites et leur reversement au sein des niveaux FRBR pourra être plus intuitive et ainsi plus efficace. La mise en place d’une

¹¹⁹ *Ibid.*

¹²⁰ Aurélie Bergonnier Signoles, « Mise en œuvre d’une nouvelle structuration des données pour valoriser le fonds documentaire de l’IIPÉ UNESCO : l’expérience FRBR » ().

interface appropriée prépare la mise en place de l'intelligence artificielle dans laquelle elle pourra s'inscrire. L'interface peut être un outil pédagogique et un guide pour l'utilisateur dans un moment de transition technologique. D'autre part, si les études sur l'UI/UX en contexte patrimonial se concentrent sur la construction d'une interface intuitive pour l'utilisateur faisant partie d'un public, en ligne, il est également important de construire une interface intuitive, navigable et visuelle pour les professionnels métier. La mise en place d'une interface intuitive permet à l'utilisateur de se concentrer sur sa tâche, mettre en place des repères que les utilisateurs peuvent suivre pour atteindre leur objectif et prendre de meilleures décisions plus rapidement

Nous présenterons des améliorations en trois temps. Tout d'abord nous présenterons des nouvelles fonctionnalités afin d'améliorer la compréhension du FRBR pour l'utilisateur, puis des fonctionnalités pour améliorer les liens et la navigation entre les notices plus spécifiquement. Enfin, nous proposerons des fonctionnalités qui visent notamment à préparer l'intégration de l'intelligence artificielle au sein de l'interface.

Pour des raisons de concision, l'implémentation concrète de ces améliorations dans l'interface sont détaillées en annexe.

a. Améliorer la compréhension du FRBR

Modifier l'affichage de la hiérarchie :

Premièrement, améliorer l'affichage de la hiérarchie des niveaux FRBR pourrait permettre une meilleure intuitivité au sein de l'interface. Faire apparaître une hiérarchie avec le plus haut niveau en haut, duquel découle les autres niveaux serait plus clair pour les utilisateurs. A plusieurs endroits, la hiérarchie est affichée de manière inversée, comme dans le menu burger où l'affichage des tables se fait du plus bas niveau (film) en haut, au plus haut niveau (oeuvres) en bas. Par ailleurs, dans le menu des notices, les onglets peuvent être paramétrés comme l'utilisateur le souhaite, laissant ainsi libre cours à la possibilité d'afficher une hiérarchie incohérente. Rétablir une hiérarchie conforme au modèle FRBR permettrait de lever les ambiguïtés sur les niveaux de descriptions où l'utilisateur doit inscrire ses données. (Un développement plus précis de cette amélioration est développée en annexe).

Corrections terminologiques :

Dans le même objectif de construire l'interface la plus claire possible, quelques corrections terminologiques seraient à apporter. Par exemple, nous l'avons évoqué, le niveau Item est matérialisé dans l'application par le terme "film". Or, dans un contexte cinématographique, le film peut désigner plusieurs éléments à la fois. Selon la définition de Journot, il désigne à la fois le support matériel et l'oeuvre : "Le film, [...] désigne d'abord la pellicule photographique, puis la bande perforée recouverte d'émulsion photographique qui permet

d'enregistrer et de conserver les images. Par extension, il désigne l'œuvre cinématographique et l'ensemble des œuvres considérées par domaines"¹²¹. Dans le contexte du FRBR, le terme pourrait désigner les trois niveaux, puisqu'il ne contient pas ne lui-même la notion d'exemplaire. Mettre en place un terme plus précis comme celui d'"item-film" par exemple, serait plus intuitif pour le utilisateurs, puisqu'il induit cette notion d'exemplaire unique qui caractérise le niveau item. Par ailleurs, le terme expression est encore utilisée à certains endorits de l'interface, notamment au sein des configurations possibles. Or, les recommandatiins de la FIAF évoquent la fusion du niveau expression avec celui d'oeuvre. Conserver uniquement le terme d'oeuvre permettrait à l'utilisateur d'identifier un modle FRBR propre à la gestion de collections cinématographiques, pour ne pas le confondre avec celui des bibliothèques par exemple. Rappelons que certains utilisateurs alternent entre différents espaces de travail qui peuvent être fondés sur le même modèle de données, mais différents car appliqués à uen collection différentes, comme c'est le cas avec les colelctions filmiques et les collections bibliographiques. Il est important que l'interface signale et mette en avant ces différences pour ne pas induire l'utilisateur en erreur. De plus, afin d'améliorer l'affichage hiérarchique et la navigation au sein de l'interface, nous proposons la mise en place de points de repère afin d'aider l'utilisateur à se situer au sein du modèle FRBR. Par exemple, l'affichage, dans l'onglet d'une notice, des niveaux dans lesquels elle est imbriquée, permettrait à l'utilisateur de se repérer en tout temps au sein des liens d'une notice. Par exemple, l'onglet d'une notice d'item-film mentionnerait l'oeuvre et la manifestation dont elle découle. Des précisions sur les modalités d'affichage de cette amélioration sont précisées en annexe. Cet affichage produirait un affichage de la hiérarchie et des liens auxquels appartiendrait une notice. Par ailleurs, un repérage par couleurs sur les niveaux pourrait être mis en place afin d'améliorer l'intuitivité de l'interface. Ainsi, chaque niveau du FRBR serait associé à une couleur spécifique au sein de l'interface, rendant, pour l'utilisateur, un repérage visuel rapide et une navigation plus efficace. Plus largement, nous proposons une refonte du parcours utilisateur pour davantage guider ses choix documentaires en accord avec le modèle FRBR. Nous avons par exemple pensé à la mise en place d'un questionnaire d'assistance au catalogage lors de la création de notices au sein de l'espace de travail. CE questionnaire serait nourrit par les définition et les exemples du manuel de le FIAF, afin d'aider l'utilisateur à décrire les données au bon endroit de l'interface selon les cas. Par exemple, lorsque l'utilisateur crée une notice dans un des niveaux du FRBR (oeuvre, manifestation, item-film), il devrait répondre à plusieurs questions qui affinent le choix de lien à effectuer avec ladite notice. Par exemple, le questionnaire devrait pouvoir répondre aux incertitudes suivantes : faut-il créer une manifestation en lien avec cet item ? Cet item découle-t-il d'une variante de l'oeuvre ? Le questionnaire devrait

¹²¹M.T. Journot, *Le vocabulaire du cinéma...*

ainsi prévoir les différents cas de figure à documenter et les liens qui doivent être établis entre les notices. Le détail des questions possibles et du parcours utilisateur sont décrit en annexe. De plus, il semble que les notions de variante et de manifestation soient assez floues et poreuses pour les utilisateurs. Afin de les aider dans leurs choix : créer, à partir d'une oeuvre, une variante ou une manifestation, le questionnaire pourrait inclure des infobulles contenant les différents types de variantes et de manifestation, évitant ainsi davantage les confusions. Cette modification du parcours utilisateur afin de clarifier les différents niveaux du FRBR permettraient également aux utilisateurs de davantage utiliser les niveaux de variante et de manifestations qui sont actuellement peu utilisés.

Par ailleurs, afin de permettre à l'utilisateur de visualiser les liens entre les notices, et la pluralité de liens qu'induit le modèle FRBR, nous proposons une visualisation en graphe. En effet, actuellement, l'interface permet seulement de visualiser les liens entre les tables à l'intérieur d'une notice, par le biais d'onglets séparés. Par exemple, une notice d'item contiendra d'une part les manifestations liées et d'autre part, l'oeuvre liée. Mais il n'est pas possible de visualiser l'interconnexion de ces liens et de visualiser l'ensemble des liens dont fait l'objet une entité. Une visualisation d'ensemble serait pertinente notamment au niveau oeuvre, afin de pouvoir visualiser ses variantes, ses manifestations, ses exemplaires. De plus, visualiser rapidement les liens entre entités permettrait d'identifier les incohérences et les erreurs plus facilement, comme par exemple, des éléments vides ou isolés. Pour cette idée de visualisation en graphes, nous nous sommes inspirés de la "balade intuitive" proposée par la bibliothèque Kandinsky, qui propose, à partir d'une notice, une visualisation en graphe arborescente autour du niveau concerné. Le choix du graphe est justifié ici puisque les entités principales du FRBR sont au nombre de trois. En effet, la représentation en graphe découle du modèle RDF (Resource description framework : sujet-prédicat-objet) qui permet l'interopérabilité des données au sein du web sémantique. **(à sourcer et à développer le lien entre les deux)** Les modalités d'implémentation de cette fonctionnalité au sein de l'interface est détaillée en annexe.

b. Améliorer les liens et la navigation entre les notices

Dans un second temps, il s'agit d'améliorer la création de liens entre les niveaux du FRBR au sein de l'espace de travail. En effet, nous l'avons évoqué, les liens ne sont pas rendus obligatoires par l'interface au moment de la création d'une notice. Or, le FRBR prévoit une description en plusieurs niveaux qui doit être matérialisée par un lien indissociable entre les notices. La création de notices au sein de tables distinctes et individuelles n'incite pas l'utilisateur à créer des liens avec les autres tables. Au moment de la création d'une notice item dans la table des items, un "message" apparaît pour suggérer à l'utilisateur de l'associer à

une manifestation. Le lien est ici optionnel. Or, un item est relié soit à une manifestation, soit à une oeuvre, soit les deux. Nous proposons plutôt de contraindre l'utilisateur à relier la notice à un ou plusieurs niveaux supérieurs en bloquant la saisie tant que le lien n'est pas établi. Nous proposons ici de placer le lien comme une condition préalable à celle de la notice. Finalement, dans le même objectif de contraindre la création de lien au sein de l'interface, nous proposons même de repenser la création de notices dans des tables individuelles, voire de la supprimer. Cela rendrait nos idées sur la mise en place d'un questionnaire et la précédente caduques. En effet, la création de notices au sein de tables individuelles n'encourage pas l'utilisateur à lier les notices entre elles, sur plusieurs niveaux. Le risque est ainsi que l'utilisateur crée des notices individuelles, elles aussi, sans les relier à d'autres niveaux du FRBR. Pour éviter cela, il pourrait être intéressant de proposer la création de liens prédéfinis, au lieu de créer au sein de tables. Les tables pourraient être alors réservées à la consultation et à l'affichage des notices créées. Cette idée rapprocherait S-Movies d'une interface où l'utilisateur crée un réseau de liens, propre à une collection cinématographique. Au risque de surcharger l'interface, on peut également imaginer qu'au sein de chacune des tables, la possibilité de créer une notice de manière simple soit remplacée par la création de liens. Par exemple, au sein de la table oeuvre, l'utilisateur pourrait lier une oeuvre à une manifestation, lier une oeuvre à une manifestation, lier une oeuvre à un item, lier une oeuvre à une variante. Au sein de ce lien, l'utilisateur pourrait soit lier l'entité à une notice déjà existante, soit en créer une nouvelle dont le lien indissociable serait automatiquement mis en place. La limite de cette idée est qu'elle est contre intuitive : la création d'une notice de chaque entité se fait dans d'autres tables que celle qui lui est dédiée. Cette refonte du mode de création des notices assure toutefois un lien indissociable entre les entités, qui permettra notamment d'empêcher la suppression d'une entité et des éléments qui lui sont liés par exemple. Cela faciliterait aussi la mise en place de visualisation des liens, si les entités sont toutes interconnectées. Surtout, ces nouvelles modalités suppriment la possibilité de créer des notices individuelles, sans lien avec les niveaux du FRBR. Les modalités précises des liens proposés sont détaillés en annexe. Par ailleurs, l'interface pourrait permettre une meilleure visibilité sur l'héritage des données prévue par les méta masques dont nous avons évoqué la configuration en première partie. Actuellement, les champs issus des méta masques glissés et déposés dans la table concernée perdent la mention du niveau FRBR auquel ils appartiennent. L'utilisateur n'a plus le moyen de savoir, une fois dans la notice, que tel champ appartient à tel niveau. Conserver la mention du niveau du FRBR sur les metas masques au sein de la saisie de la notice permettrait une meilleure compréhension et visibilité pour l'utilisateur. Ainsi, par exemple, dans une notice de manifestation, le champ Titre afficherait : Œuvre – Titre.

c. Préparer l'intégration de l'IA

transition de pratiques utilisateur vers la mise en place de l'automatisation

Annotation de séquences : créer déjà des données temporelles permettra d'entraîner l'IA directement sur ces données (introduire que l'IA a besoin d'entraînement)

La table média actuelle permet seulement de visualiser une photo ou une vidéo, au clic sur la notice. Toutefois, il serait intéressant de développer une visionneuse spécifique à la vidéo qui permettrait non seulement de la visionner, mais également d'y placer des repères, des marqueurs, et de pouvoir l'annoter.

Tout d'abord, deux possibilités de "séquençage" manuel seraient possibles :

L'utilisateur saisit des repères temporels sur la vidéo sans la modifier. Ces repères sont reversés dans des champs prévus pour accueillir les "time codes" dans la notice de l'objet numérique. À l'ouverture du fichier numérique, les marqueurs laissés par l'utilisateur apparaissent, visibles sur la barre de défilement de la vidéo. L'utilisateur peut alors cliquer sur ces marqueurs pour naviguer au sein de la vidéo comme il le souhaite, et y voir les annotations associées.

L'utilisateur pourrait aussi vouloir segmenter le fichier vidéo en plusieurs séquences distinctes à partir de time codes précis. Dans ce cas-là, à la manière d'un logiciel de montage, l'utilisateur peut créer des cuts sur la vidéo et ainsi créer plusieurs fichiers numériques à partir de celle-ci, mais qui lui sont toujours liés. En effet, ces nouveaux objets, fragments du fichier vidéo d'origine, auraient leur propre notice de description mais resteraient rattachés à la notice principale, à la manière d'un ensemble.

Cette nouvelle fonctionnalité permettrait d'apprécier l'hétérogénéité des collections, et s'avèrerait utile dans le cas, par exemple, de rushes documentaires non édités que l'utilisateur souhaiterait diviser par mots clés ou thématiques. La description des médias vidéo n'en serait que plus affinée et précisée.

Par ailleurs, ce séquençage devra être effectué dans une optique d'annotation "sur" l'image, permettant ainsi d'associer des séquences plus précises à une description thématique. Concrètement, deux cas d'annotation sont possibles :

L'utilisateur pourrait être capable de placer des tags sur des éléments de l'image (objets, personnes, éléments techniques, contenu...) et d'en décrire le contenu dans les champs prévus. La notice du média prévoit alors l'affichage d'une description par time codes, sur lesquels l'utilisateur peut cliquer pour accéder directement à l'image en question.

L'utilisateur peut également vouloir décrire une séquence dans sa globalité, à l'intérieur d'un time code précis. Dans ce cas, les champs sont saisis à partir d'un tag sur le time code, et non plus sur un élément précis de l'image. L'affichage de la description dans la notice peut rester le même que le précédent.

À l'ouverture du fichier vidéo, les annotations saisies apparaissent à droite de la visionneuse, et les time codes superposés à la barre de défilement de la vidéo.

La description précise sur des séquences vidéo permettrait à la recherche d'être plus performante : l'utilisateur pourrait, en cherchant certains mots clés, tomber directement sur les séquences numériques associées, aux time codes correspondants.

Il est intéressant de penser également à la mise en place d'une recherche par mots clés au sein du fichier numérique vidéo. La recherche d'un mot clé amène l'utilisateur à une séquence décrite par ce mot clé.

Recherche de média par format : à supprimer ?

Il serait pratique de mettre en place, dans la table médias, une recherche par type de formats.

L'application pourrait détecter automatiquement le format du média créé par l'utilisateur et l'indexer pour le proposer comme critère de tri/de recherche à l'utilisateur.

Cela permettrait notamment de pouvoir rapidement visualiser les fichiers vidéo présents dans la table, au lieu de devoir faire des albums par types de médias.

Deux types de filtres seraient pertinents à proposer :

Type de média : vidéo, image, son

Format : mp4, mpeg, jpeg, mov...

Automatisation du catalogage

Il serait pertinent de mettre en place une automatisation de la hiérarchie FRBR à partir de la création d'une notice. Cette fonctionnalité serait assistée par l'IA. Par exemple, depuis l'item, l'application détecterait la hiérarchie supérieure à créer depuis les actions suivantes :

Description de l'item

Scan du code-barres

Création d'une notice item depuis la table films

Création d'une notice item depuis la table des entrées

L'assistant IA détecterait les liens à effectuer entre l'item en question et des notices de manifestation et d'œuvre si elles existent. Si elles n'existent pas, il créerait automatiquement les notices manifestation et œuvre et proposerait à l'utilisateur de les remplir. Ces notices seraient automatiquement liées.

Dans le cadre de la mise en place d'un chatbot, l'utilisateur pourrait simplement décrire l'item et son contenu, et l'intelligence artificielle suggérerait à l'utilisateur ce qu'il faut créer, ou la marche à suivre. Par exemple :

Cet item est issu de la manifestation de telle oeuvre. Les deux notices existent déjà, il faut y lier cet item

Cet item est issu d'une nouvelle manifestation de telle oeuvre, il faut la créer et la lier

à l'item

Cet item est issu de la variante de telle oeuvre, il faut la créer et la lier à l'item. Pas besoin de créer une manifestation, cet item est l'exemplaire unique de la variante de cette oeuvre.

Conclusion

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

Annexe A

Le titre très long de la première
annexe

Table des matières

Résumé	i
Remerciements	iii
Introduction	xvii
I Indexer les archives audiovisuelles	1
1. Le FRBR, modèle d’indexation conçu pour les bibliothèques	3
a. Un modèle conceptuel fondé sur les besoins utilisateurs . . .	3
b. Son adaptation à l’archivistique et au contexte muséal . . .	4
c. Un modèle adapté aux archives audiovisuelles	5
2. Adapter le FRBR aux archives audiovisuelles	7
a. Un espace de travail dédié à la gestion de collections audio- visuelles : S-Movies	8
b. L’inscription des corpus de données dans la remodelisation du FRBR	10
c. Vers une refonte de S-Movies	12
3. Le projet d’une indexation automatisée des archives audiovisuelles, conditionnée par le modèle en place	14
a. Projet SKAI	15
b. Segmentation	17
c. Indexation	19
II Implémenter l’indexation automatique des archives audiovi- suelles au sein d’une remodelisation du FRBR	21
4. Traitement audiovisuel	23
a. Machine learning et deep learning	24

	b.	Outils et modèles disponibles	28
5.		Mise en application	30
	a.	entraîner ces outils et ces modèles	32
	b.	analyse du mouvement	33
6.		Description et indexation automatique	35
	a.	Quoi décrire ?	35
	b.	Outils utilisés	35
7.		Intégration dans le processus	36
8.		Entraînement	37
9.		plateforme de validation humaine	40
10.		La nécessaire refonte de S-Movies pour la mise en place d'un tel projet	41
	a.	Améliorer la compréhension du FRBR	42
	b.	Améliorer les liens et la navigation entre les notices	45
	c.	Préparer l'intégration de l'IA	46
Conclusion			49
A Titre court			53