

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- Aide et FAQ Médiascope / INA*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).
- AKATA (Zeynep), BALLIET (Dan), DE RIJKE (Maarten), DIGNUM (Frank), DIGNUM (Virginia), EIBEN (Guszt), FOKKENS (Antske), GROSSI (Davide), HINDRIKS (Koen), HOOS (Holger), *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53-8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587.
- Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).
- Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-editor-options.html> (visité le 30/08/2026).
- Analyse Des Tendances Médias Par l'IA - Les Traitements Réalisés Par Les Outils d'intelligence Artificielle Utilisés Sur Data.Ina.Fr / Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- Apprentissage profond (deep learning)*, URL : <https://www.cnil.fr/fr/definition/apprentissage-profond-deep-learning> (visité le 18/07/2026).
- AQUINO (Alexandra Jonker Judith), *Pourquoi la qualité des données est essentielle au succès de l'IA / IBM*, janv. 2026, URL : <https://www.ibm.com/fr-fr/think/topics/ai-data-quality> (visité le 14/08/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service

- de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4–2 (juill. 2019), DOI : 10.22148/16.043.
- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).
- *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BARREAUX (Sabine), DAILLE (Béatrice) et JACQUEY (Évelyne), « Indexation automatique en SHS : bilan d'une expérimentation », *I2D - Information, données & documents*, 54–1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.
- BASSAÏSTEGUY (Sidonie), *Le Médium, c'est La Mémoire : Archivages Du Document à l'Institut National de l'audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).
- BENJAMIN (Walter), *L'oeuvre d'art à l'époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l'IA 2025 », dans *Conférence Nationale Sur Les Applications de l'Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of*

- Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/authorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CHAMBONNET (Sébastien), « Définir une architecture de l'information pour la sauvegarde du patrimoine scientifique et technique contemporain (Patstec), à l'heure du web de données » (, 2015).
- COCO Detection Dataset*, nov. 2023, URL : <https://docs.ultralytics.com/datasets/detect/coco> (visité le 26/07/2026).
- COLAVIZZA (Giovanni), BLANKE (Tobias), JEURGENS (Charles) et NOORDEGRAAF (Julia), « Archives and AI : An Overview of Current Debates and Future Perspectives », *J. Comput. Cult. Herit.* 15-1 (déc. 2021), 4 :1-4 :15, DOI : 10.1145/3479010.
- COLAVIZZA (Giovanni) et JAILLANT (Lise), « AI Ready : How to Prepare Archives for Artificial Intelligence, Improve Discoverability, and Enhance Access », *Archives and Records*, 0-0 (juin 2026), p. 1-22, DOI : 10.1080/23257962.2026.2675937.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ?* | IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).
- DEVELOPMENT (S. O.), *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).
- DIALOGUE (IFLA Working Group on FRBR/CRM), « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).
- Dico des musées* | Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- DU (Lin), LE (Brandon) et HONIG (Edouardo), « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16–4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.
- Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- FICK (Hanna), FREDRIKSSON (Anneli), LINDBLOM (Helena), FREDRIKSSON (Anneli) et LINDBLOM (Helena), « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.
- France 2030 : un plan d'investissement pour la France* | economie.gouv.fr, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.

- GILL (Sandrine), « Les archives audiovisuelles au tamis des archivistes », dans *Les nouveaux paradigmes de l'archive*, dir. Claire Scopsi, Clothilde Roullier, Martine Sin Blima-Barru et Édouard Vasseur, Pierrefitte-sur-Seine, 2024 (Actes), DOI : 10.4000/books.pan.7249.
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].
- HERVÉ (Nicolas), LETESSIER (Pierre), DERVAL (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- IFLASTANDARDS.INFO, *Frbrroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- *Frbrroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- ISAAC (Antoine), BACHIMONT (Bruno) et LAUBLET (Philippe), « Indexation de documents AV : ontologies, patrons de conception et d'utilisation » (, 2005).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOLY (A.), LOMBARDO (J-C), MOREUX (J-P), LEROY (Q) et BUISSON (O), « Snoop, Un Moteur de Recherche Visuelle Interactif », *Culture et Recherche (141)*–141 (2020), p. 14-15.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.

- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.
- L'intelligence artificielle au service de la création de métadonnées*, URL : <https://www.archimag.com/demat-cloud/2022/04/15/intelligence-artificielle-creation-metadonnees> (visité le 03/08/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et*, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables | Ministère de la Culture*, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).
- LALANDE (Steffen), BELOUED (Abdelkrim) et FARGE (Odile), « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco-MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.
- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), DERVAL (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.

- LIU (Haotian), LI (Chunyu), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).
- MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- Modèles FRBR, FRAD et FR SAD, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- Module 6 - Section 7 : Indexation - Introduction, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].

- MORSE (Christopher), « Les musées et l'expérience utilisateur (UX) », *La Lettre de l'OCIM. Musées, Patrimoine et Culture scientifiques et techniques*-200 (2022/mars/01), p. 38-43, DOI : 10.4000/ocim.4777.
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).
- Outils d'aide à l'analyse des médias audiovisuels / INA*, URL : <https://inatheque.ina.fr/outils-d-aide-a-l-analyse-des-medias-audiovisuels> (visité le 03/08/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).
- PAILLARD (Isabelle), « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).

- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Prelinger Archive – Internet Archive Help Center*, URL : <https://help.archive.org/help/prelinger-archive/> (visité le 14/08/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Projet Dataset / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 05/08/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ? / IBM*, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ? / IBM*, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- Qu'est-ce que la modélisation de données ? / IBM*, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- Qu'est-ce que la qualité des données ? / IBM*, sept. 2022, URL : <https://www.ibm.com/fr-fr/think/topics/data-quality> (visité le 14/08/2026).
- Qu'est-Ce Que Le Machine Learning (ML)? / IBM*, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).

- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SCHIAPPA (Madeline C.), RAWAT (Yogesh S.) et SHAH (Mubarak), « Self-Supervised Learning for Videos : A Survey », *ACM Computing Surveys*, 55–13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].
- SIGNOLES (Aurélie Bergonnier), « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.
- Systèmes et données*, URL : <https://www.transition-bibliographique.fr/systemes-et-donnees/> (visité le 08/07/2026).
- TALBI (Ilyes), *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).
- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLETT, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

Traitement du langage naturel : découvrez comment les machines lisent et écrivent, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).

TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.

— « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.

ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).

Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).

UNIVERSALIS (Encyclopædia), *Rushes : définition et synonymes*, URL : <https://www.universalis.fr/dictionnaire/rushes/> (visité le 22/08/2026).

Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).

VANG-Z, *Annotating a YOLOv8 Dataset Using Label Studio*, sept. 2023, URL : <https://richelf.tech/en/posts/2023-09/0f87cd80-8c23-c2dd-40f3-e1d2df83c2f7.html> (visité le 29/08/2026).

VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*—hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.

WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].

WISE (Nikki), FENLON (Katrina), MARSH (Diana), SORENSEN (Amanda), SMOKE (Ugoma), NAVARETTE (Candy) et HAVENS (Lucy), « ‘Appears to Be about’ : An Evaluation of AI-generated Metadata Quality for Community Archives », *Information Research an international electronic journal*, 31—iConf (mars 2026), p. 417-437, DOI : 10.47989/ir31iConf64144.

XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

Première partie

Indexer les archives audiovisuelles

Deuxième partie

Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR

1. Traitement audiovisuel

Les tâches d'analyse automatique pouvant être appliquées aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent davantage vers le media vidéo, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance¹. Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. Si la détection automatique des plans dans un flux vidéo est maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image, la détection sémantique de séquences reste inexploitée. Comme le souligne Bhargav dans quel article ? et ses coauteurs, "pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques. [Traduction personnelle]"².

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle et d'indexation automatisée. Au courant de notre proposition, la segmentation est moins considérée comme un prérequis technique que comme une fonctionnalité documentaire à part entière, directement articulée à l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

a. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont globalement désignées sous le terme de Audiovisual Processing (AVP)³.

Appliquées à un grand nombre de données, ces technologies permettent de passer du

¹Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

²"reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material" Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240

³Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

”close” au ”distant viewing”, c’est-à-dire d’une vue des données rapprochée, réduite, à une vue d’ensemble.⁴ Les tâches de traitement automatique permettraient en effet de passer de l’analyse manuelle de certaines archives audiovisuelles, à une vue d’ensemble sur les données afin d’en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

De nombreux projets sont dédiés à l’analyse automatique de corpus audiovisuels, toutefois, aucun projet n’est concrètement dédié à la segmentation temporelle en différentes séquences afin d’en indexer le contenu. L’Institut National Audiovisuel (Institut National de l’Audiovisuel (INA)), est notamment pionnier dans la proposition de projets d’analyse automatique appliquée à l’audiovisuel. L’INA a par exemple mis en place un outil de segmentation, InaSpeechSegmenter, toutefois dédié à la segmentation du discours entre hommes et femmes, dans une optique statistique⁵. Cet algorithme de segmentation, appliqué au son, ne peut être pris comme exemple d’application pour notre étude, centrée sur l’analyse du sens de l’image en mouvement.

Par ailleurs, le projet MeMad, réunit un ensemble d’outils dédiés à l’analyse automatique de l’audiovisuel développés par l’Université d’Aalto, EURECOM, l’INA et l’Université d’Helsinki⁶. Parmi les outils développés, nous pouvons citer par exemple un outil de traduction du discours (Speech translation), l’outil inaFaceGender, un outil de reconnaissance faciale (Face recognition), un outil permettant d’identifier la langue parlée (Spoken language identification)⁷. Ces projets restent centrés sur l’analyse du son et du texte inclut dans l’image et ne peuvent donc pas être pris en compte dans notre analyse. Au sein de cette sous section, nous tenterons ainsi d’évaluer les outils et méthodes disponibles et dédiés au traitement audiovisuels, afin de proposer un processus adéquat.

L’application des technologies d’intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de *computer vision*, ou de vision par ordinateur. Le terme définit un sous-domaine d’application de l’intelligence artificielle qui permet d’entraîner un système d’intelligence artificielle à l’analyse des images fixes ou en mouvement⁸. La vision par ordinateur s’appuie largement sur des modèles de *machine learning*, ou apprentissage machine, qui désigne une branche de l’intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique

⁴ *Ibid.*

⁵ *Analyse Des Tendances Médias Par l’IA - Les Traitements Réalisés Par Les Outils d’intelligence Artificielle Utilisés Sur Data.Ina.Fr / Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).

⁶ *MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).

⁷ *Ibid.*

⁸ Rina Diane Caballar Stryker Cole, *Qu’est-ce que la vision par ordinateur ? / IBM*, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

plus intelligent.⁹ L'apprentissage machine permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données.¹⁰ La vision par ordinateur classique s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques¹¹. Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d'apprentissage machine¹². De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut être mis en place sur l'ensemble des données, seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds¹³. Ces modèles relèvent également de la vision par ordinateur, mais fondée sur l'apprentissage profond, permettant notamment de gérer l'analyse de flux vidéo. La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l'apprentissage machine. L'apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'exécuter des tâches automatisées, réduisant le besoin d'intervention humaine, et améliorant ainsi le rapport cout-efficacité¹⁴. Il suffirait de fournir

⁹Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹⁰*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹¹Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹²*Ibid.*

¹³Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

¹⁴N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données¹⁵. Par rapport aux techniques traditionnelles de vision par ordinateur, l'apprentissage profond permet d'obtenir une plus grande précision dans les tâches d'analyse audiovisuelle telles que la classification d'images, la segmentation, la détection d'objets¹⁶.

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la vision par ordinateur pour la classification d'images et la reconnaissance d'objets, est celui des réseaux de neurones convolutifs (CNN). Appliqués à des corpus d'images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d'en extraire les couleurs et les contours.¹⁷ Les tâches que permettent les CNN sont plutôt bien adaptées à l'image fixe, puisqu'ils extraient des éléments fixes de l'image.

Néanmoins, d'autres modèles issus de l'apprentissage profond tels que les transformers s'avèrent davantage efficace sur des tâches dédiées à l'image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent grâce à un mécanisme d'auto-attention qui leur permet de détecter les relations et dépendances entre les données¹⁸. Tandis que les CNN analysent les données de manière locale dans l'image, sans prendre en compte les interdépendances qui les régissent temporellement, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d'entre elles¹⁹. Les CNN ne permettent pas, par exemple, de discerner les "dépendances à longue portée" telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins²⁰. Ainsi, ils seraient davantage adaptés à l'analyse d'images en mouvement puisqu'ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d'une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l'intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d'interpréter les analyses qui sont produites²¹. En effet, une fois entraînés, il est difficile d'en modifier les paramètres puisqu'ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi

¹⁵ *Ibid.*

¹⁶ *Ibid.*

¹⁷ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

¹⁸ Cole Stryker Bergmann Dave, *Qu'est-ce qu'un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

¹⁹ *Ibid.*

²⁰ *Ibid.*

²¹ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

difficile à comprendre et à exposer²². Deuxièmement, les algorithmes de type transformers sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe²³. Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d'un large jeu de données d'entraînement afin d'éviter un surapprentissage impliquant des biais multiples²⁴. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu'il s'agirait de réadapter à un contexte patrimonial²⁵. Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l'analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d'analyse automatique d'un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 1 ci-dessous permet de comparer les compétences des types de modèles cités pour l'analyse d'un flux vidéo.

²²N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

²³Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

²⁴Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

²⁵*Ibid.*

Type d'approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan - Calcul d'histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d'objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d'images fixes extraites du flux vidéo - Détection d'objets ou caractéristiques dans l'image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 1 : Comparatif des approches de traitement audiovisuel automatique

Comme l'illustre le Tableau 1, si les architectures fondées sur les transformers offrent des compétences puissantes, notamment pour l'automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d'entraînement conséquents. À l'inverse, la vision par ordinateur classique offre une stabilité d'analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d'en extraire le sens. Ce constat justifie l'orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

b. Outils et modèles disponibles

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués de documents audiovisuels, leur architecture nous donne des pistes d'expérimentations afin de pouvoir implémenter un tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéos

en différentes séquences. L’optique de cette étude est de fournir une proposition d’implémentation de fonctionnalités automatiques au sein d’un outil de gestion des collections d’un point de vue métier, au regard des besoins utilisateurs. Par conséquent, notre étude analysera l’architecture des algorithmes sélectionnés sans en détailler les mécanismes techniques.

Tout d’abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des transformers notamment, une des solutions envisagée consisterait à transformer un flux d’images en mouvement en la série d’images fixes qui le composent. Ce processus écarterait notamment le besoin d’analyser les relations entre les images par un mécanisme d’auto-attention prévu par les transformers. En effet, le médium cinématographique se caractérise par l’enchaînement d’une succession d’images fixes produisant ainsi l’illusion du mouvement. La transformation de ce flux à l’état d’images fixes par un outil technique permettrait de pouvoir gérer l’analyse sémantique de ces images par des processus légers prévus par la vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d’analyse que ceux prévus pour l’image fixe, fondés sur la vision par ordinateur classique.

Cette segmentation d’un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d’une analyse sémantique, regroupant ces plans fixes en des séquences sémantiques. Dans un article sur la mise en place d’un processus de segmentation temporelle, Xin prône notamment le découpage syntaxique tel que nous l’avons défini comme étape préliminaire à l’analyse sémantique des images par des modèles d’intelligence artificielle²⁶. La segmentation syntaxique d’un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

Ainsi, la segmentation automatique d’un document audiovisuel en séquences serait fondée sur l’analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes²⁷. Ces plans sont en réalité retenus par l’algorithme comme des images-clés contenues au sein de chaque séquences, calculées comme l’image la plus représentative de la présence des éléments dans un flux donné²⁸. Ce principe, qualifié de sélection de données, permet d’alléger nettement la puissance de calcul et la structure des algorithmes²⁹. Ces images-clés seraient ensuite analysées par un algorithme fondé sur des CNN, afin d’y ajouter une analyse sémantique et de les regrouper

²⁶Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

²⁷*Ibid.*

²⁸*Ibid.*

²⁹*Ibid.*

en séquences.

Ce processus est notamment appliqué par la bibliothèque python Pyscenedetect qui permet la segmentation d'un flux vidéo à l'aide de différents paramètres définis en amont³⁰. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l'analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquences audiovisuelle, Pyscenedetect permet d'en extraire les image clés, c'est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de vision par ordinateur classique, qui concrétise la mise en oeuvre de la comparaison syntaxique d'images fixes. L'outil s'appuie sur des détecteurs mathématiques afin d'analyser les différences structurales entre les images-clés tirées d'une vidéo³¹. Il s'agit ainsi d'un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d'entraînement particulier, comme c'est le cas des outils de vision par ordinateur fondés sur l'apprentissage profond. Pyscenedetect permet d'isoler des images-clés de l'image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l'outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l'image, une détection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d'un plan avec les plans adjacents (méthode *detect-adaptative*)³². En théorie, Pyscenedetect isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d'images, et non des séquences, unités de sens narratives. Néanmoins, Pyscenedetect permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l'élévation de la valeur du seuil de détection ou la fixation d'une durée minimale de séquences (*min-scene-len*), l'outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu'en cas de détection de changements visuels majeurs tels que l'éclairage, le décor, la composition, etc³³. Par ce biais, la segmentation syntaxique proposée par Pyscenedetect pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l'outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquences retenue. Le diagramme de flux 1 ci-dessous illustre la manière dont l'outil pourrait être paramétré afin de segmenter le flux vidéo en séquences.

Pour chaque changement détecté, une nouvelle séquence est ainsi créée et une images-clés est automatiquement enregistrée, associée au fichier vidéo d'origine. Nous proposerons

³⁰ Home - PySceneDetect, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³¹ Command-Line - PySceneDetect, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

³² Ibid.

³³ Ibid.




FIG. 1 : Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect

la réutilisation de cette images-clés au sein du processus suivant, dédié à l'analyse sémantique des séquences préalablement détectées, afin de ne pas surcharger les algorithmes. Ce système images-clés permettrait ainsi d'alléger le processus d'analyse sémantique, puisque les algorithmes reçoivent des images fixes au lieu de fichiers vidéos plus ou moins lourds. Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Samarth Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus³⁴. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même après numérisation ou restauration³⁵. En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus³⁶. De plus, Samarth Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé³⁷. Toutefois, un des avantages majeurs de l'outil Pyscenedetect est sa disponibilité et la possibilité de le mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

³⁴S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

³⁵*Ibid.*

³⁶J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

³⁷S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

c. Mise en application

Au sein du chapitre suivant, nous mettrons à l'épreuve l'adaptabilité de l'outil que nous avons décrit pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, construit par des plans fixes, en noir et blanc et muets. Nous tenterons d'appliquer le processus de segmentation proposé par Pyscenedetect sur un tel corpus, afin d'en comprendre les données qui pourraient être générées. Le corpus, utilisé ici comme cas d'étude, se caractérise notamment par son ancienneté, et donc par la dégradation de la pellicule sur laquelle l'image s'inscrit. L'outil pourrait ainsi rencontrer des difficultés lors de l'identification des coupures et des changements de plans, brouillés par la dégradation de l'image. Toutefois, la structure du contenu de ces archives facilite la tâche de l'outil, composé d'une succession de plans fixes, dont les coupures sont suffisamment marquées, en fait un corpus relativement bien adapté à ce type de tâche automatique, qui pourrait identifier les coupes plus facilement.

Par ailleurs, Pyscenedetect, nous l'avons vu, est un outil dédié à la détection de coupures et à la segmentation d'un flux vidéo en différents plans. Or, dans cette étude, nous cherchons à montrer comment segmenter un flux audiovisuel en différentes séquences, unités sémantiques autonomes. Dès lors, comment paramétrer un tel outil pour la détection d'éléments sémantiques plus larges tels que les séquences ?

Une solution envisagée serait d'augmenter la valeur du seuil de coupures (treshold), pour que l'outil ne détecte plus les micro-coupures entre les images mais des coupes plus larges, à l'échelle de séquences³⁸. L'outil enregistrerait alors un changement de séquence seulement lors d'une rupture significative de l'espace-temps à l'image. Ce paramétrage reste toutefois limité puisque plusieurs plans adjacents peuvent être radicalement différents d'un point de vue syntaxiques, tout en appartenant bien à la même séquence. Par exemple, une même séquence peut contenir un gros plan et un plan d'ensemble, dont la composition visuelle est bien différente. Dans le cas du corpus d'archives audiovisuelles décrit, les plans restent larges et fixes, montrant l'ensemble du décor dans lequel ils s'inscrivent. Ainsi, le paramétrage du seuil pourrait être adéquatement réglé pour la détection de changements de décor, sur ce corpus donné, afin de segmenter le flux vidéo en différentes séquences.

Par ailleurs, il est possible de régler l'outil sur une durée minimale de détection de coupures à l'aide du paramètre "min-scene-len", pour que le processus n'effectue de coupures qu'après un laps de temps défini³⁹. La définition de ce paramètre nécessite une analyse statistique du corpus segmenté afin d'en définir la durée moyenne d'une séquence. Au sein du

³⁸ *Command-Line - PySceneDetect...*

³⁹ *Ibid.*

logiciel de gestion des collections prévu par Skinsoft, l’institution qui gère ce corpus d’archives documente déjà les séquences contenues par les différentes œuvres au sein des notices de films physiques, sous la forme de repères temporels. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de time codes afin de déterminer la durée moyenne d’une séquence au sein du corpus. D’après nos observations, les séquences extraites sont généralement d’une durée de 60 secondes. Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d’images plus importante, permettant à l’outil de comparer le contenu visuel d’un plan par rapport à une grande variété de plans qui l’entourent⁴⁰. Ce paramètre permettrait encore de régler l’outil sur la détection de changements majeurs dans l’image, dans l’optique d’en extraire uniquement les séquences.

Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données en sortie. D’une part, un fichier JSON ou CSV contenant les time codes de début et de fin correspondant aux séquences identifiées au sein de chaque fichier vidéo ingéré. Chaque séquence est alors associée à un identifiant unique et à des times codes de début et de fin. D’autre part, l’outil permet également d’extraire pour chaque séquence un fichier image, qui correspond à l’image fixe médiane, censée être la plus représentative de la séquence, désignée par le terme d’image clé⁴¹.

Toutefois, si ce paramétrage permettrait une plus grande flexibilité pour la segmentation d’un flux vidéo en séquences, l’outil reste limité dans l’automatisation de cette tâche. D’une part l’outil est prévu pour la détection automatique de changement de plan, et d’autre part, une séquence ne se définit pas seulement comme une caractéristique syntaxique du langage cinématographique, comme c’est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence concrétise un choix narratif, matérialisé généralement par un changement d’espace-temps. C’est pourquoi, un outil dont l’automatisation est fondée sur des seuils mathématiques reste limité pour une telle tâche. Nous proposons alors de réaliser une analyse sémantique des séquences détectées, afin de ré associer leur sens à ces coupures détectées automatiquement, tout en réutilisant les données produites : les times codes et l’image clé associés à chaque séquence.

La segmentation syntaxique effectuée par Pyscenedetect constitue un “filtre”, c’est-à-dire un premier niveau dans notre chaîne d’indexation automatique des archives audiovisuelles⁴². Les données issues de ce premier niveau permettent d’amoindrir le volume de données, caractéristique des fichiers vidéo, transmis aux algorithmes d’indexation automatique. Dès lors, les images-clés produites par glspyscene peuvent être soumises à un modèle neuronal de détection d’objets tel que YOLO (You only look once), afin d’extraire le sens

⁴⁰ *Ibid.*

⁴¹ *Ibid.*

⁴² Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*




FIG. 2 : Mise en application de Pyscenedetect

de ces segments et leur rendre leur valeur sémantique. La sous-section suivante détaille la manière dont ce modèle, appliqué aux glsimgcle des séquences, permet d'en extraire les caractéristiques sémantiques à des fins d'indexation.

2. Description et indexation automatique

La description automatique d'images peut être centrée sur de nombreux éléments au sein d'une séquences de film : dialogues, ambiance sonore, visages, objets, spatialité des éléments, actions, émotions... Toutefois, la définition d'un processus au sein d'un logiciel de gestion des collections impose un cadrage défini des fonctionnalités. Le corpus patrimonial retenu pour notre étude, constitué de rush muets des premiers temps, exclue d'emblée l'analyse automatique de caractéristiques sonores. L'analyse automatique se concentre donc exclusivement sur les caractéristiques visuelles de l'image. Deux approches coexistent alors, celle de l'identification des éléments dans l'image de manière précise, ou celle d'éventuellement générer des résumés automatiques sur ces séquences, à une échelle plus globale. Or, la seconde approche, fondée sur des grands modèles de langage, implique des architectures génératives couteuses et lourdes. Nous choisissons ainsi d'adopter la première, afin de garantir une indexation fiable et stable, plus légère, à travers la détection et l'identification d'objets sur les images-cléspréalablement extraites. Cette tâche peut être réalisée par des architectures de réseaux de neurones relativement légers, pouvant extraire des concepts directement indexables au sein du logiciel.

a. Outils utilisés

Si pour la tâche de segmentation automatique, nous avons écarté les architectures de modèles fondés sur des réseaux de neurones, la reconnaissance d'objets dans l'image suppose une prédiction fondée sur un apprentissage machine profond des réseaux de neurones. En effet, la plupart des outils de reconnaissance d'objets dans l'image sont fondés sur des modèles de réseaux de neurones convolutifs (CNN) dont nous avons exposé le fonctionnement dans la section précédente. Dans le domaine du patrimoine, dont le logiciel de Skinsoft gère les données des institutions, se pose la question d'une infrastructure adaptée qui permet d'assurer la sécurité des données produites. Les solutions commerciales d'analyse automatique sont pour la plupart fondées sur un Cloud externe qui implique le déplacement des données. Ces solutions sont inadaptées au contexte d'analyse de données patrimoniales en raison de propriété intellectuelle et de sécurité. Ainsi, le principe retenu afin de guider notre choix d'outil est celui d'"amener l'algorithme aux données [Traduction personnelle]" ⁴³, via un développement

⁴³ *"bring algorithms to the data"*

local interne des modèles d'analyse⁴⁴. Afin de répondre à cette contrainte, notre choix s'est tourné vers des modèles en libre accès. Nous détaillerons dans cette section l'utilisation de l'architecture YOLO, une série d'algorithmes dédiés à la détection d'objets visuels dans les images et les flux vidéo, et fondé sur les réseaux neuronaux convolutifs, développé par Joseph Redmon en 2015, puis repris par Ultralytics en 2020⁴⁵. C'est l'un des outils de détection d'objets les plus documentés, y compris dans le domaine des sciences humaines et du patrimoine. Fondé sur la vision par ordinateur et entraîné grâce à des méthodes d'apprentissage profond, YOLO est en accès libre, et permet notamment la détection d'objets et la classification d'images, permettant ainsi de poser les bases d'une indexation⁴⁶. Le modèle extrait dans un premier temps les caractéristiques visuelles de l'image qui lui est donnée, les agrège, afin de finalement proposer une détection d'objets⁴⁷. Les versions récentes du modèle telles que YoLo12 ne sont désormais plus seulement basées sur des CNN mais sur des mécanismes d'auto-attention, similaires à ceux des transformers dont nous avons évoqué l'architecture⁴⁸. Toutefois, comme nous l'avons évoqué, cette architecture demande une consommation de mémoire élevée et une puissance de calcul lourde⁴⁹. Ultralytics, créateur du modèle, recommande des versions moins avancées pour une mise en application rapide, telles que la version YOLOv8, uniquement fondée sur un réseau de neurones convolutif⁵⁰. YOLOv8 propose une version optimisée de cette architecture en trois temps : extraction, aggrégation, et détection⁵¹. Le modèle se caractérise par sa capacité à analyser l'image en une seule fois, contrairement à d'autres modèles dont les résultats impliquent plusieurs analyses de certaines parties de l'image⁵². Si la détection d'objets prévue par YOLO peut être appliquée à des flux vidéo, nous souhaitons l'intégrer comme composant complémentaire au processus de segmentation précédemment décrit. De fait, il est pertinent de réutiliser l'image clé fixe, produite et sauvegardée par l'outil pycenedetect, associée à chaque séquence, afin de la faire analyser par le modèle. Ceci permettrait de réduire le temps de calcul du processus et d'améliorer l'efficacité des prédictions, puisque le modèle reçoit un minimum d'informations. Ainsi, l'application du

⁴⁴N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁴⁵Ilyes Talbi, *YOLO : le framework de référence en vision par ordinateur*, juin 2025, URL : <https://larevueia.fr/yolo/> (visité le 30/08/2026).

⁴⁶Glenn Jocher, *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.

⁴⁷J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴⁸*YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).

⁴⁹*Ibid.*

⁵⁰*Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).

⁵¹Muhammad Yaseen, *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].

⁵²Joseph Redmon, Santosh Divvala, Ross Girshick et Ali Farhadi, *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

modèle YOLO s'impose comme la suite logique du pipeline de segmentation détaillé précédemment, afin d'indexer les segments produits, via l'utilisation des images-clés. Si le premier processus de segmentation produit des données temporelles associées à chaque séquence sous la forme de time codes, YOLO produit des données sémantiques sur ces mêmes séquences. À l'issue de l'analyse d'une images-clés, le modèle YOLO est capable de produire trois types de données : des étiquettes sur les objets identifiés, un score de confiance qui indique l'indice de certitude concernant la prédiction, des coordonnées spatiales de localisation de l'objet détecté dans l'image⁵³. Les étiquettes produites sur les objets identifiés, permettant de décrire les caractéristiques de l'image, pourront être indexées comme des mots-clés au sein du logiciel de gestion des collections. Le processus de détection d'objets prévu par YOLO à partir de l'image clé peut être schématisé ainsi :




FIG. 3 : Processus de détection d'objets de YOLO

Les mots-clés produits à partir des étiquettes sont ensuite associés aux time-codes de chaque séquence détectée. Ainsi, chaque séquence contiendrait les données suivantes : des

⁵³ *Ibid.*

time codes qui l'identifient comme extrait, des étiquettes/mots-clés sur les objets qu'elle contient, et des données qui permettraient aux utilisateurs de vérifier la prédiction et de la valider. Le score de confiance produit par le modèle, permet en effet d'indiquer à l'utilisateur la certitude de l'étiquette associée à tel objet détecté. De même, les coordonnées spatiales de l'étiquette produite permettent à l'utilisateur de vérifier dans l'image si l'étiquette produite est associée au bon objet.

b. Entraînement

L'analyse automatique du contenu des images repose donc sur les architectures des CNN, fondées sur des méthodes d'apprentissage profond, dont YOLO est un exemple concret. Toutefois, les algorithmes fondés sur l'apprentissage profond subissent généralement un entraînement supplémentaire afin d'analyser adéquatement le contenu des images en fonction d'un contexte donné. Deux approches méthodologiques d'entraînement peuvent être appliquées, l'apprentissage supervisé et l'apprentissage non supervisé. L'apprentissage supervisé est fondé sur l'utilisation de données annotées pour l'amélioration des prédictions du modèle d'analyse d'image, tandis que l'apprentissage non supervisé exécute des tâches d'analyse et de classification à partir de données brutes, non annotées⁵⁴. Toutefois, l'apprentissage non supervisé ne permet pas d'adapter suffisamment le modèle de détection d'objets au corpus d'images spécifique étudié. En effet, si Yolov8 a toutefois fait l'objet d'un pré-entraînement en amont de sa mise à disposition, sur le jeu de données COCO, ce dernier, composé de 200 000 images annotées, reste généraliste et adapté à la détection d'objets communs et contemporain⁵⁵. Or, l'efficacité des modèles basés sur l'apprentissage profond sur un corpus spécifique dépend fondamentalement de nature et de la qualité de leur données d'entraînement. Au sein des sous sections suivantes, nous prendrons comme exemple d'application le projet des archives britanniques en ligne, qui propose une chaîne de traitement pour la détection d'objet basée sur l'apprentissage profond et la supervision humaine⁵⁶. Le projet, à travers la mise en place d'une supervision au sein du processus d'analyse par le modèle, propose de mettre en application le concept de Human-in-the-Loop⁵⁷. Le corpus étudié, caractérisé par l'ancienneté

⁵⁴Julianna Delua, *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

⁵⁵YOLO Algorithm for Object Detection Explained [+Examples], janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

⁵⁶Surya Kasturi, Alex Shenfield, Chris Roast, Danny Le Page et Alice Broome, « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

⁵⁷*Ibid.*

de ses images en fait un corpus d'images spécifique sur lequel l'algorithme doit subir un entraînement supplémentaire, supervisé. Afin d'adapter le modèle à notre corpus et ainsi d'en améliorer l'efficacité, une phase de pré traitement est nécessaire sur les données du corpus, au cours de laquelle des images sont sélectionnées afin d'être annotées pour être pré-testées par le modèle⁵⁸. La supervision humaine est déterminante dans ce processus, particulièrement dans le cas d'analyse de corpus inédits sur lesquels l'algorithme reste à entraîner⁵⁹. Les british online archives implémentent l'adaptation du modèle par la pré sélection d'un nombre d'images définis, annotées manuellement à l'aide de la plateforme Label Studio⁶⁰. Label Studio est une plateforme open source déployable localement, qui permet ainsi de respecter la protection des données analysées⁶¹. Afin d'éviter l'annotation manuelle de l'ensemble des images-clés issues du processus de segmentation, il peut être envisagé d'exécuter au préalable YOLO depuis Label Studio sur l'ensemble des images-clés du corpus afin de générer une base de prédictions⁶². Les détections brutes générées peuvent ensuite être importées au sein de la plateforme comme une couche d'annotation préalable à partir de laquelle affiner le modèle. Au sein de Label Studio, les prédictions s'affichent sous la forme de *bounding boxes*, c'est-à-dire de boîtes englobantes autour des objets détectés dans l'image, avec le score de confiance qui y est associé⁶³. Le paramètre [choices] permet au modèle de proposer une classification sur les objets détectés, c'est-à-dire un mot clé⁶⁴. Afin de focaliser la supervision du modèle sur les éléments les plus pertinents, il peut être décidé de ré annoter les images dont la détection est jugée incertaine par le modèle via un score de confiance en dessous du seuil minimal attendu⁶⁵. Les archives britanniques préconisent également la suppression des boîtes englobantes redondantes afin de sélectionner celles qui sont les plus pertinentes pour la supervision⁶⁶. Dans Label Studio, les utilisateurs (une équipe technique dans le cas de Skinsoft) examinent les prédictions ainsi générées sur les images, rectifient si besoin la définition des "boîtes" et la classification associée⁶⁷. Les données ainsi corrigées sont exportées au format YOLO depuis Label Studio, puis réinjectées dans la chaîne de réentraînement du modèle afin d'améliorer

⁵⁸ *Ibid.*

⁵⁹ *Ibid.*

⁶⁰ *Ibid.*

⁶¹ *Open Source Data Labeling and AI Evaluation*, URL : <https://labelstud.io/> (visité le 29/08/2026).

⁶² S. O. Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline*, déc. 2025, URL : <https://sodevelopment.medium.com/fine-tuning-yolo-models-with-an-automated-data-labeling-pipeline-3704b6472aa1> (visité le 29/08/2026).

⁶³ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁶⁴ *Label Studio — Choices Tag for Multiple Choice Labels*, URL : <https://labelstud.io/tags/choices> (visité le 29/08/2026).

⁶⁵ S. O. Development, *Fine-Tuning YOLO Models with an Automated Data-Labeling Pipeline...*

⁶⁶ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁶⁷ *Ibid.*

les performances en accord avec le corpus⁶⁸. Cette méthode s'appuie sur le transfert d'apprentissage (transfert learning), qui consiste à *fine tuner* un modèle existant, c'est-à-dire de l'affiner, afin de l'adapter au corpus analysé⁶⁹. À défaut de réentraîner le modèle dans sa globalité, les prédictions réalisées à partir du jeu de données d'entraînement COCO sont conservées puis spécialisées sur un corpus donné⁷⁰. L'affinage du modèle via la rectification et l'annotation des données, constitue une étape de prétraitement, en amont de l'analyse des données, afin d'améliorer l'efficacité de la détection d'objets⁷¹. Cette étape de pré-traitement, avant le processus d'analyse, implique la définition des types de mots clés souhaités, pour l'indexation des séquences. En effet, les étiquettes associées aux objets au sein des images correspondent aux mots-clés qui seront prédits par le modèle lors de l'analyse. Dans le cadre du corpus étudié, il est pertinent d'extraire les mots-clés déjà indexés sur les séquences au sein du logiciel. Ces mots-clés varient selon le contenu de l'image et peuvent, par exemple, être les suivants : affiche, foule, policier, gendarme, drapeau, etc. Ces mots-clés, tout comme le jeu de données COCO, sont assez génériques. De fait, le pré traitement est avant tout utile pour l'entraînement du modèle à pouvoir détecter des objets au sein d'images dont la qualité est compromise.

c. Processus de validation technique

Afin de gérer les essais-erreurs de l'affinage du modèle sur les données spécifiques du corpus, il est pertinent de mettre en place un processus de validation technique du traitement. Ce processus permettrait d'une part de valider les résultats du modèle, et d'autre part, d'assurer la concordance entre les données produites par le modèle avec les données déjà existantes au sein du logiciel.

La validation des prédictions du modèle peut être effectuée au sein de la plateforme Label Studio. Les archives britanniques proposent que le jeu de données test utilisé précédemment afin de corriger les prédictions, soit distinct d'un second jeu de données test, dédié à l'évaluation des performances du modèle, à différents niveaux de supervision humaine⁷². Sur ce second jeu de données, sont notamment intégrées des métadonnées de supervision humaine. En effet, Kasturi explique l'introduction des notations "HIL-10 %, HIL-15 % et HIL-20 %, qui signifient respectivement que les utilisateurs ont corrigé 10 %, 15 % et 20 % des boîtes englobantes prédites peu performantes dans l'ensemble de données de test."⁷³. (tra-

⁶⁸ *Ibid.*

⁶⁹ S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

⁷⁰ *Ibid.*

⁷¹ S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁷² *Ibid.*

⁷³ *Ibid.*

duction de : HIL-10%, HIL-15%, and HIL-20%, which signify that users have corrected 10%, 15%, and 20% of poorly performing predicted bounding boxes in the test dataset, respectively). Les données corrigées manuellement remplacent ensuite certaines images au hasard dans le premier jeu de données d'apprentissage, constituant un nouveau jeu de données d'entraînement sur lequel le modèle s'affine⁷⁴. Le modèle ainsi affiné est finalement exécuté sur le second jeu de données, corrigé selon différents niveaux d'intervention humaine⁷⁵. Pour chaque niveau de supervision, sont analysés les "scores moyens d'Intersection over Union (mIOU) et de précision moyenne (mAP), ainsi que de la précision et du rappel"⁷⁶. Les résultats obtenus montrent que les performances du modèle s'améliorent considérablement à mesure que le pourcentage d'images corrigées manuellement augmente⁷⁷. En effet, l'enrichissement du jeu de données permet au modèle d'appréhender l'analyse des images de manière plus précise. L'auteur note toutefois la nécessité de poursuivre l'évaluation du modèle sur d'autres données afin de vérifier son adaptabilité et ses performances pour la détection d'autres types d'objets⁷⁸. En effet, le modèle devrait être ré entraîné constamment, à mesure qu'il soit exécuté sur de nouvelles données. (Active learning)

De plus, le processus de validation technique implique également la validation de l'indexation des données produites au sein du logiciel, en adéquation avec les règles métier en place. Au sein de l'espace de travail S-Movies dédié au corpus étudié, l'indexation des mots-clés est contrôlée par le thésaurus "keyword". Or, le modèle YOLO est nativement pré entraîné sur un jeu de données généraliste dont les étiquettes produites ne correspondront pas directement aux autorités indexées dans la base de données. Deux cas peuvent être gérés par l'utilisateur côté technique. D'une part, les mots-clés produits par le modèle peuvent déjà être indexés sous une forme contrôlée au sein du logiciel. Dans ce cas, il revient à l'utilisateur de vérifier que les mots-clés générés par le modèle concordent avec la forme indexée contrôlée au sein du logiciel. À terme, cette tâche de validation pourra être gérée par un LLM, un grand modèle de langage, déjà employé par Skinsoft pour un outil de recherche en langage naturel par exemple. Ce grand modèle de langage pourra être capable, à partir du thésaurus indexé dans le logiciel, de valider les formes contrôlées des mots-clés générés par YOLO. Pour cela, un mapping (tableau de corespondance) pourra être fourni au LLM entre les mots-clés que le modèle peut potentiellement générer, et leur forme contrôlée dans le thésaurus. Nous avons effectivement déjà élaboré un tel tableau au cours de notre stage dans le cadre de la mise en place de l'intelligence artificielle pour d'autres tâches, notamment la mise en place

⁷⁴ *Ibid.*

⁷⁵ *Ibid.*

⁷⁶ *Ibid.*

⁷⁷ *Ibid.*

⁷⁸ *Ibid.*

d’une recherche en langage naturel. Pour cette tâche tout à fait différente que celle que nous décrivons dans ce mémoire, nous avons effectué une table de correspondance entre les champs contrôlés pouvant être requêtés dans le logiciel et leur définition en langage naturel, préparant ainsi la gestion de synonymes et de termes employés par l’utilisateur potentiellement pour requêter ces champs. Sur le même principe, nous pourrions mettre en place une table de correspondance afin d’assurer la validation des données produites et d’assurer *in fine* leur indexation au sein de l’application. Un calcul de similarité aide le LLM à repérer les termes similaires et les rapprocher de leur forme contrôlée. D’autre part, si les mots clés n’existent pas sous une forme contrôlée au sein du thésaurus et qu’aucune correspondance n’est détectée, un nouveau terme de thésaurus pourra être créé au sein du logiciel, avec l’accord de l’utilisateur.

La segmentation temporelle ne se suffit pas à elle-même, mais nécessite une description du contenu des segments, afin d’en rétablir la qualité de séquences, unité audiovisuelle à la fois syntaxique et sémiotique. L’approche retenue afin de décrire automatiquement le contenu de ces segments est celle de l’implémentation du modèle YOLOv8, dont le temps de calcul et de prédiction est réduit par son application aux images-clés produites par la segmentation. L’efficacité du processus repose sur la supervision et la validation humaine, côté technique, des prédictions produites par le modèle, en accord avec les règles métier du logiciel. Toutefois, l’indexation définitive au sein du logiciel doit être validée par l’utilisateur métier via une interface dédiée, et au sein du modèle de données FRBR.

3. Comment indexer les données automatiquement produites ? : interface d’indexation

L’objet de notre étude est le reversement des données produites par l’indexation automatique au sein du modèle FRBR, adapté aux archives audiovisuelles. Si les outils d’extraction automatique tels que YOLOv8, nécessitent un réentraînement spécifique au corpus étudié, une seconde difficulté s’impose, celle de l’alignement de ces données avec un modèle de données personnalisé. Le modèle de données FRBR est, en effet, configuré selon les besoins métier de chaque institution et conditionne l’organisation des données pour l’utilisateur au sein de l’interface. Dès lors, comment reverser des données produites automatiquement, au sein d’un modèle de données configurable ? Ce reversement concrétise en effet l’indexation automatique, puisque les données deviennent visibles et requêtables par les utilisateurs, au sein de l’interface du logiciel.

a. Reversement des données au sein du FRBR

Le processus automatisé proposé repose sur l'exécution de deux phases : d'une part la segmentation temporelle d'un flux vidéo (gérant des time codes et des images-clé), et d'autre part la détection et la classification d'objets (générant des mots-clés). L'enjeu est de prévoir la structuration de ces différents types de données, chiffrées et textuelles, au sein du modèle FRBR existant.

Les outils automatiques utilisés lors du processus ont extrait des données depuis un média, associé au niveau de l'item numérique au sein du modèle de données préexistant. Or, le niveau item contient des éléments de description matérielle techniques, alors que les mots-clés et repères temporels relèvent d'une description intellectuelle et syntaxique. Dès lors, la création d'une entité intellectuelle dédiée à la séquence s'impose. Afin d'illustrer l'intégration d'une entité de description intermédiaire, entre l'oeuvre et l'item numérique, prenons l'exemple de la plateforme Okapi (Open and Knowledge-based Annotation and Publishing Interface), développée par le département Recherche et Innovation de l'INA⁷⁹. Afin de favoriser la description collaborative de contenus multimédias, la plateforme offre la possibilité aux utilisateurs de concevoir des modèles de description personnalisés⁸⁰. La plateforme permet notamment de séparer l'extrait audiovisuel du média, dont il constitue un niveau descriptif propre. Une strate supplémentaire de description est ainsi dédiée à la description intellectuelle du média. Le modèle FRBR tel que nous l'avons décrit ne propose, a priori, pas d'entité descriptive dédiée à la séquence. L'entité "d'agrégats", proposée par le manuel de la FIAF pourrait y correspondre. Toutefois, ceux-ci "sont conçus et créés dès le début pour rassembler plusieurs composantes individuelles formant un tout."⁸¹. Or, au sein du corpus étudié, les rushes ne font pas partie d'un montage. Toute segmentation est une interprétation a posteriori de la construction de l'archive, et donc un remontage. L'entité de "fragment d'expression" proposé par l'IFLA au sein du modèle FRBR bibliographique semble plus adéquate⁸². L'International Federation of Library Associations and Institutions (IFLA) définit le fragment comme "des parties d'expressions qui ne constituent pas elles-mêmes des expressions autonomes.[...] Un « Fragment d'expression » n'est identifié qu'en fonction de son occurrence au sein d'un tout connu ou supposé."⁸³. Cette entité semble correspondre à la notion de séquences telle que

⁷⁹Steffen Lalande, Abdelkrim Beloued et Odile Farge, « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco-MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.

⁸⁰*Ibid.*

⁸¹FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

⁸²iflstandards.info, *Frbrroo*, mars 2026, URL : <https://www.iflstandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).

⁸³*Ibid.*

nous l'avons décrite. Elle serait rattachée à l'Oeuvre, conformément à l'adaptation du FRBR par les recommandations de la FIAF¹, et permettrait le reversement spécifique des times-codes et mots-clés. La figure 4 ci-dessous illustre l'intégration de l'entité du fragment d'oeuvre au modèle de données existant.




FIG. 4 : Intégration du Fragment au modèle de données

Au sein de la plateforme Okapi, la création d'une entité intermédiaire de description, permet aux données descriptives produites à partir du média, d'être reversées au sein d'un niveau parent essentiellement descriptif, celui de l'extrait. Au sein du modèle de données existant, adapté au corpus étudié, les time codes et les mots-clés sont déjà indexés manuellement en tant que données au sein de l'application. En effet, les times codes sont renseignés au niveau de l'item numérique, dans un champ notes, et l'item comporte le champ type renseigné par la valeur "fichier time codé", afin de signifier sa qualité d'extrait. De plus, les mots-clés sont renseignés au niveau de l'indexation de l'œuvre, donc du rush original. La modélisation de la segmentation au sein du modèle actuel implique un nombre conséquent de relations entre les éléments, complexifiant ainsi la navigation de l'utilisateur. En effet, une notice d'item physique renseigne tous les extraits numériques (items numériques) qui lui sont liés. L'item numérique (segment) renseigne le film physique duquel il est extrait, tandis que le niveau œuvre renseigne uniquement les extraits numériques qui lui sont associés. La création d'une nouvelle entité simplifierait la navigation au sein de l'interface et permettrait de séparer la description en différents niveaux, intellectuel et technique, conformément aux principes du FRBR. La nouvelle entité de fragments permettrait éventuellement de préciser un contexte de segmentation et des champs dédiés aux mots clés et aux time codes. Le tableau 2 ci-dessous illustre la répartition de la description entre le fragment d'Oeuvre et l'item numérique. Pour des raisons de clarté, d'autres données descriptives ont été intégrées afin

d'illustrer la répartition entre la description intellectuelle et matérielle.

Entité FRBR	Champ / Attribut	Exemples de valeurs
Fragment d'Oeuvre <i>(Description intellectuelle)</i>	Contexte	Segmentation automatique de tel item physique
	Description générale	Description du contenu sémantique de la séquence
	Processus de segmentation	Automatique (Outil utilisé et paramètres appliqués)
	Time codes	Time codes de début et de fin de la séquence
	Mots-clés	Mots-clés extraits par YOLO
	Image-clé associée	Lien direct vers le fichier de l'image-clé
	Oeuvre parente	Identifiant de l'oeuvre associée, lien direct vers la notice
	Item physique associé	Identifiant de l'item physique associé dont est tirée la séquence, lien direct vers la notice
	Item numérique associé	Identifiant de l'item numérique associé, lien direct vers la notice
Item Numérique <i>(Description technique et matérielle)</i>	Fragment associé	Identifiant du fragment associé, lien direct vers la notice
	Données techniques	Résolution de l'image, taille, format
	Données de conservation	Emplacement, contenant
	Média associé	fichier média de la séquence

TAB. 2 : Attributs et exemples de valeurs associées aux entités Fragment d'Expression et Item Numérique.

Les métadonnées automatiquement produites seraient intégrées au niveau du fragment, tandis que l'item numérique contiendrait le média et les données techniques. Une difficulté subsiste toutefois. En effet, les processus s'exécutent au niveau du fichier numérique et de son média, tandis que les métadonnées produites doivent pouvoir enrichir un niveau descriptif supérieur, celui du fragment. Deux configurations peuvent être envisagées afin d'opérer ce reversement automatiquement. D'une part, l'application gère actuellement l'héritage des données d'un niveau supérieur à un niveau inférieur via la configuration de méta-masques, qui ciblent les niveaux inférieurs au sein desquels reverser les données. Néanmoins, le processus automatisé décrit impliquerait la configuration de masques ascendants, permettant de reverser des métadonnées générées au niveau de l'item, vers l'entité de fragment. Cette configuration complexifie toutefois la compréhension du modèle de données. D'autre part, pourrait être en-

visagé la mise en place d'un tableau de correspondance ou d'un script permettant d'associer les sorties de données du processus aux entités dans lesquelles elles doivent être injectées. Une fois la modélisation du transfert établie entre les métadonnées automatiquement produites, et le modèle de données existant, le reversement définitif est toutefois laissé à l'utilisateur métier, au sein de l'interface du logiciel.

b. Interface de validation pour l'utilisateur

Si la redéfinition du modèle FRBR s'effectue en *backend* de l'application, par les équipes techniques et les équipes métiers de Skinsoft afin de préparer l'implémentation de processus automatiques, les étapes de ces processus doivent toutefois être restituées au sein de l'interface auprès de l'utilisateur métier. Afin de donner à l'utilisateur le rôle de validation finale sur les données produites, l'espace de travail S-Movies doit permettre de visualiser les résultats afin de les valider.

En effet, dans le cadre de l'implémentation de fonctionnalités automatiques, fondées sur l'intelligence artificielle, la Commission Nationale de l'Informatique et des Libertés (CNIL) recommande que les utilisateurs soient familiarisés au fonctionnement et aux limites de ces outils, par exemple "la manière dont sont produites les sorties, les éventuels transferts de données, ainsi que les usages autorisés et les usages interdits."⁸⁴. Ces informations pourraient notamment guider l'utilisateur pour la validation des données produites par les modèles. Si l'exposition de ces étapes peut être effectuée au sein de modes d'emploi dédiés, comme Skinsoft le prévoit déjà, les informations relatives aux fonctionnalités automatiques devront toutefois être directement intégrées à l'interface pour un souci de transparence. Ainsi, la CNIL recommande que "l'intégration de briques d'IA générative dans un système d'information (SI) devrait être pensée avec des éléments de design informant clairement les utilisateurs de l'origine de la proposition [...]"⁸⁵. De plus, en cas de non-validation des données produites par l'utilisateur, il pourrait être pertinent de proposer "un point de contact pour remonter des problèmes ou des difficultés d'ordre éthique"⁸⁶. L'interface devra ainsi prévoir un formulaire décrivant la raison du refus des données, envoyé à l'équipe technique afin que l'algorithme puisse être amélioré, voire affiné. Au cours de notre stage, un système similaire a été proposé afin de prévoir la gestion des erreurs d'un outil de recherche en langage naturel. Un formulaire est prévu pour l'utilisateur en cas de résultats non pertinents pour que le processus soit amélioré. (cf ANNEXE) ? Si notre étude ne relève pas de l'IA générative, il est toutefois

⁸⁴Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).

⁸⁵*Ibid.*

⁸⁶*Ibid.*

pertinent d’offrir à l’utilisateur un niveau de transparence maximal au sein de l’interface, via la visualisation des données produites et leur validation finale. À l’image des deux phases de traitement automatiques développées dans les sections précédentes (segmentation et classification), la validation côté interface pourra prendre la forme de deux phases de décision. Il pourra d’abord être demandé à l’utilisateur d’actionner ou non le processus de segmentation puis de le valider ou de l’invalider. Une fois le processus de segmentation finalisé, l’utilisateur pourra décider de déclencher le processus de détection d’objets sur les segments produits, puis de finalement les modifier ou de les valider. Afin de concrétiser le processus de validation côté interface, nous nous appuyons sur l’exemple de la plateforme Amalia.js, développée par l’INA en 2015, conçue pour visualiser les résultats d’algorithmes d’analyse audiovisuelle⁸⁷. Le besoin à l’origine d’Amalia.js est donc de permettre de visualiser les résultats divers issus de pipelines d’automatisation⁸⁸. Cette interface permettrait d’une part de visualiser les résultats et d’autre part, de vérifier la conformité des données produites en lien avec les standards métiers en vigueur au sein du logiciel⁸⁹. L’interface permet également d’annoter directement le flux vidéo afin de corriger les données produites⁹⁰. La correction effectuée par l’utilisateur permet de constituer des données d’entraînement supplémentaires afin d’améliorer les algorithmes d’indexation automatique⁹¹. Amalia.js intègre notamment un *plugin* de *timeline* pour l’affichage des segments temporels et des images-clés associées, ainsi qu’un *plugin* de superposition (*overlay*) qui permettrait l’affichage de l’encadrement des objets détectés⁹². Plutôt que de développer deux modules distincts, cette logique pourrait être combinée au sein de S-Movies sous la forme d’un module d’édition des données. Ce module présenterait d’abord à l’utilisateur la ligne temporelle des séquences associées aux images-clés, puis après leur validation, le module prévoirait l’ouverture d’une fenêtre d’édition latérale contenant les propositions de mots-clés et les objets détectés entourés au sein des images-clés. Ce module d’édition s’inspire du *plugin Editor* au sein d’Amalia.js dont la figure 5 ci-dessous illustre la disposition :

⁸⁷ *Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).

⁸⁸ Nicolas Hervé, Pierre Letessier, Mathieu Derval et Hakim Nabi, « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

⁸⁹ *Ibid.*

⁹⁰ *Ibid.*

⁹¹ *Ibid.*

⁹² *Amalia.js - Metadata Enriched HTML5 Video Player...*




FIG. 5 : *Plugin Editor* dans Amalia.js⁹³

En cas de modification par l'utilisateur, l'interface pourrait enregistrer les données validées, tout en les envoyant en *backend*, afin que le processus soit amélioré. Le développement de l'interface serait ainsi conforme à la mise en place d'une automatisation facilitatrice de la création de données, en incitant l'utilisateur "à vérifier les données fournies en entrée et la qualité des sorties"⁹⁴.

Concrètement, en *frontend*, dans l'interface de l'application prévue pour l'utilisateur, le processus suivant peut-être imaginé, illustré par un diagramme de décision (6) :

⁹⁴Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative...




FIG. 6 : Processus de validation de l'utilisateur métier

Ce processus permet de laisser l'utilisateur métier décider de l'indexation des données via l'actionnage ou non des fonctionnalités automatiques. L'utilisateur décide en amont du processus, et valide ensuite les données produites à es fins d'indexation.

c. Rendre les données recherchables et découvrables

Une fois les données validées et indexées au sein du modèle de données, elles modifient l'accès aux archives. L'indexation de séquences décrites par une nouvelle entité de description, permet à l'institution de non plus seulement avoir accès aux archives dans leur globalité, mais à une "indexation fine" de leur contenu⁹⁵. Ainsi, par une recherche de mots-clés, l'utilisateur peut directement accéder aux segments d'archives concernés. La modélisation descriptive prévue par le FRBR permet de conserver le contexte du fragment, associé d'une part à l'oeuvre dont il est extrait, et d'autre part au média numérique associé. Les liens entre le fragment et les entités liées sont toujours requis, empêchant ainsi un risque de désolidarisation du contexte. Les séquences créées par le processus automatique pourront ainsi être requêtées par l'utilisateur via les outils de recherche offerts par le logiciel développé par Skinsoft. En effet, le logiciel propose les modes de recherche suivants : recherche simple, recherche avancée, recherche plein texte ciblée, recherche par image. De plus, une recherche en langage naturel, basée sur le Natural Language Processing (NLP) et sur une génération augmentée de récupération (Retrieval-Augmented Generation (RAG)), imaginée au cours de notre stage, est en cours de développement au sein du logiciel. Ce mode de recherche permet à l'utilisateur de formuler des requêtes complexes en langage naturel, afin d'améliorer l'expérience de navigation au sein de l'interface. L'utilisateur, via ce mode de recherche, n'a plus besoin d'employer les mots-clés exacts pour obtenir certains résultats. Par exemple, il peut formuler la requête suivante : "toutes les archives sur des défilés militaires". Le moteur effectue ensuite le lien entre la formulation de l'utilisateur en langage naturel, et les mots-clés indexés sur les séquences. Les résultats de recherche pourront par exemple présenter les séquences contenant les mots-clés suivants : "foule", "drapeau", "armée", "police". Une fois les résultats de recherche présentés, l'utilisateur peut cliquer sur une notice et accéder directement au média lié à une séquence spécifique, au sein d'une grille de recherche. Cela permet une large découvrabilité des archives, concrétisant ainsi les besoins utilisateurs fondateurs du modèle FRBR, de "trouver, identifier, sélectionner, obtenir"⁹⁶. Les résultats de recherche pourront présenter en vignette, l'image clé associée au segment décrit, sur laquelle l'utilisateur peut cliquer. Outre la recherche textuelle, l'indexation fine des contenus audiovisuels peut déve-

⁹⁵Bruno Bachimont, *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).

⁹⁶Tillett, Barbara B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

lopper l’usage d’autres modes de recherche visuels innovants. Le moteur Snoop, développé conjointement par l’INA et l’Institut national de recherche en informatique et en automatique (Institut national de recherche en informatique et en automatique (INRIA)), permet de croiser une exploration fine des contenus audiovisuels avec une interactivité qui place l’utilisateur au centre⁹⁷. Fondé sur un bouclage de pertinence, il permet, à partir d’une requête sur une caractéristique visuelle, de proposer à l’utilisateur des résultats pertinents que celui-ci peut annoter comme résultats pertinents ou non pertinents⁹⁸. Le moteur prend ces annotations en compte afin d’affiner la pertinence des résultats de recherche. Ce moteur innovant suit la même logique que l’interface de validation pensée sur le modèle d’Amalia.js, et que le mode de recherche en NLP, qui prévoit d’être affiné en fonction des retours utilisateurs. Les retours utilisateur, intégrés à l’interface, ne servent pas seulement à valider les données mais améliorent le fonctionnement du logiciel, fond sur des processus automatisés.

Conclusion sous partie *In fine*, l’intégration de l’indexation automatique au sein d’un logiciel de gestion des collections exige une réadaptation du modèle de données via la création d’une nouvelle entité qui permet d’accueillir adéquatement les nouvelles métadonnées produites. De plus, l’implémentation du processus automatique implique la mise en place d’une interface de validation qui place l’utilisateur au centre de l’indexation définitive. Une fois indexées, la masse de données produites permet de concrétiser la finalité du FRBR, celle de la découvrabilité, via des outils de recherche innovants qui permettent d’explorer directement le contenu de l’image.

Conclusion partie II : La seconde partie de cette étude a permis de poser les fondements d’une proposition d’un processus automatisé pour la segmentation et l’indexation des archives audiovisuelles au sein d’un logiciel de gestion des collections. Afin de répondre aux contraintes de sécurité des données et de la réduction du temps de traitement, nous avons proposé un processus en deux temps : une segmentation automatique exécutée par un outil de vision par ordinateur classique, et une classification par mots-clés avec un outil fondé sur la vision par ordinateur et l’apprentissage profond. Enfin, l’adaptation du modèle de données afin d’accueillir ces nouvelles fonctionnalités automatiques a permis d’imaginer un processus de validation au sein duquel l’utilisateur est décisionnaire de l’indexation. Toutefois, l’opérationnalité d’un tel processus réside moins dans la performance des outils employés que dans l’adaptation aux contraintes de développement d’un éditeur de logiciels pour la navigation fluide de l’utilisateur et la personnalisation des interfaces.

⁹⁷ *Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).

⁹⁸ A. Joly, J-C Lombardo, J-P Moreux, Q Leroy et O Buisson, « Snoop, Un Moteur de Recherche Visuelle Interactif », *Culture et Recherche* (141)–141 (2020), p. 14-15.

Troisième partie

partie 3

Conclusion

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

Annexe A

Le titre très long de la première
annexe

Glossaire

apprentissage machine . 36, 37, 55

apprentissage profond . 37, 55

Archives audiovisuelles . 7, 55

Audiovisual Processing . 35, 55

CNN Architecture de réseau de neurones artificiels spécialement adaptée au traitement et à l'analyse d'images numériques.. 37, 38, 55

Expression . 55

FIAF Fédération Internationale des archives du film. Organisation regroupant les cinémathèques et édité le manuel de catalogage audiovisuel fondé sur le modèle FRBR.. 55

FRBR Functional Requirements for Bibliographic Records. Modèle conceptuel entité-association développé par l'IFLA.. 3–7, 55, 61

Item . 55

Manifestation . 55

Oeuvre . 55

rush Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant le matériau source d'un film.. 55

réseaux de neurones profonds . 37, 55

transformers . 37, 38, 55

vision par ordinateur . 36, 37, 55

Liste des abréviations

CIDOC-CRM object-oriented Conceptual Reference Model. 6, 55

FRAD Fonctionnalités requises des données d'autorité. 6, 55

FRBRoo long. 6, 7, 55

FRSAD Fonctionnalités requises des données d'autorité matière. 55

IFLA International Federation of Library Associations and Institutions. 3, 55

IFLA-LRM long. 6, 55

WVMI Work, Variant, Manifestation, Item.. 55

Liste des tableaux

1	Comparatif des approches de traitement audiovisuel automatique	10
2	Attributs et exemples de valeurs associées aux entités Fragment d’Expression et Item Numérique.	27

Table des figures

1	Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect	13
2	Mise en application de Pyscenedetect	16
3	Processus de détection d'objets de YOLO	19
4	Intégration du Fragment au modèle de données	26
5	<i>Plugin Editor</i> dans Amalia.js ¹	30
6	Processus de validation de l'utilisateur métier	31

¹*Amalia.Js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-editor-options.html> (visité le 30/08/2026).

Table des matières

Résumé	i
Remerciements	iii
Introduction	xix
I Indexer les archives audiovisuelles	1
II Implémenter l’indexation automatique des archives audiovisuelles au sein d’une remodelisation du FRBR	3
1. Traitement audiovisuel	5
a. Machine learning et deep learning	5
b. Outils et modèles disponibles	10
c. Mise en application	14
2. Description et indexation automatique	17
a. Outils utilisés	17
b. Entraînement	20
c. Processus de validation technique	22
3. Comment indexer les données automatiquement produites ? : interface d’indexation	24
a. Reversement des données au sein du FRBR	25
b. Interface de validation pour l’utilisateur	28
c. Rendre les données recherchables et découvrables	32
III partie 3	35
Conclusion	37

A Titre court	41
Glossaire	45
Liste des abréviations	47