

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- Aide et FAQ Médiascope / INA*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).
- AKATA (Zeynep), BALLIET (Dan), DE RIJKE (Maarten), DIGNUM (Frank), DIGNUM (Virginia), EIBEN (Guszt), FOKKENS (Antske), GROSSI (Davide), HINDRIKS (Koen), HOOS (Holger), *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53-8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587.
- Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- Apprentissage profond (deep learning)*, URL : <https://www.cnil.fr/fr/definition/apprentissage-profond-deep-learning> (visité le 18/07/2026).
- AQUINO (Alexandra Jonker Judith), *Pourquoi la qualité des données est essentielle au succès de l'IA / IBM*, janv. 2026, URL : <https://www.ibm.com/fr-fr/think/topics/ai-data-quality> (visité le 14/08/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4-2 (juill. 2019), DOI : 10.22148/16.043.

- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).
- *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BARREAUX (Sabine), DAILLE (Béatrice) et JACQUEY (Évelyne), « Indexation automatique en SHS : bilan d’une expérimentation », *I2D - Information, données & documents*, 54–1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.
- BASSAÏSTEGUY (Sidonie), *Le Médium, c’est La Mémoire : Archivages Du Document à l’Institut National de l’audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).
- BENJAMIN (Walter), *L’oeuvre d’art à l’époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu’est-ce qu’un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l’IA 2025 », dans *Conférence Nationale Sur Les Applications de l’Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC ’19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/ unauthorizedDownload/10.1515/>

- 9783598441028 . 2 . 131 ?action=Downloading+PDF&countDenial=true&download=true&lang=en (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CHAMBONNET (Sébastien), « Définir une architecture de l'information pour la sauvegarde du patrimoine scientifique et technique contemporain (Patstec), à l'heure du web de données » (, 2015).
- COCO Detection Dataset*, nov. 2023, URL : <https://docs.ultralytics.com/datasets/detect/coco> (visité le 26/07/2026).
- COLAVIZZA (Giovanni), BLANKE (Tobias), JEURGENS (Charles) et NOORDEGRAAF (Julia), « Archives and AI : An Overview of Current Debates and Future Perspectives », *J. Comput. Cult. Herit.* 15-1 (déc. 2021), 4 :1-4 :15, DOI : 10.1145/3479010.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What's the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

- DIALOGUE (IFLA Working Group on FRBR/CRM), « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).
- Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- DU (Lin), LE (Brandon) et HONIG (Edouardo), « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.
- Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- FICK (Hanna), FREDRIKSSON (Anneli), LINDBLOM (Helena), FREDRIKSSON (Anneli) et LINDBLOM (Helena), « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.
- France 2030 : un plan d'investissement pour la France* / economie.gouv.fr, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GILL (Sandrine), « Les archives audiovisuelles au tamis des archivistes », dans *Les nouveaux paradigmes de l'archive*, dir. Claire Scopsi, Clothilde Roullier, Martine Sin Blima-Barru et Édouard Vasseur, Pierrefitte-sur-Seine, 2024 (Actes), DOI : 10.4000/books.pan.7249.
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].

- HERVÉ (Nicolas), LETESSIER (Pierre), DERVAL (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- Home - PySceneDetect, URL : <https://www.scsenetect.com/> (visité le 25/07/2026).
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- IFLASTANDARDS.INFO, *Frbroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- *Frbroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- ISAAC (Antoine), BACHIMONT (Bruno) et LAUBLET (Philippe), « Indexation de documents AV : ontologies, patrons de conception et d'utilisation » (, 2005).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.
- L'intelligence artificielle au service de la création de métadonnées, URL : <https://www.archimag.com/demat-cloud/2022/04/15/intelligence-artificielle-creation-metadonnees> (visité le 03/08/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).

La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

LALANDE (Steffen), BELOUED (Abdelkrim) et FARGE (Odile), « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.

LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).

Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).

Les secrets du traitement du langage naturel décryptés, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).

LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), Derval (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.

LIU (Haotian), LI (Chunyu), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].

LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().

LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), *et al.*, *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].

MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].

MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

- Modèles FRBR, FRAD et FR SAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- Module 6 - Section 7 : Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- MORSE (Christopher), « Les musées et l'expérience utilisateur (UX) », *La Lettre de l'OCIM. Musées, Patrimoine et Culture scientifiques et techniques-200* (2022/mars/01), p. 38-43, DOI : 10.4000/ocim.4777.
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- Outils d'aide à l'analyse des médias audiovisuels / INA*, URL : <https://inatheque.ina.fr/outils-d-aide-a-l-analyse-des-medias-audiovisuels> (visité le 03/08/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).

- PAILLARD (Isabelle), « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Prelinger Archive – Internet Archive Help Center*, URL : <https://help.archive.org/help/prelinger-archive/> (visité le 14/08/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Projet Dataset / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 05/08/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ? / IBM*, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ? / IBM*, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- Qu'est-ce que la modélisation de données ? / IBM*, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- Qu'est-ce que la qualité des données ? / IBM*, sept. 2022, URL : <https://www.ibm.com/fr-fr/think/topics/data-quality> (visité le 14/08/2026).
- Qu'est-Ce Que Le Machine Learning (ML)? / IBM*, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction

- and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SCHIAPPA (Madeline C.), RAWAT (Yogesh S.) et SHAH (Mubarak), « Self-Supervised Learning for Videos : A Survey », *ACM Computing Surveys*, 55–13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].
- SIGNOLES (Aurélie Bergonnier), « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ? | IBM*, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605. *Systèmes et données*, URL : <https://www.transition-bibliographique.fr/systemes-et-donnees/> (visité le 08/07/2026).

- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLET, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).
- UNIVERSALIS (Encyclopædia), *Rushes : définition et synonymes*, URL : <https://www.universalis.fr/dictionnaire/rushes/> (visité le 22/08/2026).
- Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters*, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*—hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

”Les archives audiovisuelles doivent satisfaire à des normes sévères en ce qui concerne la documentation de leurs acquisitions, des communications et d’autres transactions afin de démontrer le sérieux de leur gestion. Du fait de la complexité de leurs fonds, la précision de l’information est ici essentielle.”¹

Dans la Philosophie de l’archivistique audiovisuelle publiée par l’UNESCO, Edmonson Ray pose les fondements de la complexité de la gestion et de l’indexation des documents audiovisuels en raison de la nature de leur support, une indexation qui doit alors être soumise à une structure définie et claire pour en instaurer la compréhension. L’auteur définit les documents audiovisuels comme suit :

”Constituent des documents audiovisuels les œuvres comprenant des images et / ou des sons reproductibles réunis sur un support matériel dont : l’enregistrement, la transmission, la perception et la compréhension exigent le recours à un dispositif technique ; le contenu visuel présente une durée linéaire”²

Ainsi, contrairement aux documents imprimés dont la forme rend accessible le contenu, les supports audiovisuels (films, bandes audio, fichiers vidéo) se caractérisent par une opacité qui nous amène à les qualifier de « boîtes noires »³. Le support physique ne révèle que peu ou pas d’informations sur le contenu du document, qui n’est accessible qu’à sa lecture à l’aide d’un appareil de lecture adéquat, et cela, même une fois le document numérisé. Les institutions patrimoniales préservatrices de fonds audiovisuels sont, d’une part, spécifiquement confrontées à la complexité de ce type de contenu dont l’archiviste doit en analyser les images, le son, le montage, la linéarité, etc, et d’autre part, au volume de ces collections,

¹Une Philosophie de l’archivistique Audiovisuelle - UNESCO Bibliothèque Numérique, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).

²*Ibid.*

³Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

que le support ne permet pas d'en décrire le contenu de manière efficace. La description du contenu audiovisuel demande un temps de travail considérable, et repose inévitablement sur un matériel de lecture adéquat. L'outil utilisé afin de gérer les collections peut aider à structurer la description d'un contenu complexe. (deuxième problème : volume : solution = automatisation) En effet, au sein des institutions patrimoniales, la gestion des collections est le plus souvent permise par un outil de gestion des collections, défini comme suit par le ministère de la culture :

Progiciel spécialisé permettant de gérer des informations structurées et des multimédias sur les objets conservés au sein d'un musée, que ces derniers lui soient affectés ou déposés. C'est un système d'information partagé dont les fonctionnalités correspondent au cycle de vie de l'objet⁴.

Ainsi défini, un outil de gestion des collections permet la réalisation des diverses actions liées au cycle de vie de l'ensemble des objets de collection préservés au sein d'une institution. La réalisation de ces actions repose nécessairement sur la production "d'informations structurées" exploitables au sein du système. Cette structuration est permise par l'indexation, « l'opération qui consiste à décrire et à caractériser un document à l'aide de représentations des concepts évoqués dans ce document ».⁵ L'indexation permet précisément d'intelligibiliser un objet au sein d'un système de gestion des collections et de le rendre repérable et interrogeable auprès de l'utilisateur. Dans le cas des collections audiovisuelles, la description d'un objet existe à plusieurs niveaux : contenu intellectuel de l'oeuvre, versions de l'oeuvre, publications de l'oeuvre, localisation et état matériel de ses exemplaires... Une indexation simple ne permet pas la hiérarchisation de ces différents niveaux de description, or, ils facilitent la gestion de l'objet. La mise en place d'une modélisation des données d'indexation permet notamment de les structurer et de les hiérarchiser, afin de mieux appréhender la complexité de la description de tels contenus. Un outil de gestion des collections peut ainsi s'appuyer sur un modèle de données, tel que le FRBR (*Functional Requirements for Bibliographic Records*), modèle que nous analyserons au cours de cette étude. Issu du milieu des bibliothèques, il est également largement utilisé pour la gestion de collections audiovisuelles dont la nature se prête particulièrement à une indexation à différents niveaux. En effet, un document audiovisuel, reproductible par nature, se caractérise par son contenu intellectuel et ses multiples versions et publications, ainsi que ses exemplaires physiques. Ce modèle, implanté au sein

⁴ *Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).

⁵ *Module 6 - Section 7 : Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).

d'un outil de gestion des collections, permet alors de dissocier le contenu intellectuel d'un objet de son support matériel. Le FRBR est toutefois variable selon la collection audiovisuelle, dont la nature conditionne les niveaux d'indexation nécessaires. Une collection expérimentale non diffusée ne nécessite pas les mêmes niveaux d'indexation qu'une collection destinée au grand public. Ainsi, la structure de l'indexation des collections au sein d'un outil de gestion peut être adapté en fonction de la nature de la collection gérée au sein de chaque institution.

Par ailleurs, si la modélisation des données d'indexation permet d'adapter l'outil de gestion des collections à la complexité descriptive des collections audiovisuelles, le volume de ces collections ne permet pas à une institution de rendre compte de la globalité de ses objets au sein d'un tel outil. C'est pourquoi face à l'augmentation croissante des productions de documents et des acquisitions patrimoniales, la mise en place de solutions automatiques au sein d'outils de gestion permettrait d'accélérer la structuration de l'information afin de pouvoir y donner largement accès.⁶ Les tâches d'indexation permises par un outil de gestion des collections restent en effet répétitives et chronophage, et font désormais l'objet de tentatives d'automatisation à l'aide de l'intelligence artificielle. Dans le cas de documents textuels ou iconographiques, l'émergence des modèles fondés sur l'intelligence artificielle, offre des possibilités d'extraction automatique de métadonnées efficaces sur des documents numérisés. Toutefois, les collections audiovisuelles, résistent à la mise en place d'une extraction automatique de leur contenu, en raison de leur format "boîte noire"⁷. Ainsi, d'une part, l'indexation automatique de ces fonds supposerait que les modèles d'intelligence artificielle soient capables de lire et de comprendre le langage cinématographique, caractérisé par la mise en mouvement d'images fixes, le son, et le montage. Or, la compréhension automatique de ce langage reste inégale, en particulier lorsqu'elle est confrontée à des fonds d'archives audiovisuels patrimoniaux, anciens ou dégradés, dont la qualité sonore et visuelle est compromise. A priori, l'étude d'un tel type de documents nécessiterait des algorithmes d'intelligence artificielle lourds et coûteux, incompatibles avec les logiques institutionnelles patrimoniales. Le rôle de recherche et de proposition d'une indexation automatique pour les collections audiovisuelles reviendrait à l'éditeur de l'outil de gestion des collections, dont la logique produit encourage l'innovation constante. Toutefois cette innovation se heurte à une double difficulté que nous avons posée : la complexité pour les modèles automatiques de lire et de comprendre un contenu visuel, sonore et temporel, ainsi que l'inscription de fonctionnalités automatiques au sein d'un modèle de données (FRBR) variable, hautement dépendant du contexte institutionnel. C'est précisément cette double difficulté qui anime l'étude de ce mémoire de recherche, réalisé dans

⁶Sabine Barreaux, Béatrice Daille et Évelyne Jacquey, « Indexation automatique en SHS : bilan d'une expérimentation », *I2D - Information, données & documents*, 54-1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.

⁷B. Bachimont, *Indexation et archivage de contenus multimédias...*

le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, éditrice de solutions logicielles de gestion des collections. Effectué au sein de l'équipe métier, forte de propositions de fonctionnalités innovantes adaptées aux besoins des clients institutionnels, ce stage se porte spécifiquement sur l'amélioration de l'espace de travail dédié aux archive audiovisuelles (S-movies), fondé sur le FRBR, à travers le projet d'automatiser certains pans de l'indexation à l'aide de l'intelligence artificielle. Les réflexions et observations d'un point de vue métier qui ont traversé ce stage constituent le point de départ de ce mémoire, dont l'étude examine les conditions de faisabilité et les modalités d'intégration d'une indexation automatique appliquée à l'audiovisuel au sein d'un système de gestion de collections fondé sur une modélisation adaptative du FRBR.

Intégrer un état de l'art : sur l'automatisation de l'indexation des archives audiovisuelles : combinaison de plusieurs algorithmes, pas d'outils concret qui feraient l'ensemble du processus d'indexation. Ce mémoire tente d'articuler un pipeline d'indexation automatique avec un modèle FRBR adaptatif

Dans quelle mesure la variabilité du modèle de données FRBR adapté aux archives audiovisuelles conditionne-t-elle la mise en place d'une indexation automatique pour ce type d'archives ? Quels types d'algorithmes fondés sur l'intelligence artificielle peuvent être proposés au sein d'un outil de gestion des collections adaptatif à la nature des collections audiovisuelles ? Dans une première partie, nous analyserons les fondements du modèle FRBR et les modalités de son adaptation aux archives audiovisuelles, afin d'examiner les questions documentaires posées par le projet de la mise en place d'une indexation automatique de tels documents. Dans une seconde partie nous étudierons la possibilité d'une implémentation concrète d'outils d'indexation automatique au sein d'une modélisation FRBR d'un outil de gestion des collections. Nous y analyserons la faisabilité technique d'une mise en place de l'indexation à partir d'un séquençage automatique de fichiers numériques audiovisuels et d'une extraction automatique de mots-clés, pour en analyser le reversement au sein des différents niveaux de description modélisés par le FRBR. Enfin, nous évaluerons dans une troisième partie les limites, biais et enjeux éthiques liés à l'inadaptation des données d'entraînement d'IA aux fonds d'archives. Nous montrerons alors que les limites du « tout-automatique » invitent à réorienter la conception des logiciels métier vers un paradigme d'indexation augmentée et d'intelligence hybride**, plaçant l'interaction homme-machine au cœur de la gouvernance de la qualité documentaire.

Première partie

Indexer les archives audiovisuelles

Deuxième partie

Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR

1. Traitement audiovisuel

Les tâches d'analyse automatique pouvant être appliquée aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent davantage vers le media vidéo, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance⁸. Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. Si la détection automatique des plans dans un flux vidéo est maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image, la détection sémantique de séquences reste inexploitée. Comme le souligne Bhargav dans quel article ? et ses coauteurs, "pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques."⁹. (traduction : reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material)

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle et d'indexation automatisée. Au courant de notre proposition, la segmentation est moins considérée comme un prérequis technique que comme une fonctionnalité documentaire à part entière, directement articulée à l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées, à notre connaissance, au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

a. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont globalement désignées sous le terme de Audiovisual Processing (AVP)¹⁰.

⁸Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁹Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.

¹⁰Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Appliquées à un grand nombre de données, ces technologies permettent de passer du "close" au "distant viewing", c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble.¹¹ Les tâches de traitement automatique permettraient en effet de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données afin d'en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

De nombreux projets sont dédiés à l'analyse automatique de corpus audiovisuels, toutefois, aucun projet n'est concrètement dédié à la segmentation temporelle en différentes séquences dans une optique d'indexation de leur contenu. L'Institut National Audiovisuel, notamment, est pionnier dans la proposition de projets d'analyse automatique appliquée à l'audiovisuel. L'INA a par exemple mis en place un outil de segmentation, InaSpeechSegmenter, mais dédié à la segmentation du discours entre hommes et femmes à visée statistique (<https://data.ina.fr/traitements-ia>). Cet algorithme de segmentation, dédié au son, ne peut être pris comme exemple d'application pour notre étude, centrée sur l'analyse du sens de l'image en mouvement.

Par ailleurs, le projet MeMad, réunit un ensemble d'outils dédiés à l'analyse automatique de l'audiovisuel développés par l'Université d'Aalto, EURECOM, l'INA et l'Université d'Helsinki. Parmi les outils développés, nous pouvons citer par exemple un outil de traduction du discours (Speech translation), l'outil inaFaceGender, un outil de reconnaissance faciale (Face recognition), un outil permettant d'identifier la langue parlée (Spoken language identification). Ces projets restent centrés sur l'analyse du son et du texte inclut dans l'image et ne peuvent donc pas être pris en compte dans notre analyse (<https://github.com/MeMAD-project/mmca>).

<https://www.ai4media.eu/>

Groupe de recherche et de réflexion et de développement d'outils pour l'analyse des médias par l'IA : pas de modules dédiés à la segmentation par séquence. Modules développés : reconnaissance d'objets, génération de résumés, segmentation sémantique. Mais modules bcp basés sur les mécanismes d'auto-attention pour l'analyse vidéo. Documentation des projets non accessible. Un outil intéressant de détection de changement de plans mais documentation non accessible :

L'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de *computer vision*, ou de Vision par ordinateur. Le terme définit un sous-domaine d'application de l'intelligence artificielle qui permet d'entraîner un système d'intelligence artificielle à l'analyse des images fixes ou en mouvement¹² La Vision par ordinateur s'appuie largement sur des modèles de *machine learning*, ou apprentis-

¹¹ *Ibid.*

¹² Rina Diane Caballar Stryker Cole, *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

sage machine, qui désigne une branche de l'intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent.¹³ L'apprentissage machine permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données.¹⁴ La Vision par ordinateur s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques.¹⁵ Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d'apprentissage machine.¹⁶ De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut être mis en place sur l'ensemble des données, seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds.¹⁷ La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l'apprentissage machine. L'apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'exécuter des tâches automatisées, réduisant le besoin d'intervention humaine, et améliorant ainsi le rapport coût-efficacité.¹⁸ Il suffirait de

¹³Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹⁴*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹⁵Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹⁶*Ibid.*

¹⁷Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

¹⁸N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

fournir au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données¹⁹. Par rapport aux techniques traditionnelles de Vision par ordinateur, l'apprentissage profond permet d'obtenir une plus grande précision dans les tâches d'analyse audiovisuelle telles que la classification d'images, la segmentation, la détection d'objets.²⁰

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la Vision par ordinateur pour la classification d'images et la reconnaissance d'objets, est celui des réseaux de neurones convolutifs (CNN) (CNN). Appliqués à des corpus d'images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d'en extraire les couleurs et les contours.²¹ Les tâches que permettent les CNN sont plutôt bien adaptées à l'image fixe, puisqu'ils extraient des éléments fixes de l'image.

Néanmoins, d'autres modèles issus de l'apprentissage profond tels que les transformers s'avèrent davantage efficace sur des tâches dédiées à l'image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent sur un mécanisme d'auto-attention qui leur permet de détecter les relations et dépendances entre les données.²² Tandis que les CNN analysent les données de manière locale dans l'image, sans prendre en compte les interdépendances qui les régissent temporellement, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d'entre elles.²³ Les CNN ne permettent pas, par exemple, de discerner les "dépendances à longue portée" telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins.²⁴ Ainsi, ils seraient davantage adaptés à l'analyse d'images en mouvement puisqu'ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d'une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l'intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d'interpréter les analyses qui sont produites²⁵. En effet, une fois entraînés, il est difficile d'en modifier les paramètres puisqu'ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi

¹⁹ *Ibid.*

²⁰ *Ibid.*

²¹ Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

²² Cole Stryker Bergmann Dave, *Qu'est-ce qu'un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

²³ *Ibid.*

²⁴ *Ibid.*

²⁵ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

difficile à comprendre et à exposer.²⁶ Deuxièmement, les algorithmes de type transformers sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe.²⁷ Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d'un large jeu de données d'entraînement afin d'éviter un surapprentissage impliquant des biais multiples²⁸. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu'il s'agirait de réadapter à un contexte patrimonial²⁹. Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l'analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient Vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d'analyse automatique d'un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 1 ci-dessous permet de comparer les compétences des types de modèles cités pour l'analyse d'un flux vidéo.

Comme l'illustre le Tableau 1, si les architectures fondées sur les transformers offrent des compétences puissantes, notamment pour l'automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d'entraînement conséquents. À l'inverse, la Vision par ordinateur classique offre une stabilité d'analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d'en extraire le sens. Ce constat justifie l'orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la Vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

b. Outils et modèles disponibles

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués de documents audiovisuels, leur architecture nous donne des pistes d'expérimentations afin de pouvoir implémenter un

²⁶N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

²⁷Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

²⁸Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

²⁹*Ibid.*

Type d'approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan (<i>shot boundary detection</i>) - Calcul d'histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d'objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d'images fixes extraites du flux vidéo - Détection d'objets ou caractéristiques dans l'image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 1 : Comparatif des approches de traitement audiovisuel automatique

tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la Vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéos en différentes séquences. L'optique de cette étude est de fournir une proposition d'implémentation de fonctionnalités automatiques au sein d'un outil de gestion des collections d'un point de vue métier, au regard des besoins utilisateurs. Par conséquent, notre étude analysera l'architecture des algorithmes sélectionnés sans en détailler les mécanismes techniques.

Tout d'abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des transformers notamment, une des solutions envisagée consisterait à transformer un flux d'images en mouvement en la série d'images fixes qui le composent. Ce processus écarterait notamment le besoin d'analyser les relations entre les images par un mécanisme d'auto-attention prévu par les transformers. En effet, le médium cinématographique se caractérise par l'enchaînement d'une succession d'images fixes produisant ainsi l'illusion du mouvement. La transformation de ce flux à l'état d'images fixes par un outil technique permettrait de pouvoir gérer l'analyse sémantique de ces images par des processus légers prévus par la Vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d'analyse que ceux prévus pour l'image fixe, fondés sur la Vision

par ordinateur classique.

Cette segmentation d'un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d'une analyse sémantique, regroupant ces plans fixes en des séquences sémantiques. Dans un article sur la mise en place d'un processus de segmentation temporelle, Xin prône notamment le découpage syntaxique tel que nous l'avons défini comme étape préliminaire à l'analyse sémantique des images par des modèles d'intelligence artificielle³⁰. La segmentation syntaxique d'un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

Ainsi, la segmentation automatique d'un document audiovisuel en séquences serait fondée sur l'analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes³¹. Ces plans sont en réalité retenus par l'algorithme comme des images-clés contenues au sein de chaque séquences, calculées comme l'image la plus représentative de la présence des éléments dans un flux donné³². Ce principe, qualifié de sélection de données, permet d'alléger nettement la puissance de calcul et la structure des algorithmes³³. Ces images-clés seraient ensuite analysées par un algorithme fondé sur des CNN, afin d'y ajouter une analyse sémantique et de les regrouper en séquences.

Ce processus est notamment appliqué par la bibliothèque python Pyscenedetect qui permet la segmentation d'un flux vidéo à l'aide de différents paramètres définis en amont³⁴. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l'analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquences audiovisuelle, Pyscenedetect permet d'en extraire les image clés, c'est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de Vision par ordinateur classique, qui concrétise la mise en oeuvre de la comparaison syntaxique d'images fixes. L'outil s'appuie sur des détecteurs mathématiques afin d'analyser les différences structurelles entre les images-clés tirées d'une vidéo³⁵. Il s'agit ainsi d'un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d'entraînement particulier, comme c'est le cas des outils de Vision par ordinateur fondés sur l'apprentissage profond.

³⁰Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

³¹*Ibid.*

³²*Ibid.*

³³*Ibid.*

³⁴*Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³⁵*Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

Pyscenedetect permet d'isoler des images-clés de l'image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l'outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l'image, une détection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d'un plan avec les plans adjacents (méthode *detect-adaptative*)³⁶. En théorie, Pyscenedetect isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d'images, et non des séquences, unités de sens narratives. Néanmoins, Pyscenedetect permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l'élévation de la valeur du seuil de détection ou la fixation d'une durée minimale de séquences (*min-scene-len*), l'outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu'en cas de détection de changements visuels majeurs tels que l'éclairage, le décor, la composition, etc³⁷. Par ce biais, la segmentation syntaxique proposée par Pyscenedetect pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l'outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquences retenue.

Pour chaque changement détecté, une images-clés est ainsi automatiquement enregistrée, associée au fichier vidéo d'origine. Nous proposerons la réutilisation de cette images-clés au sein du processus suivant, dédié à l'analyse sémantique des séquences préalablement détectées, afin de ne pas surcharger les algorithmes. Ce système images-clés permettrait ainsi d'alléger le processus d'analyse sémantique, puisque les algorithmes reçoivent des images fixes au lieu de fichiers vidéos plus ou moins lourds.

Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus³⁸. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même après numérisation ou restauration³⁹. En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus⁴⁰. De plus, Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé⁴¹. Toutefois, un des avantages majeurs de l'outil Pyscenedetect est sa disponibilité et la possibilité de le

³⁶ *Ibid.*

³⁷ *Ibid.*

³⁸ S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

³⁹ *Ibid.*

⁴⁰ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴¹ S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...




FIG. 1 : Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect

mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de Vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

Après pyscenedetect : apposer une analyse sur les séquences. Pas adapté pour des archives plus complexes. Sur notre corpus : ancien donc ruptures moins visibles avec la dégradation. Pourrait convenir, mais pour d'autres corpus, appliquer un pipeline basé sur des mécanismes plus lourds d'auto-attention.

Quand déclencher le processus??? réalité métier : application de l'IA : à la demande du client ? Sur certaines archives ? À l'ingest d'un fichier numérique ? Sur tous les fichiers numériques ?

c. Mise en application

Au sein du chapitre suivant, nous mettrons à l'épreuve l'adaptabilité de l'outil que nous avons décrit pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, construit par des plans fixes, en noir et blanc et muets. Nous tenterons d'appliquer le processus de segmentation proposée par Pyscenedetect sur un tel corpus, afin d'en comprendre les données qui pourraient être générées. Le corpus, utilisé ici comme cas d'étude, se caractérise notamment par son ancienneté, et donc par la dégradation de la pellicule sur laquelle l'image s'inscrit. L'outil pourrait ainsi rencontrer des difficultés lors

de l'identification des coupures et des changements de plans, brouillés par la dégradation de l'image. Toutefois, la structure du contenu de ces archives facilite la tâche de l'outil, composé d'une succession de plans fixes, dont les coupures sont suffisamment marquées, en fait un corpus relativement bien adapté à ce type de tâche automatique, qui pourrait identifier les coupes plus facilement.

Par ailleurs, Pyscenedetect, nous l'avons vu, est un outil dédié à la détection de coupures et à la segmentation d'un flux vidéo en différents plans. Or, dans cette étude, nous cherchons à montrer comment segmenter un flux audiovisuel en différentes séquences, unités sémantiques autonomes. Dès lors, comment paramétrer un tel outil pour la détection d'éléments sémantiques plus larges tels que les séquences ?

Une solution envisagée serait d'augmenter la valeur du seuil de coupures (treshold), pour que l'outil ne détecte plus les micro-coupures entre les images mais des coupes plus larges, à l'échelle de séquences⁴². L'outil enregistrerait alors un changement de séquence seulement lors d'une rupture significative de l'espace-temps à l'image. Ce paramétrage reste toutefois limité puisque plusieurs plans adjacents peuvent être radicalement différents d'un point de vue syntaxiques, tout en appartenant bien à la même séquence. Par exemple, une même séquence peut contenir un gros plan et un plan d'ensemble, dont la composition visuelle est bien différente. Dans le cas du corpus d'archives audiovisuelles décrit, les plans restent larges et fixes, montrant l'ensemble du décor dans lequel ils s'inscrivent. Ainsi, le paramétrage du seuil pourrait être adéquatement réglé pour la détection de changements de décor, sur ce corpus donné, afin de segmenter le flux vidéo en différentes séquences.

Par ailleurs, il est possible de régler l'outil sur une durée minimale de détection de coupures à l'aide du paramètre "min-scene-len", pour que le processus n'effectue de coupures qu'après un laps de temps défini⁴³. La définition de ce paramètre nécessite une analyse statistique du corpus segmenté afin d'en définir la durée moyenne d'une séquence. Au sein du logiciel de gestion des collections prévu par Skinsoft, l'institution qui gère ce corpus d'archives documente déjà les séquences contenues par les différentes œuvres au sein des notices de films physiques, sous la forme de repères temporels. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de time codes afin de déterminer la durée moyenne d'une séquence au sein du corpus. Analyse statistique : les séquences sont généralement d'une minute

TCin : 10 :03 :59 :18

TCout : 10 :04 :45 :07

TCin : 00 :02 :46 :00

⁴² *Command-Line - PySceneDetect...*

⁴³ *Ibid.*

TCout : 00 :06 :12 :00

TCin : 01 :28 :50 :07

TCout : 01 :31 :28 :20

TCin : 01 :00 :03 :12

TCout : 01 :01 :32 :12

TCin : 13 :59 :59 :18

TCout : 14 :01 :48 :21

Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d’images plus importante, permettant à l’outil de comparer le contenu visuel d’un plan par rapport à une grande variété de plans qui l’entourent⁴⁴. Ce paramètre permettrait encore de régler l’outil sur la détection de changements majeurs dans l’image, dans l’optique d’en extraire uniquement les séquences.

Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données en sortie. Est produit d’une part un fichier json ou csv contenant les time codes de début et de fin correspondant aux séquences identifiées au sein de chaque fichier vidéo ingéré. Chaque séquence est alors associée à un identifiant unique et à des times codes de début et de fin. L’outil permet également d’extraire pour chaque séquence un fichier image, qui correspond à l’image fixe médiane, censée être la plus représentative de la séquence, désignée par le terme d’image clé⁴⁵.

Toutefois, si ce paramétrage permettrait une plus grande flexibilité pour la segmentation d’un flux vidéo en séquences, l’outil reste limité dans l’automatisation de cette tâche. D’une part l’outil est prévu pour la détection automatique de changement de plan, et d’autre part, une séquence ne se définit pas seulement comme une caractéristique syntaxique du langage cinématographique, comme c’est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence concrétise un choix narratif, matérialisé généralement par un changement d’espace-temps. C’est pourquoi, un outil dont l’automatisation est fondée sur des seuils mathématiques reste limité pour une telle tâche. Nous proposons alors de réaliser une analyse sémantique des séquences détectées, afin de ré associer leur sens à ces coupures détectées automatiquement, tout en réutilisant les données produites : les times codes et l’image clé associés à chaque séquence.

La segmentation syntaxique effectuée par Pyscenedetect constitue un “filtre”, c’est-à-dire un premier niveau dans notre chaîne d’indexation automatique des archives audiovisuelles⁴⁶. Les données issues de ce premier niveau permettent d’amoindrir le volume de données, caractéristique des fichiers vidéo, transmis aux algorithmes d’indexation automa-

⁴⁴ *Ibid.*

⁴⁵ *Ibid.*

⁴⁶ Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*

tique. Dès lors, les images-clés produites par glspyscene peuvent être soumises à un modèle neuronal de détection d'objets tel que YOLO (You only look once), afin d'extraire le sens de ces segments et leur rendre leur valeur sémantique. La sous-section suivante détaille la manière dont ce modèle, appliqué aux glsimcgle des séquences, permet d'en extraire les caractéristiques sémantiques à des fins d'indexation.

????

Il est courant d'utiliser des modèles préentraînés sur un grand jeu de données et de le réajuster ensuite au jeu de données en question, au sein d'un contexte précis.⁴⁷ Ce modèle peut justement servir de modèle de caractéristiques à analyser sur les vidéos, un second entraînement, dans le contexte peut aider à l'affiner et à l'adapter au corpus spécifique. Le rendre d'abord familier au langage audiovisuel.

Malgré de grandes avancées dans le processing audiovisuel, avec des outils comme la computer vision appliquée à la vidéo, et la reconnaissance de discours automatique (ASR), ces outils restent largement inaccessibles et hors de portée pour les institutions patrimoniales.⁴⁸ Ils sont utilisés par des entreprises commerciales pour du montage vidéo par exemple. Le manque d'utilisation de ces outils dans le domaine des sciences humaines expliquent l'inexistence de données d'entraînement adaptées au secteur.⁴⁹ L'analyse vidéo par un processus humain prend un temps considérable, puisqu'il faut lire le fichier audiovisuel et en analyser les composants, le langage. Ainsi, l'indexation des archives audiovisuelles se cantonne souvent aux métadonnées, sans en exposer les données, le contenu.

Et donc en pratique, comment appliquer le traitement audiovisuel à des corpus d'archives audiovisuelles patrimoniales ?

transition : nécessité d'un mapping vers le FRBR : faire correspondre la sortie de ces pipelines avec un modèle de données.

2. Description et indexation automatique

Quoi décrire ?

à rajouter pour faire la transition :

La description automatique d'images peut être centrée sur de nombreux éléments au sein d'une séquences de film : dialogues, ambiance sonore, visages, objets, spatialité des éléments, actions, émotions... Toutefois, la définition d'un processus au sein d'un logiciel de

⁴⁷J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴⁸N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁴⁹*Ibid.*

gestion des collections impose un cadrage défini des fonctionnalités. Le corpus patrimonial retenu pour notre étude, constitué de rush muets des premiers temps, exclue d’emblée l’analyse automatique de caractéristiques sonores. L’analyse automatique se concentre donc exclusivement sur les caractéristiques visuelles de l’image. Deux approches coexistent alors, celle de l’identification des éléments dans l’image de manière précise, ou celle d’éventuellement générer des résumés automatiques sur ces séquences, à une échelle plus globale. Or, la seconde approche, fondée sur des grands modèles de langage, implique des architectures génératives couteuses et lourdes. Nous choisissons ainsi d’adopter la première, afin de garantir une indexation fiable et stable, plus légère, à travers la détection et l’identification d’objets sur les images-cléspréalablement extraites. Cette tâche peut être réalisée par des architectures de réseaux de neurones relativement légers, pouvant extraire des concepts directement indexables au sein du logiciel.

a. Outils utilisés

à utiliser ?

à intégrer ? :

à intégrer ? :

Si pour la tâche de segmentation automatique, nous avons écarté les architectures de modèles fondés sur des réseaux de neurones, la reconnaissance d’objets dans l’image suppose une prédiction fondée sur un apprentissage machine profond des réseaux de neurones. En effet, la plupart des outils de reconnaissance d’objets dans l’image sont fondés sur des modèles de réseaux de neurones convolutifs (CNN) dont nous avons exposé le fonctionnement dans la section précédente.

Avantage de placer un réseau de neurones qu’à cette étape-là du processus (cf article 2sds)

Par exemple, l’outil Snoop développé par l’INA est fondé sur le CNN ResNet. (c’est un moteur de recherche : pas pertinent ?)

Nous détaillerons dans cette section l’utilisation de l’architecture YOLO, une série d’algorithmes dédiés à la détection d’objets visuels dans les images et les flux vidéo, et fondé sur les réseaux neuronaux convolutifs, développé par Ultralytics en 2015. C’est l’un des outils de détection d’objets les plus documentés, y compris dans le domaine des sciences humaines et du patrimoine. Fondé sur la Vision par ordinateur et entraîné grâce à des méthodes d’apprentissage profond, YOLO est en accès libre, et permet notamment la détection d’objets et la classification d’images, permettant ainsi de poser les bases d’une indexation⁵⁰. Le modèle extrait dans un premier temps les caractéristiques visuelles de l’image qui lui est

⁵⁰Glenn Jocher, *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.

donnée, les agrège, afin de finalement proposer une détection d’objets⁵¹. Les versions récentes du modèle telles que YoLo12 ne sont désormais plus seulement basées sur des CNN mais sur des mécanismes d’auto-attention, similaires à ceux des transformers dont nous avons évoqué l’architecture⁵². Toutefois, comme nous l’avons évoqué, cette architecture demande une consommation de mémoire élevée et une puissance de calcul lourde⁵³. Ultralytics, créateur du modèle, recommande des versions moins avancées pour une mise en application rapide, telles que la version YOLOv8, uniquement fondée sur un réseau de neurones convolutif⁵⁴. YOLOv8 propose une version optimisée de cette architecture en trois temps : extraction, aggrégation, et détection⁵⁵. Le modèle se caractérise par sa capacité à analyser l’image en une seule fois, contrairement à d’autres modèles dont les résultats impliquent plusieurs analyses de certaines parties de l’image⁵⁶.

Si la détection d’objets prévue par YOLO peut être appliqué à des flux vidéo, nous souhaitons l’intégrer comme composant complémentaire au processus de segmentation précédemment décrit. De fait, il être pertinent de réutiliser l’image clé fixe, produite et sauvegardée par l’outil pycenedetect, associée à chaque séquence, afin de la faire analyser par le modèle. Ceci permettrait de réduire le temps de calcul du processus et d’améliorer l’efficacité des prédictions, puisque le modèle reçoit un minimum d’informations.

À intégrer ? “YOLO impose des contraintes spatiales strictes aux prédictions de boîtes englobantes, puisque chaque cellule de la grille ne prédit que deux boîtes et ne peut contenir qu’une seule classe. Cette contrainte spatiale limite le nombre d’objets proches que notre modèle peut prédire. Notre modèle éprouve des difficultés avec les petits objets qui apparaissent en groupes, comme les volées d’oiseaux.”⁵⁷ (“YOLO imposes strong spatial constraints on bounding box predictions since each grid cell only predicts two boxes and can only have one class. This spatial constraint limits the number of nearby objects that our model can predict. Our model struggles with small objects that appear in groups, such as flocks of birds.”⁵⁸

Ainsi, l’application du modèle YOLO s’impose comme la suite logique du pipeline de segmentation détaillé précédemment, afin d’indexer les segments produits, via l’utilisation des images-clés. Si le premier processus de segmentation produit des données temporelles

⁵¹J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁵²*YOLO12 : Détection d’objets centrée sur l’attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).

⁵³*Ibid.*

⁵⁴*Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).

⁵⁵Muhammad Yaseen, *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].

⁵⁶Joseph Redmon, Santosh Divvala, Ross Girshick et Ali Farhadi, *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].

⁵⁷*Ibid.*

⁵⁸*Ibid.*

associées à chaque séquence sous la forme de time codes, YOLO produit des données sémantiques sur ces mêmes séquences. À l'issue de l'analyse d'une images-clés, le modèle YOLO est capable de produire trois types de données : des étiquettes sur les objets identifiés, un score de confiance qui indique l'indice de certitude concernant la prédiction, des coordonnées spatiales de localisation de l'objet détecté dans l'image⁵⁹. Les étiquettes produites sur les objets identifiés, permettant de décrire les caractéristiques de l'image, pourront être indexées comme des mots-clés au sein du logiciel de gestion des collections. Ces mots-clés seront associés aux time-codes de chaque séquence détectée. Ainsi, chaque séquence contiendrait les données suivantes : des time codes qui l'identifient comme extrait, des étiquettes/mots-clés sur les objets qu'elle contient, et des données qui permettraient aux utilisateurs de vérifier la prédiction et de la valider. Le score de confiance produit par le modèle, permet en effet d'indiquer à l'utilisateur la certitude de l'étiquette associée à tel objet détecté. De même, les coordonnées spatiales de l'étiquette produite permettent à l'utilisateur de vérifier dans l'image si l'étiquette produite est associée au bon objet.

b. Entraînement

à intégrer ? :

Pour les deux sous sections suivantes, nous prendront comme exemple d'application les archives britanniques en ligne, qui proposent une chaîne de traitement pour la détection d'objet basée sur l'apprentissage profond et sur comment intégrer la supervision humaine dans la chaîne de traitement et de vérification.

Toutefois, afin d'analyser le contenu des images, les CNN subissent un apprentissage supervisé (Supervised Learning), c'est-à-dire un entraînement au cours duquel les algorithmes apprennent la détection d'objets à partir de données labellisées par l'humain⁶⁰. L'efficacité des modèles basés sur l'apprentissage profond dépend fondamentalement de nature et de la qualité de leur données d'entraînement. YOLOv8 a fait l'objet d'un entraînement préalable en amont de sa mise à disposition, sur le jeu de données COCO, prévu notamment pour la détection d'objets, et composé de multiples objets du quotidien en tous genres⁶¹. Il est composé de 200 000 images annotées où les objets sont entourés et décrits. Il s'agit d'un jeu de données généraliste qui permet au modèle de détecter des objets communs tels qu'une voiture, un chat, un parapluie.

Or, l'ancienneté et la qualité d'image du corpus d'archives audiovisuelles étudié, en fait

⁵⁹ *Ibid.*

⁶⁰ Julianna Delua, *Supervised vs. Unsupervised Learning : What's the Difference ?* / IBM, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

⁶¹ *YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).

un corpus d'images spécifique sur lequel l'algorithme doit être entraîné. Afin d'adapter le modèle à notre corpus et ainsi d'en améliorer l'efficacité, une phase de pré traitement est nécessaire sur les données du corpus, au cours de laquelle il est des données sont sélectionnée afin d'être annotées et testées⁶². La supervision humaine est déterminante dans ce processus, particulièrement dans le cas d'analyse de corpus inédits sur lesquels l'algorithme reste à entraîner⁶³. Les british online archives implémentent par exemple l'adaptation du modèle en deux étapes (dans quel projet ?? : , dans le cadre de la mise en place d'un pipeline de détection d'objets sur un corpus d'images d'archives. Certaines archives sont sélectionnées et annotées manuellement à l'aide de la plateforme Label Studio⁶⁴. La méthode du transfert d'apprentissage (transfert learning) est ensuite appliquée, au cours de laquelle les données annotées servent d'entraînement de détection d'objets au modèle⁶⁵. Le transfert d'apprentissage permet notamment de *fine tuner* un modèle existant, c'est-à-dire de l'affiner, afin de l'adapter au corpus analysé⁶⁶. Ainsi, la même méthode pourra être appliquée au corpus étudié. Le modèle existant, entraîné en amont sur des données génériques, pourra être affiné sur un jeu de données restreint annoté, plus spécifique⁶⁷. Ces deux étapes, l'annotation des données et l'affinage du modèle, constituent des étapes de prétraitement, en amont de l'analyse des données, afin d'améliorer l'efficacité de la détection d'objets⁶⁸. Concrètement, certaines des images-clés produites par le processus de segmentation pourraient être sélectionnées afin d'être annotées. Ces annotations, dédiées à la détection d'objets, prennent la forme de détournages sur les objets ou caractéristiques que le modèle doit détecter, associées à des étiquettes⁶⁹. L'outil Label Studio permet notamment la réalisation de ces annotations sur les images, à partir desquelles le modèle est entraîné à une détection spécifique.

Cette étape de pré-traitement, avant le processus d'analyse, implique la définition des types de mots clés souhaités, pour l'indexation des séquences. En effet, les étiquettes associées aux objets au sein des images correspondent aux mots-clés qui seront prédits par le modèle

⁶²Surya Kasturi, Alex Shenfield, Chris Roast, Danny Le Page et Alice Broome, « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.

⁶³*Ibid.*

⁶⁴*Ibid.*

⁶⁵*Ibid.*

⁶⁶S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

⁶⁷*Ibid.*

⁶⁸S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁶⁹Lin Du, Brandon Le et Edouardo Honig, « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.

lors de l'analyse. Dans le cadre du corpus étudié, il est pertinent d'extraire les mots-clés déjà indexés sur les séquences au sein du logiciel. Ces mots-clés varient selon le contenu de l'image et peuvent, par exemple, être les suivants : affiche, foule, policier, gendarme, drapeau, etc. Ces mots-clés, tout comme le jeu de données COCO, sont assez génériques. De fait, le pré traitement est avant tout utile pour l'entraînement du modèle à pouvoir détecter des objets au sein d'images dont la qualité est compromise.

c. Interface de validation technique

Afin de gérer les essais-erreurs de l'affinage du modèle sur les données du corpus, il est pertinent de mettre en place une interface de validation technique et d'amélioration du modèle. Cette interface permettrait d'une part de valider les résultats du modèle, et d'autre part, d'assurer la concordance entre les données produites par le modèle avec les données déjà existantes au sein du logiciel.

En effet, suite à l'affinage du modèle, les archives britanniques en ligne préconisent des étapes supplémentaires de validation des données produites⁷⁰. Cette validation se structure en différentes étapes qui consistent notamment en l'analyse des données produites par le modèle, la modification et la correction de ces données, le potentiel réentraînement du modèle avec de nouveaux paramètres et/ou de nouvelles annotations, et enfin, l'évaluation des résultats sur les données de test⁷¹. Cette validation peut s'effectuer sur la même interface que celle proposée pour l'annotation des données, label studio, qui permet la modification et la correction des annotations. Les modifications des annotations sont ainsi réinjectées dans le modèle afin d'améliorer ses performances⁷². Est ce que c'est aussi simple ?

Décrire plus précisément comment label studio interagit avec yolo : format de fichier, seuil de confiance

Utiliser le score de confiance pour la validation : les étiquettes qui ont un score de confiance élevée sont valides, les autres sont vérifiées et re-annotées.

De plus, afin de pouvoir valider les données produites par le modèle, il faut pouvoir valider leur indexation au sein du logiciel, en adéquation avec les règles métier en place. Au sein de l'espace de travail S-Movies dédié au corpus étudié, l'indexation des mots-clés est contrôlée par le thésaurus "keyword". L'affinage et la correction des données produites par le modèle devra ainsi prendre en compte la concordance des mots-clés générés avec le thésaurus de mots clés contrôlés dans l'application. Or, le modèle Yolo est nativement pré entraîné sur un jeu de données généraliste duquel la majorité des prédictions seront puisées. Ainsi, afin

⁷⁰S. Kasturi, A. Shenfield, C. Roast, *et al.*, « Object Detection in Heritage Archives Using a Human-in-Loop Concept »...

⁷¹*Ibid.*

⁷²*Ibid.*

d'éviter la génération de mots clés trop éloignés des termes du thésaurus dans l'application, il pourrait être pertinent d'établir un mapping, c'est-à-dire une table de correspondance entre les mots clés que le modèle peut potentiellement générer, et leur forme contrôlée dans le thésaurus, pour aider la validation technique des données produites par le modèle. Nous avons effectivement déjà mis ce procédé en place au cours de notre stage dans le cadre de la mise en place de l'intelligence artificielle pour d'autres tâches, notamment la mise en place d'une recherche en langage naturel. (Mettre une note de bas de page pour expliquer). Pour cette tâche tout à fait différente que celle que nous décrivons dans ce mémoire, nous avons effectué une table de correspondance entre les champs contrôlés pouvant être requêtés dans le logiciel et leur définition en langage naturel, préparant ainsi la gestion de synonymes et de termes employés par l'utilisateur potentiellement pour requêter ces champs. Sur le même principe, nous pourrions mettre en place une table de correspondance afin d'assurer la validation des données produites et d'assurer *in fine* leur indexation au sein de l'application.

La finalité est de pouvoir permettre à l'utilisateur de pouvoir recherche ces mots clés et d'accéder aux segments concernés. Transition vers la prochaine sous partie avec ça

Nécessité de l'active learning : pour que le modèle soit développé et cohérent, il faudrait qu'il soit entraîné et réentraîné en permanence, à mesure qu'il reçoit des données client et que les données sont validées ou non

citation supplémentaire sur les détails des corrections d'entraînement :

"The evaluation employs two distinct test datasets, namely test-1 and test2. One of these datasets will be utilised for the purpose of rectifying the predictions, while the other dataset will be exclusively utilised for evaluating the model's performance across varying levels of HIL. Upon the user's modification of the bounding boxes on one of the test dataset, the corresponding corrected images will replace some random images in the initial training dataset which then becomes a new training dataset. A small learning rate of 0.00005 (in our case) is employed to retrain the model using the new training dataset. To retain previously learned information while incorporating the user-provided data, we utilize transfer-learning techniques that load the pre-trained weights of the model from HIL-0

Transition avec la partie suivante : la validation finale est laissée à l'utilisateur métier : interface de validation livrée au client, une fois ue les entraînements et affiages sont concluants.

généralement, un algorithme de machine learning comprend trois étapes : data pre processing, data modelling, process optimisation. Dans le pre processing : humain requis pour transformer des données non structurées en données structurées et annotées⁷³

⁷³ *Ibid.*

3. Comment indexer les données automatiquement produites ? : interface d'indexation

- Processus côté interface

Faire le lien avec le NLP le plus possible : le NLP pourra être étendu pour la recherche de contenus visuels

Yolo est une IA discriminative

a. Reversement au sein du FRBR

FRBRisation des données générées par IA

Rappelons-le, l'objet de notre problématique est de pouvoir reverser les données produites par l'indexation automatique au sein du modèle FRBR, adapté aux archives audiovisuelles. L'extraction automatique de données et de contenu est réalisée par des outils génériques utilisés dans tous types de domaines, aussi bien patrimoniaux que commerciaux. En effet, nous avons vu que l'algorithme YOLOv8 est entraîné sur des données visuelles généralistes, qui supposent un affinage afin d'être adaptées à des domaines spécifiques tel que celui qui fait l'objet de ce mémoire. Si les données produites sont bien spécifiques au domaine, notre pipeline se heurte à une nouvelle difficulté, celle du reversement de ces données au sein d'un modèle documentaire personnalisé et spécifique à l'indexation des archives audiovisuelles. Le modèle de données FRBR est, en effet, spécifique aux besoins métier de chaque institution et conditionne l'organisation des données pour l'utilisateur au sein de l'interface. Dès lors, comment reverser des données produites automatiquement par des outils génériques, au sein d'un modèle de données personnalisé et configuré selon les besoins d'une institution précise ? Le reversement de ces données au sein de l'interface concrétise en effet l'indexation automatique, puisqu'elles deviennent visibles par les utilisateurs, dans des champs pertinents, adaptés et requêtables.

Certains outils ont déjà été développés dans d'autres applications de gestion des collections afin d'effectuer ce reversement de manière automatique : Wedia, Keepeek, Einden, MomaSoft "classent automatiquement les images et vidéos en leur attribuant les métadonnées appropriées."⁷⁴

Une fois les processus de notre pipeline finalisés, deux types de données sont produits : les time codes, chiffrés, et les mots-clés, sémantiques.

Premièrement, les time codes produisent des séquences définies au sein des rushes documentaires que nous avons décrits. Il se pose la question suivante : ces séquences doivent-elles

⁷⁴L'intelligence artificielle au service de la création de métadonnées, URL : <https://www.archimag.com/demat-cloud/2022/04/15/intelligence-artificielle-creation-metadonnees> (visité le 03/08/2026).

faire l’objet d’entités à part entière au sein du modèle de données ? La FIAF, dans son manuel de catalogage des images animées ne prévoit pas la description de séquences, ou de segments d’œuvres. En effet, le manuel, édité en 2016, ne prend pas en compte cette possibilité rendue réalisable par les technologies de computer vision. C’est le terme d’agrégats qui semble se rapprocher le plus de séquences faisant partie d’une œuvre. Or, le manuel décrit que ces agrégats “sont conçus et créés dès le début pour rassembler plusieurs composantes individuelles formant un tout. CROCHETS Il s’agit d’un film intentionnellement structuré comme une série d’histoires différentes, parfois reliées entre elles par des décors et des personnages, et faisant partie d’un tout continu”. Ce n’est pas le cas pour le corpus décrit ici, les rushes n’ont pas été pensés en termes de montage et sont restés à l’état de rushes. Toute segmentation est donc une interprétation a posteriori de la construction de l’archive, un remontage. L’IFLA propose le terme de “fragment d’expression”, définit comme “des parties d’expressions qui ne constituent pas elles-mêmes des expressions autonomes. L’existence d’une instance « Fragment d’expression » peut être due à un accident, tel que la perte de matière au fil du temps CROCHETS, ou à un isolement délibéré, comme des extraits tirés d’un texte par le compilateur d’un recueil d’extraits. Un « Fragment d’expression » n’est identifié qu’en fonction de son occurrence au sein d’un tout connu ou supposé.”⁷⁵ Cette entité pourrait correspondre aux séquences créées par le processus de segmentation et serait rattachée à l’expression (ici comprise au sens d’Œuvre, conformément à l’adaptation du FRBR par les recommandations de la FIAF). L’implémentation du processus de segmentation supposerait donc la création d’une nouvelle entité au sein du modèle de données FRBR, au sein de laquelle seraient reversés les time codes et les mots clés.

Penchons-nous sur l’exemple de l’application dans laquelle est intégré le corpus que nous décrivons. En effet, les time codes et les mots clés existent déjà en tant que données au sein de l’application. Rappelons que le modèle FRBR y est structuré en trois niveaux principaux : œuvre, manifestation, item. Pour le corpus de rushes, seuls les niveaux œuvre et items sont décrits, puisque le corpus est composé essentiellement de rushes documentaires qui n’ont pas fait l’objet de publications spécifiques (niveau manifestation). En observant les données déjà existantes dans l’application, nous en avons conclu que pour les Rushes ayant déjà fait l’objet d’une segmentation documentaire manuelle, les time codes sont renseignés au niveau de l’item, dans un champ notes. L’item numérique comporte le champ type = “fichier time codé”. Ainsi, par exemple, une bobine au niveau item, déjà segmentée en séquences, dispose de plusieurs items liés, ses séquences, qui possèdent chacune un time code de début et de fin au sein de cette bobine. Certaines œuvres/rushes sont liées à des items-films numérique

⁷⁵[iflstandards.info, Frbroo](https://www.iflstandards.info/frbroo), mars 2026, URL : <https://www.iflstandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).

qui sont en réalité les segments, et ces items-films sont associés à des films physiques qui sont le film physique duquel ils ont été numérisés. Ainsi, l'utilisateur métier ne numérise que des segments d'un item physique. Les items numériques sont toujours des segments. Cela implique beaucoup de relations non hiérarchiques donc pas très claires. Un item de film physique renseigne tous les extraits numériques qui lui sont liés. L'item numérique (segment) renseigne le film physique duquel il est extrait, le niveau œuvre renseigne seulement les films associés numériques. Complexe. La création d'une nouvelle entité simplifierai les choses au niveau de la hiérarchie mais la complexifierai également : la nouvelle entité "fragment" devra être décrite de manière intellectuelle : pourquoi le choix de ce segment, le contexte, et devra être associé aux items numériques, fragments numérisés concrets avec les times codes. Actuellement, dans l'application, les time codes sont renseignés dans un champ note. Ils ne possèdent donc pas de champs dédiés et ne sont pas vraiment requêtables. L'idée n'est pas de chambouler l'expérience utilisateur avec l'implémentation d'un processus automatique et la modification du modèle de données. Nous pourrions par exemple simplement proposer un champ dédié aux time codes pour rendre la saisie plus facile et la recherche plus facile également. Toutefois, il est également nécessaire de se demander où reverser les mots clés produits par le second processus d'indexation. Actuellement dans l'application, les mots-clés sont renseignés au niveau de l'indexation de l'œuvre globale, donc des rushes. Si une entité fragment est créée, les mots clés spécifiques au segment et générés par le processus automatique pourront être reversés sur la notice de fragment, hérités au niveau de l'item numérique. Les mots clés généraux au niveau œuvre sont conservés au niveau œuvre. Si la nouvelle entité n'est pas créée, le nouveau champ time code pourra contenir un sous champ mots clés, afin d'indiquer que ces mots clés sont spécifiques à un segment de l'œuvre. Mais la création d'une entité à part entière serait idéale, notamment pour expliquer le contexte de création automatique de ces segments.

La création d'une nouvelle entité : faciliterait la visibilité et la recherche mais compromis avec surcharge de l'interface et habitudes utilisateur.

Informations au niveau entité fragments d'œuvres/expression :

Contexte

Choix du segment

Processus de segmentation

Mots clés : peuvent aider à expliquer le choix du segment : syntaxe + sémantique

Image clé associée

Item numérique associé

Informations au niveau de l'item numérique :

Fragment associé

Données techniques de conservation

Données héritées de l'oeuvre et du fragment

L'IFLA propose sinon le fragment d'expression :⁷⁶ avec la description suivante : Cette classe regroupe des parties d'expressions qui ne constituent pas elles-mêmes des expressions autonomes. L'existence d'une instance de F23 « Fragment d'expression » peut être due à un accident, tel que la perte de matière au fil du temps (par exemple, le seul manuscrit restant d'un texte ancien partiellement rongé par les vers), ou à un isolement délibéré, comme des extraits tirés d'un texte par le compilateur d'un recueil d'extraits. Un « F23 Fragment d'expression » n'est identifié qu'en fonction de son occurrence au sein d'un tout connu ou supposé. La taille d'une instance de « F23 Fragment d'expression » varie de plus de 99 pourcent d'une instance de « F22 Expression autonome » à de minuscules fragments (quelques mots d'un texte, une mesure d'une composition musicale, un détail d'une image fixe, un extrait de deux secondes d'un film, etc.). »

Remarque : « L'existence d'une instance de F23 Fragment d'expression peut être due à un accident, tel que la perte de matériel au fil du temps — par exemple, le seul manuscrit restant d'un texte ancien ayant été partiellement rongé par les vers —, ou à un isolement délibéré, tel que des extraits tirés d'un texte par le compilateur d'un recueil d'extraits. Un F23 Fragment d'expression n'est identifié qu'en fonction de son occurrence au sein d'un tout connu ou supposé. La taille d'un exemple de F23 « Fragment d'expression » varie de plus de 99 pourcent d'un exemple de F22 « Expression autonome » à de minuscules fragments (quelques mots d'un texte, une mesure d'une composition musicale, un détail d'une image fixe, un extrait de deux secondes d'un film, etc.). »

Dans le FRBR, la séquence n'est pas définie : comment l'intégrer ? Différentes possibilités. Le FRBRoo inclut les notions suivantes :

partie d'oeuvre ;

oeuvre complexe ;

relations entre composants ;

objets informationnels structurés

Selon le manuel de la FIAF p. 159, il peut être utilisé le titre segment dans le cas suivant : “S’emploie pour tout document identifié comme étant une ou des séquences, un ou des segments, un ou des extraits, un ou des fragments (à l’exception des « reportages d’actualités » et des « extraits pour l’analyse », voir ci-dessous).”⁷⁷

Autre possibilité : Agrégats « hybrides » et images animées à composantes multiples p 168 : “Les Œuvres à composantes multiples sont conçues et créées dès le début pour rassembler

⁷⁶ *Ibid.*

⁷⁷ FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

plusieurs composantes individuelles formant un tout, par exemple les films à sketches et les émissions TV (p. ex. *Dead of night*, *Quartet*, *Retour à la vie*, *Kaamelott*).

Elles doivent être traitées comme des Œuvres monographiques. (Voir 1. Œuvres et Variantes).

Les différentes sections constituant l'ensemble ne sont pas des Œuvres/Variantes créées indépendamment et ayant une existence propre en dehors du film. Il s'agit d'un film intentionnellement structuré comme une série d'histoires différentes, parfois reliées entre elles par des décors et des personnages, et faisant partie d'un tout continu."

"Chaque composante ne doit normalement pas être créée comme une nouvelle Œuvre, car ce n'est pas de cette façon que le contenu a été imaginé (c.-à-d. qu'il a été conçu pour être regroupé et visionné en tant qu'unité et ne peut pas être segmenté). Aucun d'entre eux n'aura alors de notice de Manifestation en tant qu'Œuvre individuelle.

Les institutions qui ont la capacité ou le désir de les dissocier afin de lier des descriptions (p. ex. des génériques) séparées à chaque composante (c.-à-d. représentant la relation parent-enfant), peuvent les enregistrer en tant qu'Œuvres analytiques"⁷⁸

À l'ingest : données interdépendantes entre la description d'un item numérique et de son média. Mentionner la relation nouvelle sur l'item numérique et son média : facilite les choses pour le reversement

Comment sont décrits les time codes dans l'application du corpus que nous décrivons ? Comment sont gérées ces données, puisque la segmentation existe déjà ? L'idée est de ne pas modifier à outrance l'expérience utilisateur avec de nouveaux outils.

Rappelons que le modèle FRBR est structuré théoriquement en trois niveaux principaux : œuvre, manifestation, item. Si nous prenons l'environnement d'application adapté au corpus que nous avons décrit jusqu'ici, seuls les niveaux œuvre et items sont décrits puisque le corpus est composé presque essentiellement de rushes documentaires qui n'ont pas fait l'objet de publications spécifiques (niveau manifestation). En observant les métadonnées déjà existantes, nous en avons conclu que pour les

Rushes qui ont déjà fait l'objet d'une segmentation documentaire manuelle, les times codes sont renseignés au niveau de l'item, dans un champ notes. Ainsi, par exemple, une bobine au niveau item, déjà segmentée en séquences, dispose de plusieurs items liés, ses séquences, qui possèdent chacune un time code de début et de fin au sein de cette bobine. Une notice de bobine item physique : (captures d'écran word)

Ainsi, les données produites par les deux processus automatiques combinés proposent des métadonnées indexables sur deux niveaux différents. Les processus IA sont appliqués sur un fichier numérique, donc au niveau d'un item numérique. Comment procéder pour que les

⁷⁸ *Ibid.*

métadonnées produites à partir du fichier numérique enrichissent le niveau œuvre, niveau de description intellectuelle qui doit contenir les mots clés ?

Pour les times codes, des champs dédiés devront être prévus sous le champ film associé.

Les fichiers numériques segmentées, donc les séquences, possèdent la catégorie “fichier time codé”

Faire un schéma de métadonnées pour pouvoir adapter les données aux normes du logiciel via des connecteurs par exemple.

L’automatisation modifie le schéma des données actuels. En effet, si les mots clés définis pour chaque segment sont reportés au niveau œuvre, il faut pouvoir créer une notice d’œuvre pour chaque segment, ou alors reporter les time codes aussi au niveau œuvre pour pouvoir indiquer que ces mots clés sont spécifiques à tel segment. Ou alors on garde le champ de films liés, on crée un champ séquences : les times codes sont renseignés et els mots clés sont saisis sous chaque séquence. Les mots clés pourront également être reportés au champ général mots clés qui décrit l’œuvre dans sa globalité. Il y aurait ainsi deux types de champs mots clés : un champ spécifique à la séquence, un champ mots clés qui décrit les mots clés généraux de l’œuvre.

Plateforme okapi, modélisation de la plateforme intéressante pour notre étude :

“Chaque modélisation de domaine vient étendre le modèle Okapi en utilisant les mécanismes d’extensions propres aux langages RDFS/OWL. Ces derniers permettent également à un modélisateur de définir sa propre « upper ontology » et de déclarer des points d’adhérence uniquement entre certaines classes de son modèle et celles d’Okapi. La Figure 1 montre la simplicité du modèle générique et illustre les possibilités de classements offertes en terme d’organisation des connaissances.”⁷⁹ (voir schéma word)

“De manière similaire, le modèle de description multimédia d’Okapi regroupe un nombre limité d’objets structurant la description : le média (image fixe, vidéos, sons), la description (ou analyse de média), la strate (ou plan/point de vue de description), l’extrait (ou segment/fragment/région) de média, le corpus d’extraits et la publication hypermédia. À l’instar du modèle de domaine, l’ensemble de ces éléments est regroupé au sein d’une ontologie de description qu’il convient d’étendre afin de construire un modèle de description multimédia propre à son domaine. Le modèle proposé s’inspire notamment des notions de descriptions, de segments et de décomposition que l’on retrouve dans des standards de description comme Mpeg7 et s’inscrit plus spécifiquement dans l’esprit des travaux de (Hunter, 2002) portant sur un portage de ce langage de XML Schema vers OWL. Par le biais des mécanismes d’extension de OWL, le modèle permet de définir de manière déclarative les strates de descriptions que

⁷⁹Steffen Lalande, Abdelkrim Beloued et Odile Farge, « La plateforme Okapi pour l’analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.

l'on souhaite utiliser pour un type de description particulier et d'associer à chaque type de segment porté par ces strates, une branche particulière du domaine.”⁸⁰

b. Interface de validation pour l'utilisateur

Deux axes : visualisation et validation (intégrer à ces deux axes la transparence sur le processus : données de gestion)

Processus d'interface avec ce nouveau schéma de données

(Proposer un diagramme de décision pour exposer le processus interface utilisateur)

Le changement au niveau du modèle FRBR s'effectue en backend de l'application, par les équipes techniques et les équipes métiers afin de préparer l'application à l'implémentation de processus automatiques. Toutefois, comment le processus automatique de segmentation puis d'indexation est-il représenté au sein de l'interface, pour l'utilisateur ?

D'abord théorie, puis mise en application dans l'exemple de l'application. D'abord lire ce que j'ai écrit en citations.

Nous pouvons imaginer le processus suivant en frontend, dans l'interface visible de l'application pour l'utilisateur. L'utilisateur procède à l'ingest d'un fichier numérisé d'une œuvre/rushe dans sa globalité. L'ingest d'un fichier numérique vidéo devrait pouvoir déclencher la proposition suivante pour l'utilisateur : Souhaitez-vous segmenter automatiquement ce fichier ? Une infobulle devrait indiquer à l'utilisateur ce qu'implique cette segmentation automatique, le processus expliqué en quelques phrases. En effet, au début de l'implémentation du processus et pour tout nouvel utilisateur confronté à cette nouvelle fonctionnalités automatiques, il est recommandé d'être “familiarisé” au “fonctionnement et limites” de ces outils, comme par exemple “la manière dont sont produites les sorties, les éventuels transferts de données, ainsi que les usages autorisés et les usages interdits.”⁸¹ Ces informations pourront notamment aider l'utilisateur à pouvoir valider, par la suite, les données produites par les pipelines automatisés. Skinsoft prévoit par exemple déjà des modes d'emploi à l'attention des utilisateurs lors de la livraison de nouvelles fonctionnalités. Toutefois, les informations relatives au processus devront être intégrées à l'interface et au processus, pour des soucis de transparence et de création conforme des données. Ainsi, “l'intégration de briques d'IA générative dans un système d'information (SI) devrait être pensée avec des éléments de design informant clairement les utilisateurs de l'origine de la proposition, leur rappelant qu'il leur revient de ne pas prendre « telle quelle » la proposition. Par exemple, le système peut proposer pour chaque question au moins deux réponses, ce qui permet à l'opérateur humain

⁸⁰ *Ibid.*

⁸¹ *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).

de sélectionner les éléments pertinents de chaque réponse pour consolider la sienne.”⁸² Au lieu de proposer deux réponses, ce qui surchargerait l’interface, et de plus, ce n’est pas adapté ici puisque le processus de segmentation n’utilise pas d’intelligence artificielle capable de raisonner. Nous pourrions proposer, si l’utilisateur ne valide pas les données produites, la possibilité de ”permettre CROCHETS un point de contact pour remonter des problèmes ou des difficultés d’ordre éthique”⁸³. L’interface devra ainsi prévoir un formulaire décrivant la raison du refus des données, envoyé à l’équipe technique afin que le processus puisse être amélioré au niveau de ses paramètres. Ainsi, dans les premiers mois de sa mise en place, l’implémentation pourra faire l’objet d’essais erreurs auprès des utilisateurs afin de pouvoir être perfectionné. Selon les recommandations du livre blanc : ”lors des premiers mois et années de l’utilisation des IA, il est recommandé de recueillir régulièrement l’avis des utilisateurs finaux sur l’utilité et les limites du système”⁸⁴

En effet, il faudra également lui indiquer les actions qu’il va devoir effectuer au cours du processus. En effet, il devra être demandé à l’utilisateur de valider ou non, les données produites.

La validation est utile à la responsabilisation des utilisateurs pour l’usage des outils d’automatisation en les “incitant à vérifier les données fournies en entrée et la qualité des sorties ”⁸⁵ Les outils d’automatisation doivent être des facilitateurs sans rendre l’indexation trop automatique et facile. L’interface doit prévoir ces étapes de validation de manière simple pour l’utilisateur.⁸⁶

Les données de gestion sur la production de ces données doivent être automatiquement enregistrées par l’application : quel est l’outil utilisé, le processus effectué, qui a validé, quand... L’application prévoit déjà un enregistrement des données de gestion et de l’historique des modifications automatique sur les notices via un menu spécifique. Un nouveau menu pourrait être créé pour les données de gestion automatiques des notices.

Une fois que le fichier numérique a été segmenté, l’interface doit pouvoir présenter à l’utilisateur les times codes choisis avec l’image clé associée pour que l’utilisateur puisse visualiser les coupures qui ont été sélectionnées en accord avec les différences entre les images. Si l’utilisateur valide la segmentation, l’interface indexe les time codes sur le fichier numérique associé automatiquement dans le champ dédié, propose la génération de mots clés sur les segments générés : l’utilisateur pourra alors choisir s’il veut appliquer la génération de mots clés sur tous les segments ou seulement des segments spécifiques sous la forme d’une sélection.

⁸² *Ibid.*

⁸³ *Ibid.*

⁸⁴ *Ibid.*

⁸⁵ *Ibid.*

⁸⁶ **zotero-item-632.**

Une fois le processus de génération de mots clés terminé, l'interface propose à l'utilisateur de valider les mots clés en accord avec les images clés analysées.

Si l'utilisateur ne valide pas les segments, ou n'en valide qu'une partie : il sera important d'intégrer à l'interface un formulaire d'erreurs qui explique les raisons du refus, afin de perfectionner l'algorithme de détection de segmentations. Même chose pour les mots clés. Pour les mots clés, l'interface peut proposer à l'utilisateur de modifier manuellement les mots clés pour les indexer mais aussi m-pour les renvoyer au modèle et alimenter le jeu de données sur lequel il s'entraîne.

À l'INA, les chercheurs ont développé Amalia.js, un lecteur HTML5 extensible qui synchronise des métadonnées avec la lecture de flux vidéo ou audio, au départ conçu pour visualiser les résultats d'algorithmes d'analyse audiovisuelle. Le besoin à l'origine d'Amalia.js est donc de permettre de visualiser les résultats de pipelines d'automatisation, avec leur lot de métadonnées produites⁸⁷ Ce besoin s'explique la production de résultats et de données de différentes natures qui nécessitent d'être présentés à l'utilisateur.⁸⁸ L'indexation automatique regroupe tout un tas de métadonnées issues d'algorithmes et d'outils différents qu'il faut réunir dans une interface de présentation. Ainsi, à l'inverse de la visualisation des résultats que nous avons proposée en deux étapes, conformément aux deux processus différents, Amalia.js propose une visionneuse multimédia qui présente l'ensemble des résultats. Cette interface permettrait également de vérifier la conformité des données produites aux standards métiers en vigueur au sein du logiciel : « Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »⁸⁹. Par la même occasion, l'interface permet également d'annoter la vidéo et de corriger manuellement les données produites directement sur le fichier vidéo. Le logiciel permet à l'utilisateur d'annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »⁹⁰. La correction humaine permet d'avoir des métadonnées plus justes, mais permet aussi d'avoir des données d'entraînement pour améliorer les algorithmes d'indexation automatique. (aussi vu chez Vanderbilt). Utilisateur comme rôle de correction et d'enrichissement sur une base générée automatiquement.

Le plugin timeline proposé par Amalia.js est particulièrement intéressant pour notre

⁸⁷Nicolas Hervé, Pierre Letessier, Mathieu Derval et Hakim Nabi, « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.

⁸⁸*Ibid.*

⁸⁹*Ibid.*

⁹⁰*Ibid.*

étude puisqu'il permet d'afficher les métadonnées horodatées sur l'image.⁹¹ (cf capture d'écran word) Le plugin permet de visualiser les segments temporels et les images clés en lien avec ces segments.

Par ailleurs, le plugin de superposition permet d'encadrer les objets détectés dans l'image par les algorithmes. Nous pouvons imaginer, au lieu de développer deux plugins différents, de développer le premier plugin temporel, afin d'afficher les objets détectés par yolo sur les images clés, et d'ouvrir une fenêtre latérale avec les mots clés proposés. Un mode d'édition pourrait permettre alors à l'utilisateur de modifier les mots clés si les résultats ne sont pas satisfaisants. À la modification de l'utilisateur, l'application détecte la modification et la renvoie à l'équipe technique pour réentraîner le modèle sur les données corrigées.

Exemple d'écran scindé pour le plugin d'édition, qui serait dans le cas de notre étude, intégré au plugin temporel pour accepter la proposition de mots clés : (cf capture)

Exemple de la plateforme okapi :

“Okapi fournit un ensemble d'outils destiné à l'analyse sémantique et sémiotique de contenus multimédia (vidéo, image, son) et à la gestion de corpus de vidéos, d'extraits sonores et de parties d'images. Les outils d'analyse permettent l'indexation et la description sémantique de contenu sur la base d'ontologies qui décrivent les objets et classes des domaines étudiés. Les outils de gestion de corpus fournissent des services pour la constitution, la visualisation, l'enrichissement et la valorisation de corpus thématiques.”⁹² (cf capture d'écran)

Prévoir une file d'attente et une barre de chargement de traitement : tableau de bord skinsoft

c. Rendre les données recherchables et découvrables

Une fois les données validées et indexées au sein du modèle de données, elles peuvent être exploitées au sein du logiciel comme n'importe quelle autre donnée documentaire, et peuvent notamment être requêtables. La création d'une potentielle nouvelle entité, la séquence, modifie le rapport de l'utilisateur aux objets documentés au sein du logiciel. L'utilisateur peut désormais accéder non plus seulement aux archives audiovisuelles dans leur entièreté mais à leurs segments. L'indexation de segments d'archives audiovisuelles ne produirait ainsi non plus seulement une simple indexation mais une “indexation fine” du contenu, selon Bachimont (2007).⁹³

⁹¹ *Amalia.Js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).

⁹² S. Lalande, A. Beloued et O. Farge, « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles... ».

⁹³ B. Bachimont, *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).

Ainsi, une recherche par mots-clés dans notre cas permet à l'utilisateur d'accéder directement aux segments d'archives concernés par ce mot-clé. Cela permet notamment à l'utilisateur d'accéder à des éléments plus précis en accord avec la requête effectuée au lieu d'accéder à des archives audiovisuelles entières qu'il faudrait visionner. Mais encore faut-il que les segments sélectionnés soient compatibles avec Ainsi, une recherche par mots-clés dans notre cas permet à l'utilisateur d'accéder directement aux segments d'archives concernés par ce mot-clé. Cela permet notamment à l'utilisateur d'accéder à des éléments plus précis en accord avec la requête effectuée au lieu d'accéder à des archives audiovisuelles entières qu'il faudrait visionner. Mais encore faut-il que les segments sélectionnés soient compatibles avec les besoins utilisateurs. Les nouveaux segments créés pourront ainsi être intégrés aux différents modes de recherche et de filtrage proposés par le logiciel de gestion des collections. Par exemple, l'application de skinsoft propose une recherche simple, une recherche avancée, une recherche plein texte ciblée, une recherche par image. Une recherche en langage naturel, s'appuyant sur la technologie du NLP est également en cours de développement, dans laquelle la recherche des segments pourra s'intégrer. L'utilisateur pourrait ainsi formuler une description de ce qu'il recherche, en langage naturel, et obtenir des résultats visuels pertinents. La recherche par image pourra également être davantage employée dans le cadre de la description des segments. Les résultats de recherche pourront présenter en vignette, l'image clé associée au segment décrit, sur laquelle l'utilisateur peut cliquer. Il accède à la fiche de description intellectuelle de la séquence comprenant les mots clés et les time codes correspondants. Le fichier numérique correspondant à la séquence est associé sous la forme d'item lié dans une grille de recherche. Le risque, énoncé par Bachimont, est le suivant : "les segments peuvent se désolidariser du contenu dont ils sont issus, perdant ainsi leur origine et nature documentaires."⁹⁴. Toutefois, le modèle de données FRBR limite ce risque, dans la mesure où il contraint les liens entre les entités. Les séquences en tant que fichiers numériques, seront ainsi toujours reliées à une notice de séquence descriptive intellectuelle, elle-même rattachée au niveau le plus haut, l'œuvre. L'un des besoins utilisateur fondateur du modèle de données FRBR est précisément celui de la recherche, de pouvoir identifier des ressources précises. (Retrouver le besoin utilisateur) La création d'une nouvelle entité au sein du modèle de données permettrait d'éviter ce risque d'isolement de segments de son oeuvre originale. Les données produites automatiquement peuvent alimenter d'autres modes de recherche innovants telle que la recherche visuelle par l'exemple et l'apprentissage interactif (cf Snoop). Ces nouveaux modes de recherche permettent également aux systèmes d'IA d'apprendre grâce aux retours utilisateurs : faire le lien avec ce qui est développé par skinsoft : RAG, LLM, NLP...

Snoop v6 : moteur visuel de recherche, d'apprentissage et de prédiction à très large

⁹⁴ *Ibid.*

échelle. Cette technologie permet à un utilisateur de formuler une requête par l'exemple (un morceau d'image représentant un logo, tableau, monument, ...) à retrouver dans des fonds d'images et de vidéos de grande taille. De plus, à partir d'une base connaissances (ensemble de classes, comme dans le cas de Pl@ntNet). Snoop a aussi des fonctionnalités d'apprentissage de réseaux profonds et de prédiction. Nos forces :

Images et vidéos : Snoop peut gérer un corpus comportant à la fois des images et des vidéos ce qui permet de construire des liens visuels entre ces 2 types de contenus.

L'interactivité à très large échelle, peu coûteuse en CPU et mémoire.

Prédiction à large échelle avec des centaines de milliers d'utilisateurs par jour sur un seul serveur⁹⁵

L'un des composants technologiques de Snoop est le bouclage de pertinence, permettant de créer des modèles d'entités visuelles personnalisés. Le schéma ci-dessous résume ce processus dans lequel Snoop est sollicité par une première recherche avec quelques images choisies par l'utilisateur et représentant sa requête. Quelques contenus visuels similaires retrouvés par Snoop sont ensuite marqués par l'utilisateur, soit positivement (ceux qui correspondent à sa recherche), soit négativement (des contre-exemples). Puis Snoop utilise ces informations pour créer un modèle des connaissances transmises par l'utilisateur. Tant que ce dernier n'est pas satisfait, l'IA propose à nouveau des résultats pouvant être annotés. (source : Snoop, un moteur de recherche visuelle interactif A. Joly, J-C. Lombardo, J-P. Moreux, Q. Leroy et O. Buisson Culture et Recherche (141), 2020 (lien)

Ce que produit l'indexation des segments : "Alors que selon l'indexation traditionnelle, l'enjeu est de retrouver le ou les documents contenant l'information recherchée, l'indexation fine du contenu permet de ne retrouver que les segments concernés par la recherche d'information et de paramétrer l'usage de ces segments. Si le document demeure présent dans les résultats de la recherche dans une indexation et recherche traditionnelles, il n'en est pas de même dans une recherche profitant de l'indexation fine du contenu, dans la mesure où les segments peuvent se désolidariser du contenu dont ils sont issus, perdant ainsi leur origine et nature documentaires. Devenant des ressources, ces segments sont remobilisés pour la production d'autres contenus dont ils constituent les composants" B. Bachimont, 2007⁹⁶

Une fois produites, les données doivent être indexées afin d'être requêtables au sein de l'application. : juste sous sous partie indexation des données d'un pdv technique pour qu'elles soient requêtables comme d'autres données.

"Si l'utilisation envisagée consiste à fournir des données personnelles (données des clients ou des collaborateurs) ou de la documentation sensible ou stratégique (par exemple pour le

⁹⁵Projet Snoop / INA, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).

⁹⁶Id., *Ingénierie des connaissances et des contenus...*

RAG), il semble généralement plus opportun et plus sécurisé de privilégier le déploiement de solutions « sur site » (on premise) qui présentent l'avantage de limiter les risques d'extraction de données auprès d'un tiers⁹⁷ "s'il est envisagé d'utiliser un système sous forme d'API, il faut souligner que la maîtrise du système est alors quasi exclusivement dans les mains du fournisseur. Il convient donc d'être particulièrement vigilant sur les données soumises au système d'IA"⁹⁸

Le besoin à l'origine d'Amalia.js est de permettre de visualiser les résultats de pipelines d'automatisation, avec leur lot de métadonnées produites : « Whatever the field of analysis, we always need to be able to quickly and easily view the results of the methods we are developing. This problem is particularly true as we often manipulate large amount of videos. Developing visualization and annotation tools is often a tedious task that deserves to be pooled. »⁹⁹ « The analysis being at different levels (keyframes, video segments, audio channels, associated synopses, one video alone or relative to a corpus...) results are obtained in very different natures, often needing quite specific approaches to be presented to the end user. »¹⁰⁰ L'indexation automatique regroupe tout un tas de métadonnées issues d'algorithmes et d'outils différents qu'il faut réunir dans une interface de présentation.

C'est une interface pour visualiser et pour corriger.

Comment regrouper dans la même interface des métadonnées de nature très différentes attachées à la même vidéo ?

Les métadonnées horodatées : issues de la segmentation vidéo.

« The main principle of amalia.js is to have a unified metadata model. Ensuring that all the metadata types are consistent and use the same standards will facilitate their use and enable us to design generic visualization plugins. »¹⁰¹. Importance d'avoir une interface de standardisation des métadonnées : important pour skinsoft qui doit s'adapter aux normes employées par les clients.

Le logiciel permet à l'utilisateur d'annoter la vidéo pour corriger les métadonnées ou les compléter : « This will allow us to enter or correct metadata directly through the player. We plan to use this version in groundtruth management applications so as to enable the creation of huge research datasets used to train supervised algorithms or to assess analysis methods performances. »¹⁰². La correction humaine permet d'avoir des métadonnées plus justes, mais permet aussi d'avoir des données d'entraînement pour améliorer les algorithmes d'indexation automatique. (aussi vu chez Vanderbilt). Utilisateur comme rôle de correction

⁹⁷ *Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative...*

⁹⁸ *Ibid.*

⁹⁹ N. Hervé, P. Letessier, M. Derval, *et al.*, « Amalia.Js... ».

¹⁰⁰ *Ibid.*

¹⁰¹ *Ibid.*

¹⁰² *Ibid.*

et d'enrichissement sur une base générée automatiquement.

SOUS PARTIE 3 :

"A major challenge for making AVP tools available is that the underlying algorithms need direct access to the data, yet due to strict IPR regulation this data often cannot leave the archives' digital environment. A side effect of this is that for the analysis of AV material commercially available tools cannot be used, as these are primarily cloud based. it is necessary that any AVP infrastructure can be integrated with a local archival infrastructure, i.e., we need to bring the algorithms to the data, rather than the data to the algorithms."¹⁰³. Solution : projet CLARIAH

"Moreover, DANE is designed to be able to function in environments where there are fewer compute resources, or environments where access to the data is rate limited, as is typical for AV archives. To make this possible, the DANE architecture (as shown in Figure 2) divides the tasks to be performed over different workers that perform one specific type of analysis, where the work is assigned to a worker by means of message broker queuing system. The results of the analyses are communicated back to the server by the workers, and made available via an API to clients (e.g., other services or individual users)."¹⁰⁴ (+ schéma qui montre l'architecture)

"To enrich the AV collections in the Media Suite with automatically generated (and time-coded) metadata an assortment of AVP tools had been added to DANE, ranging from Semantic Object Detection, to colour analysis, to Automatic Speech Recognition."¹⁰⁵

"These tools generate two types of metadata : (i) structured data which can be integrated into the existing metadata systems, and (ii) feature vectors which describe the data on a more abstract level, but which can be integrated in new types of interfaces and search systems. For instance, with an Object Recognition model it is possible to recognise which objects are present in an image, but the output of such a model can also be used to perform more abstract visual similarity queries"¹⁰⁶

exemple d'indexation automatique à la bibliothèque nationale de finlande "L'API « suggest » est au cœur de ce web service : en fournissant un document textuel en entrée, on obtient en sortie une liste (au format JSON) de suggestions de concepts pour l'indexer ainsi que l'appréciation quantifiée de leur niveau de pertinence. Autre fonctionnalité importante, « learn » est capable de mettre à jour les programmes en exploitant des correspondances vérifiées entre des documents décrits et les mots sujets choisis."¹⁰⁷ss

¹⁰³N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

¹⁰⁴*Ibid.*

¹⁰⁵*Ibid.*

¹⁰⁶*Ibid.*

¹⁰⁷Osma Suominen, « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–

4. La nécessaire refonte de S-Movies pour la mise en place d'un tel projet

La question de l'automatisation d'une indexation fondée sur le FRBR n'est pas nouvelle, comme le pose Signoles en 2012, face à la complexité d'adapter une interface au modèle : "Suffira-t-il « un jour » d'appuyer sur un bouton pour extraire d'une notice des données automatiquement FRBRisées ?"¹⁰⁸. La mise en place d'une telle automatisation se précise à travers le projet IA chez Skinsoft. Toutefois, l'automatisation est conditionnée par une interface utilisateur fluide et navigable, surtout lorsque celle-ci s'appuie sur le modèle FRBR. Or, nous avons vu que l'espace de travail S-MOVies faisait l'objet d'un projet pour améliorer la navigation de l'utilisateur au sein du modèle de données afin d'en comprendre les liens. Ce projet permettra, à terme, d'éviter une diffusion d'erreurs à trop grande échelle liées à l'automatisation. Étant donné la complexité des liens induits par le modèle de données FRBR, l'interface doit prévoir les complexités et les confusions. Si les liens entre niveaux sont confus pour l'utilisateur, ils le seront pour un algorithme d'intelligence artificielle, et pour la vérification humaine derrière. Rapellons les complexités d'interface auxquelles fait face l'espace S-Movies. IL n'existe pas actuellement d'affichage des liens entre les entités du FRBR et de leur hiérarchie. Par ailleurs, la conception d'un espace de travail divisé en tables au sein desquelles l'utilisateur peut créer des notices limite notamment la porosité des liens entre les notices et rend la création de celles-ci hermétique. Durant notre stage, nous avons proposé des propositions d'optimisation de l'interface en lien avec le FRBR sous la forme d'une spécification fonctionnelle (Voir la spécification détaillée en annexe). L'amélioration des liens et la modification de l'affichage adéquat de la hiérarchie FRBR sont les conditions d'un reversement automatique des métadonnées. Ces propositions s'inscrivent, d'une part, en amont de la mise en place de l'intelligence artificielle, afin d'instaurer une interface lisible entre l'utilisateur et la machine. La vérification des données produites et leur reversement au sein des niveaux FRBR pourra être plus intuitive et ainsi plus efficace. La mise en place d'une interface appropriée prépare la mise en place de l'intelligence artificielle dans laquelle elle pourra s'inscrire. L'interface peut être un outil pédagogique et un guide pour l'utilisateur dans un moment de transition technologique. D'autre part, si les études sur l'UI/UX en contexte patrimonial se concentrent sur la construction d'une interface intuitive pour l'utilisateur faisant partie d'un public, en ligne, il est également important de construire une interface intuitive, navigable et visuelle pour les professionnels métier. La mise en place d'une interface intuitive permet à l'utilisateur de se concentrer sur sa tâche. mettre en place des repères que les

94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605.

¹⁰⁸Aurélien Bergonnier Signoles, « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().

utilisateurs peuvent suivre pour atteindre leur objectif et prendre de meilleures décisions plus rapidement

Nous présenterons des améliorations en trois temps. Tout d’abord nous présenterons des nouvelles fonctionnalités afin d’améliorer la compréhension du FRBR pour l’utilisateur, puis des fonctionnalités pour améliorer les liens et la navigation entre les notices plus spécifiquement. Enfin, nous proposerons des fonctionnalités qui visent notamment à préparer l’intégration de l’intelligence artificielle au sein de l’interface.

Pour des raisons de concision, l’implémentation concrète de ces améliorations dans l’interface sont détaillées en annexe.

a. Améliorer la compréhension du FRBR

Modifier l’affichage de la hiérarchie :

Premièrement, améliorer l’affichage de la hiérarchie des niveaux FRBR pourrait permettre une meilleure intuitivité au sein de l’interface. Faire apparaître une hiérarchie avec le plus haut niveau en haut, duquel découle les autres niveaux serait plus clair pour les utilisateurs. A plusieurs endroits, la hiérarchie est affichée de manière inversée, comme dans le menu burger où l’affichage des tables se fait du plus bas niveau (film) en haut, au plus haut niveau (oeuvres) en bas. Par ailleurs, dans le menu des notices, les onglets peuvent être paramétrés comme l’utilisateur le souhaite, laissant ainsi libre cours à la possibilité d’afficher une hiérarchie incohérente. Rétablir une hiérarchie conforme au modèle FRBR permettrait de lever les ambiguïtés sur les niveaux de descriptions où l’utilisateur doit inscrire ses données. (Un développement plus précis de cette amélioration est développée en annexe).

Corrections terminologiques :

Dans le même objectif de construire l’interface la plus claire possible, quelques corrections terminologiques seraient à apporter. Par exemple, nous l’avons évoqué, le niveau Item est matérialisé dans l’application par le terme ”film”. Or, dans un contexte cinématographique, le film peut désigner plusieurs éléments à la fois. Selon la définition de Journot, il désigne à la fois le support matériel et l’oeuvre : ”Le film, [...] désigne d’abord la pellicule photographique, puis la bande perforée recouverte d’émulsion photographique qui permet d’enregistrer et de conserver les images. Par extension, il désigne l’œuvre cinématographique et l’ensemble des œuvres considérées par domaines”¹⁰⁹. Dans le contexte du FRBR, le terme pourrait désigner les trois niveaux, puisqu’il ne contient pas ne lui-même la notion d’exemplaire. Mettre en place un terme plus précis comme celui d’”item-film” par exemple, serait plus intuitif pour les utilisateurs, puisqu’il induit cette notion d’exemplaire unique qui caractérise le niveau item. Par ailleurs, le terme expression est encore utilisée à certains endroits

¹⁰⁹Marie-Thérèse Journot, *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.

de l'interface, notamment au sein des configurations possibles. Or, les recommandations de la FIAF évoquent la fusion du niveau expression avec celui d'oeuvre. Conserver uniquement le terme d'oeuvre permettrait à l'utilisateur d'identifier un modèle FRBR propre à la gestion de collections cinématographiques, pour ne pas le confondre avec celui des bibliothèques par exemple. Rappelons que certains utilisateurs alternent entre différents espaces de travail qui peuvent être fondés sur le même modèle de données, mais différents car appliqués à une collection différentes, comme c'est le cas avec les collections filmiques et les collections bibliographiques. Il est important que l'interface signale et mette en avant ces différences pour ne pas induire l'utilisateur en erreur. De plus, afin d'améliorer l'affichage hiérarchique et la navigation au sein de l'interface, nous proposons la mise en place de points de repère afin d'aider l'utilisateur à se situer au sein du modèle FRBR. Par exemple, l'affichage, dans l'onglet d'une notice, des niveaux dans lesquels elle est imbriquée, permettrait à l'utilisateur de se repérer en tout temps au sein des liens d'une notice. Par exemple, l'onglet d'une notice d'item-film mentionnerait l'oeuvre et la manifestation dont elle découle. Des précisions sur les modalités d'affichage de cette amélioration sont précisées en annexe. Cet affichage produirait un affichage de la hiérarchie et des liens auxquels appartiendrait une notice. Par ailleurs, un repérage par couleurs sur les niveaux pourrait être mis en place afin d'améliorer l'intuitivité de l'interface. Ainsi, chaque niveau du FRBR serait associé à une couleur spécifique au sein de l'interface, rendant, pour l'utilisateur, un repérage visuel rapide et une navigation plus efficace. Plus largement, nous proposons une refonte du parcours utilisateur pour davantage guider ses choix documentaires en accord avec le modèle FRBR. Nous avons par exemple pensé à la mise en place d'un questionnaire d'assistance au catalogage lors de la création de notices au sein de l'espace de travail. Ce questionnaire serait nourri par les définitions et les exemples du manuel de la FIAF, afin d'aider l'utilisateur à décrire les données au bon endroit de l'interface selon les cas. Par exemple, lorsque l'utilisateur crée une notice dans un des niveaux du FRBR (oeuvre, manifestation, item-film), il devrait répondre à plusieurs questions qui affinent le choix de lien à effectuer avec ladite notice. Par exemple, le questionnaire devrait pouvoir répondre aux incertitudes suivantes : faut-il créer une manifestation en lien avec cet item ? Cet item découle-t-il d'une variante de l'oeuvre ? Le questionnaire devrait ainsi prévoir les différents cas de figure à documenter et les liens qui doivent être établis entre les notices. Le détail des questions possibles et du parcours utilisateur sont décrits en annexe. De plus, il semble que les notions de variante et de manifestation soient assez floues et poreuses pour les utilisateurs. Afin de les aider dans leurs choix : créer, à partir d'une oeuvre, une variante ou une manifestation, le questionnaire pourrait inclure des infobulles contenant les différents types de variantes et de manifestation, évitant ainsi davantage les confusions. Cette modification du parcours utilisateur afin de clarifier les différents niveaux du FRBR

permettraient également aux utilisateurs de davantage utiliser les niveaux de variante et de manifestations qui sont actuellement peu utilisés.

Par ailleurs, afin de permettre à l'utilisateur de visualiser les liens entre les notices, et la pluriété de liens qu'induit le modèle FRBR, nous proposons une visualisation en graphe. En effet, actuellement, l'interface permet seulement de visualiser les liens entre les tables à l'intérieur d'une notice, par le biais d'oglets séparés. Par exemple, une notice d'item contiendra d'une part les manifestations liées et d'autre part, l'oeuvre liée. Mais il n'est pas possible de visualiser l'interconnexion de ces liens et de visualiser l'ensemble des liens dont fait l'objet une entité. Une visualisation d'ensemble serait pertinente notamment au niveau oeuvre, afin de pouvoir visualiser ses variantes, ses manifestations, ses exemplaires. De plus, visualiser rapidement les liens entre entités permettrait d'identifier les incohérences et les erreurs plus facilement, comme par exemple, des éléments vides ou isolés. Pour cette idée de visualisation en graphes, nous nous sommes inspirés de la "balade intuitive" proposée par la bibliothèque Kandinsky, qui propose, à partir d'une notice, une visualisation en graphe arborescente autour du niveau concerné. Le choix du graphe est justifié ici puisque les entités principales du FRBR sont au nombre de trois. En effet, la représentation en graphe découle du modèle RDF (Resource description framework : sujet-prédicat-objet) qui permet l'interopérabilité des données au sein du web sémantique. **(à sourcer et à développer le lien entre les deux)** Les modalités d'implémentation de cette fonctionnalité au sein de l'interface est détaillée en annexe.

b. Améliorer les liens et la navigation entre les notices

Dans un second temps, il s'agit d'améliorer la création de liens entre les niveaux du FRBR au sein de l'espace de travail. En effet, nous l'avons évoqué, les liens ne sont pas rendus obligatoires par l'interface au moment de la création d'une notice. Or, le FRBR prévoit une description en plusieurs niveaux qui doit être matérialisée par un lien indissociable entre les notices. La création de notices au sein de tables distinctes et individuelles n'incite pas l'utilisateur à créer des liens avec les autres tables. Au moment de la création d'une notice item dans la table des items, un "message" apparaît pour suggérer à l'utilisateur de l'associer à une manifestation. Le lien est ici optionnel. Or, un item est relié soit à une manifestation, soit à une oeuvre, soit les deux. Nous proposons plutôt de contraindre l'utilisateur à relier la notice à un ou plusieurs niveaux supérieurs en bloquant la saisie tant que le lien n'est pas établi. Nous proposons ici de placer le lien comme une condition préalable à celle de la notice. Finalement, dans le même objectif de contraindre la création de lien au sein de l'interface, nous proposons même de repenser la création de notices dans des tables individuelles, voire de la supprimer. Cela rendrait nos idées sur la mise en place d'un questionnaire et la précédente

caduces. En effet, la création de notices au sein de tables individuelles n'encourage pas l'utilisateur à lier les notices entre elles, sur plusieurs niveaux. Le risque est ainsi que l'utilisateur crée des notices individuelles, elles aussi, sans les relier à d'autres niveaux du FRBR. Pour éviter cela, il pourrait être intéressant de proposer la création de liens prédéfinis, au lieu de créer au sein de tables. Les tables pourraient être alors réservées à la consultation et à l'affichage des notices créées. Cette idée rapprocherait S-Movies d'une interface où l'utilisateur crée un réseau de liens, propre à une collection cinématographique. Au risque de surcharger l'interface, on peut également imaginer qu'au sein de chacune des tables, la possibilité de créer une notice de manière simple soit remplacée par la création de liens. Par exemple, au sein de la table oeuvre, l'utilisateur pourrait lier une oeuvre à une manifestation, lier une oeuvre à une manifestation, lier une oeuvre à un item, lier une oeuvre à une variante. AU sein de ce lien, l'utilisateur pourrait soit lier l'entité à une notice déjà existante, soit en créer une nouvelle dont le lien indissociable serait automatiquement mis en place. La limite de cette idée est qu'elle est contre intuitive : la création d'une notice de chaque entité se fait dans d'autres tables que celle qui lui est dédiée. Cette refonte du mode de création des notices assure toutefois un lien indissociable entre les entités, qui permettra notamment d'empêcher la suppression d'une entité et des éléments qui lui sont liés par exemple. Cela faciliterait aussi la mise en place de visualisation des liens, si les entités sont toutes interconnectées. Surtout, ces nouvelles modalités suppriment la possibilité de créer des notices individuelles, sans lien avec les niveaux du FRBR. Les modalités précises des liens proposés sont détaillés en annexe. Par ailleurs, l'interface pourrait permettre une meilleure visibilité sur l'héritage des données prévue par les méta masques dont nous avons évoqué la configuration en première partie. Actuellement, les champs issus des méta masques glissés et déposés dans la table concernée perdent la mention du niveau FRBR auquel ils appartiennent. L'utilisateur n'a plus le moyen de savoir, une fois dans la notice, que tel champ appartient à tel niveau. Conserver la mention du niveau du FRBR sur les métas masques au sein de la saisie de la notice permettrait une meilleure compréhension et visibilité pour l'utilisateur. Ainsi, par exemple, dans une notice de manifestation, le champ Titre afficherait : Œuvre – Titre.

c. Préparer l'intégration de l'IA

transition de pratiques utilisateur vers la mise en place de l'automatisation

Annotation de séquences : créer déjà des données temporelles permettra d'entraîner l'IA directement sur ces données (introduire que l'IA a besoin d'entraînement)

La table média actuelle permet seulement de visualiser une photo ou une vidéo, au clic sur la notice. Toutefois, il serait intéressant de développer une visionneuse spécifique à la vidéo qui permettrait non seulement de la visionner, mais également d'y placer des repères,

des marqueurs, et de pouvoir l'annoter.

Tout d'abord, deux possibilités de "séquençage" manuel seraient possibles :

L'utilisateur saisit des repères temporels sur la vidéo sans la modifier. Ces repères sont reversés dans des champs prévus pour accueillir les "time codes" dans la notice de l'objet numérique. À l'ouverture du fichier numérique, les marqueurs laissés par l'utilisateur apparaissent, visibles sur la barre de défilement de la vidéo. L'utilisateur peut alors cliquer sur ces marqueurs pour naviguer au sein de la vidéo comme il le souhaite, et y voir les annotations associées.

L'utilisateur pourrait aussi vouloir segmenter le fichier vidéo en plusieurs séquences distinctes à partir de time codes précis. Dans ce cas-là, à la manière d'un logiciel de montage, l'utilisateur peut créer des cuts sur la vidéo et ainsi créer plusieurs fichiers numériques à partir de celle-ci, mais qui lui sont toujours liés. En effet, ces nouveaux objets, fragments du fichier vidéo d'origine, auraient leur propre notice de description mais resteraient rattachés à la notice principale, à la manière d'un ensemble.

Cette nouvelle fonctionnalité permettrait d'apprécier l'hétérogénéité des collections, et s'avèrerait utile dans le cas, par exemple, de rushes documentaires non édités que l'utilisateur souhaiterait diviser par mots clés ou thématiques. La description des médias vidéo n'en serait que plus affinée et précisée.

Par ailleurs, ce séquençage devra être effectué dans une optique d'annotation "sur" l'image, permettant ainsi d'associer des séquences plus précises à une description thématique. Concrètement, deux cas d'annotation sont possibles :

L'utilisateur pourrait être capable de placer des tags sur des éléments de l'image (objets, personnes, éléments techniques, contenu...) et d'en décrire le contenu dans les champs prévus. La notice du média prévoit alors l'affichage d'une description par time codes, sur lesquels l'utilisateur peut cliquer pour accéder directement à l'image en question.

L'utilisateur peut également vouloir décrire une séquence dans sa globalité, à l'intérieur d'un time code précis. Dans ce cas, les champs sont saisis à partir d'un tag sur le time code, et non plus sur un élément précis de l'image. L'affichage de la description dans la notice peut rester le même que le précédent.

À l'ouverture du fichier vidéo, les annotations saisies apparaissent à droite de la visionneuse, et les time codes superposés à la barre de défilement de la vidéo.

La description précise sur des séquences vidéo permettrait à la recherche d'être plus performante : l'utilisateur pourrait, en cherchant certains mots clés, tomber directement sur les séquences numériques associées, aux time codes correspondants.

Il est intéressant de penser également à la mise en place d'une recherche par mots clés au sein du fichier numérique vidéo. La recherche d'un mot clé amène l'utilisateur à une séquence

décrite par ce mot clé.

Recherche de média par format : à supprimer ?

Il serait pratique de mettre en place, dans la table médias, une recherche par type de formats.

L'application pourrait détecter automatiquement le format du média créé par l'utilisateur et l'indexer pour le proposer comme critère de tri/de recherche à l'utilisateur.

Cela permettrait notamment de pouvoir rapidement visualiser les fichiers vidéo présents dans la table, au lieu de devoir faire des albums par types de médias.

Deux types de filtres seraient pertinents à proposer :

Type de média : vidéo, image, son

Format : mp4, mpeg, jpeg, mov...

Automatisation du catalogage

Il serait pertinent de mettre en place une automatisation de la hiérarchie FRBR à partir de la création d'une notice. Cette fonctionnalité serait assistée par l'IA. Par exemple, depuis l'item, l'application détecterait la hiérarchie supérieure à créer depuis les actions suivantes :

Description de l'item

Scan du code-barres

Création d'une notice item depuis la table films

Création d'une notice item depuis la table des entrées

L'assistant IA détecterait les liens à effectuer entre l'item en question et des notices de manifestation et d'œuvre si elles existent. Si elles n'existent pas, il créerait automatiquement les notices manifestation et œuvre et proposerait à l'utilisateur de les remplir. Ces notices seraient automatiquement liées.

Dans le cadre de la mise en place d'un chatbot, l'utilisateur pourrait simplement décrire l'item et son contenu, et l'intelligence artificielle suggérerait à l'utilisateur ce qu'il faut créer, ou la marche à suivre. Par exemple :

Cet item est issu de la manifestation de telle oeuvre. Les deux notices existent déjà, il faut y lier cet item

Cet item est issu d'une nouvelle manifestation de telle oeuvre, il faut la créer et la lier à l'item

Cet item est issu de la variante de telle oeuvre, il faut la créer et la lier à l'item. Pas besoin de créer une manifestation, cet item est l'exemplaire unique de la variante de cette oeuvre.

Troisième partie

partie 3

Conclusion

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

Annexe A

Le titre très long de la première
annexe

Glossaire

apprentissage machine . 36, 37, 55

apprentissage profond . 37, 55

Archives audiovisuelles . 7, 55

Audiovisual Processing . 35, 55

CNN Architecture de réseau de neurones artificiels spécialement adaptée au traitement et à l'analyse d'images numériques.. 37, 38, 55

Expression . 55

FIAF Fédération Internationale des archives du film. Organisation regroupant les cinémathèques et édité le manuel de catalogage audiovisuel fondé sur le modèle FRBR.. 55

FRBR Functional Requirements for Bibliographic Records. Modèle conceptuel entité-association développé par l'IFLA.. 3–7, 55, 61

Item . 55

Manifestation . 55

Oeuvre . 55

rush Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant le matériau source d'un film.. 55

réseaux de neurones profonds . 37, 55

transformers . 37, 38, 55

Vision par ordinateur . 36, 37, 55

Liste des abréviations

CIDOC-CRM object-oriented Conceptual Reference Model. 6, 55

FRAD Fonctionnalités requises des données d'autorité. 6, 55

FRBRoo long. 6, 7, 55

FRSAD Fonctionnalités requises des données d'autorité matière. 55

IFLA International Federation of Library Associations and Institutions. 3, 55

IFLA-LRM long. 6, 55

WVMI Work, Variant, Manifestation, Item.. 55

Liste des tableaux

1	Comparatif des approches de traitement audiovisuel automatique	10
---	--	----

Table des figures

1	Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect	13
---	---	----

Table des matières

Résumé	i
Remerciements	iii
Introduction	xix
 I Indexer les archives audiovisuelles	 1
 II Implémenter l’indexation automatique des archives audiovisuelles au sein d’une remodelisation du FRBR	 3
1. Traitement audiovisuel	5
a. Machine learning et deep learning	5
b. Outils et modèles disponibles	9
c. Mise en application	13
2. Description et indexation automatique	16
a. Outils utilisés	17
b. Entraînement	19
c. Interface de validation technique	21
3. Comment indexer les données automatiquement produites ? : interface d’indexation	23
a. Reversement au sein du FRBR	23
b. Interface de validation pour l’utilisateur	29
c. Rendre les données recherchables et découvrables	32
4. La nécessaire refonte de S-Movies pour la mise en place d’un tel projet	37
a. Améliorer la compréhension du FRBR	38
b. Améliorer les liens et la navigation entre les notices	40
c. Préparer l’intégration de l’IA	41

III	partie 3	45
	Conclusion	47
A	Titre court	51
	Glossaire	55
	Liste des abréviations	57