

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès cinéma

diplômé.e de master

Segmentation et indexation automatiques des archives audiovisuelles

L'enjeu du modèle de données au sein d'un logiciel de gestion des collections

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Clotilde Long, *Segmentation et indexation automatiques des archives audiovisuelles. L'enjeu du modèle de données au sein d'un logiciel de gestion des collections*, mémoire de master « Technologies numériques appliquées à l'histoire », dir. Maxime Challon, École nationale des chartes, 2026.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- Analyse Des Tendances Médias Par l'IA - Les Traitements Réalisés Par Les Outils d'intelligence Artificielle Utilisés Sur Data.Ina.Fr | Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BENJAMIN (Walter), *L'oeuvre d'art à l'époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu'est-ce qu'un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.
- Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara

- B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l'image et du son pour l'enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- DIALOGUE (IFLA Working Group on FRBR/CRM), « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).
- Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- France 2030 : un plan d'investissement pour la France* / *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).
- Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).

- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- La stratégie du ministère pour des intelligences artificielles culturelles et responsables* / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).
- MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).
- Modèles FRBR, FRAD et FR SAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- Qu'est-ce que la modélisation de données ?* / IBM, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).

- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ? / IBM*, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- TILLET, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wen-guan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

Première partie

Indexer les archives audiovisuelles

Chapitre 1

Le FRBR, modèle d’indexation conçu pour les bibliothèques

Cette partie s’attache à définir le FRBR comme modèle de données adaptatif à différents items intégrés à un logiciel de gestion des collections. Si le FRBR est un modèle créé pour les items bibliographiques, il est également employé et adapté aux items de musée et aux archives audiovisuelles. Les collections d’archives audiovisuelles peuvent être modélisées par le FRBR pour deux raisons. Leur statut hybride entre objet de collection et archives leur confère une complexité qui nécessite de modéliser leur description en niveaux. De plus, leur nature reproductible peut multiplier les versions, les publications, les exemplaires d’une même œuvre. La modélisation permet donc de rendre compte des liens entre les différents éléments d’une même œuvre.

I. Un modèle conceptuel fondé sur les besoins utilisateurs

La modélisation de données est structurante au sein d’un logiciel de gestion des collections, puisqu’elle désigne le “processus de création d’une représentation visuelle de l’ensemble d’un système d’information ou de parties de celui-ci pour communiquer les connexions entre les points de données et les structures.”¹. Le FRBR, en tant que modèle de données, centralise l’expérience utilisateur au sein d’un outil de gestion des collections, lui permettant de visualiser les liens entre les contenus et de les localiser plus facilement. Définissons plus en détail ce modèle de données dont la structure est déterminante pour notre étude sur l’implémentation

¹*Qu’est-ce que la modélisation de données ?* / IBM, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).

de l'indexation automatique.

Le FRBR, Functional Requirements for Bibliographic Records, est un modèle conceptuel de données bibliographiques élaboré par l'International Federation of Library Associations and Institutions (IFLA) (Fédération internationale des associations et institutions de bibliothèques) de 1992 à 1996.² Ce modèle établit la mise en place de quatre niveaux hiérarchiques pour le catalogage d'un document, comme le montre la figure 1.1 : le niveau Œuvre, niveau le plus haut décrivant les caractéristiques abstraites de la création l'œuvre, le niveau Expression, qui englobe les caractéristiques de son contenu intellectuel, le niveau Manifestation, qui décrit les modalités de sa publication, et finalement le niveau Item, qui décrit les caractéristiques individuelles du document en tant qu'exemplaire.³




FIG. 1.1 : Entités du modèle FRBR

Le FRBR est qualifié de modèle entité-relation, qui modélise précisément les relations qui peuvent exister entre les différents niveaux de description et, de ce fait, entre les éléments d'un système d'information, afin de permettre à l'utilisateur de les retrouver plus facilement. Afin d'illustrer la manière dont s'articule la description d'un ouvrage bibliographique selon la modélisation proposée par le FRBR, prenons l'exemple de l'ouvrage *Qu'est-ce que le cinéma* d'André Bazin. Au niveau Œuvre, est décrite l'idée intellectuelle de l'ouvrage, essentiellement matérialisée par son contexte de création. Cet ouvrage, est notamment exprimé et matérialisé au sein d'un texte intégral en quatre volumes écrit entre 1958 et 1962, dont les modalités sont décrites au niveau Expression. Cette expression de l'ouvrage est notamment publiée comme édition originale aux Editions du Cerf, dont les modalités sont décrites au niveau Manifestation. Enfin, l'exemplaire individuel de cette manifestation est potentiellement conservé dans une bibliothèque avec une côte unique, dont les caractéristiques physiques sont décrites au niveau Item. Une même œuvre peut être exprimée au sein de multiples expressions, de même qu'une expression peut faire l'objet de diverses manifestations. Le foisonnement d'éléments liés à une même œuvre peut rapidement rendre complexe la navigation de l'utilisateur au sein d'un outil de gestion des collections. La description proposée par le modèle FRBR permet de distinguer les différentes étapes du cycle de vie d'une œuvre et ses différentes matérialisations, permettant ainsi une navigation plus fluide entre les éléments liés au sein d'un catalogue.

Notons qu'à ces quatre entités de premier groupe (Œuvre, Expression, Manifestation, Item), s'ajoutent deux entités de second groupe : Personnes et Collectivités. Elles expriment

² *Modèles FRBR, FRAD et FRSAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).

³ *Ibid.*

le rôle joué sur la production ou le contenu d'une ou plusieurs entités du premier groupe.⁴ Par exemple, l'auteur est relié aux niveaux Œuvre et Expression, l'éditeur au niveau Manifestation, le catalogueur au niveau Item.

Enfin, il existe des entités de troisième groupe intégrées au modèle, qui correspondent à des Concepts, Objets, Événements ou Lieux liés aux entités de premier et de second groupe.⁵

Réunies, les entités des trois groupes confondus modélisent une structure complexe caractérisée par les liens entre éléments, comme le montre la figure 1.2




FIG. 1.2 : Entités du modèle FRBR

Toutefois, dans le cadre de ce mémoire, nous nous concentrerons sur les entités de premier groupe, qui constituent les entités principales de description pour les archives audiovisuelles au sein du logiciel de gestion des collections créé par Skinsoft. Les entités de second et troisième groupe constituent moins des entités à part entière que des éléments de description contrôlés par des thésaurus.

Le modèle FRBR, fondé sur les relations entre entités, est avant tout conçu dans l'optique de faciliter la navigation de l'utilisateur au sein d'un catalogue, entre les liens qui relient les différents éléments d'une collection. Le FRBR prétend en effet répondre à quatre besoins utilisateur principaux : trouver, identifier, sélectionner, obtenir.⁶ Il permet à l'utilisateur de localiser la ressource, d'identifier si elle correspond bien à ce qu'il cherche, de la sélectionner selon ses besoins, avant d'accéder finalement à son contenu. Nous ajouterons que le besoin fondateur de la création d'un tel modèle est également celui de pouvoir visualiser et explorer les liens de la ressource identifiée avec d'autres ressources pertinentes qui y sont di-

⁴IFLA Study Group on the Functional Requirements for Bibliographic Records, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).

⁵*Ibid.*

⁶Tillett, Barbara B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.

rectement associées.⁷ Ce modèle de données se situerait donc à l'intersection de deux besoins principaux : celui d'améliorer la connaissance sur une ressource donnée en visibilisant ses relations, et celui d'améliorer l'expérience utilisateur en proposant une interface navigable et intuitive.

Notons que ces besoins s'appliquent non seulement à l'utilisateur faisant partie d'un public, au sein d'un catalogue ou d'une base de données en ligne, mais également à un utilisateur métier, interne à l'institution et gestionnaire des collections. C'est précisément sur les besoins métier de ce dernier que se concentre l'analyse de ce mémoire de recherche, puisque Skinsoft propose avant tout un outil de gestion des collections interne. De fait, les enjeux de l'implémentation et de l'adaptation du modèle FRBR se situent au cœur des ambitions d'un logiciel de gestion des collections, dont l'objectif est d'améliorer l'interface afin d'assurer l'efficacité de l'utilisateur métier.

II. Son adaptation à l'archivistique et au contexte mu- séal

Le modèle FRBR est un modèle conçu par et pour les bibliothèques. À ce jour, les bibliothèques n'utilisent plus seulement le modèle FRBR mais la somme du FRBR et de ses modèles étendus : le Fonctionnalités requises des données d'autorité (FRAD) (Fonctionnalités requises des données d'autorité) pour la description des autorités, et le FRSAD (Fonctionnalités requises des données d'autorité matière) pour la description des sujets.⁸ La somme de ces modèles constitue le modèle long (IFLA-LRM), successeur du FRBR. Le modèle FRBR est toutefois largement utilisé dans le domaine de la gestion des collections muséales. Or, sa qualité de modèle ne prétend pas normaliser la description des données, seulement d'en cadrer l'affichage. De fait, les entités proposées par le modèle FRBR peuvent paraître génériques, et doivent être soumises à une redéfinition à chaque implémentation selon le contexte donné⁹. Cette flexibilité ne doit toutefois pas nuire à l'objectif principal, celui de faciliter la navigation de l'utilisateur, en explicitant les "interrelations" entre les notices et les données produites¹⁰. Nous étudierons dans les chapitres suivants une double adaptation, celle

⁷ *Ibid.*

⁸ *Modèles FRBR, FRAD et FRSAD...*

⁹ Patrick Boeuf, « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/unauthorizedDownload/10.1515/9783598441028.2.131?action=Downloading+PDF&countDenial=true&download=true&lang=en> (visité le 07/07/2026).

¹⁰ *Ibid.*

du modèle FRBR à d'autres types de documents : objets de collections et archives, et son adaptation à différents contextes institutionnels pour une même nature de documents, celle des archives audiovisuelles.

Le modèle de données FRBR a été adapté au milieu muséal à travers une version orientée objet, le long (FRBRoo), extension du object-oriented Conceptual Reference Model (CIDOC-CRM) (object-oriented Conceptual Reference Model), l'ontologie de référence dédiée au patrimoine culturel et muséal¹¹. Il s'agit d'un modèle conceptuel général visant l'interopérabilité entre les données provenant d'institutions diverses dont les musées, centres d'archives et bibliothèques.

Ce dernier modélise une approche descriptive centrée sur les événements entourant l'objet décrit. Ainsi, les entités bibliographiques ne sont plus seulement décrites par des attributs, mais par des événements spatio-temporels qui les créent et les font évoluer selon différents contextes¹². Cette adaptation du FRBR est particulièrement pertinente pour la description de collections de musées composites et de différentes natures, pouvant englober à la fois la description de tableaux, sculptures, ouvrages, spécimens, films, etc. Tandis que le FRBR est modélisé à partir de la nature d'un document bibliographique le FRBRoo replace la description dans un contexte plus large, celui d'événements situés dans l'espace et dans le temps, événements qui peuvent agir sur n'importe quel type d'objet.

Le FRBRoo est un modèle intéressant pour la gestion des archives audiovisuelles. En effet, les Archives audiovisuelles possèdent un statut hybride au sein d'institutions patrimoniales, relevant à la fois de la création artistique, de l'œuvre et d'un archivage du réel, d'un témoignage¹³. Le FRBRoo propose deux entités pertinentes, qui pourraient permettre de distinguer l'évolution de ce double statut : l'œuvre (Individual work), et la captation ou l'enregistrement (Recording work). Par exemple, l'étape du tournage serait documentée par l'entité Captation ainsi que l'ensemble des événements et des personnes qui y sont liés, alors que le montage serait documenté par l'entité Œuvre ainsi que les événements et les personnes qui y sont liés. Le FRBRoo conserve ensuite les entités prévues par le FRBR : l'Expression, la Manifestation, l'Item.

Néanmoins, si le FRBRoo constitue une adaptation pertinente du FRBR pour le milieu muséal, sa structure trop large ne permet pas de rendre compte la nature propre du médium

¹¹Sarah L. Gillis, « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Appling-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).

¹²IFLA Working Group on FRBR/CRM Dialogue, « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).

¹³Walter Benjamin, *L'œuvre d'art à l'époque de Sa Reproductibilité Technique*, 1935.

cinématographique, qui fonde la gestion des collections audiovisuelles. Ainsi, les institutions préservatrices de collections audiovisuelles se tournent davantage vers des adaptations métier spécifiques, comme celle de la fédération des archives du film (FIAF). La FIAF propose en effet une application du FRBR spécifique aux usages métier de description des archives audiovisuelles, au sein d’un manuel de catalogage des images animées.

III. Un modèle adapté aux archives audiovisuelles : le manuel de catalogage des images animées de la FIAF

L’adaptation du modèle FRBR aux archives audiovisuelles impose une double redéfinition : elle doit prendre en compte d’une part la nature propre du langage cinématographique, et d’autre part, les spécificités des corpus audiovisuels conservés. La modélisation en différentes couches de description prévue par le FRBR est pertinente pour le cinéma, qui partage avec le milieu bibliographique un mode de production industriel, permettant ainsi de distinguer la création intellectuelle de ses copies et diffusions multiples. Toutefois, les niveaux bibliographiques classiques dits WEMI (Work, Expression, Manifestation, Item) restent limitées pour la description métier des spécificités des archives audiovisuelles.

Premièrement, alors que les bibliothèques conservent principalement des copies identiques d’une même publication, les archives d’images animées sont fréquemment amenées à gérer des objets uniques et rares tels que des *rushes*, des films amateurs, montages inachevés, copies annotées, etc.¹⁴. Pour ce type de collections, le niveau Manifestation devient obsolète, en raison du caractère inédit de leur création. Deuxièmement, la distinction du FRBR bibliographique entre l’Œuvre (l’idée de création), et l’Expression (sa réalisation) s’adapte mal au contexte cinématographique. En effet, un film prend véritablement forme au moment du tournage puis du montage, rendant ainsi l’idée d’une existence abstraite de création en amont, caduque. Il paraît alors plus pertinent d’appréhender l’œuvre cinématographique moins comme une entité abstraite en amont de son expression que comme une entité concrète ancrée dans un processus d’expression.

Afin de répondre à ces contraintes imposées par le processus de création cinématographique, la FIAF a élaboré un manuel de catalogage des images animées¹⁵. Le manuel adapte

¹⁴FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).

¹⁵Ronfard, Rémi, (PDF) *Analyse Automatique de Film - Des Séquences d’images Aux Séquences d’actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).

le modèle FRBR en le combinant aux règles descriptives RDA (Ressources, Description, Accès) dédiées aux archives, et aux normes de description des œuvres cinématographiques (EN 15744 / EN 15907)¹⁶. Le manuel se focalise sur les entités de premier groupe afin d’en repenser l’articulation et de proposer de remplacer le schéma WEMI par le schéma WVMI (Work, Variant, Manifestation, Item).

En effet la FIAF propose de fusionner le niveau Expression dans celui de l’Œuvre, permettant alors à l’Œuvre de regrouper la description intellectuelle et le processus de création de l’archive cinématographique. Par exemple, si nous prenons le film *L’Aigle à deux têtes* (France, 1948, réalisé par Jean Cocteau), le niveau Oeuvre permettrait d’y décrire le contexte de création ainsi que le contenu. De plus, la FIAF propose une nouvelle entité, celle de Variante, optionnelle, qui se substitue à celle d’Expression. Elle permet de décrire toute version différente d’une œuvre originale dans la mesure où son sens principal n’est pas altéré. Par exemple, une version d’un film qui serait colorisée, censurée, doublée, remontée, etc. Si nous reprenons *L’Aigle à deux têtes*, une variante possible est celle de la restauration du film en 4K en 2023, dont le niveau Variante permettrait de décrire les variations portées sur l’œuvre. La FIAF conserve par ailleurs le niveau de Manifestation, toutefois redéfini afin de pouvoir décrire la matérialisation physique ou numérique d’une Œuvre ou de sa Variante sur un support, ainsi que son contexte de diffusion. Par exemple, la manifestation de la version restaurée de *L’Aigle à deux têtes* décrirait la sortie de cette version en Blu-Ray et DVD chez Rimini Editions. Enfin, le niveau Item est également conservé afin de décrire l’exemplaire physique ou le fichier numérique unique issu de la Manifestation d’une Œuvre ou de sa Variante. Cet exemplaire est concrètement préservé et géré par l’institution et décrit par des métadonnées de conservation.

Cette restructuration du FRBR permet ainsi de répondre aux besoins métiers spécifiques de gestion de collections d’images animées. Selon la FIAF, la modélisation de cette réadaptation du FRBR au sein d’un outil de gestion des collections devrait permettre aux utilisateurs métier “d’identifier, sélectionner et acquérir” efficacement toutes les variantes d’une œuvre, l’ensemble des manifestations d’une version d’une œuvre, les exemplaires physiques disponibles d’une manifestation d’une œuvre¹⁷. La FIAF reprend ainsi les besoins utilisateurs fondateurs de la structuration du FRBR bibliographique en les adaptant à une nécessité de pouvoir circuler entre les différentes versions d’une œuvre à différents stades du processus de l’industrie cinématographique.

Toutefois, l’implémentation d’un tel modèle au sein d’un outil de gestion des collections se heurte aux spécificités des différents corpus audiovisuels, dont certains ne possèdent pas

¹⁶FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF...*

¹⁷*Ibid.*

de manifestation par exemple. En effet, si le modèle s’applique adéquatement aux corpus de cinéma dits ”classiques” dont la chaîne de production industrielle est respectée : un film est réalisé à l’issue d’un tournage et d’un montage (Œuvre), puis distribué (Manifestation), et copié en multiples exemplaires (Item). Or, dans le cas de corpus spécifiques, expérimentaux, personnels, ou amateurs, qui font l’objet de descriptions complexes, la modélisation FRBR classique s’avère limitée. Ce type de corpus est notamment peu distribué ou diffusé, rendant notamment le niveau de Manifestation obsolète.

Ainsi, le FRBR reste un modèle qu’il s’agit de réadapter à chaque contexte institutionnel¹⁸. Le manuel de la FIAF agit comme un cadre théorique de structuration de la description pour la globalité des archives audiovisuelles, qui subit une redéfinition pour chaque type de corpus audiovisuel : amateur, commercial, documentaire, grand public, etc.

Reproductibilité technique ?¹⁹

¹⁸P. Boeuf, « Brave New FRBR World »...

¹⁹W. Benjamin, *L’œuvre d’art à l’époque de Sa Reproductibilité Technique...*

Chapitre 2

Implémenter le FRBR adapté aux archives audiovisuelles au sein d'un outil de gestion des collections

Comme défini en introduction, un logiciel de gestion des collections est un outil “spécialisé permettant de gérer des informations structurées”¹. De ce fait, il structure le système d'information qui permet à une institution d'orchestrer le cycle de vie de sa collection. Cette structuration des données doit être modélisée selon les spécificités propres au type de collection d'une institution cliente, à partir de normes descriptives définies et de cadres de référence pour l'indexation des collections. Dans le cas des archives audiovisuelles, le logiciel des gestion des collections devrait ainsi permettre une structuration de l'information adaptée au type de corpus conservé, respectant toutefois le cadre de référence pour la modélisation des données, le FRBR. La restructuration du modèle de données permet de construire pour l'utilisateur, un logiciel de gestion des collections intelligible avec des outils de recherche performants. (En accord avec les besoins utilisateurs FRBR)

I. Un espace de travail dédié à la gestion de collections audiovisuelles : S-Movies

Si le manuel de la FIAF pose le cadre d'une adaptation du modèle FRBR pour la gestion des archives audiovisuelles, il s'agit désormais de confronter ce cadre à une implémentation concrète. Pour cela, nous analyserons au cours de ce chapitre l'implémentation d'une telle

¹*Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).

modélisation au sein d’un outil de gestion des collections, celui développé par Skinsoft. Nous y analyserons spécifiquement l’espace de travail développé pour la gestion des archives audiovisuelles : S-Movies. En effet, le contexte de notre étude se situe principalement dans le cadre de l’analyse de cet espace de travail afin d’en analyser la modélisation, en vue de l’améliorer et d’y implémenter potentiellement des fonctionnalités automatiques, fondées sur l’intelligence artificielle.

Présentons d’abord le fonctionnement général de l’outil de gestion des collections développée par Skinsoft. Celui-ci est divisé en espaces de travail, chacun dédiés à un type de collection, comme le montre la capture d’écran de la page d’accueil ci-dessous (2.1). (dire en note de bas de page que les captures viennent d’une appli de test configurée par nos soins)




FIG. 2.1 : Page d’accueil de l’espace de travail

Une institution cliente de l’outil peut combiner un ou plusieurs espaces de travail, selon les données à gérer. Cette structure permet justement d’adapter l’interface à chaque type de collection géré : objets de collection de musée, collections archéologiques, collections de films, collections bibliographiques, collections d’archives, etc. Chaque espace de travail permet notamment la gestion des acquisitions, des collections, de leurs mouvements, de projets, d’expositions, des médias... De plus, chaque espace de travail est structuré selon des normes de description et un cadre de modélisation adaptés au type de collection qui y est géré. L’espace de travail S-Movies est modélisé selon les préconisations de la FIAF sur l’adaptation du FRBR, et structuré selon les normes de descriptions évoquées. Ainsi, les collections sont organisées en trois entités distinctes, conformément aux adaptations du FRBR par la FIAF : Films, Manifestations, Œuvres cinématographiques (Films désigne ici le niveau Item), comme le montre la capture d’écran du menu de l’espace de travail, ci-dessous :

Dans chacune de ces tables de données, l’utilisateur peut créer de nouvelles notices, et




FIG. 2.2 : Menu burger de l'espace de travail

y associer des notices des autres tables. Par exemple, depuis la table Œuvres cinématographiques, l'utilisateur peut créer une notice d'Œuvre et y associer des notices de Manifestations et d'Items qui y sont directement liées. La Variante telle que définie dans le manuel de la FIAF n'est pas représentée par une entité à part entière sous la forme d'une table comme c'est le cas pour les autres entités. Toutefois, il est possible de créer une notice de Variante au sein de la table Œuvres cinématographiques, directement liée à une Œuvre. La Variante aura le même statut qu'une Oeuvre, mais elle sera de type Variante.

Par exemple ci-dessous, une notice d'Œuvre cinématographique à laquelle sont associées deux notices de Manifestation :

L'interface permet d'associer des notices depuis un bouton d'action situé à droite.

De plus, en fonction de la nature du corpus géré, un paramétrage adaptatif est prévu afin d'ajuster l'interface aux pratiques métier de chaque institution. En effet, une adaptation supplémentaire de la modélisation de données via la configuration flexible de chacun des espaces de travail. Trois configurations sont principalement possibles : le paramétrage de champs de saisie pour chaque type de notice, l'organisation de ces champs dans des grilles de résultats de recherche, et l'assemblage des champs et des grilles de recherche dans des menus navigables pour chaque type de notice. (Schémas explicatifs ?) Ce paramétrage concrétise la modélisation de données selon le cadre de référence utilisé.

Ainsi, une double adaptabilité est proposée : d'une part un espace dédié à un type de collection et structuré en fonction des normes de description et de la modélisation de données préférée, et d'autre part un paramétrage précis de l'espace de travail, propre au type de corpus géré par l'institution cliente, concrétisant ainsi la modélisation de données propre qui sera utilisée.




FIG. 2.3 : Menu burger de l'espace de travail

L'espace de travail S-Movies est pré structuré suivant la modélisation FRBR préconisée par la FIAF. Cette structure stable, permet à Skinsoft de proposer un espace de travail pré défini pour chaque institution préservatrice de ce type de collection. En revanche, les corpus audiovisuels préservés par différentes institutions peuvent être de toutes sortes, sur différentes thématiques, sous différents formats. Cette hétérogénéité suppose des règles métiers spécifiques, issues des besoins de gestion de la collection préservé. Ainsi, par exemple, une collection audiovisuelle expérimentale ou amateur ne nécessitera pas les mêmes champs de saisie, les mêmes thésaurus, ou de la même disposition des résultats de recherche, qu'une collection audiovisuelle industrielle, grand public.

Concrètement, au sein de l'espace de travail, la description d'un élément s'effectue au sein de champs de saisie, sélectionnés de manière adaptée aux besoins de description de l'institution donnée. Ces champs, s'ils sont paramétrables individuellement, font en réalité partie d'une structure plus large, à l'échelle de l'espace de travail dans lequel ils se situent. En effet, ces champs sont regroupés dans des masques, qui correspondent à des formulaires de saisie spécifiques au type de notice concerné. Par exemple, une notice de film physique, décrivant le niveau Item pourra contenir un masque de saisie, contenant des champs de saisie correspondants (cf 2.4) : identifiants, format de l'item, support de l'item, etc.

Ce masque pourra ensuite être assemblé en tant qu'onglet au sein d'un menu d'une notice de film physique, permettant à l'utilisateur d'y remplir les champs que nous avons mentionnés. Ici, le menu d'une notice de film physique qui contient le masque de saisie mentionné plus haut :




FIG. 2.4 : Configuration des masques de saisie au niveau Item




FIG. 2.5 : Configuration du menu d'une notice de film physique

Et ici la manière dont il s’affiche pour l’utilisateur, à la saisie dans une nouvelle notice de film physique :

FIG. 2.6 : Affichage du menu d’une notice de film physique à la saisie

Ce système d’organisation des masques de saisie au sein de menus permet également d’effectuer des liens avec d’autres types de notices et donc d’autres entités du FRBR. Par exemple la capture d’écran suivante 2.7, montre que dans un menu de film physique, les onglets Œuvre liée et Manifestations liées permettent d’obtenir une grille de recherche, au sein d’une notice de film physique, affichant l’Œuvre liée au film et les Manifestations dont il découle.

L’affichage pour l’utilisateur au sein de la notice de film physique est le suivant, avec d’une part, l’Œuvre liée(2.8, et d’autre part, les Manifestations liées 2.9 :

Toutefois, les espaces de travail structurés sur le modèle FRBR, comme c’est le cas de S-Movies, requièrent un niveau de configuration supplémentaire, afin de concrétiser le découpage de la description en niveaux hiérarchiques. C’est le rôle des méta-masques, des formulaires de masques de saisie pouvant cibler les champs de plusieurs types de notices –et donc plusieurs niveaux du FRBR à la fois, afin d’imbriquer ces niveaux de description au sein d’une même notice. Ce système permet à l’utilisateur de saisir implicitement des éléments de description sur plusieurs niveaux du FRBR en une seule notice, permettant de surcroît au système de produire un héritage des champs d’un niveau à l’autre du FRBR.

Concrètement, dans S-Movies, la notice d’Œuvre/Expression pointe sur les champs de l’Œuvre et de l’Expression, la notice de Manifestation pointe sur les champs de l’Œuvre, l’Expression et la Manifestation, la notice de l’Item pointe sur l’Œuvre, l’Expression, la Ma-




FIG. 2.7 : Configuration de grilles de recherche pour l'affichage des éléments liés




FIG. 2.8 : Affichage des Oeuvres liées dans une notice d'item




FIG. 2.9 : Affichage des Manifestations liées dans une notice d'item

nifestation et l'Item. **(Faire un schéma explicatif) (citer le mode d'emploi interne ?)**. Ce mode de paramétrage de la description permet d'intégrer aux niveaux du FRBR inférieurs des champs hérités des niveaux supérieurs.

2

Ici par exemple (2.10), un méta masque de saisie pour une notice de film physique, ciblé sur l'expression, le film physique, la manifestation de film physique, l'œuvre cinématographique :

À droite, les champs disponibles signalent à quel niveau de description ils appartiennent. Par exemple ci-dessus (2.10), le champ description appartient au niveau Œuvre, le champ dimensions appartient au niveau Manifestation.

Ces masques et méta masques créent ainsi une structure pérenne qui fait l'objet d'un paramétrage individuel qui permet d'ajuster la structure en fonction du type de collection et des usages métiers du client concerné. Ce paramétrage est défini au cours d'un travail de mapping entre les données client et la structure proposée par Skinsoft, afin de trouver un accord sur les champs qui seront utilisés pour la description des collections. L'équipe de Skinsoft organise ensuite ces champs dans des formulaires de saisie (masques et méta masques), eux-mêmes organisés pour constituer des menus de notice et des grilles de résultats de recherche. L'équipe produit également des imports de thésaurus propres aux usages de

²Notons que la présence du niveau Expression contredit le modèle FRBR préconisé par la FIAF, qui fusionne le niveau Expression dans celui d'Œuvre. Etant donné que Skinsoft possède d'autres espaces de travail modélisés sur le FRBR, comme c'est le cas de l'espace dédié à la gestion des collections bibliographiques, le niveau Expression existe seulement en théorie, mais inutilisé en pratique au sein de S-Movies.




FIG. 2.10 : Configuration d'un méta-masque au niveau Item

l'institution en question, afin d'assurer l'interopérabilité des données saisies.

Les fondements de l'architecture de S-Movies, doublement adaptée d'une part aux collections cinématographiques et d'autre part aux pratiques métiers spécifiques à chaque institution, constitue la condition de la qualité des données et de l'expérience utilisateur. L'enjeu de l'espace de travail est d'offrir une interface qui permette à l'utilisateur de décrire les collections en plusieurs niveaux sans difficulté et de pouvoir circuler entre ces niveaux et les liens qu'ils entretiennent. Cette circulation est notamment permise par les grilles de recherche que nous avons évoquées dont le paramétrage permet d'afficher les entités liées pour chaque notice. De plus, les différents outils de recherche permettent de circuler au sein des éléments de description indexés. (À développer ?)

Toutefois, malgré la haute configurabilité de l'interface, l'hétérogénéité des corpus audiovisuels gérés d'une institution à l'autre complexifie le travail de mapping qui doit être effectué. En effet, la modélisation FRBR préconisée par la FIAF est un cadre qu'il s'agit d'ajuster aux pratiques spécifiques de gestion des collections, elles-mêmes adaptées au type de corpus géré. L'ajustement à des corpus audiovisuels spécifiques complexifie potentiellement la fluidité de la navigation entre les liens des différentes entités du FRBR au sein de l'interface.

II. L’inscription des corpus de données dans la remodelisation du FRBR

En effet, la nature du corpus audiovisuel complexifie le paramétrage puisqu’elle conditionne la capacité des données à s’adapter et s’intégrer au sein du modèle FRBR. Le modèle FRBR fait partie d’une structure fixe de l’espace de travail, avec cette séparation en trois tables de saisie (Œuvres, Manifestations, Films), dont le paramétrage peut toutefois amoindrir la rigidité. Afin d’analyser la mesure dans laquelle les corpus s’intègrent au sein du modèle FRBR, nous analyserons dans cette sous partie deux corpus de données différents gérés au sein de l’application Skinsoft.³

Premièrement, analysons l’intégration d’un corpus de cinéma dit ”classique”, au sein de l’espace de travail S-Movies. Cette collection est gérée par une institution qui préserve essentiellement des films de fiction issus d’une production commerciale ”grand public” depuis les débuts du cinéma jusqu’à nos jours. Cette collection est composée d’œuvres cinématographiques à proprement parlé, dont la description prend tout son sens au sein d’une modélisation selon le FRBR. La production cinématographique étant une production industrielle, les films qui en sont issus s’adaptent particulièrement bien à un modèle de données par niveaux, ces différents niveaux correspondant aux étapes de production. Ces films, après leur création, ont donc été produits et distribués à une échelle plus ou moins large. Ainsi, dans ce cas précis, le modèle FRBR est plutôt bien adapté. La réalisation du film par le montage et le tournage est décrite au niveau Œuvre, ses versions sont décrites au niveau variante, son édition et sa distribution sont décrites au niveau Manifestation, et l’exemplaire individuel du film, conservé par l’institution est décrit au niveau Item. De fait, le paramétrage décrit dans le chapitre précédent peut être réalisé sans trop de complexité au sein du cadre modélisé par le FRBR de la FIAF. (Développer + ?)

Deuxièmement, analysons l’implémentation d’un corpus plus spécifique, celui d’une collection de *rushes* documentaires muets et non montés, tournés des années 1910 à 1920. Les *rushes* en termes cinématographiques correspondent à des épreuves de tournages non montées⁴ Ces *rushes* bruts, ont été tournés dans une optique de documentation sur différents sujets, et ne sont pas destinés à une diffusion auprès du grand public.

Dans ce cas, l’absence de montage et de distribution commerciale rend difficile l’adaptation du corpus à la modélisation prévue par la FIAF, qui structure S-Movies. Si le contexte de création du tournage peut être décrit au niveau Œuvre, les niveaux de description inférieurs

³Notons que pour des raisons de confidentialité, nous décrirons les corpus de ces institutions sans les nommer de manière explicite.

⁴universalis..

sont inadaptés. En effet, en l’absence de montage, la Variante n’existe pas puisque chaque *rushe* correspond à une matière brute et unique. Ainsi, l’absence de différentes versions d’une même œuvre invalide l’entité de Variante.

De la même façon, le niveau Manifestation perd de sa pertinence descriptive puisque ces *rushes* ne sont ni produits ni distribué officiellement auprès d’un public. L’inscription de l’œuvre sur un support s’effectue ici de manière unique, et en un seul et même exemplaire. Les caractéristiques matérielles pourraient donc être décrites directement au niveau de l’item. Ainsi, d’un modèle à quatre niveaux, il ne reste, dans ce cas précis, plus que deux niveaux de descriptions exploitables : l’Œuvre et l’Item. Toutefois, notamment pour des raisons de conservation, une œuvre peut être copiée sur différents supports, physiques ou numériques. En effet, l’institution peut être amenée à produire des copies d’une œuvre sur des supports plus stables à des fins de préservation ou de diffusion en ligne, par exemple. Ces différentes matérialisations, bien qu’elles ne soient pas issues d’un processus commercial de distribution, peuvent être décrites comme des Manifestations. Telle que définie par le manuel de la FIAF, une manifestation induit en effet, ”tous les médias analogiques, numériques et en ligne associés à une matérialisation particulière d’une Œuvre/Variante.”⁵. Sa description peut alors être justifiée par des objectifs de conservation : copie, numérisation, restauration. Selon le FIAF, la description d’une Manifestation inclut les attributs suivants, -ici sélectionnés selon leur niveau de pertinence pour un tel corpus : type de manifestation, format (incluant les champs suivants : type de support, caractéristiques sonores, caractéristiques de couleur), notes.

Or, si théoriquement le niveau Manifestation peut être décrit, en pratique dans le cas de la description de ce corpus produite par l’institution, il ne l’est pas. Est-ce que le modèle de description utilisé en pratique correspond au modèle à deux niveaux présentés brièvement par la FIAF ?

Si au sein d’une notice d’œuvre, les champs suivants sont décrits : identification, titre, créateur, description (sujet de la prise de vue), mots clés, films associés, manifestations associées, matériel non-film associé, archives associées, bibliographie, médias, données de gestion ; la table Manifestations, en revanche, contient un nombre conséquent de notices vides. En effet, l’application Skinsoft crée automatiquement une notice de manifestation liée lorsque l’utilisateur crée une notice d’item. Dans ce cas, l’entité Manifestation devient une condition structurelle afin de maintenir la cohérence du modèle, mais perd son sens au sein d’un contexte d’indexation concret. La table des items, quant à elle, est répartie en trois catégories d’objets : bobines, cassettes —qui constituent les films physiques— et films numériques. Lorsqu’un même film physique est présent en plusieurs exemplaires dans la collection, les notices sont distinguées par la mention ”bobine originale” et ”reproduction”. Les notices de

⁵FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF...*

films physiques contiennent une description matérielle sur le support et la condition de ce support. Elles mentionnent également les collections liées vers d'autres Items et Œuvres, vers des médias et des documents. La manifestation référente est tout de même mentionnée mais il s'agit, nous l'avons évoqué, d'une notice factice. Enfin, les films numériques décrivent le support original depuis lequel la numérisation a été effectuée, les raisons de la numérisation —par exemple, copie de sauvegarde—, et l'item physique qui a fait l'objet de cette numérisation.

Par ailleurs, un élément précis a retenu notre attention dans le cadre de notre étude. En effet, la présence de *time-codes* —marqueurs temporels dans des notices de films numériques, traduisant l'inscription de la copie numérisée dans une œuvre plus large. En effet, certaines Œuvres-rushes, dont les modalités matérielles sont décrites dans une notice de film physique, ont été divisées en extraits puis numérisées. Étant donné que les Œuvres conservées sont des rushes non montés, cette division en extraits a pour but de réaliser une forme de montage et de rendre ces films intelligibles via une diffusion en ligne. Ainsi, la plupart des films numériques gérés au sein de S-Movies sont issus de ce découpage depuis les rushes originaux. Les repères temporels expriment le rattachement précis de l'item numérique au sein d'un item physique.

Ainsi, la modélisation de données adaptées à ce corpus audiovisuel précis s'apparente à un modèle hiérarchique à deux niveaux, celui d'une Œuvre matérialisée dans une Manifestation/Item, fusionnés en une seule entité. Cette hiérarchie à deux niveaux est brièvement décrite dans le catalogue de la FIAF en tant qu'exemple, mais ses modalités ne sont pas détaillées. (À développer ?)

Développer davantage le schéma de données que ça produit dans l'appli client ? Avec un schéma ? À partir des captures d'écran suivantes : schématiser les liens complexes entre éléments pour le corpus en question

Par exemple : Une notice Œuvre est liée à un item numérique, lui-même lié à un ou plusieurs films physiques : cassette, bobine, avec le time code mentionné pour traduire la place de l'extrait/film numérique au sein de ces supports physiques.

Les films physiques : contiennent la liste des films numériques qu'ils ont pour extrait + les différentes reproductions du film physiques sur d'autres supports physiques : plusieurs bobines, plusieurs cassettes (à des fins de conservation)

Si l'espace de travail S-Movies parvient à maintenir le modèle du FRBR en trois niveaux principaux pour les corpus audiovisuels standards, la description de corpus plus spécifiques éclipse notamment le niveau Manifestation pour ne conserver qu'une hiérarchie à deux niveaux. L'analyse de l'inscription d'un corpus donné au sein de la modélisation de données proposée par S-Movies soulève des interrogations sur la fluidité de la navigation de l'utilisateur au sein de l'interface. En effet, le caractère brut du corpus observé nécessite une




FIG. 2.11 : Modèle hiérarchique à deux niveaux schématisé par le manuel de la FIAF

description fine du contenu afin de restituer une intelligibilité, d’habitude produite par le montage, qui doit être prévue par une saisie ergonomique au sein de l’interface. Afin d’adapter l’espace de travail à des corpus aussi spécifiques, l’éditeur Skinsoft engage notamment une démarche de refonte de S-Movies, dont l’objectif est de repenser d’une part l’interface fondée sur le FRBR, et d’autre part d’intégrer des fonctionnalités innovantes d’indexation automatique afin d’assister l’utilisateur dans la description des collections. C’est dans ce contexte d’innovation technique que s’inscrit notre stage, au cours duquel nous avons étudié l’usage de S-Movies afin d’en améliorer l’expérience utilisateur, et ainsi préparer l’implémentation de fonctionnalités automatiques pour la description des collections audiovisuelles.

III. Vers une refonte de S-Movies

Si le cadre posé par la modélisation FRBR s’avère limité pour des collections spécifiques telles que celles que nous avons analysé, le modèle induit des difficultés plus globales au niveau de l’interface et de la navigation utilisateur. Le FRBR est fondé sur des besoins utilisateurs dont l’objectif serait “d’identifier, sélectionner et acquérir” efficacement l’ensemble des éléments décrits et répartis entre différents niveaux hiérarchiques⁶. Ces besoins semblent respectés au sein de l’interface S-Movies, via la navigation permise entre les entités et les outils de recherche disponibles. Toutefois, une double complexité subsiste dans l’implémentation de la modélisation FRBR au sein d’une interface. D’une part, il reste complexe de mettre en place une interface intuitive permettant à l’utilisateur de connaître immédiatement le rôle descriptif de telle entité du FRBR et sa place au sein de la hiérarchie du modèle. D’autre part, la visualisation des liens entre les entités du FRBR reste limitée, puisqu’elle supposerait des développements supplémentaires innovants tels que la visualisation en graphe, par exemple.

Parmi les complexités d’interface révélés par l’expérience utilisateur, certains éléments semblent anodins. Par exemple, l’affichage d’une hiérarchie inversée du FRBR dans le menu de l’application, pouvant nuire à l’intuitivité du rôle de chaque entité pour la description des collections. En effet, au sein du menu, les tables sont présentées de telle manière à ce que le plus bas niveau du FRBR (l’item) apparaisse en haut, suivi de la manifestation et du plus haut niveau (l’œuvre). Cet affichage visuel descendant peut induire en erreur l’utilisateur sur la navigation hiérarchique à employer au sein du modèle. De plus, au sein de S-Movies le plus bas niveau de la hiérarchie (l’Item) est désigné par la notion de “Film”. Or, dans un contexte cinématographique, le film peut communément désigner à la fois une œuvre et un item individuel. La notion de film n’évoque pas le caractère unique et individuel de l’exemplaire tel qu’il est défini par le manuel de la FIAF. Une autre confusion terminologique

⁶*Ibid.*

potentielle peut être créée par la présence de la notion d’Expression, alors même que ce niveau, issu du modèle FRBR bibliographique, est fusionné dans celui d’œuvre.

La visualisation des liens entre les entités descriptives au sein de l’interface est également motrice d’améliorations au sein de l’espace de travail. L’interface actuelle permet, après configuration, de visualiser les liens d’une notice avec d’autres notices issues de niveaux différents du FRBR. Or, il serait pertinent pour l’utilisateur d’avoir la possibilité de visualiser les liens entre entités à un niveau plus large, et de manière graphique. Par exemple, il serait pertinent de pouvoir visualiser, au niveau d’une notice Œuvre, l’ensemble des manifestations dans lesquelles elle est matérialisée, ainsi que tous les exemplaires issus de ses manifestations respectives et conservés par l’institution. Cette visualisation des liens pourrait être étendue de manière plus large au niveau de la table d’une entité, ou de celui de la collection de l’institution.

Par ailleurs, la mise en place de liens indissociables entre entités prévus par le modèle FRBR nécessitent, au sein de l’interface, des configurations spécifiques complexes. En effet, l’indissociabilité des liens entre les entités suppose que l’interface rende obligatoire pour l’utilisateur l’association de certaines notices entre elles. Par exemple, un Item doit obligatoirement être lié à une Manifestation et/ou à une Œuvre. Or l’obligation de ces liens n’est pas encore prévue par l’interface, laissant ainsi la possibilité à l’utilisateur de créer un Item sans Œuvre liée par exemple. De même, l’interface permet par exemple la suppression d’une notice Œuvre et de tous ses éléments liés (notices de Manifestations et d’Items), sans avertissement préalable.

Ces difficultés d’interface sont en réalité issues de la complexité de traduire un cadre de modélisation défini, en termes d’expérience utilisateur. Cette traduction est cruciale afin d’assurer la qualité des données indexées au sein de l’interface. En effet, l’intuitivité de l’interface permet à l’utilisateur de diviser la description d’un objet entre les différents niveaux prévus par l’application, et d’associer ces niveaux entre eux afin qu’ils soient requêtables au sein de l’interface. L’absence d’intuitivité peut notamment empêcher l’héritage des données entre les différents niveaux, dans le cas d’une notice dépourvue de liens, par exemple. L’interface doit ainsi assurer la qualité des données en instaurant une circulation intuitive au sein du modèle FRBR.

Transition interface utilisateur > et projet IA :

L’analyse de l’espace de travail S-Movies a permis d’étudier la manière dont le modèle FRBR structure l’architecture des relations entre entités, permettant la description des collections. Toutefois, la qualité de ce système repose moins sur la description que sur l’indexation des collections. L’indexation désigne la mise en place d’une description contrôlée et normalisée en lien avec des thésaurus, par exemple, permettant de concrétiser les besoins

utilisateurs fondateurs du modèle FRBR. En effet, c’est l’indexation qui permet à l’utilisateur d’accéder à des objets de collection via des requêtes contenant des éléments de description indexés. Cette opération d’indexation peut s’avérer complexe et chronophage dans le cas de corpus tels que nous avons analysés, poussant un éditeur d’outil de gestion des collections à proposer des outils d’assistance automatique. En effet, Skinsoft souhaite par exemple intégrer à S-Movies des fonctionnalités d’indexation fondées sur l’intelligence artificielle capables d’effectuer une segmentation d’extraits vidéo et de décrire ces extraits afin de les indexer au sein du modèle FRBR.

.

Chapitre 3

Le projet d'une indexation automatisée des archives audiovisuelles, conditionnée par le modèle en place

L'architecture modélisée par le FRBR que nous avons décrite jusqu'ici a pour objectif de fonctionner de permettre la recherche, la navigation et l'accès aux données dans un logiciel de gestion des collections. Le modèle définit la structure dans laquelle s'inscrivent les métadonnées issues de la description des collections. Toutefois, c'est véritablement l'indexation qui alimente les différentes entités du FRBR et qui rend les données requêtables, navigables et accessibles.

L'indexation de collections audiovisuelles implique un travail d'extraction du contenu conséquent, en particulier dans le cas de corpus audiovisuels opaques, non montés tels que nous avons décrits. Il revient à l'utilisateur métier d'identifier à partir de l'archive, des événements, des lieux, des personnes et même, dans le cas du corpus analysé, des découpages temporels et thématiques au sein du flux vidéo. Ces éléments doivent ensuite pouvoir être inclus dans une ou plusieurs entités du modèle FRBR. Face à la masse potentielle des collections, l'indexation peut s'avérer laborieuse et chronophage, justifiant ainsi la mise en place d'une indexation automatisée afin d'assister l'utilisateur dans cette tâche. Toutefois, avant de pouvoir proposer des algorithmes adéquats, il est essentiel de comprendre les mécanismes et les tâches induits par l'indexation documentaire des images animées.

Norme de description RDA préconisée par la FIAF

I. Indexation

L’indexation documentaire peut être définie de la manière suivante :

”L’indexation est cette technique consistant à caractériser le contenu d’un document et l’information qu’il détient de manière à le retrouver quand on effectue des recherches sur l’un des sujets dont il traite. [...] L’indexation permet de s’orienter dans la masse des documents et d’organiser ses connaissances. ”¹

Afin de ”fournir un point d’accès sûr et vérifié à l’information”, l’indexation implique la mise en relation des termes produits par la description avec des référentiels, des thésaurus et des listes d’autorité, afin de pouvoir les intégrer au modèle de données.² Ainsi, par exemple, le réalisateur d’un film est indexé au niveau Œuvre, par une liste contrôlée d’autorités prévue par l’outil de gestion des collections.

La structuration des métadonnées d’indexation permet d’améliorer la découvrabilité de ces métadonnées via des outils de recherche et la navigation entre les différentes connaissances produites.³ Une indexation reliée à des thésaurus contrôlés permet notamment à l’utilisateur d’effectuer des requêtes croisées complexes au sein de l’outil de gestion des collections. Cette tâche, prévue par le logiciel, effectue le lien indispensable entre la description produite et l’exploitabilité des données par l’utilisateur via des outils de recherche. À terme, l’indexation permet l’interopérabilité des données et leur partage sur le web.⁴

Toutefois, la nature des archives audiovisuelles complexifie l’indexation pour l’utilisateur. En effet, nous l’avons évoqué, de telles archives se constituent comme des “boîtes noires”, nécessitant le matériel de lecture adéquat afin d’en extraire le sens et de pouvoir l’indexer. De plus, l’indexation du corpus que nous avons décrit, composé de rushes documentaires, suppose en amont la division du flux vidéo en différentes unités de sens thématiques. La description ne peut pas s’appliquer de manière précise dans le cas d’un document vidéo brut contenant de multiples séquences spatio-temporelles. Dans le cas de ce type d’archives audiovisuelles, la segmentation temporelle constituerait alors la condition préalable à toute opération d’indexation.

¹Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

²*Outils pour l’indexation des archives à l’heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).

³*Ibid.*

⁴*Ibid.*

II. Segmentation

Dans le cas des archives audiovisuelles, une indexation fine ne peut s’effectuer à l’échelle du fichier brut dans sa totalité, en particulier lorsqu’il s’agit de rushes contenant une succession importante de séquences non montées. Afin de rendre le contenu de telles archives exploitable au sein d’un modèle de données cohérent, il est indispensable d’analyser finement le flux continu de l’image via une tâche de segmentation. Cette opération est à l’origine de questionnements autour de l’intelligibilité du document audiovisuel :

”Quels sont les mécanismes qui permettent d’in-terpréter cette longue séquence d’images [...] en une séquence d’actions dramatiques, reliées entre elles par des liens de causalité, et qui nous permettent d’en comprendre le sens (l’histoire) ? ”⁵

L’intelligibilité du document audiovisuel passerait ainsi par une interprétation, via une segmentation de l’enchaînement des images afin d’en extraire le sens. La segmentation revêt, dans le cadre de l’indexation d’archives audiovisuelles, une dimension essentiellement temporelle, dans l’optique de découper un flux vidéo selon certains critères. Il s’agit d’un découpage conceptuel et non d’un montage technique qui modifie le sens de l’image animée. La segmentation s’imposerait comme la condition d’une indexation fine puisqu’en apposant à des séquences des balises temporelles, elle permettrait de rendre possible ”la production de descriptions structurées”.⁶ Ces balises temporelles délimitent des ensembles homogènes au sein d’une archive audiovisuelle, à la manière de chapitres dans un ouvrage textuel⁷. Si la structuration de certains types de contenus audiovisuels tels que les journaux télévisés, le sport, la publicité, sont ”relativement stable et explicite de leur structure”, et peuvent alors facilement être segmentés, les archives audiovisuelles regroupent des corpus divers et variés à la structure aléatoire qui rendent complexe cette tâche⁸

La segmentation s’applique particulièrement bien au corpus d’archives audiovisuelles composé de rushes documentaires, que nous avons décrit. En effet, au sein du logiciel prévu par Skinsoft, la segmentation est pratiquée par l’institution patrimoniale préservant ces archives, qui associe des repères temporels à des extraits numérisés et issus de rushes filmés plus larges. Cette pratique permet d’extraire des rushes certaines séquences jugées importantes à indexer de manière précise. Ces séquences sont ensuite rendues intelligibles par l’indexation

⁵Ronfard, Rémi, (*PDF*) *Analyse Automatique de Film - Des Séquences d’images Aux Séquences d’actions...*

⁶Peter Stockinger, *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l’Information).

⁷*Ibid.*

⁸Jean Carrive, « Chapitre 4. Analyse automatique de l’image et du son pour l’enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.

de leur contenu précis et deviennent requêtables de manière autonome au sein du modèle de données.

La segmentation répond donc à un objectif fixé par l’indexation, celui d’agir comme “un filtre de pertinence” sur les éléments à indexer⁹. Sa mise en place suppose d’en définir la granularité (analyse au niveau du plan, du changement de plan, de scènes, de séquences, etc), afin d’isoler les éléments d’analyse¹⁰. Ce travail d’analyse s’articule autour de trois types de segmentation, conditionnée par la nature du médium cinématographique. En effet, la segmentation temporelle est non seulement conditionnée par l’image mais également par le son, composant essentiel des documents audiovisuels¹¹. La segmentation temporelle suppose également une segmentation spatiale, induisant l’analyse de la situation des éléments dans l’image¹². Enfin, une segmentation sémantique intervient, apposant une description aux éléments extraits, permettant de produire un découpage logique¹³. Les catégories sémantiques sont prédéfinies par l’utilisateur et peuvent être de plusieurs types conformément à la nature de l’image animée. Ces catégories peuvent être d’ordre technique, relationnelles, de contenu, de mouvement, etc.

Parmi ces trois types de segmentation, seule la segmentation temporelle est spécifique à l’image animée, puisqu’elle analyse la différence temporelle et de mouvement entre les plans ainsi que les relations qu’ils entretiennent, afin de pouvoir en extraire des séquences distinctes. Les segmentation spatiales et sémantiques sont, en revanche, également applicables à l’image fixe.

Ce processus de segmentation s’inscrit directement dans l’architecture du modèle FR-BR. Les segments temporels créés sont décrits et indexés comme des nouvelles entités et rattachés aux entités pertinentes du modèle. C’est dans le contexte de l’indexation de grands volumes d’archives et spécifiquement de corpus complexes que peut être envisagée la mise en place d’une automatisation de la segmentation, puis de l’indexation. Selon Attard, la mise en place d’une segmentation automatisée permettrait “d’accélérer le traitement de grands volumes vidéo tout en garantissant la cohérence du processus” (traduction : *automated segmentation accelerates the processing of large volumes of video content and ensures consistency and accuracy in the segmentation process.*)¹⁴.

⁹P. Stockinger, *Les archives audiovisuelles...*

¹⁰*Ibid.*

¹¹J. Carrive, « Chapitre 4. Analyse automatique de l’image et du son pour l’enrichissement de contenus audiovisuels »...

¹²Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

¹³*Ibid.*

¹⁴Jonathan Attard et Dylan Seychell, *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848

Toutefois, l’efficacité promise par l’automatisation de la segmentation et de l’indexation ne pourra être mise en place qu’à la condition selon laquelle les algorithmes d’apprentissage automatique puissent produire ces tâches selon des règles métiers précises et un modèle de données explicite. En tant qu’éditeur de logiciel de gestion des collections, Skinsoft ambitionne de résoudre ces complexités afin d’intégrer ces nouvelles fonctionnalités au sein de l’espace de travail S-Movies. Dès lors, il convient d’examiner les directions adoptées par l’éditeur afin de proposer une automatisation innovante conditionnée par une structure de données complexe.

III. **Projet SKAI**

La mise en place d’une indexation automatique, visant à faciliter le travail des utilisateurs et à le rendre efficace, s’inscrit dans un projet de mise en place de l’intelligence artificielle à une plus large échelle au sein de l’application chez Skinsoft, afin d’automatiser et de faciliter les pratiques de gestion des collections. L’intelligence artificielle (IA) peut être définie ainsi :

Par IA, on entend, dans une acception large et ouverte, la tentative de construire des machines et des systèmes capables de penser et d’agir rationnellement.

15

L’objectif serait alors celui de rendre ces systèmes capables de pouvoir raisonner afin d’effectuer les mêmes actions que l’homme. Dans le cadre d’un système de gestion des collections, cela signifie que les systèmes d’intelligence artificielle devront effectuer des tâches documentaires complexes. Cette implémentation s’inscrit donc dans cadre défini par l’éditeur, qui donne la direction de développement de ces ”machines”, dans un contexte patrimonial.

L’implémentation de l’IA au sein de l’application n’est pas seulement issue d’une logique “produit”, mais elle est davantage centrée sur l’amélioration de l’expérience utilisateur. L’une des caractéristiques majeures de l’application, nous l’avons dit, est sa flexibilité et son adaptabilité aux spécificités des collections et des règles métier. La mise en place de l’IA permettrait de mettre cette adaptabilité en place plus efficacement et à plus large échelle. Automatiser la migration de données, le paramétrage de l’application, la navigation dans l’application permettrait à l’entreprise de satisfaire ses clients plus rapidement et de gérer ainsi de multiples contrats. Cette volonté d’implémenter l’IA s’inscrit notamment dans l’appel à

[cs.CV].

¹⁵Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L’apprentissage Automatique Dans Les Archives : L’indexation En Profondeur Au Service de l’accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

projets ”France 2030” qui couvre la maîtrise des technologies numériques et le ”déploiement de l’innovation”¹⁶. Ce projet finance des initiatives à l’intersection de la culture, du numérique et de l’IA.

Toutefois, la question du besoin est centrale, pour une utilisation de l’IA éthique. En effet, l’IA est-elle une fonctionnalité attendue côté client ? Comme le mentionne le ministère de la culture : ”il ne s’agit pas d’utiliser l’IA par défaut, mais d’abord d’examiner le besoin à couvrir et de vérifier la capacité des systèmes d’IA à satisfaire ce besoin dans des conditions optimales ; le cas échéant, de favoriser des alternatives moins consommatrices que l’IA si elles sont suffisantes à répondre au besoin”.¹⁷ L’objectif est double pour Skinsoft. La mise en place de l’IA dans l’application permettrait d’autonomiser les institutions sur leur usage du logiciel et d’être plus productifs dans l’indexation de leurs collections. Ainsi, les équipes Skinsoft seraient moins sollicitées pour des difficultés liées à l’usage de l’application qui pourraient être réglées par une machine intelligente. Pour répondre à ces objectifs, Skinsoft prévoit notamment la mise en place d’une recherche en langage naturel, c’est-à-dire de permettre à l’utilisateur d’effectuer des recherches plus facilement en utilisant un langage naturel—son propre langage— plutôt qu’un langage contrôlé. L’objectif est ainsi de rendre l’utilisation de l’application plus simple, et d’améliorer l’efficacité de la gestion de collections.

Toutefois, l’implémentation de l’IA pour la création de contenus structurées soulève des questions éthiques dès lors que l’objectif de l’indexation est de produire des connaissances pour la transmission auprès du public. De plus, les pratiques documentaires, nous l’avons vu, sont des pratiques normalisées par des modèles de données (FRBR), des normes, des référentiels, afin d’assurer leur interopérabilité.

Ainsi, Skinsoft porte des points d’attention au projet. Les moteurs d’intelligence artificielle implémentés devraient faciliter le travail des utilisateurs et être construits comme des outils de proposition, sans réaliser entièrement eux-mêmes la production de connaissance. L’humain est toujours intégré au sein de la chaîne de travail dans la définition du projet, en étant le décisionnaire de ce que produit l’IA.

Concrètement, Skinsoft souhaite mettre en place différents moteurs d’intelligence artificielle, entraînés sur des données patrimoniales, et dédiés à l’automatisation partielle de tâches métier dans l’application. Parmi ces tâches, il est prévu l’automatisation de l’indexation au sens large au sein de l’application, et notamment appliquée aux archives audiovisuelles, dans S-Movies. Si, pour les images fixes, peut être mise en place une analyse automatique de leur

¹⁶France 2030 : un plan d’investissement pour la France / *economie.gouv.fr*, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).

¹⁷La stratégie du ministère pour des intelligences artificielles culturelles et responsables / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).

contenu afin de l’indexer, l’indexation automatique des archives audiovisuelles se découpe, elle, en plusieurs sous-tâches, propres à la nature du médium cinématographique.

Ainsi, le moteur d’intelligence artificielle dédié à l’indexation des archives audiovisuelles se divise en plusieurs sous-moteurs, dédiés à l’analyse de la coordination du son avec le mouvement des images et leur contenu. Concrètement, cela désigne les tâches automatiques suivantes : transcription et analyse du son, reconnaissance des locuteurs, segmentation et analyse des images en mouvement, qui induit à elle-même, nous le verrons d’autres sous-tâches, une reconnaissance des voix des interlocuteurs, transcription du texte présent dans l’image. Les données extraites de ces tâches automatiques devront être automatiquement inscrites dans des référentiels (thésaurus) afin d’assurer leur interopérabilité. Par exemple, lors de la reconnaissance d’un locuteur, son nom doit pouvoir être relié à sa notice d’autorité dans l’application.

La segmentation désigne la division d’images en mouvements en plusieurs séquences. Une séquence au cinéma peut être définie comme suit : ”La séquence est une unité d’action, un fragment du film qui raconte en plusieurs plans une suite d’événements isolable dans la construction narrative.”¹⁸

Ce besoin de séparer un film en différentes séquences est issue d’un besoin client, celui du second corpus d’archives audiovisuelles que nous avons décrit. En effet, ce corpus contient essentiellement des *rushes*, donc des images en mouvement brutes dépourvues de montage. Le client souhaiterait ainsi avoir un outil qui détecterait automatiquement les changements de séquences, pour pouvoir les décrire individuellement, et ainsi éviter de décrire des *rushes* dans leur entiereté. Des marqueurs temporels sont déjà présents dans les données de ce client, au sein des notices Oeuvres, afin de délimiter les *rushes* en séquences pertinentes. L’objectif est alors d’automatiser l’apposition de marqueurs temporels sur la vidéo en détectant les changements d’actions, de lieu, d’objets ou de personnages, marquant le passage d’une séquence à une autre. Si elle est dédiée au besoin d’un client précis, cette fonctionnalité pourra être toutefois étendue à toutes les institutions préservatrices de collections audiovisuelles.

La volonté d’automatiser les pratiques documentaires vise à faciliter l’expérience utilisateur, mais elle ne répond pas pour l’instant aux problèmes soulevés par la modélisation de S-Movies par le FRBR. La mise en place de l’IA ajoute simplement de nouvelles fonctionnalités afin de fluidifier le travail documentaire. Ainsi, il s’agit de proposer dans un premier temps des améliorations d’interface relatives au modèle FRBR pour pouvoir, à terme, y inscrire une indexation automatique fondée sur un processus de segmentation. Il s’agit également d’analyser la manière dont l’automatisation pourrait modifier les pratiques et le modèle de données au sein de l’interface, et penser les améliorations en fonction de ces éléments.

¹⁸Marie-Thérèse Journot, *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.

segmentation » découper la vidéo en segments analysables » pour pouvoir les décrire et ainsi les indexer » inscrire ces descriptions dans la hiérarchie documentaire » mais cette hiérarchie n’est pas claire pour le moment (II)

Deuxième partie

Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR

Chapitre 4

Traitement audiovisuel

Les tâches d'analyse automatique pouvant être appliquées aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent davantage vers le media vidéo, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance¹. Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. Si la détection automatique des plans dans un flux vidéo est maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image, la détection sémantique de séquences reste inexploitée. Comme le souligne Bhargav dans quel article ? et ses coauteurs, "pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques. [Traduction personnelle]"².

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle et d'indexation automatisée. Au courant de notre proposition, la segmentation est moins considérée comme un prérequis technique que comme une fonctionnalité documentaire à part entière, directement articulée à l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées au domaine des humanités numériques. Nous établirons ainsi un état

¹Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

²"reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material" Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240

des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

I. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont globalement désignées sous le terme de Audiovisual Processing (AVP)³.

Appliquées à un grand nombre de données, ces technologies permettent de passer du "close" au "distant viewing", c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble.⁴ Les tâches de traitement automatique permettraient en effet de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données afin d'en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

De nombreux projets sont dédiés à l'analyse automatique de corpus audiovisuels, toutefois, aucun projet n'est concrètement dédié à la segmentation temporelle en différentes séquences afin d'en indexer le contenu. L'Institut National Audiovisuel (Institut National de l'Audiovisuel (INA)), est notamment pionnier dans la proposition de projets d'analyse automatique appliquée à l'audiovisuel. L'INA a par exemple mis en place un outil de segmentation, InaSpeechSegmenter, toutefois dédié à la segmentation du discours entre hommes et femmes, dans une optique statistique⁵. Cet algorithme de segmentation, appliqué au son, ne peut être pris comme exemple d'application pour notre étude, centrée sur l'analyse du sens de l'image en mouvement.

Par ailleurs, le projet MeMad, réunit un ensemble d'outils dédiés à l'analyse automatique de l'audiovisuel développés par l'Université d'Aalto, EURECOM, l'INA et l'Université d'Helsinki⁶. Parmi les outils développés, nous pouvons citer par exemple un outil de traduction du discours (Speech translation), l'outil inaFaceGender, un outil de reconnaissance faciale (Face recognition), un outil permettant d'identifier la langue parlée (Spoken language identification)⁷. Ces projets restent centrés sur l'analyse du son et du texte inclut dans l'image et ne peuvent donc pas être pris en compte dans notre analyse. Au sein de cette

³Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

⁴*Ibid.*

⁵*Analyse Des Tendances Médias Par l'IA - Les Traitements Réalisés Par Les Outils d'intelligence Artificielle Utilisés Sur Data.Ina.Fr / Data.Ina.Fr*, URL : <https://data.ina.fr/traitements-ia> (visité le 29/08/2026).

⁶*MeMAD-project/Mmca : MeMAD Multimodal Content Analysis and Machine Translation : Collection of Tools and Libraries*, URL : <https://github.com/MeMAD-project/mmca> (visité le 29/08/2026).

⁷*Ibid.*

sous section, nous tenterons ainsi d'évaluer les outils et méthodes disponibles et dédiés au traitement audiovisuels, afin de proposer un processus adéquat.

L'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de *computer vision*, ou de vision par ordinateur. Le terme définit un sous-domaine d'application de l'intelligence artificielle qui permet d'entraîner un système d'intelligence artificielle à l'analyse des images fixes ou en mouvement⁸. La vision par ordinateur s'appuie largement sur des modèles de *machine learning*, ou apprentissage machine, qui désigne une branche de l'intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent.⁹ L'apprentissage machine permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données.¹⁰ La vision par ordinateur classique s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques¹¹. Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d'apprentissage machine¹². De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut être mis en place sur l'ensemble des données, seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'analyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds¹³. Ces modèles relèvent également de la vision par ordinateur, mais fondée sur l'apprentissage profond, per-

⁸Rina Diane Caballar Stryker Cole, *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

⁹J. Arnold, M. Lüpold, L. Theilkäs, *et al.*, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives »...

¹⁰*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹¹Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹²*Ibid.*

¹³Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

mettant notamment de gérer l’analyse de flux vidéo. La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l’apprentissage machine. L’apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s’adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l’apprentissage profond permet d’exécuter des tâches automatisées, réduisant le besoin d’intervention humaine, et améliorant ainsi le rapport cout-efficacité¹⁴. Il suffirait de fournir au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données¹⁵. Par rapport aux techniques traditionnelles de vision par ordinateur, l’apprentissage profond permet d’obtenir une plus grande précision dans les tâches d’analyse audiovisuelle telles que la classification d’images, la segmentation, la détection d’objets¹⁶.

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la vision par ordinateur pour la classification d’images et la reconnaissance d’objets, est celui des réseaux de neurones convolutifs (CNN). Appliqués à des corpus d’images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d’en extraire les couleurs et les contours.¹⁷ Les tâches que permettent les CNN sont plutôt bien adaptées à l’image fixe, puisqu’ils extraient des éléments fixes de l’image.

Néanmoins, d’autres modèles issus de l’apprentissage profond tels que les transformers s’avèrent davantage efficace sur des tâches dédiées à l’image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent grâce à un mécanisme d’auto-attention qui leur permet de détecter les relations et dépendances entre les données¹⁸. Tandis que les CNN analysent les données de manière locale dans l’image, sans prendre en compte les interdépendances qui les régissent temporellement, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines étapes de chacune d’entre elles¹⁹. Les CNN ne permettent pas, par exemple, de discerner les “dépendances à longue portée” telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins²⁰. Ainsi, ils seraient davantage adaptés à l’ana-

¹⁴N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

¹⁵*Ibid.*

¹⁶*Ibid.*

¹⁷Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

¹⁸Cole Stryker Bergmann Dave, *Qu’est-ce qu’un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

¹⁹*Ibid.*

²⁰*Ibid.*

lyse d’images en mouvement puisqu’ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d’une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l’intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d’interpréter les analyses qui sont produites²¹. En effet, une fois entraînés, il est difficile d’en modifier les paramètres puisqu’ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi difficile à comprendre et à exposer²². Deuxièmement, les algorithmes de type transformers sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe²³. Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d’un large jeu de données d’entraînement afin d’éviter un surapprentissage impliquant des biais multiples²⁴. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu’il s’agirait de réadapter à un contexte patrimonial²⁵. Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l’analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d’analyse automatique d’un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 4.1 ci-dessous permet de comparer les compétences des types de modèles cités pour l’analyse d’un flux vidéo.

²¹A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

²²N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

²³Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

²⁴Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

²⁵*Ibid.*

Type d'approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan - Calcul d'histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d'objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d'images fixes extraites du flux vidéo - Détection d'objets ou caractéristiques dans l'image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 4.1 : Comparatif des approches de traitement audiovisuel automatique

Comme l'illustre le Tableau 4.1, si les architectures fondées sur les transformers offrent des compétences puissantes, notamment pour l'automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d'entraînement conséquents. À l'inverse, la vision par ordinateur classique offre une stabilité d'analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d'en extraire le sens. Ce constat justifie l'orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

II. Outils et modèles disponibles

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués de documents audiovisuels, leur architecture nous donne des pistes d'expérimentations afin de pouvoir implémenter un tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer

à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéos en différentes séquences. L'optique de cette étude est de fournir une proposition d'implémentation de fonctionnalités automatiques au sein d'un outil de gestion des collections d'un point de vue métier, au regard des besoins utilisateurs. Par conséquent, notre étude analysera l'architecture des algorithmes sélectionnés sans en détailler les mécanismes techniques.

Tout d'abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des transformers notamment, une des solutions envisagée consisterait à transformer un flux d'images en mouvement en la série d'images fixes qui le composent. Ce processus écarterait notamment le besoin d'analyser les relations entre les images par un mécanisme d'auto-attention prévu par les transformers. En effet, le médium cinématographique se caractérise par l'enchaînement d'une succession d'images fixes produisant ainsi l'illusion du mouvement. La transformation de ce flux à l'état d'images fixes par un outil technique permettrait de pouvoir gérer l'analyse sémantique de ces images par des processus légers prévus par la vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d'analyse que ceux prévus pour l'image fixe, fondés sur la vision par ordinateur classique.

Cette segmentation d'un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d'une analyse sémantique, regroupant ces plans fixes en des séquences sémantiques. Dans un article sur la mise en place d'un processus de segmentation temporelle, Xin prône notamment le découpage syntaxique tel que nous l'avons défini comme étape préliminaire à l'analyse sémantique des images par des modèles d'intelligence artificielle²⁶. La segmentation syntaxique d'un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

Ainsi, la segmentation automatique d'un document audiovisuel en séquences serait fondée sur l'analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes²⁷. Ces plans sont en réalité retenus par l'algorithme comme des images-clés contenues au sein de chaque séquences, calculées comme l'image la plus représentative de la présence des éléments dans un flux donné²⁸. Ce principe, qualifié de sélection de données, permet d'alléger nettement la puissance de calcul et la structure des algorithmes²⁹. Ces images-clés seraient ensuite analysées par un

²⁶Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

²⁷*Ibid.*

²⁸*Ibid.*

²⁹*Ibid.*

algorithme fondé sur des CNN, afin d’y ajouter une analyse sémantique et de les regrouper en séquences.

Ce processus est notamment appliqué par la bibliothèque python Pyscenedetect qui permet la segmentation d’un flux vidéo à l’aide de différents paramètres définis en amont³⁰. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l’analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquences audiovisuelle, Pyscenedetect permet d’en extraire les image clés, c’est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de vision par ordinateur classique, qui concrétise la mise en oeuvre de la comparaison syntaxique d’images fixes. L’outil s’appuie sur des détecteurs mathématiques afin d’analyser les différences structurelles entre les images-clés tirées d’une vidéo³¹. Il s’agit ainsi d’un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d’entraînement particulier, comme c’est le cas des outils de vision par ordinateur fondés sur l’apprentissage profond. Pyscenedetect permet d’isoler des images-clés de l’image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l’outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l’image, une détection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d’un plan avec les plans adjacents (méthode *detect-adaptative*)³². En théorie, Pyscenedetect isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d’images, et non des séquences, unités de sens narratives. Néanmoins, Pyscenedetect permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l’élévation de la valeur du seuil de détection ou la fixation d’une durée minimale de séquences (*min-scene-len*), l’outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu’en cas de détection de changements visuels majeurs tels que l’éclairage, le décor, la composition, etc³³. Par ce biais, la segmentation syntaxique proposée par Pyscenedetect pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l’outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquences retenue. Le diagramme de flux 4.1 ci-dessous illustre la manière dont l’outil pourrait être paramétré afin de segmenter le flux vidéo en séquences.

Pour chaque changement détecté, une nouvelle séquence est ainsi créée et une images-

³⁰ *Home - PySceneDetect*, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³¹ *Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

³² *Ibid.*

³³ *Ibid.*




FIG. 4.1 : Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect

clés est automatiquement enregistrée, associée au fichier vidéo d'origine. Nous proposerons la réutilisation de cette images-clés au sein du processus suivant, dédié à l'analyse sémantique des séquences préalablement détectées, afin de ne pas surcharger les algorithmes. Ce système images-clés permettrait ainsi d'alléger le processus d'analyse sémantique, puisque les algorithmes reçoivent des images fixes au lieu de fichiers vidéos plus ou moins lourds. Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Samarth Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus³⁴. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même après numérisation ou restauration³⁵. En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus³⁶. De plus, Samarth Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé³⁷. Toutefois, un des avantages majeurs de l'outil Pyscenedetect est sa disponibilité et la possibilité de le mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

³⁴S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

³⁵*Ibid.*

³⁶J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

³⁷S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

III. Mise en application

Au sein du chapitre suivant, nous mettrons à l'épreuve l'adaptabilité de l'outil que nous avons décrit pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, construit par des plans fixes, en noir et blanc et muets. Nous tenterons d'appliquer le processus de segmentation proposé par Pyscenedetect sur un tel corpus, afin d'en comprendre les données qui pourraient être générées. Le corpus, utilisé ici comme cas d'étude, se caractérise notamment par son ancienneté, et donc par la dégradation de la pellicule sur laquelle l'image s'inscrit. L'outil pourrait ainsi rencontrer des difficultés lors de l'identification des coupures et des changements de plans, brouillés par la dégradation de l'image. Toutefois, la structure du contenu de ces archives facilite la tâche de l'outil, composé d'une succession de plans fixes, dont les coupures sont suffisamment marquées, en fait un corpus relativement bien adapté à ce type de tâche automatique, qui pourrait identifier les coupes plus facilement.

Par ailleurs, Pyscenedetect, nous l'avons vu, est un outil dédié à la détection de coupures et à la segmentation d'un flux vidéo en différents plans. Or, dans cette étude, nous cherchons à montrer comment segmenter un flux audiovisuel en différentes séquences, unités sémantiques autonomes. Dès lors, comment paramétrer un tel outil pour la détection d'éléments sémantiques plus larges tels que les séquences ?

Une solution envisagée serait d'augmenter la valeur du seuil de coupures (threshold), pour que l'outil ne détecte plus les micro-coupures entre les images mais des coupes plus larges, à l'échelle de séquences³⁸. L'outil enregistrerait alors un changement de séquence seulement lors d'une rupture significative de l'espace-temps à l'image. Ce paramétrage reste toutefois limité puisque plusieurs plans adjacents peuvent être radicalement différents d'un point de vue syntaxiques, tout en appartenant bien à la même séquence. Par exemple, une même séquence peut contenir un gros plan et un plan d'ensemble, dont la composition visuelle est bien différente. Dans le cas du corpus d'archives audiovisuelles décrit, les plans restent larges et fixes, montrant l'ensemble du décor dans lequel ils s'inscrivent. Ainsi, le paramétrage du seuil pourrait être adéquatement réglé pour la détection de changements de décor, sur ce corpus donné, afin de segmenter le flux vidéo en différentes séquences.

Par ailleurs, il est possible de régler l'outil sur une durée minimale de détection de coupures à l'aide du paramètre "min-scene-len", pour que le processus n'effectue de coupures qu'après un laps de temps défini³⁹. La définition de ce paramètre nécessite une analyse statistique du corpus segmenté afin d'en définir la durée moyenne d'une séquence. Au sein du

³⁸ *Command-Line - PySceneDetect...*

³⁹ *Ibid.*

logiciel de gestion des collections prévu par Skinsoft, l’institution qui gère ce corpus d’archives documente déjà les séquences contenues par les différentes œuvres au sein des notices de films physiques, sous la forme de repères temporels. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de time codes afin de déterminer la durée moyenne d’une séquence au sein du corpus. D’après nos observations, les séquences extraites sont généralement d’une durée de 60 secondes. Enfin, sur ce corpus, le mode de détection adaptatif pourrait être privilégié, couplé à une analyse d’images plus importante, permettant à l’outil de comparer le contenu visuel d’un plan par rapport à une grande variété de plans qui l’entourent⁴⁰. Ce paramètre permettrait encore de régler l’outil sur la détection de changements majeurs dans l’image, dans l’optique d’en extraire uniquement les séquences.

Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données en sortie. D’une part, un fichier JSON ou CSV contenant les time codes de début et de fin correspondant aux séquences identifiées au sein de chaque fichier vidéo ingéré. Chaque séquence est alors associée à un identifiant unique et à des times codes de début et de fin. D’autre part, l’outil permet également d’extraire pour chaque séquence un fichier image, qui correspond à l’image fixe médiane, censée être la plus représentative de la séquence, désignée par le terme d’image clé⁴¹.

Toutefois, si ce paramétrage permettrait une plus grande flexibilité pour la segmentation d’un flux vidéo en séquences, l’outil reste limité dans l’automatisation de cette tâche. D’une part l’outil est prévu pour la détection automatique de changement de plan, et d’autre part, une séquence ne se définit pas seulement comme une caractéristique syntaxique du langage cinématographique, comme c’est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence concrétise un choix narratif, matérialisé généralement par un changement d’espace-temps. C’est pourquoi, un outil dont l’automatisation est fondée sur des seuils mathématiques reste limité pour une telle tâche. Nous proposons alors de réaliser une analyse sémantique des séquences détectées, afin de ré associer leur sens à ces coupures détectées automatiquement, tout en réutilisant les données produites : les times codes et l’image clé associés à chaque séquence.

La segmentation syntaxique effectuée par Pyscenedetect constitue un “filtre”, c’est-à-dire un premier niveau dans notre chaîne d’indexation automatique des archives audiovisuelles⁴². Les données issues de ce premier niveau permettent d’amoindrir le volume de données, caractéristique des fichiers vidéo, transmis aux algorithmes d’indexation automatique. Dès lors, les images-clés produites par glspyscene peuvent être soumises à un modèle neuronal de détection d’objets tel que YOLO (You only look once), afin d’extraire le sens

⁴⁰ *Ibid.*

⁴¹ *Ibid.*

⁴² Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*




FIG. 4.2 : Mise en application de Pyscenedetect

de ces segments et leur rendre leur valeur sémantique. La sous-section suivante détaille la manière dont ce modèle, appliqué aux glsingle des séquences, permet d'en extraire les caractéristiques sémantiques à des fins d'indexation.

Troisième partie

Perspectives

Conclusion

Annexe A

Le titre très long de la première
annexe

Annexes

Annexe A

Suggestions d'améliorations pour l'espace de travail S-Movies

I. Améliorations

1. Amélioration des liens

Actuellement, le parcours utilisateur de navigation entre les niveaux du WEMI dans S-Movies pourrait être amélioré. Plusieurs éléments faisant l'objet de liens sont ici proposés et soumis à des améliorations :

a. Contraindre les liens entre les niveaux depuis les tables

Actuellement, lorsque l'utilisateur crée un élément du WEMI depuis une table (films, manifestation, œuvre), la création supplémentaire d'un lien avec les autres niveaux du WEMI n'est pas rendue obligatoire par l'application.

Par exemple, lorsque l'utilisateur crée une manifestation depuis la table dédiée –bien qu'il ne s'agisse pas du parcours le plus courant, la création d'un lien entre cette manifestation et une œuvre ou un item film n'est pas obligatoire. Or, une manifestation est toujours reliée, a minima, à une œuvre cinématographique. Il faudrait pouvoir contraindre l'utilisateur à relier la notice de manifestation à une œuvre, et que les champs œuvre de la notice manifestation héritent automatiquement des données de l'œuvre liée (titre, auteur, contexte de création...).

C'est le même problème pour la création d'un item film et pour la création d'une œuvre.

L'encart qui apparait en haut à droite de la notice pour proposer à l'utilisateur de créer un lien avec une autre notice n'est pas suffisant. Il faudrait contraindre l'association de liens entre les niveaux du WEMI par une fenêtre pop-up qui bloquerait la saisie momentanément.

Ainsi, à la création d’un item film par exemple, une fenêtre pop-up s’ouvrirait pour demander à l’utilisateur de lier cet item à une manifestation et/ou une œuvre.

Si la collection est particulière, par exemple le musée Albert Kahn ne décrit pas la manifestation, il faut permettre la possibilité d’enlever cette obligation de lien entre les trois niveaux et laisser seulement l’encart existant.

b. Améliorer les liens depuis les notices

Les liens rendus possibles depuis les menus des notices pourraient aussi être améliorés.

Par exemple, depuis une notice œuvre, il faudrait proposer un bouton d’action qui permette de créer un item et une manifestation liés, et non plus seulement un item. En effet, proposer à l’utilisateur de créer un item et sa manifestation serait conforme à la logique déjà mise en place dans l’application du lien indissociable entre un item et sa manifestation.

De plus il faudrait, depuis une notice œuvre, pouvoir créer directement sa variante. Il faudrait ajouter au bouton d’action : ajouter et créer une oeuvre variante, et par conséquent, ajouter un onglet de menu qui affiche les variantes associées à l’oeuvre.

2. Modifier la hiérarchie d’affichage

Actuellement, la hiérarchie d’affichage des niveaux dans le menu burger se fait du plus petit niveau en haut (films) au plus grand niveau en bas (œuvres). Cet affichage est contre intuitif puisqu’il induit une hiérarchie inversée. Il faudrait que l’œuvre soit affichée comme le niveau le plus haut de la hiérarchie, suivi par la manifestation et enfin, par l’item-film.

Il pourrait également être plus intuitif de contraindre l’affichage correct de la hiérarchie dans les menus des notices. Par exemple dans une notice œuvre, l’onglet “manifestations liées” apparaît au-dessus de l’onglet “items-films liés”. Cela pourrait prendre la forme d’une fenêtre de suggestion à l’utilisateur lors de la configuration du menu d’une notice afin de produire un affichage conforme à la hiérarchie du modèle FRBR.

Par ailleurs, la page d’accueil de S-Movies a été configurée de telle sorte que ce sont toutes les œuvres cinématographiques qui apparaissent. Or, ce sont bien les items qui composent véritablement la collection. Il serait pertinent de proposer une amélioration, en proposant par exemple d’afficher les items contenus dans chaque œuvre, pour avoir un aperçu réaliste de la collection.

3. Corrections terminologiques

Cela peut paraître anodin, mais corriger la terminologie à certains endroits permettrait d’améliorer la compréhension des nuances et des liens entre les niveaux du FRBR.

Par exemple, actuellement depuis une notice film (item), le bouton d’action propose à l’utilisateur d’ajouter “des œuvres/expressions”. Il faudrait modifier la conjugaison pour mettre le terme au singulier : un item ne peut être lié qu’à une seule œuvre/expression.

Par ailleurs, il peut y avoir confusion de compréhension autour du terme film. En effet dans un contexte cinématographique, le film peut désigner à la fois l’œuvre, la manifestation et l’exemplaire. Il faudrait proposer un terme qui pointe cette notion d’exemplaire individuel qui découle d’une œuvre puis d’une manifestation, tel qu’item-film par exemple.

De plus, à plusieurs endroits, le terme d’œuvre est privilégié alors qu’à d’autres c’est celui d’expression qui est utilisé. Il faudrait normaliser l’emploi d’œuvre/expression ou d’œuvre en tout temps. C’est le cas dans certains masques comme celui d’expression référente, qui peut être utilisé au détriment de celui d’œuvre associée. Dans ce message d’erreur ci-dessous, c’est également le terme d’expression qui est employé :




FIG. A.1 : Message de suppression d’une notice d’Oeuvre

Cette proposition rejoint l’idée de supprimer la table œuvre cinématographique dans la gestion des masques alors que c’est la table œuvre/expression qui est couramment utilisée.

Enfin, une confusion peut également s’installer entre les termes “œuvre liée” et “œuvre associée” dans les masques qui décrivent la manifestation par exemple. Le terme d’œuvre liée pourrait être corrigé en “œuvre parente” pour que la nature du lien soit plus claire entre les deux entités.

4. Conserver le niveau du FRBR en mode saisie sur les métas masques

Actuellement, lors de la configuration des méta-masques, les champs glissés et déposés dans le type de notice concernée perdent la mention du niveau FRBR auquel ils appartiennent. L'utilisateur n'a plus le moyen de savoir, une fois dans la notice, que tel champ appartient à tel niveau. Conserver la mention du niveau du FRBR sur les métas masques au sein de la saisie de la notice permettrait une meilleure compréhension et visibilité pour l'utilisateur. Ainsi, par exemple, dans une notice de manifestation, le champ Titre afficherait : Œuvre – Titre.

II. Nouvelles fonctionnalités

1. Annotation de séquences sur un fichier vidéo numérique

La table média actuelle permet seulement de visualiser une photo ou une vidéo, au clic sur la notice. Toutefois, il serait intéressant de développer une visionneuse spécifique à la vidéo qui permettrait non seulement de la visionner, mais également d'y placer des repères, des marqueurs, et de pouvoir l'annoter.

Tout d'abord, deux possibilités de “séquençage” manuel seraient possibles :

- L'utilisateur saisit des repères temporels sur la vidéo sans la modifier. Ces repères sont reversés dans des champs prévus pour accueillir les “time codes” dans la notice de l'objet numérique. À l'ouverture du fichier numérique, les marqueurs laissés par l'utilisateur apparaissent, visibles sur la barre de défilement de la vidéo. L'utilisateur peut alors cliquer sur ces marqueurs pour naviguer au sein de la vidéo comme il le souhaite, et y voir les annotations associées.
- L'utilisateur pourrait aussi vouloir segmenter le fichier vidéo en plusieurs séquences distinctes à partir de time codes précis. Dans ce cas-là, à la manière d'un logiciel de montage, l'utilisateur peut créer des cuts sur la vidéo et ainsi créer plusieurs fichiers numériques à partir de celle-ci, mais qui lui sont toujours liés. En effet, ces nouveaux objets, fragments du fichier vidéo d'origine, auraient leur propre notice de description mais resteraient rattachés à la notice principale, à la manière d'un ensemble.

Cette nouvelle fonctionnalité permettrait d'apprécier l'hétérogénéité des collections, et s'avèrerait utile dans le cas, par exemple, de rushes documentaires non édités que l'utilisateur

souhaiterait diviser par mots clés ou thématiques. La description des médias vidéo n'en serait que plus affinée et précisée.

Par ailleurs, ce séquençage devra être effectué dans une optique d'annotation "sur" l'image, permettant ainsi d'associer des séquences plus précises à une description thématique. Concrètement, deux cas d'annotation sont possibles :

- L'utilisateur pourrait être capable de placer des tags sur des éléments de l'image (objets, personnes, éléments techniques, contenu...) et d'en décrire le contenu dans les champs prévus. La notice du média prévoit alors l'affichage d'une description par time codes, sur lesquels l'utilisateur peut cliquer pour accéder directement à l'image en question.
- L'utilisateur peut également vouloir décrire une séquence dans sa globalité, à l'intérieur d'un time code précis. Dans ce cas, les champs sont saisis à partir d'un tag sur le time code, et non plus sur un élément précis de l'image. L'affichage de la description dans la notice peut rester le même que le précédent.

À l'ouverture du fichier vidéo, les annotations saisies apparaissent à droite de la visionneuse, et les times codes superposés à la barre de défilement de la vidéo.

La description précise sur des séquences vidéo permettrait à la recherche d'être plus performante : l'utilisateur pourrait, en cherchant certains mots clés, tomber directement sur les séquences numériques associées, aux time codes correspondants.

Il est intéressant de penser également à la mise en place d'une recherche par mots clés au sein du fichier numérique vidéo. La recherche d'un mot clé amène l'utilisateur à une séquence décrite par ce mot clé.

2. Recherche de médias par type de format

Il serait pratique de mettre en place, dans la table médias, une recherche par type de formats.

L'application pourrait détecter automatiquement le format du média créé par l'utilisateur et l'indexer pour le proposer comme critère de tri/de recherche à l'utilisateur.

Cela permettrait notamment de pouvoir rapidement visualiser les fichiers vidéo présents dans la table, au lieu de devoir faire des albums par types de médias.

Deux types de filtres seraient pertinents à proposer :

- Type de média : vidéo, image, son
- Format : mp4, mpeg, jpeg, mov...

3. Mise en place d'un repérage couleur pour les niveaux du FRBR

Il serait visuellement plus intuitif d'associer une couleur à un niveau du WEMI. Ainsi, les niveaux Oeuvre, manifestation, Item auraient chacun leur couleur, et ce, dans toute l'interface de l'application :

- Menu burger,
- Menus des notices,
- Méta-masques
- Onglets des notices
- Résultats de recherche

Un repérage visuel s'opère alors pour l'utilisateur, qui peut plus facilement se repérer au sein du FRBR.

4. Mise en place d'une visualisation des liens entre entités du FRBR

NB : Cette idée s'inspire notamment de la "balade intuitive" proposée par la bibliothèque Kandinsky dont voici un exemple :




FIG. A.2 : Vue "balade intuitive" proposée par la bibliothèque Kandinsky¹

Lorsque l'utilisateur ouvre S-Movies, ce sont les œuvres qui apparaissent sous la forme de résultats de recherche. Les liens avec d'autres notices (manifestations et items) n'apparaissent

FIG. A.3 : Vue en graphe de la balade intuitive²

pas à première vue. Il faut ouvrir une notice pour voir la liste des entités qui y sont liées, si toutefois ces liens sont configurés dans le menu de la notice. Or, la visualisation de liens entre les entités d'une collection est primordiale dans la logique d'une structuration selon le modèle FRBR. Pouvoir avoir un aperçu de ces liens pourrait améliorer la compréhension de la hiérarchie entre les niveaux du FRBR et leur délimitation, et ainsi améliorer les pratiques de saisie selon les cas d'indexation. De plus, visualiser rapidement les liens entre entités permettrait d'identifier les incohérences et les erreurs de données plus facilement, comme par exemple, des éléments vides ou isolés.

Les entités principales du FRBR étant au nombre de trois, la représentation choisie pourrait être celle d'une représentation en graphes de connaissances, modélisant ainsi les relations entre entités. Cette représentation s'appuie sur le modèle de graphe RDF (sujet-prédicat-objet) qui permet également l'interopérabilité des données.

Pour penser la place que pourrait prendre cette visualisation des liens dans l'application, il faut se poser les questions suivantes : quel niveau du FRBR les utilisateurs préfèrent-ils visualiser ? Dans quel contexte ? Autrement dit, il faut se demander quel niveau de granularité choisir pour mettre en place cette visualisation et à quel endroit de l'application.

Puisque la page d'accueil de l'espace de travail S-Movies présente les œuvres, la représentation en graphe pourrait dans un premier temps permettre de visualiser les œuvres présentes dans la collection.

Le premier niveau permettrait donc à l'utilisateur de visualiser la liste des œuvres

préservées sous formes de cercles, plus ou moins gros selon le nombre de sous-niveaux qu'elles contiennent. Ainsi, une œuvre qui contiendrait deux variantes, quatre manifestations, 12 items sera plus grande qu'une œuvre qui contient 1 manifestation et 1 item.

Au clic sur l'œuvre, le détail de ses relations avec des sous-éléments apparaît : variantes, manifestations, items.

Ce mode d'affichage pourrait être disponible de la même manière que les modes d'affichage déjà présents dans l'application. Il faudrait ajouter un mode d'affichage en "graphe".




FIG. A.4 : Modes d'affichage disponibles dans l'application

Ce mode d'affichage, établi au niveau des tables, pourrait également être disponible au niveau des notices. Par exemple dans une notice d'item, un onglet de menu pourrait être configurable pour faire apparaître, en graphe, les relations de l'item avec les niveaux parents du FRBR.

Il serait intéressant d'intégrer à ces visualisations en graphes les médias, d'autant plus dans le cas de la mise en place d'une segmentation vidéo, pour pouvoir visualiser les différents segments reliés à l'item.

Concrètement, le parcours utilisateur de cet affichage serait le suivant :

- Que ce soit depuis une table ou depuis une notice, l'utilisateur clique sur le mode d'affichage en graphe
- Les entités concernées s'affichent sous la forme de cercles, proportionnels aux nombres de liens qu'ils entretiennent avec les autres niveaux du FRBR. Les cercles comportent des informations minimales selon le niveau : le titre et la date pour les œuvres, le titre le format et la date pour les manifestations, le titre, le format, la date et l'identifiant pour l'item.
- Une légende s'affiche en bas de l'écran avec un code couleur pour chaque entité, et le nombre d'entités présentes.
- Au clic de l'utilisateur sur l'un des cercles, le détail des relations de l'entité avec d'autres entités s'ouvre en mode graphe. Le résumé de la notice s'affiche en barre latérale sur le côté.
- Au clic sur une entité liée, le graphe se reforme et l'entité choisie devient le centre du graphe.

On pourrait également ajouter au graphe les lieux et les personnes (intervenants) liés à chaque entité du FRBR.

5. Automatisation du catalogage en niveaux FRBR

Il serait pertinent de mettre en place une automatisation de la hiérarchie FRBR à partir de la création d'une notice. Cette fonctionnalité serait assistée par l'IA. Par exemple, depuis l'item, l'application détecterait la hiérarchie supérieure à créer depuis les actions suivantes :

- Description de l'item
- Scan du code-barres
- Création d'une notice item depuis la table films
- Création d'une notice item depuis la table des entrées

L'assistant IA détecterait les liens à effectuer entre l'item en question et des notices de manifestation et d'œuvre si elles existent. Si elles n'existent pas, il créerait automatiquement les notices manifestation et œuvre et proposerait à l'utilisateur de les remplir. Ces notices seraient automatiquement liées.

Dans le cadre de la mise en place d'un chatbot, l'utilisateur pourrait simplement décrire l'item et son contenu, et l'intelligence artificielle suggérerait à l'utilisateur ce qu'il faut créer, ou la marche à suivre. Par exemple :

Cet item est issu de la manifestation de telle oeuvre. Les deux notices existent déjà, il faut y lier cet item

Cet item est issu d'une nouvelle manifestation de telle oeuvre, il faut la créer et la lier à l'item

Cet item est issu de la variante de telle oeuvre, il faut la créer et la lier à l'item. Pas besoin de créer une manifestation, cet item est l'exemplaire unique de la variante de cette oeuvre.

6. Affichage des niveaux FRBR dans l'onglet/entête d'une notice

Cette idée s'applique aux niveaux FRBR enfants : Variante, Manifestation, Item, puisque l'œuvre n'a pas de niveau supérieur à afficher.

Lorsque l'utilisateur a une notice ouverte, une notice d'item-film par exemple, il n'a pas de visibilité sur les niveaux hiérarchiques parents dans lesquels s'imbrique la notice. Il serait

pertinent d'afficher l'imbrication de niveaux dont fait partie la notice dans l'intitulé de son onglet.

Actuellement, pour le niveau Œuvre, c'est le titre qui apparaît dans l'onglet de la notice, tandis que c'est l'identifiant qui apparaît pour la manifestation et l'item.

À la manière d'une frise logique, l'onglet afficherait : œuvre > variante > manifestation > item.

La notice ouverte par l'utilisateur s'afficherait en gras, pour signaler qu'elle est la notice actuellement utilisée. Dans le cadre de la mise en place d'un code couleur, les couleurs respectives de l'œuvre et de la manifestation seraient affichées dans l'onglet, en clair, tandis que le niveau appartenant à la notice ouverte serait affiché dans sa couleur, de manière vive et en gras.

Il est important de noter que cet affichage serait plus intuitif dans le cas où les identifiants ont été paramétrés de telle sorte à pouvoir indiquer le niveau de FRBR dans l'intitulé. Par exemple : MN-0001, pour manifestation numérique 1, ou IP-0002 pour un item physique 2. Ainsi, dans l'affichage de l'onglet, cela donnerait l'intitulé suivant :

- Casablanca > MN-0002 > IN-0006.

Toutefois, même si le niveau du FRBR n'est pas indiqué dans les identifiants, l'affichage de gauche à droite induit une hiérarchie du haut vers le bas. Si un code couleur est mis en place, il pourrait rendre l'affichage intuitif sans la présence des niveaux dans les identifiants.

Nous pouvons penser également à une modification de ce qu'affiche l'onglet de la notice pour la manifestation et pour l'item. En effet, pour que cela soit encore plus clair pour l'utilisateur, la frise présente dans l'onglet d'une notice pourrait afficher, pour la manifestation, son type. Ainsi, cela donnerait la chose suivante :

- Casablanca > pré diffusion > IP-0005.

Même chose pour la variante :

- Casablanca > censuré > distribution en salles > IN-0007.

Notons tout de même que pour que cet affichage soit fonctionnel, la taille des onglets de notice devra être agrandie.

7. Repenser le mode de création de notices dans des tables individuelles

La création de notices au sein de tables individuelles n'encourage pas l'utilisateur à lier les notices entre elles, sur plusieurs niveaux. Le risque est ainsi que l'utilisateur crée des

notices individuelles, elles aussi, sans les relier à d'autres niveaux du FRBR. Pour éviter cela, il pourrait être intéressant de proposer, dans le menu burger, la création de liens prédéfinis, au lieu de créer au sein de tables. Les tables pourraient être alors réservées à la consultation et à l'affichage des notices créées. Cette idée rapprocherait S-Movies d'une interface où l'utilisateur crée un réseau de liens, propre à une collection cinématographique.

L'idée serait d'ajouter un onglet dans le menu burger intitulé "Création/liens", qui permettrait à l'utilisateur de créer des liens "préconçus". Une sorte de création rapide, sans possibilité de créer des notices uniques.

Sous cet onglet seraient ajoutées par exemple les options suivantes (de manière non-exhaustive) :

- Créer un item et sa manifestation
- Créer un item, sa manifestation, et son oeuvre
- Créer une manifestation d'une oeuvre
- Lier un item à une manifestation

Au risque de surcharger l'interface, on peut également imaginer qu'au sein de chacune des tables, le bouton d'action > créer une nouvelle notice soit supprimé, et remplacé par des boutons d'action de liens. Ainsi, au lieu d'avoir une liste de propositions de liens non organisée, les propositions de liens seraient propres au lien qu'entretient chaque table avec les autres. Ainsi, par exemple :

- Table Œuvres :
 - Lier une oeuvre à une manifestation
 - Lier une oeuvre à un item
 - Lier une oeuvre à une variante
- Table manifestations :
 - Lier une manifestation à une oeuvre
 - Lier une manifestation à un item
- Table items-films :
 - Lier un film à une oeuvre
 - Lier un film à une manifestation

Au clic, le bouton d’action propose soit à l’utilisateur de lier une entité existante à celle sélectionnée, soit d’en créer une si elle n’existe pas. Le terme “lier” dans le bouton d’action signifie ainsi également la création d’une notice en lien avec une autre, pas seulement l’ajout d’un lien entre deux notices existantes.

La limite de cette idée est qu’elle est contre intuitive : la création d’une notice de chaque entité se fait dans d’autres tables que celle qui lui est dédiée.

Cette refonte du mode de création des notices assure toutefois un lien indissociable entre les entités, qui permettra notamment d’empêcher la suppression d’une entité et des éléments qui lui sont liés par exemple. Cela faciliterait aussi la mise en place de visualisation des liens, si les entités sont toutes interconnectées. Surtout, ces nouvelles modalités suppriment la possibilité de créer des notices individuelles, sans lien avec les niveaux du FRBR.

Glossaire

apprentissage machine . 36, 37, 55

apprentissage profond . 37, 55

Archives audiovisuelles . 7, 55

Audiovisual Processing . 35, 55

CNN Architecture de réseau de neurones artificiels spécialement adaptée au traitement et à l'analyse d'images numériques.. 37, 38, 55

Expression . 55

FIAF Fédération Internationale des archives du film. Organisation regroupant les cinémathèques et édité le manuel de catalogage audiovisuel fondé sur le modèle FRBR.. 55

FRBR Functional Requirements for Bibliographic Records. Modèle conceptuel entité-association développé par l'IFLA.. 3–7, 55, 61

Item . 55

Manifestation . 55

Oeuvre . 55

rush Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant le matériau source d'un film.. 55

réseaux de neurones profonds . 37, 55

transformers . 37, 38, 55

vision par ordinateur . 36, 37, 55

Liste des abréviations

CIDOC-CRM object-oriented Conceptual Reference Model. 6, 55

FRAD Fonctionnalités requises des données d'autorité. 6, 55

FRBRoo long. 6, 7, 55

FRSAD Fonctionnalités requises des données d'autorité matière. 55

IFLA International Federation of Library Associations and Institutions. 3, 55

IFLA-LRM long. 6, 55

WVMI Work, Variant, Manifestation, Item.. 55

Liste des tableaux

4.1	Comparatif des approches de traitement audiovisuel automatique	41
-----	--	----

Table des figures

1.1	Entités du modèle FRBR	4
1.2	Entités du modèle FRBR	5
2.1	Page d'accueil de l'espace de travail	12
2.2	Menu burger de l'espace de travail	13
2.3	Menu burger de l'espace de travail	13
2.4	Configuration des masques de saisie au niveau Item	15
2.5	Configuration du menu d'une notice de film physique	15
2.6	Affichage du menu d'une notice de film physique à la saisie	16
2.7	Configuration de grilles de recherche pour l'affichage des éléments liés	17
2.8	Affichage des Oeuvres liées dans une notice d'item	17
2.9	Affichage des Manifestations liées dans une notice d'item	18
2.10	Configuration d'un méta-masque au niveau Item	19
2.11	Modèle hiérarchique à deux niveaux schématisé par le manuel de la FIAF	23
4.1	Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect	44
4.2	Mise en application de Pyscenedetect	47
A.1	Message de suppression d'une notice d'Oeuvre	59
A.2	Vue "balade intuitive" proposée par la bibliothèque Kandinsky ³	62
A.3	Vue en graphe de la balade intuitive ⁴	63
A.4	Modes d'affichage disponibles dans l'application	64

³*Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).

⁴*Bibliothèque Kandinsky*, URL : https://bibliothequekandinsky.centrepompidou.fr/graphe?id=23c50bed-1ab2-47ea-bfc8-26e84403cf0b#syrtis_search_page (visité le 01/09/2026).

Table des matières

Résumé	i
Remerciements	iii
Introduction	ix
I Indexer les archives audiovisuelles	1
1 Le FRBR, modèle d’indexation conçu pour les bibliothèques	3
I. Un modèle conceptuel fondé sur les besoins utilisateurs	3
II. Son adaptation à l’archivistique et au contexte muséal	6
III. Un modèle adapté aux archives audiovisuelles : le manuel de catalogage des images animées de la FIAF	8
2 Implémenter le FRBR adapté aux archives audiovisuelles au sein d’un outil de gestion des collections	11
I. Un espace de travail dédié à la gestion de collections audiovisuelles : S-Movies	11
II. L’inscription des corpus de données dans la remodelisation du FRBR	20
III. Vers une refonte de S-Movies	24
3 Le projet d’une indexation automatisée des archives audiovisuelles, condi- tionnée par le modèle en place	27
I. Indexation	28
II. Segmentation	28
III. Projet SKAI	31
II Implémenter l’indexation automatique des archives audiovi-	

suelles au sein d'une remodelisation du FRBR	35
4 Traitement audiovisuel	37
I. Machine learning et deep learning	38
II. Outils et modèles disponibles	42
III. Mise en application	45
III Perspectives	49
Conclusion	51
A Titre court	53
Annexes	57
A Suggestions d'améliorations pour l'espace de travail S-Movies	57
I. Améliorations	57
1. Amélioration des liens	57
a. Contraindre les liens entre les niveaux depuis les tables . . .	57
b. Améliorer les liens depuis les notices	58
2. Modifier la hiérarchie d'affichage	58
3. Corrections terminologiques	58
4. Conserver le niveau du FRBR en mode saisie sur les métas masques	60
II. Nouvelles fonctionnalités	60
1. Annotation de séquences sur un fichier vidéo numérique	60
2. Recherche de médias par type de format	61
3. Mise en place d'un repérage couleur pour les niveaux du FRBR . . .	62
4. Mise en place d'une visualisation des liens entre entités du FRBR . .	62
5. Automatisation du catalogage en niveaux FRBR	65
6. Affichage des niveaux FRBR dans l'onglet/entête d'une notice . . .	65
7. Repenser le mode de création de notices dans des tables individuelles	66
Glossaire	71
Liste des abréviations	73