

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Clotilde Long

licencié.e ès lettres

diplômé.e de master

TITRE DU MÉMOIRE

SOUS-TITRE DU MÉMOIRE

Sous la direction de **Maxime Challon**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l'histoire »

2026

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : une liste de mots-clés ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

M^Es remerciements vont tout d'abord à...

Bibliographie

- AI in Audiovisual Archives / Sound & Vision*, mai 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/ai-audiovisual-archives> (visité le 07/05/2026).
- Aide et FAQ Médiascope / INA*, URL : <https://inatheque.ina.fr/aide-a-la-recherche/aide-et-faq-mediascope> (visité le 03/08/2026).
- AKATA (Zeynep), BALLIET (Dan), DE RIJKE (Maarten), DIGNUM (Frank), DIGNUM (Virginia), EIBEN (Guszt), FOKKENS (Antske), GROSSI (Davide), HINDRIKS (Koen), HOOS (Holger), *et al.*, « A Research Agenda for Hybrid Intelligence : Augmenting Human Intellect With Collaborative, Adaptive, Responsible, and Explainable Artificial Intelligence », *Computer*, 53-8 (août 2020), p. 18-28, DOI : 10.1109/MC.2020.2996587.
- Amalia.js - Metadata Enriched HTML5 Video Player*, URL : <https://ina-foss.github.io/amalia.js/guide-plugin-timeline-options.html> (visité le 03/08/2026).
- APA GenAI Best Practices_Sept2024.Pdf*, URL : https://drive.google.com/file/d/1WS4iZ2Wi_wft5x54RG-hYb45sf10W8nV/view?usp=embed_facebook (visité le 12/05/2026).
- Apprentissage profond (deep learning)*, URL : <https://www.cnil.fr/fr/definition/apprentissage-profond-deep-learning> (visité le 18/07/2026).
- AQUINO (Alexandra Jonker Judith), *Pourquoi la qualité des données est essentielle au succès de l'IA / IBM*, janv. 2026, URL : <https://www.ibm.com/fr-fr/think/topics/ai-data-quality> (visité le 14/08/2026).
- ARNAB (Anurag), DEGHANI (Mostafa), HEIGOLD (Georg), SUN (Chen), LUČIĆ (Mario) et SCHMID (Cordelia), *ViViT : A Video Vision Transformer*, nov. 2021, DOI : 10.48550/arXiv.2103.15691, arXiv : 2103.15691 [cs.CV].
- ARNOLD (Jonas), LÛPOLD (Martin), THEILKÄS (Lorenz) et KANSY (Lambert), « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.
- ARNOLD (Taylor), TILTON (Lauren) et BERKE (Annie), « Visual Style in Two Network Era Sitcoms », *Journal of Cultural Analytics*, 4-2 (juill. 2019), DOI : 10.22148/16.043.

- ASPERTI (Andrea), DESSÌ (Leonardo), TONETTI (Maria Chiara) et WU (Nico), *Does CLIP Perceive Art the Same Way We Do ?*, oct. 2025, DOI : 10.48550/arXiv.2505.05229, arXiv : 2505.05229 [cs.CV].
- ATTARD (Jonathan) et SEYCHELL (Dylan), *Comparative Analysis of Image, Video, and Audio Classifiers for Automated News Video Segmentation*, mars 2025, DOI : 10.48550/arXiv.2503.21848, arXiv : 2503.21848 [cs.CV].
- BACHIMONT (Bruno), *Ingénierie des connaissances et des contenus : le numérique entre ontologies et documents*, Paris, 2007 (Collection Science informatique et SHS).
- *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).
- BARREAUX (Sabine), DAILLE (Béatrice) et JACQUEY (Évelyne), « Indexation automatique en SHS : bilan d’une expérimentation », *I2D - Information, données & documents*, 54–1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.
- BASSAÏSTEGUY (Sidonie), *Le Médium, c’est La Mémoire : Archivages Du Document à l’Institut National de l’audiovisuel*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05384062> (visité le 13/05/2026).
- BENJAMIN (Walter), *L’oeuvre d’art à l’époque de Sa Reproductibilité Technique*, 1935.
- BERGMANN (Cole Stryker Dave), *Qu’est-ce qu’un modèle transformer ? | IBM*, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).
- BERMÈS (Emmanuelle) et CHARPIER (Marion), « Repenser Les Collections Patrimoniales Par Le Prisme de l’IA 2025 », dans *Conférence Nationale Sur Les Applications de l’Intelligence Artificielle*, Dijon, France, 2025, URL : <https://hal.science/hal-05138697> (visité le 23/05/2026).
- BHARGAV (Samarth), VAN NOORD (Nanne) et KAMPS (Jaap), « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC ’19), p. 61-68, DOI : 10.1145/3347317.3357240.
- BOEUF (Patrick), « Brave New FRBR World », dans *IFLA Cataloguing Principles : Steps towards an International Cataloguing Code, 5 : Report from the 5th IFLA Meeting of Experts on an International Cataloguing Code, Pretoria, South Africa, 2007*, dir. Barbara B. Tillett, Tienie de Klerk, Hester van der Walt et Ana Lupe Cristán, 2008, p. 131-142, URL : <https://www.degruyterbrill.com/ unauthorizedDownload/10.1515/>

- 9783598441028 . 2 . 131 ?action=Downloading+PDF&countDenial=true&download=true&lang=en (visité le 07/07/2026).
- BRACHMANN (Anselm) et REDIES (Christoph), « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.
- Bringing AI into the Audiovisual Archive / Sound & Vision*, juin 2021, URL : <https://www.beeldengeluid.nl/en/research/blog/bringing-ai-audiovisual-archive> (visité le 07/05/2026).
- BROSTOW (Gabriel J.), FAUQUEUR (Julien) et CIPOLLA (Roberto), « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30–2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.
- CARON (Mathilde), BOJANOWSKI (Piotr), JOULIN (Armand) et DOUZE (Matthijs), « Deep Clustering for Unsupervised Learning of Visual Features », dans *Computer Vision – ECCV 2018*, dir. Vittorio Ferrari, Martial Hebert, Cristian Sminchisescu et Yair Weiss, Cham, 2018, p. 139-156, DOI : 10.1007/978-3-030-01264-9_9.
- CARRIVE (Jean), « Chapitre 4. Analyse automatique de l’image et du son pour l’enrichissement de contenus audiovisuels », *Information et stratégie* (, 2014), p. 61-76, DOI : 10.3917/dbu.caan.2014.02.0061.
- CHAMBONNET (Sébastien), « Définir une architecture de l’information pour la sauvegarde du patrimoine scientifique et technique contemporain (Patstec), à l’heure du web de données » (, 2015).
- COCO Detection Dataset*, nov. 2023, URL : <https://docs.ultralytics.com/datasets/detect/coco> (visité le 26/07/2026).
- COLAVIZZA (Giovanni), BLANKE (Tobias), JEURGENS (Charles) et NOORDEGRAAF (Julia), « Archives and AI : An Overview of Current Debates and Future Perspectives », *J. Comput. Cult. Herit.* 15–1 (déc. 2021), 4 :1-4 :15, DOI : 10.1145/3479010.
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- Command-Line - PySceneDetect*, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).
- CORDELL (Ryan), « Machine Learning + Libraries » ().
- DELUA (Julianna), *Supervised vs. Unsupervised Learning : What’s the Difference ? / IBM*, mars 2024, URL : <https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning> (visité le 08/06/2026).

- DIALOGUE (IFLA Working Group on FRBR/CRM), « Definition of FRBRoo : A Conceptual Model for Bibliographic Information in Object-Oriented Formalism » (, mars 2017), URL : <https://repository.ifla.org/handle/20.500.14598/659> (visité le 22/08/2026).
- Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).
- DU (Lin), LE (Brandon) et HONIG (Edouardo), « Probing Historical Image Contexts : Enhancing Visual Archive Retrieval through Computer Vision », *ACM Journal on Computing and Cultural Heritage*, 16-4 (janv. 2024), 84 :1-84 :17, DOI : 10.1145/3631129.
- Explorer Ultralytics YOLOv8*, nov. 2023, URL : <https://docs.ultralytics.com/fr/models/yolov8> (visité le 25/07/2026).
- FEWSTER (Kaila) et ARIAS (Richard), « Teachable AI for the Archival Professions – Module 4 : » ().
- FIAF, *Le Manuel de Catalogage Des Images Animées de La FIAF*, 2022, URL : <https://www.fiafnet.org/pages/E-Resources/Manuel-Catalogage-FIAF.html> (visité le 23/06/2026).
- FIAT/IFTA Archive Achievement Awards 2019*, sept. 2025, URL : <https://fiatifta.org/awards-editions/awards-2019/> (visité le 07/05/2026).
- FICK (Hanna), FREDRIKSSON (Anneli), LINDBLOM (Helena), FREDRIKSSON (Anneli) et LINDBLOM (Helena), « RDA ; An Opportunity for Library and Archive Collaboration », *Archiving Conference*, 12 (mai 2015), p. 22-26, DOI : 10.2352/issn.2168-3204.2015.12.1.art00006.
- France 2030 : un plan d'investissement pour la France* / economie.gouv.fr, URL : <https://www.economie.gouv.fr/france-2030> (visité le 20/06/2026).
- GERVEREAU (Laurent), *Voir, comprendre, analyser les images*, 2020, DOI : 10.3917/dec.gerv.2020.01.
- GILL (Sandrine), « Les archives audiovisuelles au tamis des archivistes », dans *Les nouveaux paradigmes de l'archive*, dir. Claire Scopsi, Clothilde Roullier, Martine Sin Blima-Barru et Édouard Vasseur, Pierrefitte-sur-Seine, 2024 (Actes), DOI : 10.4000/books.pan.7249.
- GILLIS (Sarah L.), « FRBR and TMS : Applying a Conceptual Organizational Model for Cataloguing Photographic Archives », dans 2015, URL : <https://www.semanticscholar.org/paper/FRBR-and-TMS%3A-Applying-a-Conceptual-Organizational-Gillis/f306103f1832cda79e27676bfce58a5329098cf2> (visité le 08/07/2026).
- GONG (Yuan), CHUNG (Yu-An) et GLASS (James), *AST : Audio Spectrogram Transformer*, juill. 2021, DOI : 10.48550/arXiv.2104.01778, arXiv : 2104.01778 [cs.SD].

- HERVÉ (Nicolas), LETESSIER (Pierre), DERVAL (Mathieu) et NABI (Hakim), « Amalia.js : An Open-Source Metadata Driven HTML5 Multimedia Player », dans *Proceedings of the 23rd ACM International Conference on Multimedia*, Brisbane Australia, 2015, p. 709-712, DOI : 10.1145/2733373.2807406.
- Home - PySceneDetect, URL : <https://www.scsenetect.com/> (visité le 25/07/2026).
- HUSSON (Pierre), « Indexation iconographique et intelligence artificielle : expérimentations autour du Répertoire des tableaux italiens dans les collections publiques françaises (RE-TIF) » (, oct. 2025), p. xviii, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387482> (visité le 13/05/2026).
- IFLA STUDY GROUP ON THE FUNCTIONAL REQUIREMENTS FOR BIBLIOGRAPHIC RECORDS, *Fonctionnalités Requises Des Notices Bibliographiques : Rapport Final (2e Édition)*, URL : <https://repository.ifla.org/items/7303960c-35d1-41c0-9a50-a1ce3136b03b> (visité le 07/07/2026).
- IFLASTANDARDS.INFO, *Frbroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- *Frbroo*, mars 2026, URL : <https://www.iflastandards.info/fr/frbr/frbroo.html> (visité le 03/08/2026).
- INDEXATION : Définition de INDEXATION, URL : <https://www.cnrtl.fr/definition/indexation> (visité le 30/05/2026).
- ISAAC (Antoine), BACHIMONT (Bruno) et LAUBLET (Philippe), « Indexation de documents AV : ontologies, patrons de conception et d'utilisation » (, 2005).
- JOCHER (Glenn), *YOLOv5 by Ultralytics*, nov. 2022, DOI : 10.5281/zenodo.3908559.
- JOURNOT (Marie-Thérèse), *Le vocabulaire du cinéma*, 2008, DOI : 10.14375/NP.9782200355067.
- KASTURI (Surya), SHENFIELD (Alex), ROAST (Chris), LE PAGE (Danny) et BROOME (Alice), « Object Detection in Heritage Archives Using a Human-in-Loop Concept », dans *Advances in Computational Intelligence Systems. Contributions Presented at The 22nd UK Workshop on Computational Intelligence (UKCI 2023), September 6-8, 2023, Birmingham, UK*, dir. Nitin Naik, Paul Jenkins, Paul Grace, Longzhi Yang et Shaligram Prajapat, Cham, 2024 (Advances in Intelligent Systems and Computing, 1453), p. 170-181, DOI : 10.1007/978-3-031-47508-5_14.
- L'intelligence artificielle au service de la création de métadonnées, URL : <https://www.archimag.com/demat-cloud/2022/04/15/intelligence-artificielle-creation-metadonnees> (visité le 03/08/2026).
- L'UNESCO lance un dialogue mondial sur l'intelligence artificielle et, URL : <https://www.unesco.org/fr/articles/lunesco-lance-un-dialogue-mondial-sur-lintelligence-artificielle-et-lavenir-des-musees> (visité le 20/06/2026).

- La stratégie du ministère pour des intelligences artificielles culturelles et responsables* / Ministère de la Culture, juill. 2025, URL : <https://www.culture.gouv.fr/thematiques/innovation-numerique/la-strategie-du-ministere-pour-des-intelligences-artificielles-culturelles-et-responsables> (visité le 20/06/2026).
- LALANDE (Steffen), BELOUED (Abdelkrim) et FARGE (Odile), « La plateforme Okapi pour l'analyse et la publication de corpus de données audiovisuelles : Le cas du portail Inalco–MediaScape », dans *Corpus audiovisuels*, dir. Louise Ouvrard et Odile Farge, 2022, p. 77-94, DOI : 10.17184/eac.5702.
- LE BER (Fantin), *IA et Patrimoine, Un Changement Dans La Continuité : L'exemple Du Projet Highvision*, mém. de mast., 2025, URL : <https://dumas.ccsd.cnrs.fr/dumas-05387596> (visité le 13/05/2026).
- Les questions-réponses de la CNIL sur l'utilisation d'un système d'IA générative*, URL : <https://www.cnil.fr/fr/les-questions-reponses-de-la-cnil-sur-lutilisation-dun-systeme-dia-generative> (visité le 26/07/2026).
- Les secrets du traitement du langage naturel décryptés*, URL : <https://www.iso.org/fr/intelligence-artificielle/traitement-langage-naturel> (visité le 06/05/2026).
- LETESSIER (Pierre), HERVÉ (Nicolas), JOLY (Alexis), NABI (Hakim), Derval (Mathieu) et BUISSON (Olivier), « DigInPix : Visual Named-Entities Identification in Images and Videos », dans *Proceedings of the 5th ACM on International Conference on Multimedia Retrieval*, Shanghai China, 2015, p. 661-664, DOI : 10.1145/2671188.2749369.
- LIU (Haotian), LI (Chunyu), WU (Qingyang) et LEE (Yong Jae), *Visual Instruction Tuning*, déc. 2023, DOI : 10.48550/arXiv.2304.08485, arXiv : 2304.08485 [cs.CV].
- LIU (Ying-Hsang), « Navigating the AI-Driven Metadata Landscape : A Human Centered Approach » ().
- LONGPRE (Shayne), SINGH (Nikhil), CHEREP (Manuel), TIWARY (Kushagra), MATERZYNSKA (Joanna), BRANNON (William), MAHARI (Robert), OBENG-MARNU (Naana), DEY (Manan), HAMDY (Mohammed), et al., *Bridging the Data Provenance Gap Across Text, Speech and Video*, févr. 2025, DOI : 10.48550/arXiv.2412.17847, arXiv : 2412.17847 [cs.AI].
- MAHDI (Walid), CHEN (Liming) et ARDEBILIAN (Mohsen), *Automatic Video Scene Segmentation Based on Spatial-Temporal Clues and Rhythm*, déc. 2014, DOI : 10.48550/arXiv.1412.4470, arXiv : 1412.4470 [cs.CV].
- MAHONY (Niall O'), CAMPBELL (Sean), CARVALHO (Anderson), HARAPANAHALLI (Suman), VELASCO-HERNANDEZ (Gustavo), KRPALKOVA (Lenka), RIORDAN (Daniel) et WALSH (Joseph), *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

- Modèles FRBR, FRAD et FR SAD*, URL : <https://www.bnf.fr/fr/modeles-frbr-frad-et-frsad> (visité le 30/06/2026).
- Module 6 - Section 7 : Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).
- MOIRAGHI (Eleonora), *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- *Explorer des corpus d'images. L'IA au service du patrimoine*, Billet, avr. 2018, DOI : 10.58079/m3cp.
- MONNIER (Tom), VINCENT (Elliot), PONCE (Jean) et AUBRY (Mathieu), *Unsupervised Layered Image Decomposition into Object Prototypes*, août 2021, DOI : 10.48550/arXiv.2104.14575, arXiv : 2104.14575 [cs.CV].
- MORSE (Christopher), « Les musées et l'expérience utilisateur (UX) », *La Lettre de l'OCIM. Musées, Patrimoine et Culture scientifiques et techniques-200* (2022/mars/01), p. 38-43, DOI : 10.4000/ocim.4777.
- NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia), « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.
- NORINDR (Jade), *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).
- *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, p. 152, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 08/06/2026).
- Notre Vision*, URL : <https://evenementswapikoni.ca/vision> (visité le 20/09/2024).
- NUM (France), *Comment faciliter la gestion de votre relation client avec un chatbot ? - francenum.gouv.fr*, URL : <https://www.francenum.gouv.fr/guides-et-conseils/intelligence-artificielle/agents-conversationnels-et-assistants-virtuels/comment> (visité le 27/05/2026).
- Outils d'aide à l'analyse des médias audiovisuels / INA*, URL : <https://inatheque.ina.fr/outils-d-aide-a-l-analyse-des-medias-audiovisuels> (visité le 03/08/2026).
- Outils pour l'indexation des archives à l'heure du web*, URL : <https://francearchives.gouv.fr/fr/article/37832> (visité le 13/07/2026).

- PAILLARD (Isabelle), « Comprendre Le Modèle FRBR et Ses Extensions » (, mars 2014), URL : <https://www.enssib.fr/bibliotheque-numerique/documents/65520-comprendre-le-modele-frbr-et-ses-extensions.pdf>.
- PATTICHIS (Marios S.), JATLA (Venkatesh) et CERNA (Alvaro E. Ullao), *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].
- PATTON (Stacey), *AI Meets Archives : The Future of Machine Learning in Cultural Heritage*, oct. 2024, URL : <https://www.clir.org/2024/10/ai-meets-archives-the-future-of-machine-learning-in-cultural-heritage/> (visité le 06/05/2026).
- POSTS (View all of Tord Nilsen's), *Semantic Search in an Online Collection – Nasjonalmuseet Beta*, déc. 2023, URL : <https://beta.nasjonalmuseet.no/2023/08/add-semantic-search-to-a-online-collection/> (visité le 06/05/2026).
- Prelinger Archive – Internet Archive Help Center*, URL : <https://help.archive.org/help/prelinger-archive/> (visité le 14/08/2026).
- Principles for Accountable Algorithms and a Social Impact Statement for Algorithms :: FAT ML*, URL : <https://www.fatml.org/resources/principles-for-accountable-algorithms> (visité le 02/06/2026).
- Projet Dataset / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-dataset> (visité le 14/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 03/08/2026).
- Projet Snoop / INA*, URL : <https://www.ina.fr/institut-national-audiovisuel/equipe-recherche/projet-snoop> (visité le 05/08/2026).
- Qu'est-ce qu'un réseau de neurones convolutifs ? / IBM*, oct. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/convolutional-neural-networks> (visité le 08/06/2026).
- Qu'est-ce que la conception de chatbot ? / IBM*, août 2023, URL : <https://www.ibm.com/fr-fr/think/topics/chatbot-design> (visité le 26/05/2026).
- Qu'est-ce que la modélisation de données ? / IBM*, sept. 2021, URL : <https://www.ibm.com/fr-fr/think/topics/data-modeling> (visité le 06/08/2026).
- Qu'est-ce que la qualité des données ? / IBM*, sept. 2022, URL : <https://www.ibm.com/fr-fr/think/topics/data-quality> (visité le 14/08/2026).
- Qu'est-Ce Que Le Machine Learning (ML)? / IBM*, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).
- RATTINGER (André), ALLIATA (Giacomo), BENZI (Kirell), KENDERDINE (Sarah), ALLIATA (Giacomo), BENZI (Kirell) et KENDERDINE (Sarah), « AI-driven Metadata Extraction

- and Semantic Search for Audiovisual Archives », *Archiving Conference*, 22 (juin 2025), p. 112-116, DOI : 10.2352/issn.2168-3204.2025.22.1.21.
- REDMON (Joseph), DIVVALA (Santosh), GIRSHICK (Ross) et FARHADI (Ali), *You Only Look Once : Unified, Real-Time Object Detection*, mai 2016, DOI : 10.48550/arXiv.1506.02640, arXiv : 1506.02640 [cs.CV].
- REIGNIER (Virgile), *Vers l'indexation Automatique Du Trésor Des Chartes : Constitution, Alignement et Utilisation d'un Référentiel d'entités Nommées Au Sein Du Projet Himanis*, mém. de mast., 2022, URL : <https://dumas.ccsd.cnrs.fr/dumas-04538777> (visité le 13/05/2026).
- ROBERT (Jérémy), *Convolutional Neural Network : Tout ce qu'il y a à savoir*, févr. 2026, URL : <https://liora.io/convolutional-neural-network> (visité le 08/06/2026).
- RONFARD, RÉMI, (PDF) *Analyse Automatique de Film - Des Séquences d'images Aux Séquences d'actions*. URL : https://www.researchgate.net/publication/41117180_Analyse_automatique_de_film_-_Des_sequences_d'images_aux_sequences_d'actions (visité le 21/06/2026).
- SCHIAPPA (Madeline C.), RAWAT (Yogesh S.) et SHAH (Mubarak), « Self-Supervised Learning for Videos : A Survey », *ACM Computing Surveys*, 55–13s (déc. 2023), p. 1-37, DOI : 10.1145/3577925, arXiv : 2207.00419 [cs.CV].
- SIGNOLES (Aurélie Bergonnier), « Mise en œuvre d'une nouvelle structuration des données pour valoriser le fonds documentaire de l'IIPÉ UNESCO : l'expérience FRBR » ().
- STAFF (Coursera), *Recherche sur l'expérience utilisateur : méthodes et carrières*, juin 2025, URL : <https://www.coursera.org/fr-FR/articles/user-experience-research> (visité le 23/05/2026).
- STOCKINGER (Peter), *Les archives audiovisuelles : description, indexation et publication*, Paris, 2011 (Traité des Sciences et Techniques de l'Information).
- STRYKER (Rina Diane Caballar Cole), *Qu'est-ce que la vision par ordinateur ? | IBM*, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).
- SULLIVAN (Peter) et ABDUL-MAGEED (Muhammad), *On Barriers to Archival Audio Processing*, juill. 2025, DOI : 10.48550/arXiv.2507.08768, arXiv : 2507.08768 [cs.SD].
- SUOMINEN (Osma), « Annif, l'indexation automatique à la Bibliothèque nationale de Finlande », *Arabesques*–94 (juill. 2019), p. 21-23, DOI : 10.35562/arabesques.605. *Systèmes et données*, URL : <https://www.transition-bibliographique.fr/systemes-et-donnees/> (visité le 08/07/2026).

- TANNIER (Xavier), *Extraction et recherche d'information en langage naturel dans les documents semi-structurés*, thèse de doct., Ecole Nationale Supérieure des Mines de Saint-Etienne, 2006, URL : <https://theses.hal.science/tel-00121721> (visité le 06/05/2026).
- TEAM (ReelMind), *Automated Video Scene Detection : AI for Seamless Editing*, juin 2025, URL : <https://reelmind.ai/blog/automated-video-scene-detection-ai-for-seamless-editing> (visité le 13/05/2026).
- TILLET, BARBARA B., *FRBR Model*, 4, URL : <https://www.loc.gov/catdir/cpsd/frbreng.pdf>.
- Traitement du langage naturel : découvrez comment les machines lisent et écrivent*, URL : <https://www.oracle.com/fr/artificial-intelligence/natural-language-processing/> (visité le 06/05/2026).
- TROJAHN (Tiago Henrique) et GOULARTE (Rudinei), « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- « Temporal Video Scene Segmentation Using Deep-Learning », *Multimedia Tools and Applications*, 80–12 (mai 2021), p. 17487-17513, DOI : 10.1007/s11042-020-10450-2.
- ULLBERG (Rielle), *Axiell Pilots Its AI Tool for Catalogue Discovery at Nacka Libraries*, mars 2026, URL : <https://www.axiell.com/blog-post/axiell-pilots-its-ai-tool-for-catalogue-discovery-at-nacka-libraries/> (visité le 12/05/2026).
- Une Philosophie de l'archivistique Audiovisuelle - UNESCO Bibliothèque Numérique*, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).
- UNIVERSALIS (Encyclopædia), *Rushes : définition et synonymes*, URL : <https://www.universalis.fr/dictionnaire/rushes/> (visité le 22/08/2026).
- Using Graph Visualization to Enhance Representation and Evaluation of Work Clusters*, URL : <https://repository.ifla.org/items/325e74e8-42b1-4c89-9248-f987afed63ef> (visité le 03/08/2026).
- VASSEUR (Édouard), « L'IA : quels défis pour le monde des archives ? », *Archimag*—hs81 (déc. 2025), p. 8-9, DOI : 10.3917/arma.hs81.0008.
- WANG (Yiyuan), JOHNSTON (Andrew), SADOKIERSKI (Zoë), STEPHENS (Rhiannon) et AHYONG (Shane T.), *Conversational AI-Enhanced Exploration System to Query Large-Scale Digitised Collections of Natural History Museums*, mars 2026, DOI : 10.48550/arXiv.2603.10285, arXiv : 2603.10285 [cs].
- XIN (Yuelin), ZHOU (Zihan) et XIA (Yuxuan), *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

- XINYU LIN, ZHOU (Yingjie), LIU (Yipeng) et ZHU (Ce), *A Comprehensive Review of Image Line Segment Detection and Description : Taxonomies, Comparisons, and Challenges*, mai 2024, DOI : 10.48550/arXiv.2305.00264, arXiv : 2305.00264 [cs.CV].
- YASEEN (Muhammad), *What Is YOLOv8 : An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector*, août 2024, DOI : 10.48550/arXiv.2408.15857, arXiv : 2408.15857 [cs.CV].
- YOLO Algorithm for Object Detection Explained [+Examples]*, janv. 2023, URL : <https://www.v7darwin.com/blog/yolo-object-detection> (visité le 06/06/2026).
- YOLO12 : Détection d'objets centrée sur l'attention*, févr. 2025, URL : <https://docs.ultralytics.com/fr/models/yolo12> (visité le 25/07/2026).
- YOON (Sangwoong), KANG (Woo Young), JEON (Sungwook), LEE (SeongEun), HAN (Changjin), PARK (Jonghun) et KIM (Eun-Sol), *Image-to-Image Retrieval by Learning Similarity between Scene Graphs*, déc. 2020, DOI : 10.48550/arXiv.2012.14700, arXiv : 2012.14700 [cs.CV].
- YUAN (Haochen), PENG (Junjie) et CAI (Zesu), « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.
- ZHOU (Tianfei), PORIKLI (Fatih), CRANDALL (David), GOOL (Luc Van) et WANG (Wenguan), *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

Sources par notions

Indexation automatique

CORDELL (Ryan), « Machine Learning + Libraries » ().

NOORD (Nanne), OLESEN (Christian), ORDELMAN (Roeland) et NOORDEGRAAF (Julia),
« Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Introduction

”Les archives audiovisuelles doivent satisfaire à des normes sévères en ce qui concerne la documentation de leurs acquisitions, des communications et d’autres transactions afin de démontrer le sérieux de leur gestion. Du fait de la complexité de leurs fonds, la précision de l’information est ici essentielle.”¹

Dans la Philosophie de l’archivistique audiovisuelle publiée par l’UNESCO, Edmonson Ray pose les fondements de la complexité de la gestion et de l’indexation des documents audiovisuels en raison de la nature de leur support, une indexation qui doit alors être soumise à une structure définie et claire pour en instaurer la compréhension. L’auteur définit les documents audiovisuels comme suit :

”Constituent des documents audiovisuels les œuvres comprenant des images et / ou des sons reproductibles réunis sur un support matériel dont : l’enregistrement, la transmission, la perception et la compréhension exigent le recours à un dispositif technique ; le contenu visuel présente une durée linéaire”²

Ainsi, contrairement aux documents imprimés dont la forme rend accessible le contenu, les supports audiovisuels (films, bandes audio, fichiers vidéo) se caractérisent par une opacité qui nous amène à les qualifier de « boîtes noires »³. Le support physique ne révèle que peu ou pas d’informations sur le contenu du document, qui n’est accessible qu’à sa lecture à l’aide d’un appareil de lecture adéquat, et cela, même une fois le document numérisé. Les institutions patrimoniales préservatrices de fonds audiovisuels sont, d’une part, spécifiquement confrontées à la complexité de ce type de contenu dont l’archiviste doit en analyser les images, le son, le montage, la linéarité, etc, et d’autre part, au volume de ces collections,

¹Une Philosophie de l’archivistique Audiovisuelle - UNESCO Bibliothèque Numérique, URL : https://unesdoc.unesco.org/ark:/48223/pf0000113127_fre (visité le 15/08/2026).

²*Ibid.*

³Bruno Bachimont, *Indexation et archivage de contenus multimédias*, 2015, URL : <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/gestion-de-contenus-numeriques-42311210/indexation-et-archivage-de-contenus-multimedias-h7500/> (visité le 05/06/2026).

que le support ne permet pas d'en décrire le contenu de manière efficace. La description du contenu audiovisuel demande un temps de travail considérable, et repose inévitablement sur un matériel de lecture adéquat. L'outil utilisé afin de gérer les collections peut aider à structurer la description d'un contenu complexe. (deuxième problème : volume : solution = automatisation) En effet, au sein des institutions patrimoniales, la gestion des collections est le plus souvent permise par un outil de gestion des collections, défini comme suit par le ministère de la culture :

Progiciel spécialisé permettant de gérer des informations structurées et des multimédias sur les objets conservés au sein d'un musée, que ces derniers lui soient affectés ou déposés. C'est un système d'information partagé dont les fonctionnalités correspondent au cycle de vie de l'objet⁴.

Ainsi défini, un outil de gestion des collections permet la réalisation des diverses actions liées au cycle de vie de l'ensemble des objets de collection préservés au sein d'une institution. La réalisation de ces actions repose nécessairement sur la production "d'informations structurées" exploitables au sein du système. Cette structuration est permise par l'indexation, « l'opération qui consiste à décrire et à caractériser un document à l'aide de représentations des concepts évoqués dans ce document ».⁵ L'indexation permet précisément d'intelligibiliser un objet au sein d'un système de gestion des collections et de le rendre repérable et interrogeable auprès de l'utilisateur. Dans le cas des collections audiovisuelles, la description d'un objet existe à plusieurs niveaux : contenu intellectuel de l'oeuvre, versions de l'oeuvre, publications de l'oeuvre, localisation et état matériel de ses exemplaires... Une indexation simple ne permet pas la hiérarchisation de ces différents niveaux de description, or, ils facilitent la gestion de l'objet. La mise en place d'une modélisation des données d'indexation permet notamment de les structurer et de les hiérarchiser, afin de mieux appréhender la complexité de la description de tels contenus. Un outil de gestion des collections peut ainsi s'appuyer sur un modèle de données, tel que le FRBR (*Functional Requirements for Bibliographic Records*), modèle que nous analyserons au cours de cette étude. Issu du milieu des bibliothèques, il est également largement utilisé pour la gestion de collections audiovisuelles dont la nature se prête particulièrement à une indexation à différents niveaux. En effet, un document audiovisuel, reproductible par nature, se caractérise par son contenu intellectuel et ses multiples versions et publications, ainsi que ses exemplaires physiques. Ce modèle, implanté au sein

⁴ *Dico des musées* / Ministère de la Culture, URL : <https://www.culture.gouv.fr/thematiques/musees/Les-musees-en-France/les-musees-de-france/dico-des-musees> (visité le 15/08/2026).

⁵ *Module 6 - Section 7 : Indexation - Introduction*, URL : https://www.piaf-archives.org/sites/default/files/bulk_media/m06s7/co/06_section7_15.html (visité le 15/08/2026).

d'un outil de gestion des collections, permet alors de dissocier le contenu intellectuel d'un objet de son support matériel. Le FRBR est toutefois variable selon la collection audiovisuelle, dont la nature conditionne les niveaux d'indexation nécessaires. Une collection expérimentale non diffusée ne nécessite pas les mêmes niveaux d'indexation qu'une collection destinée au grand public. Ainsi, la structure de l'indexation des collections au sein d'un outil de gestion peut être adapté en fonction de la nature de la collection gérée au sein de chaque institution.

Par ailleurs, si la modélisation des données d'indexation permet d'adapter l'outil de gestion des collections à la complexité descriptive des collections audiovisuelles, le volume de ces collections ne permet pas à une institution de rendre compte de la globalité de ses objets au sein d'un tel outil. C'est pourquoi face à l'augmentation croissante des productions de documents et des acquisitions patrimoniales, la mise en place de solutions automatiques au sein d'outils de gestion permettrait d'accélérer la structuration de l'information afin de pouvoir y donner largement accès.⁶ Les tâches d'indexation permises par un outil de gestion des collections restent en effet répétitives et chronophage, et font désormais l'objet de tentatives d'automatisation à l'aide de l'intelligence artificielle. Dans le cas de documents textuels ou iconographiques, l'émergence des modèles fondés sur l'intelligence artificielle, offre des possibilités d'extraction automatique de métadonnées efficaces sur des documents numérisés. Toutefois, les collections audiovisuelles, résistent à la mise en place d'une extraction automatique de leur contenu, en raison de leur format "boîte noire"⁷. Ainsi, d'une part, l'indexation automatique de ces fonds supposerait que les modèles d'intelligence artificielle soient capables de lire et de comprendre le langage cinématographique, caractérisé par la mise en mouvement d'images fixes, le son, et le montage. Or, la compréhension automatique de ce langage reste inégale, en particulier lorsqu'elle est confrontée à des fonds d'archives audiovisuels patrimoniaux, anciens ou dégradés, dont la qualité sonore et visuelle est compromise. A priori, l'étude d'un tel type de documents nécessiterait des algorithmes d'intelligence artificielle lourds et coûteux, incompatibles avec les logiques institutionnelles patrimoniales. Le rôle de recherche et de proposition d'une indexation automatique pour les collections audiovisuelles reviendrait à l'éditeur de l'outil de gestion des collections, dont la logique produit encourage l'innovation constante. Toutefois cette innovation se heurte à une double difficulté que nous avons posée : la complexité pour les modèles automatiques de lire et de comprendre un contenu visuel, sonore et temporel, ainsi que l'inscription de fonctionnalités automatiques au sein d'un modèle de données (FRBR) variable, hautement dépendant du contexte institutionnel. C'est précisément cette double difficulté qui anime l'étude de ce mémoire de recherche, réalisé dans

⁶Sabine Barreaux, Béatrice Daille et Évelyne Jacquey, « Indexation automatique en SHS : bilan d'une expérimentation », *I2D - Information, données & documents*, 54-1 (avr. 2017), p. 15-17, DOI : 10.3917/i2d.171.0015.

⁷B. Bachimont, *Indexation et archivage de contenus multimédias...*

le cadre d'un stage de six mois au sein de l'entreprise Skinsoft, éditrice de solutions logicielles de gestion des collections. Effectué au sein de l'équipe métier, forte de propositions de fonctionnalités innovantes adaptées aux besoins des clients institutionnels, ce stage se porte spécifiquement sur l'amélioration de l'espace de travail dédié aux archive audiovisuelles (S-movies), fondé sur le FRBR, à travers le projet d'automatiser certains pans de l'indexation à l'aide de l'intelligence artificielle. Les réflexions et observations d'un point de vue métier qui ont traversé ce stage constituent le point de départ de ce mémoire, dont l'étude examine les conditions de faisabilité et les modalités d'intégration d'une indexation automatique appliquée à l'audiovisuel au sein d'un système de gestion de collections fondé sur une modélisation adaptative du FRBR.

Intégrer un état de l'art : sur l'automatisation de l'indexation des archives audiovisuelles : combinaison de plusieurs algorithmes, pas d'outils concret qui feraient l'ensemble du processus d'indexation. Ce mémoire tente d'articuler un pipeline d'indexation automatique avec un modèle FRBR adaptatif

Dans quelle mesure la variabilité du modèle de données FRBR adapté aux archives audiovisuelles conditionne-t-elle la mise en place d'une indexation automatique pour ce type d'archives ? Quels types d'algorithmes fondés sur l'intelligence artificielle peuvent être proposés au sein d'un outil de gestion des collections adaptatif à la nature des collections audiovisuelles ? Dans une première partie, nous analyserons les fondements du modèle FRBR et les modalités de son adaptation aux archives audiovisuelles, afin d'examiner les questions documentaires posées par le projet de la mise en place d'une indexation automatique de tels documents. Dans une seconde partie nous étudierons la possibilité d'une implémentation concrète d'outils d'indexation automatique au sein d'une modélisation FRBR d'un outil de gestion des collections. Nous y analyserons la faisabilité technique d'une mise en place de l'indexation à partir d'un séquençage automatique de fichiers numériques audiovisuels et d'une extraction automatique de mots-clés, pour en analyser le reversement au sein des différents niveaux de description modélisés par le FRBR. Enfin, nous évaluerons dans une troisième partie les limites, biais et enjeux éthiques liés à l'inadaptation des données d'entraînement d'IA aux fonds d'archives. Nous montrerons alors que les limites du « tout-automatique » invitent à réorienter la conception des logiciels métier vers un paradigme d'indexation augmentée et d'intelligence hybride**, plaçant l'interaction homme-machine au cœur de la gouvernance de la qualité documentaire.

Première partie

Indexer les archives audiovisuelles

Deuxième partie

Implémenter l'indexation automatique
des archives audiovisuelles au sein
d'une remodelisation du FRBR

1. Traitement audiovisuel

Les tâches d'analyse automatique pouvant être appliquée aux documents audiovisuels sont multiples, regroupant notamment le traitement du signal sonore (reconnaissance des locuteurs, transcription et classification audio) et l'analyse d'images (reconnaissance faciale, détection et classification d'objets, extraction de textes). Les chercheurs analysant les objets visuels s'orientent de plus en plus vers le media vidéo, puisque la détection du mouvement constitue un levier déterminant pour la mise en place d'autres tâches automatiques de reconnaissance⁸. Toutefois, l'accès au contenu actionné par le flux vidéo exige une structuration spécifique. La détection automatique des plans dans un flux vidéo (shot boundary detection) est notamment maîtrisée puisqu'elle n'engage que des changements visibles techniquement dans l'image. En revanche, la détection sémantique de séquences reste inexploitée. Comme le souligne Bhargav et ses coauteurs, "Pouvoir détecter de manière fiable les limites des scènes constituerait un exploit technique incroyable, qui ouvrirait d'énormes perspectives pour l'analyse sémantique et narrative des séquences vidéo et cinématographiques."⁹. (traduction : reliably being able to detect scene boundaries would be an incredible technical feat, which would create tremendous potential for semantic and narrative analysis of video and film material)

Au sein du chapitre suivant, nous proposerons la mise en place d'un processus de segmentation temporelle et d'indexation automatisée. Au sein de notre proposition, la segmentation est moins considérée comme un prérequis technique que comme une fonctionnalité documentaire à part entière, directement articulée avec l'indexation. Nos recherches ont montré que les études sur le sujet restent cantonnées aux expérimentations scientifiques et qu'elles n'ont pas été appliquées, à notre connaissance, au domaine des humanités numériques. Nous établirons ainsi un état des lieux de ces expérimentations, afin de proposer la mise en place d'un tel processus dans un contexte de gestion de collections audiovisuelles patrimoniales.

a. Machine learning et deep learning

Les technologies appliquées à l'analyse de contenus vidéo et audio, comprenant la computer vision et la reconnaissance de discours automatique (ASR) sont globalement désignées sous le terme de Audiovisual Processing (AVP),¹⁰

⁸Gabriel J. Brostow, Julien Fauqueur et Roberto Cipolla, « Semantic Object Classes in Video : A High-Definition Ground Truth Database », *Pattern Recognition Letters*, Video-Based Object and Event Analysis 30-2 (janv. 2009), p. 88-97, DOI : 10.1016/j.patrec.2008.04.005.

⁹Samarth Bhargav, Nanne van Noord et Jaap Kamps, « Deep Learning as a Tool for Early Cinema Analysis », dans *Proceedings of the 1st Workshop on Structuring and Understanding of Multimedia heritAge Contents*, New York, NY, USA, 2019 (SUMAC '19), p. 61-68, DOI : 10.1145/3347317.3357240.

¹⁰Nanne Noord, Christian Olesen, Roeland Ordelman et Julia Noordegraaf, « Automatic Annotations and Enrichments for Audiovisual Archives », dans 2021, p. 633-640, DOI : 10.5220/0010387706330640.

Appliquées à un grand nombre de données, ces technologies permettent de passer du "close" au "distant viewing", c'est-à-dire d'une vue des données rapprochée, réduite, à une vue d'ensemble.¹¹ Les tâches de traitement automatique permettraient en effet de passer de l'analyse manuelle de certaines archives audiovisuelles, à une vue d'ensemble sur les données afin d'en extraire les tendances globales, modifiant ainsi notre rapport à ces documents.

L'application des technologies d'intelligence artificielle au domaine des images (images fixe ou vidéo) est désignée sous le terme de *computer vision*, ou de Vision par ordinateur. Le terme définit un sous-domaine d'application de l'intelligence artificielle qui permet d'entraîner un système d'intelligence artificielle à l'analyse des images fixes ou en mouvement¹² La Vision par ordinateur s'appuie largement sur des modèles de *machine learning*, ou apprentissage machine, qui désigne une branche de l'intelligence artificielle regroupant les techniques, méthodes et processus nécessaires afin de rendre une machine ou un système informatique plus intelligent.¹³ L'apprentissage machine permet d'entraîner des algorithmes capables d'apprendre à partir de données d'entraînement, afin de prédire ou de prendre des décisions sur de nouvelles données.¹⁴ La Vision par ordinateur s'appuie sur l'apprentissage machine précisément pour sa capacité à entraîner des systèmes à prédire. En effet, les corpus d'images fixes et d'images en mouvement sont des phénomènes complexes à appréhender pour des algorithmes, contrairement à des données statistiques et mathématiques. La nature de ces corpus les rend imprévisibles autant dans leur forme que dans leur contenu. Les algorithmes d'intelligence artificielle ne peuvent donc pas seulement réaliser une analyse prédictive de ce type de corpus, définie par des critères mathématiques.¹⁵ Les corpus audiovisuels nécessitent une analyse prédictive, que les algorithmes sont entraînés à réaliser via des méthodes d'apprentissage machine.¹⁶ De plus, la plupart de ces corpus sont d'une taille conséquente, forçant ainsi la mise en place d'algorithmes de prédiction, puisque l'entraînement machine ne peut être mis en place sur l'ensemble des données, seulement sur un échantillon donné.

Pour des tâches telles que la segmentation en différentes séquences, qui implique l'ana-

¹¹*Ibid.*

¹²Rina Diane Caballar Stryker Cole, *Qu'est-ce que la vision par ordinateur ?* / IBM, sept. 2025, URL : <https://www.ibm.com/fr-fr/think/topics/computer-vision> (visité le 25/07/2026).

¹³Jonas Arnold, Martin Lûpold, Lorenz Theilkäs et Lambert Kansy, « Livre Blanc L'apprentissage Automatique Dans Les Archives : L'indexation En Profondeur Au Service de l'accès Aux Archives » (, juin 2024), URL : https://vsa-aas.ch/wp-content/uploads/2024/08/MachineLearning_im_Archiv_Whitepaper_2024-08-08_fr.pdf.

¹⁴*Qu'est-Ce Que Le Machine Learning (ML)?* / IBM, URL : <https://www.ibm.com/fr-fr/think/topics/machine-learning> (visité le 25/07/2026).

¹⁵Niall O' Mahony, Sean Campbell, Anderson Carvalho, Suman Harapanahalli, Gustavo Velasco-Hernandez, Lenka Krpalkova, Daniel Riordan et Joseph Walsh, *Deep Learning vs. Traditional Computer Vision*, t. 943, 2020, arXiv : 1910.13796 [cs.CV], URL : <http://arxiv.org/abs/1910.13796> (visité le 19/07/2026).

¹⁶*Ibid.*

lyse du contenu de l'image, sont utilisés des modèles d'intelligence artificielle reposant sur des réseaux de neurones, et notamment des réseaux de neurones profonds.¹⁷ La méthode de mise en place de ces réseaux de neurones profonds en plusieurs couches, est désignée sous le terme de *deep learning*, apprentissage profond, une sous-catégorie de l'apprentissage machine. L'apprentissage profond est basé sur des réseaux de neurones artificiels inspirés du fonctionnement du cerveau humain. Les neurones sont en réalité des cellules de calcul organisées en différentes couches qui interagissent les unes avec les autres afin de s'adapter aux données reçues, et de prendre une décision quelconque. Davantage entraîné que programmé, un modèle fondé sur l'apprentissage profond permet d'exécuter des tâches automatisées, réduisant le besoin d'intervention humaine, et améliorant ainsi le rapport cout-efficacité.¹⁸ Il suffirait de fournir au modèle quelques images annotées, dont le réseau de neurones repèrerait les caractéristiques à analyser sur de nouvelles données¹⁹. Par rapport aux techniques traditionnelles de Vision par ordinateur, l'apprentissage profond permet d'obtenir une plus grande précision dans les tâches d'analyse audiovisuelle telles que la classification d'images, la segmentation, la détection d'objets.²⁰

Au sein des réseaux de neurones, le type de réseau spécifiquement employé dans le domaine de la Vision par ordinateur pour la classification d'images et la reconnaissance d'objets, est celui des réseaux de neurones convolutifs (CNN) (CNN). Appliqués à des corpus d'images, les CNN peuvent par exemple analyser une image selon une hiérarchie de caractéristiques afin d'en extraire les couleurs et les contours.²¹ Les tâches que permettent les CNN sont plutôt bien adaptées à l'image fixe, puisqu'ils extraient des éléments fixes de l'image.

Néanmoins, d'autres modèles issus de l'apprentissage profond tels que les transformers s'avèrent davantage efficace sur des tâches dédiées à l'image en mouvement, dont fait partie la segmentation. Contrairement aux CNN, les transformers fonctionnent sur un mécanisme d'auto-attention qui leur permet de détecter les relations et dépendances entre les données.²² Tandis que les CNN analysent les données de manière locale dans l'image, sans prendre en compte les interdépendances qui les régissent temporellement, les transformers examinent simultanément les données dans leur ensemble et décident de se concentrer sur certaines

¹⁷Jade Norindr, *Le traitement des sources historiques par la vision artificielle : l'exemple des manuscrits d'astronomie de tradition ptoléméenne*, other, Observatoire de Paris - PSL, 61 avenue de l'Observatoire, 75014 Paris, 2023, URL : <https://dumas.ccsd.cnrs.fr/dumas-04255677> (visité le 30/05/2026).

¹⁸N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

¹⁹*Ibid.*

²⁰*Ibid.*

²¹Anselm Brachmann et Christoph Redies, « Computational and Experimental Approaches to Visual Aesthetics », *Frontiers in Computational Neuroscience*, 11 (nov. 2017), DOI : 10.3389/fncom.2017.00102.

²²Cole Stryker Bergmann Dave, *Qu'est-ce qu'un modèle transformer ?* / IBM, mars 2025, URL : <https://www.ibm.com/fr-fr/think/topics/transformer-model> (visité le 08/06/2026).

étapes de chacune d’entre elles.²³ Les CNN ne permettent pas, par exemple, de discerner les “dépendances à longue portée” telles que les corrélations entre les pixels entre différentes images qui ne seraient pas voisins.²⁴ Ainsi, ils seraient davantage adaptés à l’analyse d’images en mouvement puisqu’ils prendraient en compte les relations entre les images, tandis que les CNN seraient davantage adaptés aux images fixes. Idéalement, la mise en place d’une segmentation automatique des archives audiovisuelles doit donc être fondée sur une architecture de type transformers.

Toutefois, dans un contexte patrimonial, avec des ressources limitées, ces algorithmes fondés sur l’intelligence artificielle possèdent leurs limites. Premièrement, les réseaux de neurones sont conçus comme des boîtes noires, ne permettant pas d’interpréter les analyses qui sont produites.²⁵ En effet, une fois entraînés, il est difficile d’en modifier les paramètres puisqu’ils sont entremêlés entre les différentes cellules de calcul. La réflexion produite est ainsi difficile à comprendre et à exposer.²⁶ Deuxièmement, les algorithmes de type transformers sont complexes et restent difficiles à adapter à un corpus audiovisuel lui-même complexe.²⁷ Ils demandent également de grandes puissances de calcul et un temps de paramétrage important, ce qui les rend inadaptés à des contextes de gestion de collections patrimoniales. De plus, ils requièrent un grand nombre de paramètres issu d’un large jeu de données d’entraînement afin d’éviter un surapprentissage impliquant des biais multiples²⁸. Ces modèles sont, de surcroît, généralement entraînés sur des jeux de données inadaptés, qu’il s’agisse de réadapter à un contexte patrimonial²⁹. Cette réadaptation impliquerait un temps conséquent dédié à la validation et à la correction de l’analyse automatique produite. Certaines approches algorithmiques non neuronales ou hybrides, qui combindraient Vision par ordinateur et CNN par exemple, seraient ainsi davantage adaptées car fondées sur des calculs et des seuils mathématiques les rendant plus stables. Ainsi, la nature de chaque modèle conditionne la qualité d’analyse automatique d’un flux vidéo. Afin de synthétiser les apports et les contraintes de ces différentes approches, le Tableau 1 ci-dessous permet de comparer les compétences des types de modèles cités pour l’analyse d’un flux vidéo.

Comme l’illustre le Tableau 1, si les architectures fondées sur les transformers offrent

²³ *Ibid.*

²⁴ *Ibid.*

²⁵ A. Brachmann et C. Redies, « Computational and Experimental Approaches to Visual Aesthetics »...

²⁶ N. O. Mahony, S. Campbell, A. Carvalho, *et al.*, *Deep Learning vs. Traditional Computer Vision...*

²⁷ Haochen Yuan, Junjie Peng et Zesu Cai, « TDSNet : A Temporal Difference Based Network for Video Semantic Segmentation », *Information Sciences*, 686 (janv. 2025), p. 121335, DOI : 10.1016/j.ins.2024.121335.

²⁸ Marios S. Pattichis, Venkatesh Jatla et Alvaro E. Ullao Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems*, déc. 2023, DOI : 10.48550/arXiv.2312.05352, arXiv : 2312.05352 [cs.CV].

²⁹ *Ibid.*

Type d'approche	Performances appliquées au flux vidéo	Limites
Vision par ordinateur classique	- Détection de changements de plan (<i>shot boundary detection</i>) - Calcul d'histogrammes et variations de couleurs - Détection basique de mouvement par seuils	- Détection strictement syntaxique, sans extraction du sens - Absence de reconnaissance d'objets ou de concepts - Sensibilité à tous les types de mouvement, y compris les mouvements involontaires
Apprentissage profond : CNN	- Classification d'images fixes extraites du flux vidéo - Détection d'objets ou caractéristiques dans l'image	- Absence de compréhension des relations contextuelles entre les images - Incapacité à saisir les dépendances spatio-temporelles
Apprentissage profond : Transformers	- Segmentation sémantique et temporelle du flux - Analyse du contexte narratif et des relations longues	- Nécessite des infrastructures lourdes à la puissance de calcul conséquente - Nécessite un entraînement exigeant fondé sur des jeux de données volumineux et adaptés

TAB. 1 : Comparatif des approches de traitement audiovisuel automatique

des compétences puissantes, notamment pour l'automatisation de la segmentation temporelle, ces architectures reposent toutefois sur de lourdes puissances de calcul ainsi que sur des jeux de données d'entraînement conséquents. À l'inverse, la Vision par ordinateur classique offre une stabilité d'analyse de la syntaxe audiovisuelle, qui ne permet pas toutefois d'en extraire le sens. Ce constat justifie l'orientation de notre étude vers une approche hybride, combinant une architecture stable fondée sur la Vision par ordinateur et sur des CNN légers, afin de tenter de comprendre dans quelle mesure ces modèles peuvent segmenter un flux vidéo et en extraire des caractéristiques sémantiques.

b. Outils et modèles disponibles

Différents projets, extérieurs au domaine du patrimoine, tentent de mettre en place des algorithmes de segmentation vidéo. Bien que ces projets mettent en place l'analyse automatique de corpus vidéos moins spécifiques que ceux constitués de documents audiovisuels, leur architecture nous donne des pistes d'expérimentations afin de pouvoir implémenter un tel processus automatique au sein d'un logiciel de gestion des collections. En effet, face aux limites des méthodes d'apprentissage profond, nous tenterons de montrer dans quelle mesure la Vision par ordinateur classique, fondée sur une architecture plus stable, peut s'appliquer à la tâche automatique que nous souhaitons implémenter, la segmentation d'un flux vidéos en différentes séquences. L'optique de cette étude est de fournir une proposition d'implé-

mentation de fonctionnalités automatiques au sein d'un outil de gestion des collections d'un point de vue métier, au regard des besoins utilisateurs. Par conséquent, notre étude analysera l'architecture des algorithmes sélectionnés sans en détailler les mécanismes techniques.

Tout d'abord, afin de pouvoir implémenter des algorithmes plus légers que ceux des transformers notamment, une des solutions envisagée consisterait à transformer un flux d'images en mouvement en la série d'images fixes qui le composent. Ce processus écarterait notamment le besoin d'analyser les relations entre les images par un mécanisme d'auto-attention prévu par les transformers. En effet, le médium cinématographique se caractérise par l'enchaînement d'une succession d'images fixes produisant ainsi l'illusion du mouvement. La transformation de ce flux à l'état d'images fixes par un outil technique permettrait de pouvoir gérer l'analyse sémantique de ces images par des processus légers prévus par la Vision par ordinateur classique. Ces images fixes pourraient ensuite être regroupées en séquences après une analyse de leurs différences syntaxiques. Grâce à ce procédé, pourraient être appliqués les mêmes procédés d'analyse que ceux prévus pour l'image fixe, fondés sur la Vision par ordinateur classique.

Cette segmentation d'un flux audiovisuel fondé sur les différences de syntaxe entre les plans serait la condition préalable d'une analyse sémantique, regroupant ces plans fixes en des séquences sémantiques. Dans un article sur la mise en place d'un processus de segmentation temporelle, Xin prône notamment le découpage syntaxique tel que nous l'avons défini comme étape préliminaire à l'analyse sémantique des images par des modèles d'intelligence artificielle³⁰. La segmentation syntaxique d'un flux audiovisuel en différents plans fixes servirait alors de filtre permettant la classification sémantique de ces plans.

Ainsi, la segmentation automatique d'un document audiovisuel en séquences serait fondée sur l'analyse préalable des différences entre les plans fixes qui la composent. Ainsi, si la syntaxe visuelle de deux plans fixes est jugée suffisamment différente selon un seuil mathématique prédéfini, ces plans appartiendront à des séquences distinctes³¹. Ces plans sont en réalité retenus par l'algorithme comme des images-clés contenues au sein de chaque séquences, calculées comme l'image la plus représentative de la présence des éléments dans un flux donné³². Ce principe, qualifié de sélection de données, permet d'alléger nettement la puissance de calcul et la structure des algorithmes³³. Ces images-clés seraient ensuite analysées par un algorithme fondé sur des CNN, afin d'y ajouter une analyse sémantique et de les regrouper en séquences.

³⁰Yuelin Xin, Zihan Zhou et Yuxuan Xia, *Scene Separation & Data Selection : Temporal Segmentation Algorithm for Real-Time Video Stream Analysis*, août 2023, DOI : 10.48550/arXiv.2308.00210, arXiv : 2308.00210 [cs.CV].

³¹*Ibid.*

³²*Ibid.*

³³*Ibid.*

Ce processus est notamment appliqué par la bibliothèque python Pyscenedetect qui permet la segmentation d'un flux vidéo à l'aide de différents paramètres définis en amont³⁴. Les images extraites peuvent ensuite être regroupées de manière thématique, une fois l'analyse de leurs différences syntaxiques effectuée. Sans toutefois extraire la totalité des images fixes qui composent une séquences audiovisuelle, Pyscenedetect permet d'en extraire les image clés, c'est-à-dire les principaux différents plans.

Pyscenedetect est un outil en accès libre fondé sur des tâches de computer vision classique, qui concrétise la mise en oeuvre de la comparaison syntaxique d'images fixes. L'outil s'appuie sur des détecteurs mathématiques afin d'analyser les différences structurelles entre les images-clés tirées d'une vidéo³⁵. Il s'agit ainsi d'un outil basé sur des seuils et mesures visuelles mathématiques paramétrables, et ne nécessite pas d'entraînement particulier, comme c'est le cas des outils de Vision par ordinateur fondés sur l'apprentissage profond. Pyscenedetect permet d'isoler des images-clés de l'image animée, de les regrouper par similarité et de les dissocier selon leurs différences. Trois méthodes de détection sont proposées par l'outil : une détection des fondus entrants et sortants (méthode *threshold*, qui repère les niveaux de noir dans l'image, une détection de coupes rapides qui repère les changements de contenu entre images (méthode *detect-content*), et une détection de coupes fondée sur la différence d'un plan avec les plans adjacents (méthode *detect-adaptative*)³⁶. En théorie, Pyscenedetect isole des plans fixes, correspondant à des ruptures syntaxiques dans un flux d'images, et non des séquences, unités de sens narratives. Néanmoins, Pyscenedetect permet de contourner cette limite grâce à la flexibilité de son paramétrage. En effet, l'élévation de la valeur du seuil de détection ou la fixation d'une durée minimale de séquences (*min-scene-len*), l'outil est moins sensible aux variations minimales entre images et ne déclenche une rupture qu'en cas de détection de changements visuels majeurs tels que l'éclairage, le décor, la composition, etc³⁷. Par ce biais, la segmentation syntaxique proposée par Pyscenedetect pourrait permettre de diviser un flux vidéo en différentes séquences, que la variation visuelle permettrait de regrouper de manière sémantique. Une fois le processus finalisé, l'outil génère des marqueurs temporels sur les images extraites et enregistre automatiquement images-clés associée à chaque séquences retenue.

Un détail important de l'outil est sa capacité à enregistrer automatiquement une images-clés pour chaque scène détectée, associée au fichier vidéo d'origine. C'est cette images-clés qui sera réemployée au sein du processus suivant, celui de l'analyse sémantique de la séquence, afin de ne pas surcharger les algorithmes.

³⁴ Home - PySceneDetect, URL : <https://www.scenedetect.com/> (visité le 25/07/2026).

³⁵ Command-Line - PySceneDetect, URL : <https://www.scenedetect.com/cli/> (visité le 25/07/2026).

³⁶ Ibid.

³⁷ Ibid.




FIG. 1 : Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect

Toutefois, certaines mises en application de l'outil soulignent ses limites. Dans un article sur l'apprentissage profond comme outil d'analyse du cinéma des premiers temps, Bhargav explique par exemple que l'outil détecte beaucoup plus de coupures de plans que nécessaire au sein de ce type de corpus³⁸. Ce problème peut être lié à la qualité amoindrie de ce type d'archives, même numérisées ou restaurées³⁹. En effet, la qualité de l'image détermine nécessairement la performance de l'outil d'analyse utilisé et des résultats reçus⁴⁰. De plus, Bhargav souligne la nécessité de connaître de manière précise les modalités de paramétrage de l'outil, afin de pouvoir l'adapter adéquatement à la nature du corpus analysé⁴¹. Toutefois, un des avantages majeurs de l'outil Pyscenedetect est sa disponibilité et la possibilité de le mettre en oeuvre facilement et gratuitement. De plus, c'est un outil fondé sur des tâches classiques de Vision par ordinateur analytiques qui ne nécessitent pas d'entraînement particulier. Son paramétrage est également documenté et facilement modifiable, contrairement à ceux des réseaux de neurones.

Après pyscenedetect : apposer une analyse sur les séquences. Pas adapté pour des archives plus complexes. Sur notre corpus : ancien donc ruptures moins visibles avec la dégradation. Pourrait convenir, mais pour d'autres corpus, appliquer un pipeline basé sur des mécanismes plus lourds d'auto-attention.

Quand déclencher le processus??? réalité métier : application de l'IA : à la demande

³⁸S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

³⁹*Ibid.*

⁴⁰J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴¹S. Bhargav, N. van Noord et J. Kamps, « Deep Learning as a Tool for Early Cinema Analysis »...

du client ? Sur certaines archives ? À l'ingest d'un fichier numérique ? Sur tous les fichiers numériques ?

2. Mise en application

Mettons à l'épreuve l'adaptabilité de l'outil `pyscenedetect` pour la segmentation des vidéos en séquences, au corpus d'archives audiovisuelles géré au sein du logiciel de Skinsoft. Ce corpus, rappelons-le, est composé d'archives issues des années 1910 à 1920 essentiellement documentaires, à plans fixes, en noir et blanc et muettes. Nous imaginerons ici ce que pourrait produire l'outil sur un tel corpus et quelle seraient les données générées par le processus, avant même de réfléchir à une interface entre l'outil et l'utilisateur. Le corpus pris comme exemple se caractérise par son ancienneté, et donc son indéniable dégradation de la qualité de l'image. L'outil pourrait rencontrer des difficultés afin d'identifier les changements de plans et les coupures. Toutefois, la structure de ces archives en une succession de plans fixes, dont les coupures sont marquées, en fait un corpus relativement bien adapté à l'outil, qui pourrait identifier les coupes plus facilement. Par ailleurs, `pyscenedetect` est un outil davantage utilisé pour la détection de plans différents au sein d'une image animée. Or, dans ce mémoire, nous cherchons à savoir comment segmenter une archives audiovisuelle en séquences. Dès lors, comment paramétrer un tel outil pour la détection d'éléments syntaxiques plus larges que ceux des plans ? Une des solutions est d'augmenter la valeur du seuil de coupures (`threshold`), pour que l'outil ne détecte plus des micro coupures entre les images mais des coupes plus larges, à l'échelle de séquences.⁴² L'outil enregistrerait un changement seulement lors d'un changement radical d'espace temps à l'image, lorsque l'image change significativement. Ce paramètre reste limité puisque plusieurs plans peuvent être radicalement différents mais appartenir à la même séquence. Par exemple, un gros plan et un plan d'ensemble. Dans le cas du corpus d'archives décrit, les plans restent larges pour la grande majorité, montrant l'ensemble du décor dans lequel ils s'inscrivent. Par ailleurs, il est possible de paramétrer une durée minimale de scène à détecter avec le paramètre `"min-scene-len"`, pour diriger la coupure seulement après un laps de temps défini.⁴³ Ce paramètre suppose une analyse statistique du corpus afin de définir la durée moyenne d'une séquence au sein des archives. L'institution conservatrice de ce corpus documente justement déjà les séquences sur ses archives audiovisuelles à l'aide de `time codes` pour en déterminer les séquences. Une analyse statistique comparative pourrait être réalisée sur ces données documentées de `time codes` afin de déterminer la durée moyenne d'une séquence au sein du corpus. Enfin, sur ce corpus, le mode de détection adaptatif pourrait

⁴² *Command-Line - PySceneDetect...*

⁴³ *Ibid.*

être privilégié, couplé à une analyse d'images plus importante.⁴⁴ Ainsi, il est possible de paramétrer le mode de détection de telle manière à ce que l'outil compare le contenu visuel d'une image par rapport à une plus grande variété des images qui l'entourent. Ce paramétrage permettrait à l'outil de détecter uniquement les changements majeurs dans l'image, et donc les séquences. Une fois ces paramètres définis, le processus une fois enclenché produit deux types de données. Il produit un fichier json ou csv contenant les time codes de début et de fin identifiés comme séquences au sein de chaque fichier vidéo ingéré. Chaque séquence possède donc un identifiant unique associé à des times codes de début et de fin. L'outil permet également d'extraire pour chaque séquence un fichier image, qui correspond à l'image fixe médiane, censée être la plus représentative de la séquence et que nous désignerons sous le terme d'image clé.⁴⁵

Toutefois, si ce paramétrage permettrait une plus grande précision dans la détection de séquences, il comporte des limites. Ces limites sont dues à la définition d'une séquence, qui ne se définit pas seulement comme une caractéristique syntaxique au cinéma, comme c'est le cas du plan, mais bien par une double caractéristique syntaxique et sémantique. En effet, un changement de séquence est un choix narratif, un choix de sens au sein du flux animé. C'est pourquoi un outil fondé sur des seuils mathématiques appliqués au contenu visuel comporte des limites. Nous proposons alors de réaliser une analyse sémantique sur les séquences détectées, afin de réassocier la syntaxe au sens, qui en fait une séquence, en réutilisant les données produites par le processus : les times codes et l'image clé.

Il est courant d'utiliser des modèles préentraînés sur un grand jeu de données et de le réajuster ensuite au jeu de données en question, au sein d'un contexte précis.⁴⁶ Ce modèle peut justement servir de modèle de caractéristiques à analyser sur les vidéos, un second entraînement, dans le contexte peut aider à l'affiner et à l'adapter au corpus spécifique. Le rendre d'abord familier au langage audiovisuel.

Malgré de grandes avancées dans le processing audiovisuel, avec des outils comme la computer vision appliquée à la vidéo, et la reconnaissance de discours automatique (ASR), ces outils restent largement inaccessibles et hors de portée pour les institutions patrimoniales.⁴⁷ Ils sont utilisés par des entreprises commerciales pour du montage vidéo par exemple. Le manque d'utilisation de ces outils dans le domaine des sciences humaines expliquent l'inexistence de données d'entraînement adaptées au secteur.⁴⁸ l'analyse vidéo par un processus

⁴⁴ *Ibid.*

⁴⁵ *Ibid.*

⁴⁶ J. Norindr, *Le traitement des sources historiques par la vision artificielle...*

⁴⁷ N. Noord, C. Olesen, R. Ordelman, *et al.*, « Automatic Annotations and Enrichments for Audiovisual Archives »...

⁴⁸ *Ibid.*

humain prend un temps considérable, puisqu'il faut lire le fichier audiovisuel et en analyser les composants, le langage. Ainsi, l'indexation des archives audiovisuelles se cantonne souvent aux métadonnées, sans en exposer les données, le contenu.

Et donc en pratique, comment appliquer le traitement audiovisuel à des corpus d'archives audiovisuelles patrimoniales ?

a. entraîner ces outils et ces modèles

les modèles de détection neuronaux sont entraînés sur des datasets de clips courts. Or, la réalité audiovisuelle est bien différente.⁴⁹ Des approches algorithmiques non neuronales ou hybrides seraient donc plus adaptées car fondée sur des calculs et des seuils mathématiques : plus stable.

détection des coupures : approche algorithmique non neuronale (2SDS, pyscenedetect), (xin et attard) pipeline technique en 4 étapes (down sampling (miniaturisation), conversion en niveaux de gris, calcul d'empreinte numérique par hachage binaire des pixels, et calcul de la distance de Hamming pour marquer la rupture visuelle (xin2023)

efficace sur les plans fixes et mvts lents

mettre en rapport avec les travaux d'Arnold Tilton (2019), qui utilisent une méthode similaire combinant différences d'histogrammes et réduction de résolution des pixels (down-sampling) pour mesurer les ruptures de palettes de couleurs et de luminosité d'une frame à l'autre, complétée par des règles logiques pour éviter les faux positifs lors des fondus (fade-in/fade-out).

L'apport de l'IA (Vers la classification sémantique) : La détection brute des coupures ne suffit plus ; l'enjeu actuel est la Shot semantics (décrire le contenu d'un plan et sa typologie) (Arnold Tilton, 2019).

Le rôle des modèles (CNN et Détecteurs) : Pour analyser le contenu de ces plans, on utilise l'apprentissage supervisé (Supervised Learning), où des algorithmes apprennent à partir de données labellisées par l'humain (DeLua, 2024). C'est le cas des réseaux de neurones convolutifs (CNN) comme Faster R-CNN ou YOLO (un détecteur de type Single Shot qui prédit et classifie "en une seule fois") pour la détection d'objets ou de visages (Arnold Tilton, 2019 ; Robert, 2026).

Le méta-algorithme de classification : Arnold Tilton (2019) montrent qu'en combinant la position des visages détectés et les coupures de plans, on peut créer un méta-algorithme capable de classifier automatiquement le type de plan (gros plan/close-up, plan amorce/over the shoulder), permettant de comprendre comment le cadrage construit le récit.

⁴⁹M. S. Pattichis, V. Jatla et A. E. U. Cerna, *A Review of Machine Learning Methods Applied to Video Analysis Systems...*

b. analyse du mouvement

au lieu d'utiliser des larges modèles qui tentent de tout classer, plutôt utiliser des modèles "low parameter", c'est-à-dire des modèles 3D-CNN légers, avec moins de paramètres dédiés à la reconnaissance d'une seule activité précise. prennent moins de mémoire vidéo.⁵⁰

stratégie de réduction de l'annotation humaine : self supervised learning, semi supervised, active learning, zero shot⁵¹

confronter les architectures de réseaux de neurones (CNN vs. Transformers), introduire l'apprentissage non supervisé (Unsupervised Learning / DeepCluster),

Les limites des CNN 2D classiques (comme ResNet) : ils analysent la vidéo comme des images discrètes et indépendantes, ignorant la continuité du mouvement⁵². Se tourner vers les vision transformers : CLIP, ViViT (bergmann et al), mécanismes d'auto attention qui analysent l'intégralité d'une séquence

Les modèles de Video Semantic Segmentation (VSS) et le dilemme entre les méthodes orientées "vitesse" (approche par keyframes peu précise) et orientées "précision" (TDNet, flux optique, mécanismes d'auto-attention)⁵³.

La gestion du coût de calcul : présentation de TDSNet (TFRM pour extraire les zones dynamiques par soustraction d'images consécutives, et MMRM pour pondérer selon la magnitude réelle du mouvement)⁵⁴. règle ce dilemme

alternatives non supervisées : la supervision demande des données annotées (caron et al), l'apprentissage non supervisé (Unsupervised Learning) comme DeepCluster (Caron et al., 2018). Ce type de modèle regroupe les images ou frames similaires en "clusters" algorithmiques (via K-means) pour s'auto-entraîner sans intervention humaine (Caron et al., 2018). Si DeepCluster s'avère robuste face à des changements de distribution d'images (ce qui est prometteur pour des archives spécifiques), il présente deux limites majeures : il introduit des biais imprévisibles en remplaçant les labels par des métadonnées brutes (inacceptable pour la rigueur historique) et a été conçu sur des bases gigantesques (ImageNet, 1.28 million d'images), le rendant difficilement transposable à des collections d'archives réduites (Caron et al., 2018 ; Norindr, 2023).

infrastructure locale : amener l'algorithme aux données : C'est la discussion centrale de votre partie. Les outils d'AVP commerciaux (souvent basés sur le Cloud) sont inutilisables pour les archives en raison des droits de propriété intellectuelle et de la sécurité des

⁵⁰ *Ibid.*

⁵¹ *Ibid.*

⁵² Y. Xin, Z. Zhou et Y. Xia, *Scene Separation & Data Selection...*

⁵³ Tianfei Zhou, Fatih Porikli, David Crandall, Luc Van Gool et Wenguan Wang, *A Survey on Deep Learning Technique for Video Segmentation*, nov. 2022, DOI : 10.48550/arXiv.2107.01153, arXiv : 2107.01153 [cs.CV].

⁵⁴ H. Yuan, J. Peng et Z. Cai, « TDSNet... ».

données (van Noord et al., 2021). La solution réside dans des architectures locales comme DANE (projet CLARIAH), basées sur un système décentralisé de workers (van Noord et al., 2021). Ce type d'infrastructure produit des métadonnées exploitables, mais aussi des vecteurs de caractéristiques (représentations abstraites) ouvrant la voie à la recherche par similarité visuelle ou sonore (van Noord et al., 2021).

La note finale sur l'explosion des données : L'indexation automatique par IA (comme avec DigInPix ou les modèles de type VLM) génère une masse d'informations locales phénoménale : les bases de données constituées peuvent être plus lourdes en taille que les fichiers vidéos d'origine (Moiraghi Letessier, 2018).

transition : nécessité d'un mapping vers le FRBR : faire correspondre la sortie de ces pipelines avec un modèle de données.

Troisième partie

partie 3

Conclusion

Conclusion

Le modèle de données et la manière dont il est modélisé dans un système de gestion des collections dirige l'implémentation de nouvelles fonctionnalités applicatives. Dans le cadre de ce mémoire de recherche, nous avons mesuré la complexité de la mise en place de l'indexation automatisée par IA, alors même que le modèle de données adapté aux collections audiovisuelles (FRBR) pose des difficultés de navigation et de compréhension documentaires pour les utilisateurs. L'analyse de l'adaptation du modèle FRBR aux archives audiovisuelles a notamment permis de pointer sa verticalité, conçue pour les notices bibliographiques, qui écarte les spécificités et les différences de corpus vidéo. En effet, nombreuses sont les institutions qui conservent des archives documentaires, non diffusées, issues de films amateurs ou expérimentaux, auxquelles les niveaux du FRBR restent mal adaptés. Ainsi, l'utilisation du FRBR et la navigation entre ses différents niveaux dépend de la nature du corpus audiovisuel et est, de fait, hétérogène. Dans ce contexte, le projet de la mise en place d'une indexation automatique des archives audiovisuelles multimodale pose question.

Dans le cadre du projet IA chez Skinsoft, nous avons tenté de proposer la mise en place d'un pipeline d'indexation automatique au sein de l'espace de travail S-Movies. Nous nous sommes toutefois confrontés à la complexité du reversement des métadonnées produites au sein du modèle FRBR, au delà des difficultés posées par un corpus audiovisuel historique et vieillissant.

Dès lors, nous en avons conclu que la modélisation du FRBR selon le contexte institutionnel constitue un frein à la mise en place de l'indexation automatique, puisqu'elle repose sur des règles métier d'usage selon le corpus indexé. La refonte de la navigation entre les niveaux du FRBR constitue alors un tournant essentiel et nécessaire à la mise en place d'une telle automatisation, permettant aux modèles d'apprentissage et à l'utilisateur de mieux comprendre les liens entre les différents niveaux d'indexation.

Finalement, il s'agit de centrer notre approche sur l'expérience utilisateur en raison des difficultés d'entraîner un modèle d'intelligence artificielle adapté aux corpus audiovisuels et au modèle de données associé. Nous proposons alors la mise en place d'une aide à l'indexation, d'une indexation augmentée, qui suggérerait à l'utilisateur des choix en les explicitant, sans

pour autant automatiser l'ensemble du processus. Par ses choix de validation, l'utilisateur entraînerait lui-même le modèle à la fois sur les corpus utilisés et à la fois sur l'utilisation du modèle FRBR. Une telle interface d'échange pourrait permettre de rendre l'indexation plus efficace et d'améliorer la compréhension des liens entre les niveaux d'indexation du FRBR.

Annexe A

Le titre très long de la première
annexe

Glossaire

apprentissage machine . 36, 37, 55

apprentissage profond . 37, 55

Archives audiovisuelles . 7, 55

Audiovisual Processing . 35, 55

CNN Architecture de réseau de neurones artificiels spécialement adaptée au traitement et à l'analyse d'images numériques.. 37, 38, 55

Expression . 55

FIAF Fédération Internationale des archives du film. Organisation regroupant les cinémathèques et édité le manuel de catalogage audiovisuel fondé sur le modèle FRBR.. 55

FRBR Functional Requirements for Bibliographic Records. Modèle conceptuel entité-association développé par l'IFLA.. 3–7, 55, 61

Item . 55

Manifestation . 55

Oeuvre . 55

rush Ensemble des épreuves brutes de tournage, non montées et non sélectionnées, constituant le matériau source d'un film.. 55

réseaux de neurones profonds . 37, 55

transformers . 37, 38, 55

Vision par ordinateur . 36, 37, 55

Liste des abréviations

CIDOC-CRM object-oriented Conceptual Reference Model. 6, 55

FRAD Fonctionnalités requises des données d'autorité. 6, 55

FRBRoo long. 6, 7, 55

FRSAD Fonctionnalités requises des données d'autorité matière. 55

IFLA International Federation of Library Associations and Institutions. 3, 55

IFLA-LRM long. 6, 55

WVMI Work, Variant, Manifestation, Item.. 55

Liste des tableaux

1	Comparatif des approches de traitement audiovisuel automatique	9
---	--	---

Table des figures

1	Schéma du processus de détection de coupures et d'extraction d'images-clés par PySceneDetect	12
---	---	----

Table des matières

Résumé	i
Remerciements	iii
Introduction	xix
I Indexer les archives audiovisuelles	1
II Implémenter l’indexation automatique des archives audiovisuelles au sein d’une remodelisation du FRBR	3
1. Traitement audiovisuel	5
a. Machine learning et deep learning	5
b. Outils et modèles disponibles	9
2. Mise en application	13
a. entraîner ces outils et ces modèles	15
b. analyse du mouvement	16
III partie 3	19
Conclusion	21
A Titre court	25
Glossaire	29
Liste des abréviations	31